

Un Sistema de Inferencia Difusa para la Clasificación Interpretable del Comportamiento Sedentario mediante Dispositivos Wearables: Un Estudio de Validación Longitudinal con Validación Cruzada Leave-One-User-Out

Luis A. Martínez-Corral¹, David R. López-Flores², Javier Camarillo-Cisneros³, Celia María Quiñonez-Flores⁴, and Abimael Guzmán-Pando^{1,*}

Abstract—El comportamiento sedentario (CS) constituye un factor de riesgo independiente para enfermedades crónicas no transmisibles, requiriendo herramientas objetivas e interpretables para su monitoreo continuo. Este estudio desarrolla y valida un Sistema de Inferencia Difusa Mamdani interpretable para clasificar patrones semanales de sedentarismo utilizando datos longitudinales de Apple Watch (N=10 usuarios, 1,337 semanas-observación). Ante el fracaso de enfoques supervisados tradicionales (Redes Neuronales Artificiales con $R^2=0$ debido a N pequeño y ausencia de relación biométricos-calidad de vida), implementamos una estrategia dual data-driven: (1) clustering no supervisado K-Means ($K=2$, Silhouette=0.232) como Verdad Operativa (GO), y (2) sistema difuso con 4 variables de entrada normalizadas antropométricamente (actividad relativa, superávit calórico basal, HRV-SDNN, delta cardíaco) y 5 reglas expertas basadas en conocimiento fisiológico. La validación mediante concordancia difuso-clustering alcanzó F1-Score=0.840 (Recall=0.976, Precision=0.737, MCC=0.294). La validación cruzada Leave-One-User-Out (LOUO) demostró generalización inter-usuario robusta ($F1=0.847\pm0.041$, $CV=4.8\%$), superior a splits train/test tradicionales que presentan fuga temporal. El análisis de robustez reveló contribución sinérgica crítica de variables

cardiovasculares: el modelo reducido (2V) colapsó 50% en rendimiento vs modelo completo (4V), demostrando que HRV-SDNN, débil predictor univariado ($p=0.562$), resulta esencial en contexto multivariado no-lineal. Este pipeline metodológico proporciona una plantilla reproducible para análisis riguroso de datos longitudinales wearables en estudios piloto con N₃₀, priorizando interpretabilidad clínica sobre precisión de caja negra.

Index Terms—Comportamiento sedentario, dispositivos wearables, Apple Watch, lógica difusa, sistema de inferencia Mamdani, clustering K-Means, validación cruzada LOUO, inteligencia artificial interpretable, salud digital, biomarcadores digitales, ingeniería de características, imputación jerárquica.

I. INTRODUCCIÓN

EL comportamiento sedentario, definido operacionalmente como cualquier actividad en vigilia caracterizada por un gasto energético inferior o igual a 1.5 equivalentes metabólicos (METs) en postura sentada, reclinada o acostada, ha emergido como un determinante de salud pública independiente del nivel de actividad física moderada-vigorosa [1], [2]. Meta-análisis recientes basados en estudios prospectivos con más de 1 millón de participantes confirman que el tiempo sedentario prolongado se asocia con incrementos del 20-30% en el riesgo de mortalidad por todas las causas, diabetes mellitus tipo 2 y enfermedad cardiovascular, incluso en individuos que cumplen las recomendaciones mínimas de 150 minutos semanales de actividad moderada [3]. La prevalencia global de inactividad física supera el 27.5%, con tendencias ascendentes proyectadas para alcanzar el 35% en 2030 si no se implementan intervenciones efectivas, generando una carga económica estimada en 67.5 billones de dólares anuales en costos sanitarios directos e indirectos. En este contexto, la Organización Mundial de la Salud identifica la medición objetiva y el monitoreo continuo del sedentarismo como prioridad estratégica para la próxima década, enfatizando la necesidad de desarrollar tecnologías escalables, costo-efectivas y culturalmente adaptables que permitan la vigilancia epidemiológica en tiempo real y la

Manuscrito recibido [Fecha]; revisado [Fecha]; aceptado [Fecha]. Fecha de publicación [Fecha]; fecha de versión actual [Fecha]. Este trabajo fue apoyado en parte por [Agencia de Financiamiento] bajo el Grant [Número]. (Autor correspondiente: Abimael Guzmán-Pando.)

¹Luis A. Martínez-Corral y Abimael Guzmán-Pando están con el Laboratorio de Investigación en Inteligencia Artificial y Computación Médica (LIACOM), Facultad de Medicina y Ciencias Biomédicas, Universidad Autónoma de Chihuahua, Chihuahua 31125, México (e-mail: lmartinez@uach.mx; aguzmanp@uach.mx).

²David R. López-Flores está con el Tecnológico Nacional de México, Instituto Tecnológico de Chihuahua, Chihuahua 31200, México (e-mail: david.lf@chihuahua.tecnm.mx).

³Javier Camarillo-Cisneros está con el Laboratorio de Química Física Computacional, Facultad de Medicina y Ciencias Biomédicas, Universidad Autónoma de Chihuahua, Chihuahua 31125, México (e-mail: jcamarillo@uach.mx).

⁴Celia María Quiñonez-Flores está con la Facultad de Medicina y Ciencias Biomédicas, Universidad Autónoma de Chihuahua, Campus II, Chihuahua 31125, México (e-mail: cquinonez@uach.mx).

ORCID: L.A. Martínez-Corral: 0009-0002-9635-0330; D.R. López-Flores: 0000-0003-4016-0845; J. Camarillo-Cisneros: 0000-0001-7878-1546; C.M. Quiñonez-Flores: 0000-0003-0740-5783; A. Guzmán-Pando: 0000-0003-0819-0438.

personalización de intervenciones conductuales basadas en datos de vida libre.

La medición objetiva del CS mediante acelerometría triaxial integrada en dispositivos wearables de consumo masivo (e.g., Apple Watch, Fitbit, Garmin) ha revolucionado la epidemiología del comportamiento durante la última década [4], [5]. Estos dispositivos permiten cuantificar patrones de actividad física en condiciones de “vida libre” (free-living) con alta resolución temporal (≥ 1 Hz) y durante períodos extensos (semanas a años), eliminando el sesgo de recuerdo y deseabilidad social inherente a cuestionarios de auto-reporte como el IPAQ o GPAQ [6], [7]. Sin embargo, la transformación de señales biométricas crudas (aceleración, frecuencia cardíaca, fotoplethysmografía) en clasificaciones clínicamente interpretables de sedentarismo presenta desafíos metodológicos no triviales.

A. Desafíos en Clasificación Automática de Comportamiento Sedentario

Los enfoques actuales de clasificación automática de CS basados en aprendizaje automático enfrentan tres limitaciones críticas que restringen su adopción clínica a gran escala:

1) Problema de Interpretabilidad. La mayoría de algoritmos de alto rendimiento emplean modelos de “caja negra” (deep neural networks, random forests, gradient boosting) cuyas decisiones son opacas para profesionales de la salud [8], [9]. Esta falta de transparencia genera desconfianza clínica y dificulta la auditoría de errores, especialmente crítica en contextos de salud donde decisiones algorítmicas pueden impactar intervenciones terapéuticas. El movimiento reciente hacia “IA Explicable” (XAI) en salud digital [10] ha evidenciado que la interpretabilidad no es un lujo académico sino un requisito ético y regulatorio.

2) Dependencia de Tamaños Muestrales Grandes. Los enfoques supervisados tradicionales requieren conjuntos de datos etiquetados con cientos a miles de observaciones para evitar sobreajuste y alcanzar generalización robusta [11]. En estudios piloto longitudinales con wearables, donde el reclutamiento típico es $N=10-30$ participantes debido a costos, adherencia y consideraciones éticas, los modelos supervisados estándares fallan catastróficamente, exhibiendo R^2 negativos en validación cruzada y predicciones peores que la media trivial.

3) Validación Inapropiada para Datos Longitudinales. El paradigma estándar de split train/test (80/20) asume observaciones independientes e idénticamente distribuidas (i.i.d.), suposición violada en datos longitudinales con autocorrelación temporal significativa [12], [13]. La división aleatoria de observaciones temporalmente correlacionadas genera “fuga temporal” (temporal leakage), donde información del futuro contamina el entrenamiento, produciendo estimaciones optimistas de rendimiento que no se replican en aplicación real. Alternativas como validación cruzada Leave-One-Subject-Out (LOSO), aunque metodológicamente rigurosas, son raramente implementadas fuera de neuroimagen y estudios de cohorte pequeña.

B. Lógica Difusa como Alternativa Interpretable

Los Sistemas de Inferencia Difusa (FIS), introducidos por Zadeh en 1965 [14] y popularizados por Mamdani en 1974 [15], ofrecen un paradigma alternativo que balancea interpretabilidad con capacidad de modelado no-lineal. A diferencia de modelos de caja negra, los FIS codifican conocimiento experto mediante reglas lingüísticas IF-THEN (e.g., “SI actividad ES baja Y gasto-calórico ES alto ENTONCES sedentarismo ES moderado”), permitiendo a clínicos auditar, modificar y validar la lógica de decisión. En biomedicina, los FIS han demostrado utilidad en sistemas de soporte a decisión clínica, clasificación de arritmias, control de anestesia y diagnóstico asistido [16], con rendimientos comparables a métodos estadísticos avanzados pero con ventajas en transparencia y aceptabilidad clínica [17].

Sin embargo, el uso de FIS para clasificación de comportamiento sedentario a partir de datos wearables permanece escasamente explorado. Revisiones sistemáticas recientes identifican menos de 5 estudios que combinen lógica difusa con acelerometría de dispositivos comerciales, y ninguno con validación rigurosa mediante Leave-One-User-Out en cohortes longitudinales reales. Esta brecha representa una oportunidad metodológica significativa.

C. Contribuciones de Este Trabajo

Este estudio aborda las limitaciones mencionadas mediante un enfoque metodológico dual que combina descubrimiento empírico data-driven (clustering no supervisado) con modelado basado en conocimiento experto (sistema de inferencia difusa Mamdani), validado rigurosamente en datos longitudinales reales de Apple Watch durante períodos de seguimiento promedio de 130 semanas por participante. Nuestras contribuciones son:

Metodológica: Desarrollo de un pipeline completo end-to-end para análisis de datos wearables longitudinales en estudios piloto con $N < 30$, incluyendo: (1) estrategia de imputación jerárquica para datos faltantes, (2) ingeniería de características con normalización antropométrica para comparabilidad inter-sujeto, (3) establecimiento de “verdad operativa” mediante clustering no supervisado validado estadísticamente, y (4) validación cruzada Leave-One-User-Out como alternativa rigurosa a splits train/test tradicionales inapropiados para datos con autocorrelación temporal.

Técnica: Diseño, implementación y validación de un Sistema de Inferencia Difusa Mamdani interpretable con 4 variables de entrada normalizadas, 5 reglas expertas basadas en principios fisiológicos, y funciones de pertenencia parametrizadas por percentiles empíricos (data-driven). El sistema alcanza concordancia $F1=0.840$ con verdad operativa empírica y generalización robusta inter-usuario (LOUO $F1=0.812 \pm 0.067$, $CV=8.3\%$). El análisis de robustez revela contribución sinérgica crítica de variables cardiovasculares (HRV-SDNN, Delta-cardíaco), demostrando que predictores débiles univariadamente ($p=0.562$) resultan esenciales en contexto multivariado no-lineal ($\Delta F1=50\%$ si se eliminan).

Práctica: Demostración de factibilidad con datos Apple Watch HealthKit de consumo masivo en paradigma Bring-

Your-Own-Device (BYOD), sin requerimientos de hardware especializado. El sistema es computacionalmente eficiente (inferencia <1ms por observación), habilitando implementación on-device en aplicaciones móviles para feedback continuo a usuarios y clínicos.

El resto de este artículo está organizado como sigue: La Sección II describe el diseño del estudio, preprocesamiento de datos, ingeniería de características, clustering como verdad operativa, arquitectura del sistema difuso y estrategia de validación. La Sección III presenta resultados de validación de clusters, rendimiento del sistema difuso, validación cruzada LOUO y análisis de robustez. La Sección IV discute hallazgos principales, comparación con literatura, paradoja HRV y limitaciones metodológicas. La Sección V concluye con implicaciones clínicas y direcciones futuras.

II. METODOLOGÍA

A. Diseño del Estudio y Participantes

Este estudio empleó un diseño longitudinal observacional retrospectivo bajo el paradigma *Bring-Your-Own-Device* (BYOD) [18], aprovechando los dispositivos personales Apple Watch de los participantes para capturar datos biométricos en condiciones ecológicamente válidas de vida libre. El período de monitoreo abarcó desde enero de 2020 hasta julio de 2024, comprendiendo 4.5 años de recolección pasiva continua sin intervención experimental. El protocolo del estudio recibió aprobación del Comité de Ética en Investigación de la Facultad de Medicina y Ciencias Biomédicas, Universidad Autónoma de Chihuahua (registro FMCB-2024-001), adhiriendo a los principios de la Declaración de Helsinki [19] y las directrices STROBE para estudios observacionales [20].

La cohorte comprendió $N=10$ participantes adultos (5 mujeres, 5 hombres; edad: 34.2 ± 6.7 años, rango: 25-45 años; IMC: 24.8 ± 3.2 kg/m²) usuarios habituales de Apple Watch Series ≥ 3 . Los criterios de inclusión requirieron: (1) edad 18-65 años, (2) uso continuo del dispositivo ≥ 6 meses previos a la inscripción, (3) disponibilidad de datos $\geq 80\%$ a lo largo del período de monitoreo, y (4) provisión de consentimiento informado escrito. Los criterios de exclusión comprendieron: enfermedad cardiovascular establecida, uso de marcapasos cardíaco, embarazo y trastornos de movilidad severos que limitaran la actividad física. Los participantes fueron reclutados mediante muestreo por conveniencia de la comunidad universitaria entre enero y marzo de 2024. El seguimiento longitudinal produjo una media de 133.7 semanas por participante (rango: 7-298 semanas), generando 9,185 días totales de registro biométrico continuo, posteriormente agregados en 1,337 observaciones semanales válidas tras preprocesamiento.

B. Adquisición y Preprocesamiento de Datos

Los datos biométricos se exportaron de los dispositivos Apple Watch de los participantes mediante la aplicación nativa Salud (iOS), que proporciona acceso estandarizado al ecosistema HealthKit en formato XML. Se extrajeron trece variables agregadas diariamente: horas estacionarias (proxy directo de tiempo sedentario), horas con deambulaci3n, pasos diarios, distancia recorrida (km), gasto cal3rico activo (kcal),

frecuencia cardíaca en reposo (FCr, lpm), frecuencia cardíaca promedio al caminar (FCcaminar, lpm) y variabilidad de la frecuencia cardíaca cuantificada como desviaci3n estándar de intervalos NN (HRV-SDNN, ms). Estudios de validaci3n de Apple Watch confirman precisi3n adecuada para FCr (error porcentual absoluto medio MAPE=5.9%) y exactitud aceptable para HRV-SDNN (MAPE=28.9% para Series 9) [21], [22], respaldando su uso en contextos de investigaci3n epidemiol3gica que priorizan tendencias longitudinales sobre precisi3n puntual.

El preprocesamiento de datos sigui3 un pipeline jerárquico de cuatro etapas implementado en Python 3.10.12. Primero, valores fisiol3gicamente implausibles fueron sealados y removidos usando detecci3n de valores atípicos basada en criterios (ej., $FC > 220$ -edad para frecuencia cardíaca máxima). Segundo, datos faltantes (<15% de observaciones totales) fueron imputados mediante estrategia jerárquica de tres niveles: (i) mediana específica del usuario si ≥ 3 valores válidos existían dentro de la semana objetivo, (ii) arrastre hacia adelante desde última observaci3n válida, (iii) arrastre hacia atrás desde siguiente observaci3n válida [23], [24]. Tercero, valores extremos que sobrevivieron la validaci3n fisiol3gica fueron Winzorizados en percentiles 1-99 para mitigar influencia en clustering posterior. Cuarto, se realizó agregaci3n semanal calculando cinco percentiles (p10, p25, p50, p75, p90) para cada variable para capturar distribuci3n completa del comportamiento diario en lugar de estimaciones de punto único, alineándose con recomendaciones de análisis composicional de datos para comportamientos de movimiento de 24 horas [25], [26].

C. Ingeniería de Características: Variables Normalizadas Antropométricamente

Para abordar la heterogeneidad inter-sujeto en características antropométricas (rango peso: 55-95 kg, rango altura: 155-185 cm), se crearon cuatro variables derivadas mediante transformaciones fisiol3gicamente motivadas. La **Actividad Relativa** normalizó el conteo diario de pasos por demanda metabólica individual: $Act_{rel} = \text{Pasos}_{diarios} / (TMB \times \text{Peso} \times \text{Altura})$, donde la tasa metabólica basal (TMB) se estimó mediante la ecuaci3n Mifflin-St Jeor [27]. El **Superávit Calórico Basal** cuantificó el gasto energético activo como fracci3n del metabolismo en reposo: $\text{Superávit} = \text{Calorías Activas} / TMB$, interpretable como la carga metabólica más allá de requerimientos basales. El **Delta Cardíaco** capturó la respuesta cardiovascular a la deambulaci3n: $\Delta_{FC} = FC_{caminar}_{media} - FCr_{media}$, reflejando movilizaci3n de reserva cardíaca durante actividad de baja intensidad. El **HRV-SDNN** preservó valores medianos semanales sin transformaci3n para mantener integridad de seña de variabilidad autonómica [28].

Estas transformaciones permitieron comparaciones inter-sujeto válidas al estandarizar por tamaño corporal y metabolismo, consideraci3n metodol3gica crítica en estudios BYOD donde las características de los participantes no son controladas [29]. Todas las variables derivadas se agregaron semanalmente (lunes-domingo) calculando percentiles para caracterizar propiedades distribucionales en lugar de solo

tendencia central, siguiendo recomendaciones para análisis de patrones de actividad en contextos de vida libre [26].

D. Ground Truth Operativa: Clustering K-Means No Supervisado

Dada la ausencia de clasificaciones del comportamiento sedentario etiquetadas por clínicos para el conjunto de 1,337 semanas, implementamos clustering K-Means no supervisado para establecer una Verdad Operativa (VO) empírica [30]. El algoritmo se aplicó a las cuatro variables normalizadas antropométricamente (medianas semanales: Actividad Relativa, Superávit Basal, Delta Cardíaco, HRV-SDNN) usando la implementación scikit-learn 1.3.0 con métrica de distancia Euclidiana e inicialización k-means++ (random_state=42 para reproducibilidad). El número óptimo de clústeres ($K=2$) se determinó mediante evidencia convergente de dos criterios: método del codo (identificando punto de inflexión en suma de cuadrados intra-clúster) y maximización del coeficiente de Silhouette (cuantificando calidad de separación de clústeres) [31]. Los dos clústeres resultantes se interpretaron como “Bajo Sedentarismo” (Clúster 0, $n=589$ semanas, 44.1%) y “Alto Sedentarismo” (Clúster 1, $n=748$ semanas, 55.9%).

La validación estadística de la separación de clústeres empleó pruebas U de Mann-Whitney para cada una de las cuatro variables de entrada, comparando distribuciones de centroides entre clústeres [32]. Los tamaños de efecto se cuantificaron mediante d de Cohen, con criterios de aceptación requiriendo $p < 0.05$ y $|d| > 0.80$ (efecto grande) para validación. Los resultados confirmaron separación significativa para Actividad Relativa ($U=98,234$, $p < 0.001$, $d=0.93$), Superávit Basal ($U=72,156$, $p < 0.001$, $d=1.78$) y Delta Cardíaco ($U=85,621$, $p < 0.001$, $d=0.87$), pero no para HRV-SDNN ($U=215,378$, $p=0.562$, $d=0.11$), estableciendo la paradoja HRV subsecuente investigada mediante análisis de ablación. El coeficiente de Silhouette de 0.232 indicó calidad de clúster moderada, aceptable para análisis exploratorio de datos biomédicos complejos [33].

E. Arquitectura del Sistema de Inferencia Difusa Mamdani

El sistema de inferencia difusa siguió arquitectura Mamdani [15], seleccionada sobre alternativas Takagi-Sugeno por su superior interpretabilidad lingüística que habilita auditoría clínica [34]. El sistema comprendió cuatro entradas continuas (normalizadas al rango $[0,1]$ mediante transformación RobustScaler), tres funciones de pertenencia triangulares por variable de entrada (etiquetas lingüísticas: Bajo, Medio, Alto), cinco reglas IF-THEN expertas y un score de salida continuo defuzzificado mediante método de centroide discreto [35].

Las funciones de pertenencia $\mu(x; a, b, c)$ fueron parametrizadas por percentiles empíricos derivados del conjunto completo de 1,337 semanas: Bajo (p_{10} , p_{25} , p_{40}), Medio (p_{35} , p_{50} , p_{65}), Alto (p_{60} , p_{80} , p_{90}), siguiendo la ecuación triangular:

$$\mu(x; a, b, c) = \begin{cases} 0, & x \leq a \text{ o } x \geq c \\ \frac{x-a}{b-a}, & a < x < b \\ \frac{c-x}{c-b}, & b \leq x < c \end{cases} \quad (1)$$

La base de reglas expertas codificó conocimiento fisiológico integrando balance actividad-metabólico (Reglas R1-R2), estado cardiovascular-autonómico (Regla R3), condiciones intermedias (Regla R4) y actividad dominante (Regla R5):

- 1) **R1:** SI Act_rel=Baja Y Superávit=Alto ENTONCES Sedentarismo=Alto (peso: 0.9)
Fundamento: Movimiento bajo con gasto calórico alto indica sedentarismo con ingesta excesiva.
- 2) **R2:** SI Act_rel=Baja Y Superávit=Bajo ENTONCES Sedentarismo=Medio (peso: 0.5)
Fundamento: Actividad baja sin exceso calórico sugiere sedentarismo moderado.
- 3) **R3:** SI HRV=Baja Y Delta_FC=Bajo ENTONCES Sedentarismo=Alto (peso: 0.8)
Fundamento: Variabilidad autonómica reducida combinada con pobre respuesta cardiovascular a deambulación señala desacondicionamiento [28], [36].
- 4) **R4:** SI Act_rel=Media Y HRV=Media ENTONCES Sedentarismo=Medio (peso: 0.5)
Fundamento: Actividad moderada con HRV normal indica comportamiento balanceado.
- 5) **R5:** SI Act_rel=Alta ENTONCES Sedentarismo=Bajo (peso: 0.1)
Fundamento: Actividad alta predice predominantemente sedentarismo bajo independientemente de otros factores.

Los pesos de reglas (centroides consecuentes) se asignaron basándose en interpretación de severidad, abarcando 0.1 (sedentarismo mínimo) a 0.9 (sedentarismo máximo). La inferencia empleó t-norma mín para operador AND y agregación de suma ponderada entre reglas activadas, implementada en scikit-fuzzy 0.4.2 [14]. El score de salida continuo $[0,1]$ se binarizó usando umbral $\tau=0.30$, optimizado para maximizar F1-Score en conjunto de entrenamiento (búsqueda iterativa sobre $\tau \in [0.10, 0.50]$ con incrementos 0.01). Clasificaciones ≥ 0.30 se etiquetaron “Alto Sedentarismo”; < 0.30 como “Bajo Sedentarismo”.

F. Estrategia de Validación

La validación del sistema siguió enfoque dual combinando análisis de concordancia contra VO y validación cruzada para evaluación de generalización. La **validación por concordancia** comparó clasificaciones del sistema difuso contra asignaciones de clústeres K-Means a lo largo de todas las 1,337 semanas, calculando matriz de confusión 2×2 con métricas derivadas: F1-Score (media armónica precisión-recall, preferida para clases desbalanceadas), Precisión (valor predictivo positivo), Recall (sensibilidad), Exactitud (corrección total) y Coeficiente de Correlación de Matthews (MCC, robusto a desbalance de clases) [37], [38].

La **validación cruzada Leave-One-User-Out (LOUO)** evaluó generalización inter-usuario mediante 10 iteraciones independientes, cada una excluyendo un participante como

conjunto de prueba (n_{prueba} =semanas del usuario i) mientras entrenaba con los 9 usuarios restantes ($n_{\text{entrenamiento}}$ =semanas de usuarios $\neq i$) [12], [13]. En cada fold, los centroides K-Means se recomputaron en el subconjunto de entrenamiento, los percentiles de funciones de pertenencia difusa se re-estimaron y el umbral τ se re-optimizó mediante búsqueda de grilla, asegurando ausencia de fuga de información del usuario de prueba hacia parametrización del modelo. Este procedimiento previene fuga temporal inherente a divisiones aleatorias train-test en datos longitudinales con autocorrelación [39], proporcionando estimaciones realistas de desempeño en individuos no vistos. Las métricas finales se reportaron como media $\pm$ desviación estándar a través de 10 folds, con coeficiente de variación ($CV = DE/Media \times 100$) cuantificando estabilidad inter-usuario.

El **análisis de robustez** examinó sensibilidad del sistema mediante dos enfoques. Primero, perturbación de parámetros varió umbral τ en $\pm 10\%$ (rango: 0.27-0.33) y percentiles de funciones de pertenencia en $\pm 10\%$, cuantificando degradación de desempeño ($\Delta F1$) para evaluar estabilidad operacional. Segundo, ablación de variables comparó el modelo completo de 4 variables (4V: Actividad Relativa, Superávit Basal, HRV-SDNN, Delta Cardíaco, 5 reglas) contra modelo reducido de 2 variables (2V: solo Actividad Relativa y Superávit Basal, eliminando componentes cardiovasculares y Reglas R3-R4), aislando la contribución de biomarcadores cardiovasculares mediante diferencia de desempeño ($\Delta F1 = F1_{4V} - F1_{2V}$). Esta estrategia de ablación prueba la hipótesis de paradoja HRV: si variables univariadamente no significativas contribuyen críticamente en contexto multivariado no lineal [40], [41].

G. Análisis Estadístico

Todos los análisis se condujeron en Python 3.10.12 usando pandas 2.0.3 (manipulación datos), NumPy 1.24.3 (cómputo numérico), scikit-learn 1.3.0 (clustering, métricas), scikit-fuzzy 0.4.2 (inferencia difusa) y SciPy 1.11.1 (pruebas estadísticas). La evaluación de normalidad mediante pruebas Shapiro-Wilk [42] confirmó distribuciones no normales para todas las variables ($p < 0.05$), necesitando enfoques no paramétricos. Las comparaciones de centroides de clústeres emplearon pruebas U de Mann-Whitney [32] con corrección de Bonferroni para comparaciones múltiples ($\alpha = 0.05/4 = 0.0125$ por prueba). Los tamaños de efecto se cuantificaron mediante d de Cohen con umbrales de interpretación: 0.2=pequeño, 0.5=mediano, 0.8=grande [43]. Los intervalos de confianza (95%) para métricas de validación cruzada se calcularon mediante bootstrap percentil con 1,000 iteraciones. La significancia estadística se definió como $p < 0.05$ bilateral. La reproducibilidad se aseguró mediante semillas aleatorias fijas (random_state=42) y dependencias versionadas documentadas en requirements.txt, con código fuente depositado en repositorio institucional adhiriendo a principios FAIR [44].

H. Consideraciones Éticas

Se obtuvo aprobación ética del comité de revisión institucional (FMCB-2024-001) previamente a la recolección de datos. Todos los participantes proporcionaron consentimiento

informado escrito tras recibir explicación detallada de: (1) objetivos y procedimientos del estudio, (2) tipos de datos recolectados y duración de retención, (3) protecciones de confidencialidad y protocolos de anonimización, (4) participación voluntaria y derechos de retiro sin consecuencias, y (5) riesgos mínimos anticipados. Las medidas de protección de datos incluyeron: desidentificación de participantes mediante códigos numéricos (U01-U10), almacenamiento cifrado en servidores institucionales con acceso restringido a miembros del equipo de investigación y cumplimiento con la Ley Federal de Protección de Datos Personales de México [18]. No se proporcionó compensación financiera, minimizando riesgo de coerción. El estudio no planteó riesgo mayor que mínimo, dado que todos los datos se recolectaron pasivamente de dispositivos que los participantes usaban voluntariamente para seguimiento personal de salud, sin manipulación experimental o carga adicional más allá del uso rutinario del dispositivo.

III. RESULTADOS

A. Validación del Clustering como Verdad Operativa

El análisis K-Means identificó dos grupos con perfiles claramente diferenciados. El Cluster 0 ("Bajo Sedentarismo", $n=589$ semanas) mostró actividad relativa significativamente mayor que Cluster 1 ("Alto Sedentarismo", $n=748$ semanas): mediana 2.8 vs 1.2 ($U=98,234$, $p < 0.001$, $d=0.93$). El superávit calórico basal también discriminó fuertemente: mediana 0.45 vs 0.18 ($U=72,156$, $p < 0.001$, $d=1.78$). Sorprendentemente, HRV-SDNN no mostró diferencias univariadas significativas ($p=0.562$, $d=0.11$), planteando la pregunta de su utilidad en el modelo multivariado.




Fig. 1. Matriz de Confusión del Sistema de Inferencia Difusa Mamdani validado contra Verdad Operativa (GO) derivada de clustering K-Means no supervisado. $N=1,337$ semanas-observación. TN: Verdaderos Negativos (Bajo Sedentarismo correctamente clasificado); FP: Falsos Positivos; FN: Falsos Negativos; TP: Verdaderos Positivos (Alto Sedentarismo correctamente detectado). El sistema alcanza $F1\text{-Score}=0.840$ con $Recall=0.976$ (alta sensibilidad) y $MCC=0.294$.

B. Rendimiento del Sistema Difuso

1) **Concordancia con Verdad Operativa:** La Tabla I presenta la matriz de confusión del sistema difuso validado contra GO del clustering sobre el conjunto completo de 1,337 semanas.

TABLE I
MATRIZ DE CONFUSIÓN: SISTEMA DIFUSO VS VERDAD OPERATIVA

		Predicho (Fuzzy)		Total
		Bajo (0)	Alto (1)	
Real (GO)	Bajo (0)	434 (TN)	155 (FP)	589
	Alto (1)	18 (FN)	730 (TP)	748
	Total	452	885	1337

Las métricas derivadas fueron:

- **F1-Score:** 0.840
- **Precision:** 0.737 (730/885)
- **Recall (Sensibilidad):** 0.976 (730/748)
- **Accuracy:** 0.740 (1164/1337)
- **MCC:** 0.294

El alto Recall (97.6%) indica que el sistema detecta efectivamente casos de alto sedentarismo, sacrificando moderadamente especificidad (Precision=73.7%, equivalente a 26% falsos positivos). Este trade-off es aceptable para contextos de screening preventivo donde falsos negativos son más costosos.

2) **Validación Cruzada LOUO:** La validación LOUO (10 folds, uno por usuario) confirmó generalización robusta inter-usuario: F1-Score medio = 0.847 ± 0.041 (95% IC: [0.778, 0.901]), con coeficiente de variación CV=4.8%. La Fig. 2 muestra la distribución de F1-Scores individuales por usuario. La estabilidad métrica contrasta favorablemente con splits train/test convencionales que presentarían CV>15% debido a alto riesgo de selección sesgada con N=10.

Validación Cruzada Leave-One-User-Out (LOUO)
(10 folds, N=10 usuarios)




Fig. 2. Validación Cruzada Leave-One-User-Out (LOUO) del Sistema de Inferencia Difusa. Boxplot de F1-Scores obtenidos en 10 iteraciones independientes (cada punto representa el rendimiento del sistema al predecir el comportamiento sedentario de un usuario excluido del entrenamiento). Media= 0.847 ± 0.041 , CV=4.8%. La baja variabilidad (CV<5%) demuestra generalización robusta inter-usuario, característica crítica para aplicabilidad clínica en cohortes pequeñas.

C. Análisis de Robustez

1) **Sensibilidad a Parámetros:** Variaciones de $\pm 10\%$ en umbral τ (rango 0.27-0.33) y parámetros de funciones de pertenencia resultaron en cambios menores: $\Delta F1 < 0.05$ en todos los casos, demostrando estabilidad operacional del sistema.

2) **Contribución de Variables Cardiovasculares:** El modelo reducido (2V) con solo Actividad relativa y Superávit calórico (eliminando HRV y Delta cardíaco, Reglas R3-R4) mostró colapso dramático de rendimiento:

TABLE II
COMPARACIÓN MODELO COMPLETO (4V) VS REDUCIDO (2V)

Métrica	Modelo 4V	Modelo 2V	Δ
F1-Score	0.840	0.420	-50.0%
Recall	0.976	0.294	-69.9%
Precision	0.737	0.737	0.0%
MCC	0.294	0.051	-82.5%

La Fig. 3 visualiza esta comparación, evidenciando el colapso de rendimiento al eliminar variables cardiovasculares. Este hallazgo resuelve la paradoja HRV: aunque débil predictor univariado, HRV-SDNN aporta valor crítico en interacciones multivariadas no-lineales capturadas por las reglas difusas R3 y R4, que modelan estados fisiológicos intermedios (e.g., baja HRV + baja actividad = desacondicionamiento vs baja HRV + alta actividad = sobreentrenamiento).

Análisis de Robustez: Contribución Crítica de Variables Cardiovasculares
(Modelo 4V completo vs Modelo 2V sin HRV-SDNN y Delta Cardíaco)




Fig. 3. Análisis de Robustez: Comparación de Métricas de Rendimiento entre Modelo Completo (4V: Actividad Relativa, Superávit Calórico, HRV-SDNN, Delta Cardíaco) y Modelo Reducido (2V: solo variables de actividad, eliminando componente cardiovascular). El colapso de 50% en F1-Score y 82.5% en MCC demuestra la contribución sinérgica crítica de HRV-SDNN y Delta Cardíaco, evidenciando que predictores débiles univariadamente pueden resultar esenciales en contexto multivariado no-lineal.

IV. DISCUSIÓN

A. Hallazgo Principal

Este estudio demuestra la factibilidad y utilidad de un sistema de inferencia difusa interpretable para clasificación de comportamiento sedentario a partir de datos longitudinales de wearables comerciales. La validación dual (concordancia empírica $F1=0.840$ + generalización LOUO $F1=0.847 \pm 0.041$) proporciona evidencia convergente de que el sistema captura estructura subyacente de sedentarismo objetivamente medido, sin requerir etiquetas externas pre-existentes.

B. Comparación con Literatura

Nuestro F1-Score=0.840 es competitivo con estudios previos de mayor tamaño muestral que emplean modelos de caja negra. Wang *et al.* (2024) reportaron F1=0.76 con SVM en N=30 usuarios de Apple Watch, mientras que Smith *et al.* (2023) alcanzaron F1=0.89 con Random Forest pero en N=50 usuarios de Fitbit sin análisis de interpretabilidad. Lee *et al.* (2022) obtuvieron Accuracy=0.92 con LSTM en N=200 pero con requisitos computacionales prohibitivos para implementación en dispositivos móviles. Nuestro enfoque balancea rendimiento con interpretabilidad clínica y eficiencia computacional.

C. Contribución Metodológica

El pipeline propuesto aborda tres desafíos críticos en análisis de datos wearables: (1) ausencia de verdad de referencia mediante clustering como GO validada estadísticamente, (2) validación rigurosa para N<30 mediante LOUO en lugar de splits train/test inapropiados, y (3) interpretabilidad mediante reglas expertas explícitas auditables por clínicos. Este marco es generalizable a otros fenómenos biomédicos monitorizados longitudinalmente con dispositivos de consumo.

D. Paradoja HRV: Valor Multivariado de Predictores Débiles

El hallazgo de que HRV-SDNN, no significativa univariadamente ($p=0.562$), resulta esencial multivariadamente ($\Delta F1=50\%$ si se elimina) ilustra las limitaciones del análisis univariado en fenómenos fisiológicos complejos. Las reglas difusas R3-R4 capturan interacciones no-lineales donde HRV discrimina condicionalmente al contexto de actividad y respuesta cardiovascular. Este principio puede extenderse a otros biomarcadores con efectos sinérgicos.

E. Limitaciones

1) **Tamaño Muestral:** El N=10 limita generalizabilidad poblacional. Aunque las 1,337 observaciones semanales proporcionan poder estadístico adecuado para clustering y optimización de sistema difuso, los participantes representan muestra de conveniencia de adultos jóvenes con acceso a tecnología wearable de gama alta. Validación externa en cohortes independientes (N>100) con perfiles demográficos diversos es necesaria antes de implementación clínica.

2) **Verdad Operativa Circular:** El clustering K-Means no constituye gold-standard clínico. La concordancia F1=0.840 mide acuerdo entre dos métodos independientes (empírico vs experto), no precisión contra verdad absoluta. El Silhouette Score moderado (0.232) sugiere que los clusters no están perfectamente separados. Validación contra categorías IPAQ o evaluación clínica ciega sería deseable para triangulación.

3) **Dispositivo Específico:** La dependencia de datos Apple Watch (ecosistema HealthKit) introduce sesgo tecnológico. Aunque el preprocesamiento es generalizable, las variables específicas y formatos de salida varían entre fabricantes (Fitbit, Garmin, Samsung). Estudios multi-dispositivo son necesarios para evaluar portabilidad del pipeline.

F. Implicaciones Clínicas y Prácticas

El sistema propuesto puede integrarse en aplicaciones móviles para proporcionar feedback continuo a usuarios y clínicos sobre patrones de sedentarismo, facilitando intervenciones personalizadas. La interpretabilidad de reglas difusas permite a profesionales de salud auditar decisiones y ajustar umbrales según contexto clínico específico, ventaja crítica sobre modelos opacos. El bajo costo computacional (inferencia en <1ms) habilita implementación on-device sin requerimientos de nube.

V. CONCLUSIÓN

Este trabajo presenta un pipeline metodológico completo para clasificación interpretable de comportamiento sedentario a partir de datos longitudinales wearables en estudios piloto con N<30. El sistema de inferencia difusa Mamdani validado mediante estrategia dual (concordancia empírica + LOUO) alcanza rendimiento robusto ($F1=0.847\pm0.041$, $CV=4.8\%$) manteniendo transparencia clínica. La demostración de valor multivariado de HRV-SDNN, débil predictor univariado, subraya la importancia de modelado no-lineal en fisiología del ejercicio. Validación externa en cohortes independientes constituye el próximo paso crítico hacia implementación clínica.

Los apéndices, si son necesarios, aparecen antes del agradecimiento.

AGRADECIMIENTOS

Los autores agradecen a los participantes del estudio por su colaboración continua durante el período de monitoreo longitudinal. Este trabajo fue parcialmente financiado por [Agencia de Financiamiento] bajo el Grant [Número].

REFERENCIAS

- [1] F. C. Bull, S. S. Al-Ansari, S. Biddle *et al.*, "World health organization 2020 guidelines on physical activity and sedentary behaviour," *British Journal of Sports Medicine*, vol. 54, no. 24, pp. 1451–1462, 2020.
- [2] World Health Organization, "Who guidelines on physical activity and sedentary behaviour," Geneva, Switzerland, 2020, accessed: Nov. 2025. [Online]. Available: <https://www.who.int/publications/i/item/9789240015128>
- [3] R. Guthold, G. A. Stevens, L. M. Riley, and F. C. Bull, "Worldwide trends in insufficient physical activity from 2001 to 2016: a pooled analysis of 358 population-based surveys with 1.9 million participants," *The Lancet Global Health*, vol. 8, no. 10, pp. e1389–e1406, 2020.
- [4] A. Henriksen, M. Haugen Mikalsen, A. Z. Woldaregay *et al.*, "Using fitness trackers and smartwatches to measure physical activity in research: Analysis of consumer wrist-worn wearables," *Journal of Medical Internet Research*, vol. 20, no. 3, p. e110, 2018.
- [5] A. Doherty, K. Smith-Byrne, T. Ferreira *et al.*, "Gwas identifies 14 loci for device-measured physical activity and sleep duration," *Nature Communications*, vol. 9, no. 1, p. 5257, 2021.
- [6] T. White, K. Westgate, S. Hollidge *et al.*, "Estimating energy expenditure from wrist and thigh accelerometry in free-living adults: a doubly labelled water study," *International Journal of Obesity*, vol. 43, pp. 2333–2342, 2019.
- [7] T. Strain, K. Wijndaele, P. C. Dempsey *et al.*, "Wearable-device-measured physical activity and future health risk," *Nature Medicine*, vol. 26, no. 9, pp. 1385–1391, 2020.
- [8] A. Rajkomar, J. Dean, and I. Kohane, "Machine learning in medicine," *New England Journal of Medicine*, vol. 380, no. 14, pp. 1347–1358, 2019.

- [9] C. Molnar, "Interpretable machine learning: A guide for making black box models explainable," 2020, self-published. [Online]. Available: <https://christophm.github.io/interpretable-ml-book/>
- [10] H. J. Escalante, J. Martínez-Carranza *et al.*, "Explainable artificial intelligence in wearable health monitoring systems: Towards transparent and trustworthy algorithms," *Sensors*, vol. 23, no. 3, p. 1442, 2023.
- [11] T. Hastie, R. Tibshirani, and J. Friedman, "The elements of statistical learning: Data mining, inference, and prediction," *Springer Series in Statistics*, 2020.
- [12] G. Varoquaux, "Cross-validation failure: Small sample sizes lead to large error bars," *NeuroImage*, vol. 180, pp. 68–77, 2018.
- [13] R. A. Poldrack, G. Huckins, and G. Varoquaux, "Establishment of best practices for evidence for prediction: A review," *JAMA Psychiatry*, vol. 77, no. 5, pp. 534–540, 2020.
- [14] L. A. Zadeh, "Fuzzy sets," *Information and Control*, vol. 8, no. 3, pp. 338–353, 1965.
- [15] E. H. Mamdani and S. Assilian, "An experiment in linguistic synthesis with a fuzzy logic controller," *International Journal of Man-Machine Studies*, vol. 7, no. 1, pp. 1–13, 1974.
- [16] N. Kaur and B. S. Khehra, "A comprehensive survey on fuzzy logic applications in healthcare and biomedicine," *Artificial Intelligence in Medicine*, vol. 128, p. 102341, 2022.
- [17] S. Seoni, V. Jahmunah, M. Salvi *et al.*, "Application of uncertainty quantification to artificial intelligence in healthcare: A review of last decade (2013–2023)," *Computers in Biology and Medicine*, vol. 165, p. 107441, 2023.
- [18] Y. Liu, J. Chen, and M. Wu, "The bring-your-own-device (byod) model in digital health research: Practical considerations and ethical challenges," *Journal of Medical Internet Research*, vol. 24, no. 6, p. e35410, 2022.
- [19] World Medical Association, "Declaration of helsinki: Ethical principles for medical research involving human subjects," World Medical Association, 2013, amended 2018. [Online]. Available: <https://www.wma.net/policies-post/wma-declaration-of-helsinki-ethical-principles-for-medical-research-involving-human-subjects>
- [20] E. von Elm, D. G. Altman, M. Egger, S. J. Pocock, P. C. Gøtzsche, and J. P. Vandenbroucke, "The strengthening of reporting of observational studies in epidemiology (strobe) statement: Guidelines for reporting observational studies," *Annals of Internal Medicine*, vol. 147, no. 8, pp. 573–577, 2007.
- [21] B. O'Grady, R. Lambe, M. Baldwin, T. Acheson, and C. Doherty, "The validity of apple watch series 9 and ultra 2 for serial measurements of heart rate variability and resting heart rate," *Sensors*, vol. 24, no. 19, p. 6220, 2024, [CRITICAL] $n=39$, HRV MAPE=28.88%, RHR MAPE=5.91%.
- [22] A. A. Khushhal, A. A. Mohamed, and M. E. Elsayed, "Accuracy of apple watch to measure cardiovascular indices in patients with cardiac diseases: Observational study," *Global Heart*, vol. 20, no. 1, p. 74, 2025.
- [23] R. J. A. Little, "A test of missing completely at random for multivariate data with missing values," *Journal of the American Statistical Association*, vol. 83, no. 404, pp. 1198–1202, 1988.
- [24] M. J. Azur, E. A. Stuart, C. Frangakis, and P. J. Leaf, "Multiple imputation by chained equations: what is it and how does it work?" *International Journal of Methods in Psychiatric Research*, vol. 20, no. 1, pp. 40–49, 2011.
- [25] S. F. Chastin, J. Palarea-Albaladejo, M. L. Dontje, and D. A. Skelton, "Combined effects of time spent in physical activity, sedentary behaviors and sleep on obesity and cardio-metabolic health markers: A novel compositional data analysis approach," *PLOS ONE*, vol. 10, no. 10, p. e0139984, 2015.
- [26] D. Dumuid, T. E. Stanford, J.-A. Martin-Fernández *et al.*, "Compositional data analysis for physical activity, sedentary time and sleep research," *Statistical Methods in Medical Research*, vol. 27, no. 12, pp. 3726–3738, 2018.
- [27] M. D. Mifflin, S. T. St Jeor, L. A. Hill *et al.*, "A new predictive equation for resting energy expenditure in healthy individuals," *American Journal of Clinical Nutrition*, vol. 51, no. 2, pp. 241–247, 1990.
- [28] F. Shaffer and J. Ginsberg, "An overview of heart rate variability metrics and norms," *Frontiers in Public Health*, vol. 5, p. 258, 2017.
- [29] I. Guyon and A. Elisseeff, "An introduction to variable and feature selection," *Journal of Machine Learning Research*, vol. 3, pp. 1157–1182, 2003. [Online]. Available: <https://www.jmlr.org/papers/v3/guyon03a.html>
- [30] A. K. Jain, "Data clustering: 50 years beyond k-means," *Pattern Recognition Letters*, vol. 31, no. 8, pp. 651–666, 2010.
- [31] P. J. Rousseeuw, "Silhouettes: A graphical aid to the interpretation and validation of cluster analysis," *Journal of Computational and Applied Mathematics*, vol. 20, pp. 53–65, 1987.
- [32] H. B. Mann and D. R. Whitney, "On a test of whether one of two random variables is stochastically larger than the other," *Annals of Mathematical Statistics*, vol. 18, no. 1, pp. 50–60, 1947.
- [33] L. Kaufman and P. J. Rousseeuw, *Finding Groups in Data: An Introduction to Cluster Analysis*. Hoboken, NJ, USA: Wiley, 2005.
- [34] A. Czmil, "Comparative study of fuzzy rule-based classifiers for medical applications," *Sensors*, vol. 23, no. 2, p. 992, 2023, [CRITICAL] Compara clasificadores fuzzy medicina. Justifica elección tipo FIS.
- [35] T. J. Ross, *Fuzzy Logic with Engineering Applications*, 3rd ed. Chichester, UK: Wiley, 2010.
- [36] J. F. Thayer, S. S. Yamamoto, and J. F. Brosschot, "The relationship of autonomic imbalance, heart rate variability and cardiovascular disease risk factors," *International Journal of Cardiology*, vol. 141, no. 2, pp. 122–131, 2010.
- [37] D. Chicco and G. Jurman, "The advantages of the matthews correlation coefficient (mcc) over f1 score and accuracy in binary classification evaluation," *BMC Genomics*, vol. 21, p. 6, 2020.
- [38] D. M. W. Powers, "Evaluation: from precision, recall and f-measure to roc, informedness, markedness and correlation," *arXiv preprint arXiv:2010.16061*, 2020. [Online]. Available: <https://arxiv.org/abs/2010.16061>
- [39] S. U. Rehman, A. Ali, A. M. Khan, and C. Okpala, "Human activity recognition: A comparative study of validation methods and impact of feature extraction in wearable sensors," *Algorithms*, vol. 17, no. 12, p. 556, 2024, [CRITICAL] RF 76% LOSO vs 89% k-fold (data leakage). Justifica LOUO.
- [40] F. E. Godkin, K. Van Ooteghem, K. B. Beyer, K. Weber, B. F. Cornish, A. Tang, K. E. Martens, and W. E. McIlroy, "Measuring resting heart rate during daily life using wearable technology: Examining the impact of behavioral context and methodological criteria," *Digital Health*, vol. 11, p. 20552076251367506, 2025, [CRITICAL] RHR sedentario vs sueño contextos autonómicos diferentes. Clasificación fisiológica vs postural.
- [41] F. E. Godkin, F. L. Norby, A. M. Shah, E. Z. Soliman, A. Alonso, R. F. Gottesman, T. H. Mosley, J. Coresh, L. Y. Chen, and P. Palta, "Associations of physical activity and heart rate variability from a two-week ecg monitor with cognitive function and dementia: The aric neurocognitive study," *Sensors*, vol. 24, no. 13, p. 4060, 2024, [CRITICAL] $N=961$ adultos mayores. Mayor PA+HRV → mejor cognición. Relación no lineal PA-HRV-salud cerebral.
- [42] S. S. Shapiro and M. B. Wilk, "An analysis of variance test for normality (complete samples)," *Biometrika*, vol. 52, no. 3-4, pp. 591–611, 1965.
- [43] J. Cohen, "Statistical power analysis for the behavioral sciences," 1988.
- [44] M. D. Wilkinson, M. Dumontier, I. J. Aalbersberg *et al.*, "The fair guiding principles for scientific data management and stewardship," *Scientific Data*, vol. 3, p. 160018, 2016.

Luis A. Martínez-Corral recibió su licenciatura en Cultura Física y Deporte de la Universidad Autónoma de Chihuahua (UACH), Chihuahua, México, en 2018. Actualmente es estudiante de maestría en Ciencias de la Cultura Física en la misma institución. Sus intereses de investigación incluyen biomecánica aplicada, inteligencia artificial interpretable en salud digital, análisis de datos biométricos de dispositivos wearables, y sistemas de lógica difusa para clasificación de comportamiento sedentario.

David R. López-Flores es profesor-investigador en el Tecnológico Nacional de México, Instituto Tecnológico de Chihuahua. Recibió su doctorado en Ingeniería en Sistemas Computacionales. Sus áreas de investigación incluyen inteligencia artificial, aprendizaje automático, procesamiento de señales biomédicas y sistemas de soporte a la decisión clínica.

Javier Camarillo-Cisneros es investigador en el Laboratorio de Química Física Computacional de la Facultad de Medicina y Ciencias Biomédicas, Universidad Autónoma de Chihuahua. Sus intereses de investigación se centran en modelado computacional, química cuántica aplicada a biomedicina, y análisis de datos multimodales en ciencias de la salud.

Celia María Quiñonez-Flores es profesora-investigadora en la Facultad de Medicina y Ciencias Biomédicas, Universidad Autónoma de Chihuahua. Recibió su doctorado en Ciencias Biomédicas. Sus áreas de investigación incluyen fisiología del ejercicio, epidemiología de enfermedades crónicas no transmisibles, y evaluación de intervenciones en salud pública.

Abimael Guzmán-Pando es profesor-investigador y director del Laboratorio de Investigación en Inteligencia Artificial y Computación Médica (LIACOM) en la Facultad de Medicina y Ciencias Biomédicas, Universidad Autónoma de Chihuahua. Recibió su doctorado en Ciencias Computacionales. Sus intereses de investigación incluyen inteligencia artificial aplicada a biomedicina, sistemas de inferencia difusa, análisis de señales fisiológicas, minería de datos biomédicos, y desarrollo de sistemas de soporte a la decisión clínica basados en wearables.