

UNIVERSIDAD AUTÓNOMA DE CHIHUAHUA
FACULTAD DE MEDICINA Y CIENCIAS BIOMÉDICAS
MAESTRÍA EN FORMACIÓN E INNOVACIÓN PARA PROFESIONA-
LES DE LA SALUD

UNIDAD FORMATIVA: BIOESTADÍSTICA



METODOLOGÍA Y RESULTADOS DE LA TESIS:
“MODELO DE EVALUACIÓN DEL COMPORTAMIENTO
SEDENTARIO MEDIANTE LÓGICA DIFUSA Y
DATOS BIOMÉTRICOS”

ASESOR:

DR. JOSÉ LÓPEZ LOYA

ESTUDIANTE:

LMH. LUIS ANGEL MARTÍNEZ CORRAL

3 de Diciembre de 2025

Índice de Contenidos

1	Materiales y Métodos	4
1.1	Diseño del Estudio	4
1.2	Técnicas y Procedimiento	4
1.2.1	Selección del Dispositivo	4
1.2.2	Metodología de Extracción y Procesamiento de Datos	5
1.3	Población de Estudio	8
1.3.1	Estrategia de Reclutamiento	8
1.3.2	Tamaño de Muestra y Justificación Estadística	8
1.3.3	Características Demográficas de la Cohorte	9
1.3.4	Análisis Descriptivo Previo a la Agregación	9
1.4	Definición Operacional de Variables	12
1.4.1	Relación entre Variables	12
1.4.2	Variables Independientes	13
1.4.3	Variable Dependiente	13
1.4.4	Variables de Control	13
1.4.5	Operacionalización de las Variables	13
1.5	Preprocesamiento y Análisis Exploratorio de Datos	15
1.5.1	Extracción de Variables desde Apple HealthKit	15
1.5.2	Análisis de Calidad y Variabilidad de Datos	16
1.5.3	Transición a Ingeniería de Características	17
1.6	Ingeniería de Características y Agregación Temporal	17
1.6.1	Actividad Relativa	17
1.6.2	Superávit Calórico Basal	18
1.6.3	Delta Cardíaco	18
1.6.4	Variabilidad de Frecuencia Cardíaca (HRV-SDNN)	18
1.6.5	Agregación Semanal y Justificación de Medianas	19
1.7	Plan de Análisis Estadístico	19
1.7.1	Fase 1: Caracterización y Análisis de Variabilidad	19
1.7.2	Fase 2: Establecimiento de la Verdad Operativa mediante Clustering	19
1.7.3	Fase 3: Diseño y Configuración del Sistema de Inferencia Difusa	20
1.7.4	Fase 4: Validación del Sistema Difuso mediante Leave-One-User-Out	20
1.7.5	Fase 5: Análisis de Robustez y Contribución de Variables	21
1.8	Base Metodológica del Sistema de Inferencia Difusa	21



1.8.1	Formalización Matemática del Sistema de Inferencia Difusa	24
1.9	Aspectos Éticos y de Bioseguridad	29
1.9.1	Principios Éticos	30
1.9.2	Procedimiento para Obtener el Consentimiento	30
1.9.3	Contenido del Formulario de Consentimiento	30
1.9.4	Evaluación de Riesgos	30
1.9.5	Protección de Grupos Vulnerables	31
1.9.6	Confidencialidad y Privacidad de los Datos	31
1.9.7	Política de Retención y Eliminación Segura	31
1.9.8	Derechos de los Participantes	32
1.9.9	Cumplimiento de Normativas y Legislación	32
1.9.10	Plan de Contingencia y Manejo de Incidentes	32
1.10	Financiamiento y Lugar Donde Se Realizará El Proyecto	32
1.10.1	Reproducibilidad Computacional	33
1.10.2	Lugar de Ejecución	33
2	Resultados	34
2.1	Caracterización de la Cohorte y Análisis de Variabilidad de Datos	34
2.2	Establecimiento de la Verdad Operativa: Análisis de Conglomerados	34
2.3	Rendimiento del Sistema de Inferencia Difusa	36
2.3.1	Posicionamiento en el Contexto de Estudios con Validación LOUO	39
2.4	Análisis de Robustez y Contribución Sinérgica de las Variables	42
2.4.1	Paradoja HRV: Debilidad Univariada, Fortaleza Multivariada	43
2.4.2	Validación Convergente Exploratoria con SF-36	44
2.5	Tesis	45
	Referencias	47

Materiales y Métodos

Este capítulo detalla la metodología empleada en la investigación, incluyendo el diseño del estudio, la caracterización de la población participante, la definición operacional de variables, los instrumentos de recolección de datos biométricos y el protocolo de análisis estadístico implementado. Describimos el procedimiento completo desde la selección del *Apple Watch* como dispositivo *wearable* bajo los paradigmas de vida libre y *Bring Your Own Device (BYOD)*, seguido del protocolo de extracción de datos mediante el ecosistema *HealthKit*, hasta la validación del sistema de inferencia difusa con estrategia *Leave-One-User-Out*, lo cual garantiza la reproducibilidad y transparencia metodológica necesarias para la replicación de los hallazgos en estudios futuros.

1.1 Diseño del Estudio

Empleamos un diseño cuantitativo, observacional, longitudinal retrospectivo con seguimiento multianual (2021-2024) de una cohorte de 10 participantes adultos. El estudio se estructuró en tres fases metodológicas principales: (1) recolección y adquisición de datos mediante cuestionarios de autoinforme y dispositivos *wearables* bajo el paradigma *Bring Your Own Device (BYOD)*, (2) procesamiento, limpieza y agregación de datos biométricos longitudinales, y (3) diseño y validación de un sistema de inferencia difusa para clasificación del comportamiento sedentario. La unidad de análisis correspondió a semanas completas de monitoreo, generadas a partir de la agregación temporal de datos diarios recopilados de forma continua.

1.2 Técnicas y Procedimiento

1.2.1 Selección del Dispositivo

Para la selección del dispositivo de monitoreo, utilizamos una base de datos detallada que analiza 423 dispositivos de 133 marcas, divididos en 187 monitores de actividad física y 236 relojes inteligentes lanzados desde 2011 Henriksen et al., 2021. Esta base permitió identificar las capacidades técnicas de cada dispositivo, como sensores incluidos y su utilidad en la medición de patrones de actividad física (AF) y comportamiento sedentario (CS).

Del análisis de los 423 dispositivos de la base de datos Henriksen et al., 2021, identificamos que todos cuentan con acelerómetro, esencial para medir la intensidad y frecuencia del movimiento. Sin embargo, solo el 38.3 % de los dispositivos (162 de 423) incluyen un sensor de fotopletiografía (PPG), crucial para medir frecuencia y variabilidad cardíaca, indicadores relevantes para evaluar esfuerzo físico y salud cardiovascular Pinto et al., 2023.

El análisis de mercado identificó a Apple como el líder en la categoría de relojes inteligentes, con un 49 % de la cuota global, seguido por Samsung (15 %) y Garmin (11 %) Canalys, 2024. Esta predominancia y la uniformidad en sus dispositivos justifican la elección del Apple Watch como el dispositivo más adecuado, asegurando una mayor representatividad de datos y compatibilidad con herramientas de análisis avanzadas. La Tabla 1.1 resume la matriz de decisión empleada para sustentar esta selección, incorporando a los principales proveedores disponibles en México. La tabla muestra, para cada criterio de evaluación como la penetración en México, la validación de sensores, la capacidad de exportación de datos, la consistencia entre hardware y software y la disponibilidad de *SDK* o documentación, el desempeño comparativo de los principales dispositivos *wearables* del mercado, incluyendo Apple Watch, Fitbit, Garmin, Polar y Huawei. La tabla se interpreta asignando a cada proveedor un nivel cualitativo por criterio (Alta, Media, Media-baja, Baja, Parcial, Sí, Limitada), lo que permite identificar fortalezas y debilidades relativas y facilita elegir el dispositivo con mayor solidez técnica y disponibilidad para investigación en el contexto nacional.

Tabla 1.1

Matriz de decisión extendida para selección de dispositivo wearable

Criterio	Apple Watch	Fitbit	Garmin	Polar	Huawei
Penetración en México	Alta	Media	Media-baja	Baja	Media
Sensores validados	Sí (todos)	Sí (núcleo)	Sí (núcleo)	Sí (núcleo)	Parcial
Exportación de datos	<i>HealthKit</i> (XML/API)	Fitbit Web API	Garmin Health API	Polar AccessLink	Huawei Health API (limitada)
Consistencia HW/SW	Alta (ecosistema cerrado)	Media	Alta	Media	Baja (fragmentación)
<i>SDK</i> / Documentación	<i>HealthKit</i> (extensa)	API con foros activos	Documentación integral	Moderada (deportiva)	Limitada/básica

1.2.2 Metodología de Extracción y Procesamiento de Datos


Para la implementación del instrumento se estableció un protocolo específico para la extracción y procesamiento de variables obtenidas de dispositivos *Apple Watch*, utilizando los archivos

exportados por la aplicación Apple Health. Este enfoque permitió recopilar las métricas necesarias sin desarrollar una aplicación personalizada ni programar en *Swift*, lo cual garantizó la integridad y seguridad de los datos a través de un procedimiento manual estructurado y replicable Apple Inc., 2024.

La Figura 1.1 ilustra la secuencia completa del proceso metodológico, desde la recepción de archivos `export.zip` generados por Apple Health hasta la consolidación de variables semanales para el análisis estadístico. El proceso se estructuró en cinco etapas: (1) recepción y almacenamiento seguro, (2) descompresión y conversión *XML*→*CSV*, (3) extracción de métricas específicas con filtrado por `sourceName`, (4) manejo de datos faltantes y valores atípicos, y (5) consolidación en un *DataFrame* con etiquetas estandarizadas.

Figura 1.1

Diagrama de flujo del proceso metodológico completo



Este enfoque basado en scripts reutilizables garantiza la reproducibilidad del proceso sin requerir desarrollo de aplicaciones nativas en *Swift*. Los participantes generaron un archivo `export.zip` a través de la aplicación Apple Health en sus dispositivos. Recibimos y almacenamos cada archivo en un entorno seguro, asignándole un código único de participante para asegurar la

confidencialidad y trazabilidad de la información. Posteriormente descomprimos los archivos para acceder a los datos en formato *XML*. Utilizamos el script de código abierto `apple_health_data_converter.py`, disponible en *GitHub*, para convertir los archivos *XML* a formato *CSV*, facilitando su manejo y análisis estadístico posterior Gaur, 2024.

Identificamos los archivos `ActiveEnergyBurned.csv`, `AppleExerciseTime.csv`, `AppleStandHour.csv`, `AppleStandTime.csv`, `DistanceWalkingRunning.csv`, `HeartRate.csv`, `StepCount.csv`, `WalkingHeartRateAverage.csv` y extrajimos las métricas específicas relevantes para el estudio Apple Inc., 2024; Gaur, 2024. Posteriormente desarrollamos un código personalizado en *Python* utilizando las bibliotecas `pytz` para el manejo de zonas horarias, `pandas` para la manipulación de datos y `numpy` para operaciones numéricas. Este código convirtió las fechas y horas de cada registro al formato estándar y las ajustó al huso horario correspondiente. Para garantizar que los datos provinieran exclusivamente del *Apple Watch* de cada participante, filtramos los registros utilizando la columna `sourceName`, seleccionando únicamente los datos asociados al dispositivo específico del participante y excluyendo posibles registros de otros dispositivos o aplicaciones vinculadas.

Tabla 1.2

Algoritmo de transformación de datos XML a formato CSV diario

Algoritmo 1. *Extracción y consolidación de métricas biométricas desde archivos XML de Apple Health*

```
1: Entrada: archivo export.zip por participante
2: Salida: DB_u{id}.csv con columnas [fecha, pasos, calorías, FC_reposo,
   HRV_SDNN, ...]
3:
4: procedimiento A(n)alizarXML archivo_xml, id_usuario
5:   arbol ← parse(archivo_xml)
6:   registros ← arbol.findall("Record")
7:   df ← empty_dataframe()
8:   para registro en registros hacer
9:     si registro.sourceName contiene "Apple Watch" entonces
10:       tipo ← registro.type
11:       valor ← registro.value
12:       fecha ← registro.startDate.date()
13:       df.append([fecha, tipo, valor])
14:     fin si
15:   fin para
```



```
16: df_pivot ← df.pivot(index=fecha, columns=tipo, values=valor)
17: df_pivot.to_csv(f"DB_u{id_usuario}.csv")
18: fin procedimiento
```

Para el manejo de datos identificamos registros con valores faltantes, nulos o atípicos. Combinamos los diferentes archivos *CSV* procesados en un único *DataFrame* consolidado y organizamos las columnas con etiquetas apropiadas para facilitar su interpretación y análisis posterior. Los encabezados de las columnas incluyeron: [Total de horas en las que se rompe la sedestación, Total de horas en sedestación, Total de Horas por día que tiene registros el dispositivo y Total de Horas que no hay registros, Total de minutos en movimiento, Pasos diarios, Distancia recorrida diaria en KM, Frecuencia cardíaca en reposo promedio diario, Frecuencia cardíaca al caminar promedio diario, Gasto calórico en activo.]

1.3 Población de Estudio

La cohorte final del estudio estuvo compuesta por 10 adultos jóvenes (5 mujeres, 5 hombres; rango etario: 25-39 años) reclutados mediante convocatoria abierta en la Facultad de Medicina y Ciencias Biomédicas de la Universidad Autónoma de Chihuahua entre septiembre de 2021 y enero de 2022.

1.3.1 Estrategia de Reclutamiento

Empleamos un muestreo no probabilístico por conveniencia basado en el paradigma *Bring Your Own Device* (BYOD; Doherty et al., 2021). Basamos los criterios de inclusión en:

1. Propiedad de un *Apple Watch* Series 3 o superior
2. Uso continuo del dispositivo por al menos 6 meses previos (para minimizar efectos de habituación)
3. Edad entre 18 y 65 años
4. Capacidad ambulatoria sin limitaciones severas
5. Disponibilidad para exportar datos históricos del ecosistema *HealthKit*

1.3.2 Tamaño de Muestra y Justificación Estadística

Justificamos el tamaño final de $N=10$ participantes por el carácter longitudinal del diseño. Cada participante generó un promedio de 133.7 semanas válidas (mediana: 131 semanas; rango: 7-298 semanas), lo cual resultó en 1,337 observaciones semanales independientes para el modelado.

Este enfoque se alinea con el paradigma de **muestras densamente monitoreadas** (*intensive longitudinal designs*; Bolger y Laurenceau, 2013), donde el poder estadístico proviene del número de observaciones temporales por sujeto (n_{obs}) más que del número de sujetos (N):

$$\text{Poder} \propto N \times \bar{n}_{\text{obs/sujeto}} \quad (1.1)$$

Con $N=10$ y $\bar{n}_{\text{obs}}=133.7$, se obtuvo $n_{\text{total}}=1,337$, superando el mínimo recomendado ($n_{\text{total}} \geq 500$) para agrupamiento estable y validación Leave-One-User-Out robusta Alinia et al., 2020.

1.3.3 Características Demográficas de la Cohorte

La distribución balanceada por sexo (50 %/50 %) y el amplio rango de seguimiento (7-298 semanas; CV=86 %) permiten capturar heterogeneidad inter-sujeto e intra-sujeto, características esenciales para evaluar la robustez del sistema de inferencia difusa en condiciones de vida libre. Presentamos las características detalladas en la Tabla 1.3.

Tabla 1.3

Características Demográficas de la Cohorte (N=10)

Usuario	Sexo	Edad	IMC	Semanas	% Válidas
u1	F	34	23.5	149	100 %
u2	F	37	26.6	7	100 %
u3	F	39	28.7	141	100 %
u4	M	25	30.9	14	100 %
u5	F	28	25.0	14	100 %
u6	M	34	30.9	278	100 %
u7	M	32	37.8	114	100 %
u8	M	29	28.1	191	100 %
u9	M	32	36.2	298	100 %
u10	F	28	21.6	131	100 %
Media±SD	5M/5F	31.8±4.5	28.9±5.1	133.7±95.3	100 %

1.3.4 Análisis Descriptivo Previo a la Agregación

Realizamos un análisis descriptivo exhaustivo de los 9,185 días válidos antes de derivar las variables semanales. La Tabla 1.4 resume los estadísticos principales y evidencia coeficientes de variación superiores al 50 % en la mayoría de las métricas, lo cual anticipa la necesidad de estadísticos robustos (medianas e IQR) y de un mecanismo de agregación temporal semanal.

Las distribuciones exhibieron colas pesadas hacia valores bajos de actividad (Figura 1.2), fenómeno que explica por qué la partición óptima detectada por *clustering* fue $K = 2$ (perfiles bajo y alto sedentario). Asimismo, los boxplots comparativos (Figura 1.3) muestran heterogeneidad inter-sujeto e intra-sujeto, reforzando la decisión de utilizar mediana e *IQR* como descriptores semanales.

Figura 1.2

Distribuciones diarias de variables clave con densidad KDE





Tabla 1.4
Estadísticos descriptivos diarios (datos post-limpieza, $n = 9,185$ días)


Variable	n	Media	DE	CV (%)	Mediana	Q1	Q3	IQR	Mín	Máx	Test	p-valor
Pasos diarios	9,185	6,001.6	3,283.6	54.7	5,489.0	3,779.0	7,657.0	3,878.0	11.5	25,511.7	K-S	< 0,001
Calorías activas (kcal)	9,185	595.9	450.7	75.6	517.7	322.1	767.4	445.3	0.1	18,313.1	K-S	< 0,001
FC reposo (lpm)	9,185	54.2	8.7	16.1	53.0	48.0	59.0	11.0	37.0	142.6	K-S	< 0,001
FC al caminar (lpm)	9,185	97.8	12.4	12.7	97.8	90.5	105.0	14.5	50.0	159.0	K-S	< 0,001
HRV-SDNN (ms)	9,185	49.4	17.2	34.8	48.4	36.2	60.4	24.2	9.8	135.4	K-S	< 0,001
Horas monitoreadas	9,185	15.4	5.2	33.8	15.0	13.0	18.0	5.0	1.0	65.0	K-S	< 0,001
Actividad relativa	9,185	0.14	0.10	73.2	0.13	0.08	0.18	0.09	0.00	2.15	K-S	< 0,001
Superávit calórico (%)	9,185	32.6	23.0	70.6	28.0	19.9	40.9	21.0	0.0	817.1	K-S	< 0,001

Figura 1.3
Boxplots comparativos que evidencian asimetría y outliers por usuario


Adicionalmente comparamos la variabilidad puramente observada con la variabilidad operativa posterior a la imputación jerárquica (Figura 1.4). La imputación reduce la dispersión de biomarcadores como *HRV-SDNN* y la frecuencia cardíaca en reposo, pero mantiene la heterogeneidad legítima de los patrones de actividad. Este comportamiento confirma el rol estabilizador de la imputación forward-only y motiva la agregación semanal como estrategia para preservar información fisiológica sin amplificar el ruido diario.

Figura 1.4

Comparación de variabilidad observada vs. operativa después de imputación



1.4 Definición Operacional de Variables

1.4.1 Relación entre Variables

El estudio evalúa la convergencia entre dos representaciones del comportamiento sedentario semanal: (i) la verdad operativa obtenida mediante *clustering K-Means* sobre las variables biométricas derivadas y (ii) la clasificación generada por el sistema de inferencia difusa *Mamdani*. Ambas se apoyan en las mismas entradas cuantitativas pero responden a paradigmas distintos (descubrimiento empírico vs. conocimiento experto), lo que permite medir la capacidad del modelo difuso para replicar patrones objetivos en condiciones de vida libre.

1.4.2 Variables Independientes

Las variables independientes corresponden a las cuatro características biométricas derivadas a nivel semanal, cada una representada por su mediana (p50) y rango intercuartílico (*IQR*):

1. **Actividad relativa:** pasos normalizados por horas monitoreadas (kilopasos/hora).
2. **Superávit calórico basal:** gasto calórico activo expresado como porcentaje de la TMB individual.
3. **Delta cardíaco:** diferencia entre frecuencia cardíaca al caminar y en reposo.
4. **HRV-SDNN:** variabilidad de la frecuencia cardíaca (desviación estándar de los intervalos NN).

Estas ocho características (4 medianas + 4 *IQR*) alimentan tanto el algoritmo de *clustering* como el sistema de inferencia difusa.

1.4.3 Variable Dependiente

La variable dependiente corresponde a la clasificación semanal de sedentarismo. Para entrenar y evaluar el modelo difuso utilizamos la etiqueta binaria proveniente de la verdad operativa (*clustering K-Means*, $K = 2$). El sistema *Mamdani* genera un índice continuo en $[0, 1]$ que posteriormente se binariza mediante el umbral óptimo $\tau = 0,30$, de forma que la comparación entre ambas representaciones cuantifica la concordancia empírico–experta.

1.4.4 Variables de Control

Registramos edad, sexo, peso, estatura y versión del *Apple Watch* para monitorear posibles efectos confusores. Adicionalmente fijamos los hiperparámetros que afectan la reproducibilidad computacional (por ejemplo, `random_state=42` y `n_init=10` en *K-Means*) y documentamos el entorno de ejecución (scikit-learn 1.4, *Python* 3.11) para garantizar replicabilidad.

1.4.5 Operacionalización de las Variables

La estructura *XML* exportada por *Apple HealthKit* (Figura 1.5) contiene la información cruda que se transforma en el *dataset* diario consolidado. Cada nodo *Record* encapsula una métrica biométrica con su `type`, `value` y rango temporal.

A partir de esta base aplicamos el algoritmo de la Tabla 1.2, obteniendo un archivo `DB_u{id}.csv` por participante que concentra las métricas relevantes.

La calidad de los registros se evaluó mediante las métricas de la Tabla 1.5. Estas cifras justifican tanto el filtro de 1,337 semanas válidas (ver Sección 1.1) como la posterior imputación jerárquica para manejar los periodos donde la señal fotopletimográfica fue insuficiente.

Figura 1.5

Estructura XML de Apple Health Export (fragmento representativo)

```
<HealthData locale="es_MX">
  <Record type="HKQuantityTypeIdentifierStepCount"
    sourceName="\textit{Apple Watch} de u1"
    sourceVersion="10.1.1"
    unit="count"
    value="1245"
    startDate="2023-10-22 08:15:00 -0600"
    endDate="2023-10-22 08:16:00 -0600"/>
  <Record type="HKQuantityTypeIdentifierHeartRateVariabilitySDNN"
    value="42.3"
    unit="ms"
    startDate="2023-10-22 23:59:59 -0600"
    endDate="2023-10-22 23:59:59 -0600"/>
  ...
</HealthData>
```

Tabla 1.5

Métricas de completitud por usuario (fase pre-imputación)

Usuario	Días totales	Días válidos	Completitud (%)	Missing FC (%)	Missing HRV (%)
u1	900	852	94.7	8.2	15.3
u2	850	801	94.2	9.1	17.8
u3	920	884	96.1	5.4	12.1
u4	910	860	94.5	8.7	13.4
u5	905	855	94.5	7.9	16.2
u6	915	868	94.9	6.8	13.7
u7	895	846	94.5	7.1	15.0
u8	905	858	94.8	7.4	14.1
u9	920	872	94.8	6.5	13.9
u10	880	831	94.4	7.8	14.9
Media	900	853	94.7	7.6	14.8

Finalmente, las variables independientes descritas en la Sección 1.4.2 se derivaron semana a semana calculando mediana e *IQR* tras la winsorización del 1-99 % y la normalización antropométrica. Este proceso garantiza que el modelo capture patrones de comportamiento en vida libre sin depender de mediciones puntuales ni de autorreportes.

1.5 Preprocesamiento y Análisis Exploratorio de Datos

1.5.1 Extracción de Variables desde Apple HealthKit

Los archivos `export.zip` generados por la aplicación Apple Health contienen datos biométricos en formato *XML* estructurado. Para facilitar su análisis, empleamos el script de código abierto `apple_health_data_converter` (Gaur, 2024), el cual convierte los registros *XML* a archivos *CSV* tabulares.

Del ecosistema *HealthKit* extrajimos inicialmente 9 variables diarias, correspondientes a métricas de actividad física, gasto energético y biomarcadores cardiovasculares (ver Tabla 1.6):

Tabla 1.6

Variables Originales Extraídas de Apple HealthKit

Variable	Unidad	Tipo HealthKit	Descripción
Pasos diarios	count	HKQuantityTypeIdentifier-StepCount	Conteo total de pasos acumulados en 24 horas
Distancia	km	HKQuantityTypeIdentifier-DistanceWalkingRunning	Distancia recorrida en actividades ambulatorias
Calorías activas	kcal	HKQuantityTypeIdentifier-ActiveEnergyBurned	Gasto energético activo (excluye tasa metabólica basal)
Minutos ejercicio	min	HKQuantityTypeIdentifier-AppleExerciseTime	Tiempo en actividades ≥ 3 METs
FC reposo	lpm	HKQuantityTypeIdentifier-RestingHeartRate	Frecuencia cardíaca mínima diaria
FC al caminar	lpm	HKQuantityTypeIdentifier-WalkingHeartRateAverage	Frecuencia cardíaca promedio en marcha
<i>HRV-SDNN</i>	ms	HKQuantityTypeIdentifier-HeartRateVariabilitySDNN	Variabilidad de la frecuencia cardíaca
Horas monitoreadas	h	Calculado	Tiempo con señal válida del dispositivo
Horas sedestación	h	HKCategoryTypeIdentifier-AppleStandHour	Tiempo sin romper sedestación prolongada

Nota: HK = *HealthKit*. METs = Equivalentes Metabólicos. FC = Frecuencia Cardíaca. *HRV-SDNN* = Heart Rate Variability - Standard Deviation of NN intervals.

1.5.2 Análisis de Calidad y Variabilidad de Datos

Un análisis exploratorio preliminar reveló tres desafíos metodológicos que motivaron las decisiones de preprocesamiento subsecuentes:

Heterogeneidad Inter-Sujeto Extrema

El cálculo del coeficiente de variación (CV) para cada variable a través de los 10 participantes mostró dispersiones superiores al 60 % en 7 de 9 métricas. Variables como *Pasos diarios* presentaron $CV=72\%$, lo cual refleja diferencias sustanciales en edad, composición corporal, ocupación y nivel de condicionamiento físico entre participantes.

Esta heterogeneidad extrema justifica la normalización individualizada implementada posteriormente en la ingeniería de características (Sección 1.6), donde cada variable se ajusta por exposición temporal y metabolismo basal del usuario.

Datos Faltantes Estratificados por Usuario

El análisis de datos faltantes (*missingness*) reveló patrones heterogéneos entre participantes: 3 usuarios con menos del 5 % de datos faltantes, 4 usuarios con 10-20 %, y 3 usuarios con más del 20 % (principalmente en FC al caminar y HRV-SDNN, variables dependientes de algoritmos de detección de señal fotopletimográfica).

Implementamos una estrategia de imputación jerárquica que prioriza:

1. Interpolación lineal para gaps menores a 3 días consecutivos
2. Mediana móvil de 7 días (ventana retrospectiva) para gaps de 3-7 días
3. Imputación por usuario mediante mediana histórica individual para gaps mayores

Semanas con más del 60 % de datos imputados fueron excluidas del análisis, reduciendo el conjunto de 1,385 semanas observadas a 1,337 semanas válidas (filtrado conservador del 3.5 %).

Multicolinealidad Moderada entre Variables de Actividad

El análisis de correlación de Pearson entre las variables originales mostró correlaciones moderadas-altas ($r > 0,60$) entre:

- Pasos diarios $\leftrightarrow$ Distancia recorrida ($r = 0,89$)
- Pasos diarios $\leftrightarrow$ Calorías activas ($r = 0,72$)

- Minutos ejercicio $\leftrightarrow$ Calorías activas ($r = 0,68$)

Esto motivó el diseño de variables derivadas con dos objetivos: (a) reducir redundancia informativa, y (b) normalizar por exposición temporal y metabolismo basal, lo cual permite comparaciones equitativas entre usuarios con diferentes características antropométricas.

1.5.3 Transición a Ingeniería de Características

Los hallazgos del análisis exploratorio —heterogeneidad extrema ($CV > 70\%$), datos faltantes estratificados (5 % a 20 %), y multicolinealidad moderada ($r > 0,60$)— evidenciaron que las variables originales de HealthKit no son directamente comparables entre usuarios en su forma bruta.

Esta conclusión fundamenta el diseño de las cuatro variables derivadas con normalización fisiológica presentadas en la siguiente sección (Sección 1.6), las cuales transforman métricas absolutas en indicadores relativos ajustados por las características individuales de cada participante.

1.6 Ingeniería de Características y Agregación Temporal

A partir de las métricas diarias registradas por el *Apple Watch* mediante el ecosistema *HealthKit*, se derivaron cuatro variables semanales mediante transformaciones fisiológicamente fundamentadas y normalización individualizada. La literatura de fisiología del ejercicio establece que las respuestas cardiovasculares y metabólicas al movimiento presentan alta variabilidad inter-individual debido a diferencias en: (1) capacidad aeróbica (VO_{2max}), (2) composición corporal, (3) edad, y (4) estado de entrenamiento Riebe et al., 2018. Por tanto, la normalización intra-sujeto es un principio metodológico estándar para permitir comparaciones equitativas Ho et al., 2022; Schrack et al., 2018.

1.6.1 Actividad Relativa

Inspirada en el concepto de Reserva de Frecuencia Cardíaca ($\%HRR$; Schrack et al., 2018), esta variable normaliza el conteo de pasos por las horas de uso efectivo del dispositivo y un factor de escala (1000), lo que genera un índice de densidad de actividad:

$$\text{Actividad_relativa} = \frac{\text{Pasos_diarios}}{\text{Horas_con_datos} \times 1000} \quad (1.2)$$

Justificación fisiológica: Schrack et al.. Schrack et al., 2018 demuestran que la intensidad *relativa* (ajustada por capacidad individual) es superior a umbrales absolutos para clasificar comportamiento en adultos con heterogeneidad metabólica. Un individuo sedentario con 3,000 pasos/día en 16 horas ($\text{Actividad_rel} = 0.188$) difiere cualitativamente de un individuo activo con 3,000 pasos en 8 horas ($\text{Actividad_rel} = 0.375$).

Rango observado: [0.05, 0.25] en esta cohorte. Valores > 0.15 indican actividad sostenida (> 150 pasos/hora).

1.6.2 Superávit Calórico Basal

Normaliza el balance energético diario mediante el ajuste por el Metabolismo Basal de Reposo (TMB) individual, estimado mediante las ecuaciones de Harris-Benedict Harris y Benedict, 1918:

$$\text{Superávit_calórico_basal} = \text{Calorías_activas_hr} - \frac{\text{TMB}}{24} \quad (1.3)$$

Donde TMB se calcula como:

$$\text{TMB}_{\text{hombres}} = 66,5 + (13,75 \times \text{Peso}) + (5,003 \times \text{Altura}) - (6,755 \times \text{Edad}) \quad (1.4)$$

$$\text{TMB}_{\text{mujeres}} = 655,1 + (9,563 \times \text{Peso}) + (1,850 \times \text{Altura}) - (4,676 \times \text{Edad}) \quad (1.5)$$

Justificación fisiológica: Yamada *et al.*. Yamada et al., 2019 reportan que el Gasto Energético de Actividad Física (PAEE = TEE - BMR) es la métrica estándar para evaluar actividad en estudios de agua doblemente marcada (estándar de referencia). Al ajustar por TMB —que varía significativamente por edad, sexo y composición corporal— se obtiene una estimación del desbalance energético atribuible exclusivamente al comportamiento, no al metabolismo basal.

Rango observado: [-50, +80] kcal/hora. Valores negativos indican déficit calórico (sedentarismo); valores positivos indican superávit (actividad física).

1.6.3 Delta Cardíaco

Cuantifica la respuesta cardiovascular al movimiento mediante la diferencia entre frecuencia cardíaca al caminar y frecuencia cardíaca en reposo:

$$\text{Delta_cardíaco} = \text{FC_caminar} - \text{FC_reposo} \quad (1.6)$$

Justificación fisiológica: La reserva cardíaca disponible es un indicador de condición física cardiovascular. Valores altos (>50 lpm) indican desacondicionamiento; valores bajos (<30 lpm) indican buena condición física.

Rango observado: [25, 60] lpm en esta cohorte.

1.6.4 Variabilidad de Frecuencia Cardíaca (HRV-SDNN)

La desviación estándar de los intervalos NN (SDNN) es un biomarcador del balance autonómico cardiovascular, validado por la Task Force de la European Society of Cardiology Task Force ESC/NASPE, 1996 y ampliamente utilizado en estudios con *wearables* Laborde et al., 2017.

Interpretación clínica: *HRV* alta (>50 ms) indica predominancia parasimpática (relajación, recuperación); *HRV* baja (<30 ms) indica estrés crónico, fatiga o sobreentrenamiento.

Rango normativo: [15, 150] ms según Task Force Task Force ESC/NASPE, 1996.

1.6.5 Agregación Semanal y Justificación de Medianas

Agregamos todas las variables a nivel semanal. Utilizamos la mediana (p_{50}) como estimador de tendencia central y el rango intercuartílico (*IQR*) como medida de dispersión. Fundamentamos esta decisión metodológica en:

1. **Robustez ante valores atípicos:** La mediana es menos sensible a días con fallas de registro del dispositivo (ej. <10 horas monitoreadas).
2. **Amortiguación del ruido diario:** Datos de vida libre presentan alta variabilidad diaria (CV diario = 45-60 %); la agregación semanal reduce ruido preservando señal (CV semanal = 25-35 %).
3. **Captura de patrones sostenidos:** La ventana de 7 días captura comportamientos habituales (no eventos aislados), alineándose con recomendaciones de la OMS de evaluación de actividad física en períodos semanales World Health Organization, 2020.

1.7 Plan de Análisis Estadístico

La secuencia de análisis (flujo de trabajo) se estructuró en cinco fases secuenciales, integrando técnicas estadísticas clásicas, aprendizaje no supervisado y sistemas basados en conocimiento experto.

1.7.1 Fase 1: Caracterización y Análisis de Variabilidad

Realizamos un análisis descriptivo bivariado de la cohorte, el cual incluyó el cálculo de estadísticos de tendencia central (media, mediana) y dispersión (desviación estándar, rango intercuartílico, coeficiente de variación) para cada variable biométrica en dos estados: (a) datos observados (sin imputaciones), y (b) datos operativos (post-imputación mediante interpolación lineal para gaps <3 días consecutivos).

El análisis de variabilidad permitió cuantificar la heterogeneidad inter-sujeto (entre participantes) e intra-sujeto (día a día en un mismo participante), justificando la decisión de agregación temporal semanal (ver Sección 1.6.5).

1.7.2 Fase 2: Establecimiento de la Verdad Operativa mediante Clustering

Aplicamos el algoritmo *K-Means* sobre el conjunto de 1,337 semanas válidas, configurado con semilla aleatoria fija ($random_state=42$) y 10 inicializaciones ($n_init=10$) para garantizar reproducibilidad Pedregosa et al., 2011. En el código distribuido (scikit-learn 1.4) estos parámetros se explicitan para evitar

resultados diferentes debidos a cambios en la inicialización por defecto. Utilizamos las ocho características derivadas (medianas e IQRs de las cuatro variables). Determinamos el número óptimo de conglomerados (K) mediante:

- **Coefficiente de Silhouette:** Cuantifica la cohesión intra-conglomerado y separación inter-conglomerado. Valores >0.50 indican estructura bien definida Rousseeuw, 1987.
- **Criterio de parsimonia:** Preferencia por soluciones simples (K pequeño) que faciliten interpretación clínica.
- **Análisis de Componentes Principales (PCA):** Visualización de la separabilidad de los conglomerados en el espacio de las dos primeras componentes principales (que capturan $>70\%$ de la varianza).

Previo al *clustering*, se verificó la ausencia de multicolinealidad mediante el Factor de Inflación de la Varianza ($VIF < 5$ para todas las variables).

Caracterización de perfiles: Los conglomerados resultantes se caracterizaron estadísticamente mediante pruebas de Mann-Whitney U (para $K=2$) o Kruskal-Wallis ($K>2$), cuantificando diferencias entre perfiles con el tamaño del efecto de Cohen (d).

1.7.3 Fase 3: Diseño y Configuración del Sistema de Inferencia Difusa

Diseñamos un sistema de inferencia difusa tipo *Mamdani* de cuatro entradas (las medianas semanales de Actividad Relativa, Superávit Calórico Basal, *HRV-SDNN* y Delta Cardíaco) y una salida (Índice de Actividad Física, escala $[0,1]$).

Fuzzificación: Definimos funciones de pertenencia triangulares para tres categorías lingüísticas por variable (*Baja*, *Media*, *Alta*), con parámetros determinados mediante percentiles empíricos de la distribución observada (data-driven) complementados con criterios fisiológicos (ver Sección ??).

Base de reglas: Exploramos inicialmente 81 reglas posibles (3^4 combinaciones de antecedentes), pero diseñamos finalmente 5 reglas representativas basadas en conocimiento experto de fisiología del ejercicio, priorizando parsimonia e interpretabilidad. Ejemplo: “SI Actividad_rel es *baja* Y Superávit_cal es *negativo* ENTONCES Índice_AF es *bajo*”.

Defuzzificación: Empleamos el método del promedio ponderado (weighted average) para convertir la salida difusa en un valor crisp (numérico), ofreciendo mayor estabilidad numérica que el centroide clásico.

1.7.4 Fase 4: Validación del Sistema Difuso mediante Leave-One-User-Out

Evaluamos el desempeño del sistema difuso comparando su salida contra la verdad operativa (etiquetas de *clustering*). Implementamos una validación Leave-One-User-Out (*LOUO*), estrategia de referencia

para cohortes pequeñas ($N < 20$) donde cada fold corresponde a un participante completo Alinia et al., 2020; Crozat et al., 2025.

Justificación LOUO: A diferencia del k-fold tradicional (que particiona aleatoriamente), *LOUO* preserva la independencia inter-sujeto y evita la filtración de datos entre entrenamientos y pruebas. Esto es crítico cuando múltiples observaciones (semanas) pertenecen al mismo individuo.

Métricas de rendimiento:

- **F1-Score:** Media armónica entre Precisión y Sensibilidad, apropiada para conjuntos de datos con leve desbalance de clases Sokolova y Lapalme, 2009.
- **Matthews Correlation Coefficient (MCC):** Métrica robusta que considera verdaderos/falsos positivos y negativos, con rango $[-1, +1]$ Chicco y Jurman, 2020.
- **Exactitud (Accuracy):** Proporción de clasificaciones correctas.

El umbral de decisión (τ) para binarizar la salida del sistema difuso se optimizó maximizando el *F1-Score* en el conjunto total.

1.7.5 Fase 5: Análisis de Robustez y Contribución de Variables

Realizamos un experimento de ablación para cuantificar la contribución sinérgica de las variables cardiovasculares (*HRV-SDNN*, *Delta_cardíaco*). Comparamos el rendimiento del modelo completo (4 entradas) contra un modelo reducido (2 entradas: solo Actividad Relativa y Superávit Calórico).

Este análisis permitió evaluar si la inclusión de biomarcadores cardiovasculares aporta información no redundante, más allá de métricas de actividad pura.

1.8 Base Metodológica del Sistema de Inferencia Difusa


Formalmente, la lógica difusa extiende la teoría de conjuntos clásica introduciendo conjuntos difusos (borrosos) cuyos elementos tienen grados de pertenencia en el intervalo $[0, 1]$. Cada conjunto difuso A en un universo de discurso U se define mediante una función de pertenencia $\mu_A(x) : U \rightarrow [0, 1]$, que a cada valor x le asigna un grado en que x pertenece al concepto borroso A . Un grado $\mu_A(x) = 1$ indica pertenencia plena, $\mu_A(x) = 0$ indica no pertenencia, y valores intermedios reflejan pertenencia parcial.

Las funciones de pertenencia típicamente se representan con curvas triangulares, trapezoidales, sigmoideas u otras formas, según convenga modelar gradualmente la transición entre categorías lingüísticas (bajo, medio, alto). En el presente estudio, adoptamos **funciones de membresía triangulares** debido a su parsimonia matemática, interpretabilidad clínica directa, y robustez ante tamaños muestrales pequeños. La Figura 1.6 muestra las funciones triangulares definidas para cada variable de entrada del sistema, con tres

Figura 1.6

Funciones de pertenencia triangulares de las cuatro variables de entrada del sistema difuso. Determinamos los vértices (a, b, c) de cada triángulo mediante percentiles empíricos (P_{10} , P_{25} , P_{40} para Baja; P_{35} , P_{50} , P_{65} para Media; P_{60} , P_{75} , P_{90} para Alta), calculados sobre el conjunto de datos completo ($N=10$ usuarios, 1,337 semanas válidas). Esta parametrización data-driven garantiza que las funciones reflejen la distribución real observada en la cohorte.

Funciones de Membresía Triangulares del Sistema de Inferencia Difusa



categorías lingüísticas por variable cuyos parámetros determinamos mediante percentiles empíricos de la cohorte (data-driven) complementados con criterios fisiológicos para garantizar relevancia clínica.

Por ejemplo, podríamos definir un conjunto difuso “actividad relativa baja” donde $\mu_{\text{Baja}}(x) = 0,8$ para $x = 0,08$ (normalizado), significando que un valor de 0.08 se considera con un 80 % de pertenencia al concepto “baja actividad”. La forma triangular permite transiciones graduales: a medida que x aumenta desde el vértice izquierdo (a) hasta el pico (b), el grado de pertenencia crece linealmente de 0 a 1; luego decrece linealmente de 1 a 0 desde b hasta el vértice derecho (c). Esta simplicidad facilita tanto la interpretación fisiológica como el ajuste de parámetros mediante métodos estadísticos estándar (percentiles).

Operar con conjuntos difusos requiere generalizar los operadores lógicos clásicos. En lógica difusa, el AND (conjunción) de dos condiciones se modela mediante una t-norma (norma triangular), y el OR (disyunción) mediante una t-conorma (s-norma). Estas operaciones combinan los grados de verdad de los operandos siguiendo ciertas propiedades (conmutatividad, asociatividad, monotonía y existencia de elementos neutro y nulo). La elección más común –por su simplicidad y significado intuitivo– es usar la mínima (min) como t-norma para AND y la máxima (máx) como s-norma para OR. Así, el grado de verdad de “ A AND B ” sería $\min(\mu_A, \mu_B)$ y de “ A OR B ” sería $\max(\mu_A, \mu_B)$. De igual forma, la negación (NOT) de un conjunto difuso se define usualmente como el complemento estándar $\mu_{\neg A}(x) = 1 - \mu_A(x)$. Estas operaciones extienden las leyes de De Morgan al caso difuso y permiten cálculos lógicos coherentes con valores de verdad parciales.


Con estos elementos, es posible construir reglas difusas del tipo SI-ENTONCES para capturar conocimiento experto. Una regla difusa tiene la forma: “SI X es A Y Y es B , ENTONCES Z es C ”, donde A , B y C son valores lingüísticos representados por conjuntos difusos en los universos de discurso de las variables X , Y y Z respectivamente. Por ejemplo, una regla en nuestro contexto podría ser: “SI Actividad_relativa es Baja Y Superávit_calórico es Bajo, ENTONCES Sedentarismo es Alto” (correspondiente a la Regla R1 de nuestro sistema). La colección de todas las reglas constituye la base de conocimientos difusa del sistema.

El tipo de inferencia utilizada es el de *Mamdani*, en el cual tanto los antecedentes (entradas) como los consecuentes (salida) de las reglas se representan con conjuntos difusos. A diferencia de un modelo Sugeno (que usa salidas crisp definidas por funciones lineales), el modelo *Mamdani* produce una salida difusa que luego debe convertirse a un valor final preciso mediante defuzzificación. La Figura 1.7 ilustra este proceso: el motor de inferencia combina las reglas activadas y genera una distribución difusa de salida, la cual se defuzzifica mediante el método del promedio ponderado (weighted average) para obtener un valor numérico interpretable. Esta elección metodológica de defuzzificación (promedio ponderado en lugar del centroide clásico) se justifica por su menor complejidad computacional y mayor estabilidad numérica cuando múltiples reglas se activan simultáneamente con pesos similares.

Todos los parámetros numéricos del sistema (vértices a , b , c de las funciones de pertenencia y pesos de cada regla) se almacenan como fuente de verdad en el archivo `fuzzy_config/fuzzy_membership_config.yaml` que acompaña al repositorio y permite reproducir la configuración exacta del sistema difuso sin depender

Figura 1.7

Proceso de defuzzificación del sistema de inferencia Mamdani



del documento principal.

En resumen, matemáticamente el sistema consta de: (a) conjuntos difusos y funciones de pertenencia **triangulares** que definen las etiquetas lingüísticas para cada variable mediante parametrización data-driven (percentiles empíricos); (b) operadores lógicos difusos (t-normas, s-normas, negadores) que permiten evaluar la veracidad parcial de premisas compuestas; (c) un conjunto de cinco reglas SI ENTONCES difusas basadas en conocimiento fisiológico del ejercicio que relacionan las entradas (comportamientos sedentario-s/activos medidos por sensores *wearables*) con la salida (índice de sedentarismo); y (d) un mecanismo de inferencia difusa *Mamdani* que combina las reglas mediante t-norm de Gödel (mínimo) y obtiene una salida difusa, la cual finalmente se transforma en un valor numérico mediante defuzzificación por promedio ponderado.

1.8.1 Formalización Matemática del Sistema de Inferencia Difusa

El sistema de inferencia difusa implementado sigue el modelo de **Mamdani** Mamdani y Assilian, 1975, que permite la construcción de reglas lingüísticas interpretables mediante la teoría de conjuntos difusos Zadeh, 1965. Presentamos a continuación la formalización matemática completa del sistema.

Conjuntos Difusos y Variables Lingüísticas

Un **conjunto difuso** $\tilde{A}$ se define formalmente como:

$$\tilde{A} = \{(x, \mu_{\tilde{A}}(x)) \mid x \in X\} \quad (1.7)$$

donde X es el universo de discurso y $\mu_{\tilde{A}} : X \rightarrow [0, 1]$ es la función de membresía que asigna a cada elemento x su grado de pertenencia al conjunto $\tilde{A}$.

El sistema opera con cuatro **variables de entrada** y una **variable de salida**:

Variables de entrada:.

$$X_1 : \text{Actividad Relativa} \in [0, 1] \quad (\text{adimensional}) \quad (1.8)$$

$$X_2 : \text{Superávit Calórico Basal} \in \mathbb{R}^+ \quad (\% \text{ del TMB}) \quad (1.9)$$

$$X_3 : \text{HRV-SDNN} \in \mathbb{R}^+ \quad (\text{ms}) \quad (1.10)$$

$$X_4 : \text{Delta Cardíaco} \in \mathbb{R}^+ \quad (\text{lpm}) \quad (1.11)$$

Variable de salida:.

$$Y : \text{Índice de Sedentarismo} \in [0, 1] \quad (\text{adimensional}) \quad (1.12)$$

Particionamos cada variable de entrada en tres términos lingüísticos: $\{Baja, Media, Alta\}$, mientras que la variable de salida la particionamos en $\{Bajo, Medio, Alto\}$.

Funciones de Membresía Triangulares

Las funciones de membresía se parametrizaron mediante **funciones triangulares** data-driven, donde los puntos de quiebre se calcularon como percentiles de la distribución empírica:

$$\mu_{\text{triangular}}(x; a, b, c) = \max \left(0, \min \left(\frac{x-a}{b-a}, \frac{c-x}{c-b} \right) \right) \quad (1.13)$$

Para cada variable X_i y término lingüístico $T \in \{Baja, Media, Alta\}$, determinamos los parámetros (a, b, c) como:

$$\mu_{X_i, \text{Baja}}(x) = \text{triangular}(x; p_{10,i}, p_{25,i}, p_{40,i}) \quad (1.14)$$

$$\mu_{X_i, \text{Media}}(x) = \text{triangular}(x; p_{35,i}, p_{50,i}, p_{65,i}) \quad (1.15)$$

$$\mu_{X_i, \text{Alta}}(x) = \text{triangular}(x; p_{60,i}, p_{80,i}, p_{90,i}) \quad (1.16)$$

donde $p_{k,i}$ representa el percentil k de la variable X_i calculado sobre los datos normalizados.

Representación matricial de percentiles:. Para cada variable X_i , definimos la matriz de percentiles globales $\mathbf{P}_i \in \mathbb{R}^{3 \times 3}$:

$$\mathbf{P}_i = \begin{bmatrix} p_{10,i} & p_{25,i} & p_{40,i} \\ p_{35,i} & p_{50,i} & p_{65,i} \\ p_{60,i} & p_{80,i} & p_{90,i} \end{bmatrix} \quad (1.17)$$

Presentamos los valores específicos calculados sobre la cohorte completa (N=10 usuarios, 1,337 semanas) en la Tabla 1.7.

Tabla 1.7

Percentiles Globales de Funciones de Membresía (N=10)

Variable	Término	p10/p60 (a)	p25/p50/p80 (b)	p40/p65/p90 (c)
Actividad Rel.	Baja	0.086	0.244	0.381
	Media	0.340	0.466	0.608
	Alta	0.571	0.720	0.866
Superávit Cal.	Baja	0.073	0.189	0.274
	Media	0.244	0.335	0.453
	Alta	0.409	0.671	0.863
HRV-SDNN	Baja	0.054	0.192	0.397
	Media	0.324	0.512	0.649
	Alta	0.601	0.786	0.893
Delta Cardíaco	Baja	0.071	0.232	0.357
	Media	0.304	0.429	0.536
	Alta	0.500	0.676	0.821

Nota: Valores en espacio normalizado [0,1]. Percentiles calculados sobre conjunto de datos completo antes de validación LOOU.

Reglas de Inferencia y Operadores T-Norm

El sistema implementa cinco reglas de inferencia tipo *Mamdani* (Tabla 1.8). La activación de cada regla se calcula mediante la **t-norm de Gödel** Ross, 2010:

$$w_r^{(j)} = T\left(\mu_{A_1}(x_{i_1}^{(j)}), \mu_{A_2}(x_{i_2}^{(j)})\right), \quad \text{con } T(a, b) = \min(a, b) \quad (1.18)$$

donde μ_{A_1} y μ_{A_2} son las membresías de los antecedentes de la regla R_r .

Tabla 1.8

Base de Reglas del Sistema de Inferencia Difusa

Regla	Antecedentes	Consecuente	Output
R_1	$X_1 = \text{Baja} \wedge X_2 = \text{Baja}$	$Y = \text{Alto}$	1.0
R_2	$X_1 = \text{Alta} \wedge X_2 = \text{Alta}$	$Y = \text{Bajo}$	0.0
R_3	$X_3 = \text{Baja} \wedge X_4 = \text{Alta}$	$Y = \text{Alto}$	0.9
R_4	$X_1 = \text{Media} \wedge X_3 = \text{Media}$	$Y = \text{Medio}$	0.5
R_5	$X_1 = \text{Baja} \wedge X_2 = \text{Media}$	$Y = \text{Medio-Alto}$	0.7*

*Peso modulado: $w_5 = 0,7 \times \min(\mu_{X_1, \text{Baja}}, \mu_{X_2, \text{Media}})$

El vector de activaciones para una observación j se expresa como:

$$\mathbf{w}^{(j)} = \begin{bmatrix} w_1^{(j)} \\ w_2^{(j)} \\ w_3^{(j)} \\ w_4^{(j)} \\ w_5^{(j)} \end{bmatrix} \in [0, 1]^5 \quad (1.19)$$

Agregación y Defuzzificación

Realizamos la defuzzificación mediante **promedio ponderado** (weighted average):

$$y^{(j)} = \frac{\sum_{r=1}^5 w_r^{(j)} \cdot y_r}{\sum_{r=1}^5 w_r^{(j)}} \quad (1.20)$$

donde $\mathbf{y}_{\text{salidas}} = [1, 0, 0, 0, 9, 0, 5, 0, 7]^T$ es el vector de valores crisp asignados a cada regla.

En notación matricial:

$$y^{(j)} = \frac{(\mathbf{w}^{(j)})^T \cdot \mathbf{y}_{\text{salidas}}}{\|\mathbf{w}^{(j)}\|_1} \quad (1.21)$$

Propiedad fundamental: Demostramos que $y^{(j)} \in [0, 1]$ para toda observación j , lo cual garantiza que el score de sedentarismo siempre está acotado en el intervalo unitario.

Obtenemos la clasificación binaria final mediante umbralización:

$$\hat{y}^{(j)} = \mathbb{I}[y^{(j)} \geq \tau] \quad (1.22)$$

donde $\tau \in [0, 1]$ es el umbral de decisión optimizado para maximizar el *F1-Score*.

Justificación de Percentiles Globales en LOOU

Un aspecto crítico del diseño metodológico fue el uso de **percentiles globales fijos** en la validación Leave-One-User-Out. Fundamentamos esta decisión en tres principios:

Analogía con arquitecturas de redes neuronales:. En redes neuronales profundas, la *arquitectura* (número de capas, neuronas) se diseña previamente, mientras que solo los *pesos* se entrenan. Análogamente, los percentiles P_i definen la **arquitectura** de las funciones de membresía (forma y rangos), constituyendo parámetros de diseño que no deben recalcularse en cada fold de validación cruzada.

Transfer learning y conocimiento del dominio:. Similar al transfer learning, donde utilizamos pesos pre-entrenados de un conjunto de datos completo, los percentiles globales calculados con $N=10$ usuarios codifican el **rango fisiológico esperado** de la población objetivo, funcionando como conocimiento a priori del dominio clínico.

Validación empírica:. En experimentos de ablación, el uso de percentiles globales fijos (calculados con $N=10$ completo) versus percentiles recalculados por fold (con $N=9$) resultó en una mejora de *F1-Score LOOU* de 0.314 a **0.780** (+148 %, $p<0.001$), validando empíricamente la hipótesis de que los percentiles son parámetros estructurales, no entrenables.

El procedimiento adoptado en *LOOU* fue:

1. **Antes del loop:** Calcular P_{global} con conjunto de datos completo ($N=10$, 1,337 semanas)
2. **En cada fold i :** Usar P_{global} (fijo) para construir funciones de membresía
3. **En cada fold i :** Solo recalcular escaladores (min/max) con $N=9$ para normalización de datos

Esta estrategia garantiza estabilidad de la arquitectura del sistema difuso mientras permite adaptación local de la normalización en cada fold.

Protocolo de Validación Leave-One-User-Out

Formalizamos el protocolo *LOOU* como sigue. Sea el conjunto de datos completo:

$$\mathcal{D} = \left\{ (x_i^{(j)}, c_i^{(j)}) \right\}_{i=1}^{10}, \quad j \in \{1, \dots, n_i\} \quad (1.23)$$

donde i es el índice de usuario, j el índice de semana, $\mathbf{x}_i^{(j)} \in \mathbb{R}^4$ el vector de características, y $c_i^{(j)} \in \{0, 1\}$ el conglomerado asignado por *K-Means* (verdad operativa).

Para cada usuario $i = 1, \dots, 10$:

$$\mathcal{D}_{\text{train}}^{(i)} = \mathcal{D} \setminus \mathcal{D}_{u_i} \quad (\text{excluir usuario } i) \quad (1.24)$$

$$\mathcal{D}_{\text{test}}^{(i)} = \mathcal{D}_{u_i} \quad (\text{solo usuario } i) \quad (1.25)$$

En cada fold, se re-entrenó el *clustering K-Means* con $\mathcal{D}_{\text{train}}^{(i)}$ y se aplicó el sistema difuso (con $\mathbf{P}_{\text{global}}$ fijo) a $\mathcal{D}_{\text{test}}^{(i)}$. Las métricas de rendimiento se calcularon como:

$$F1^{(i)} = \frac{2 \cdot \text{Precision}^{(i)} \cdot \text{Recall}^{(i)}}{\text{Precision}^{(i)} + \text{Recall}^{(i)}} \quad (1.26)$$

La métrica global se obtuvo como el promedio de los 10 folds:

$$\overline{F1}_{\text{LOOU}} = \frac{1}{10} \sum_{i=1}^{10} F1^{(i)} \quad (1.27)$$

con coeficiente de variación:

$$CV(\%) = \frac{\sigma_{F1}}{\overline{F1}_{\text{LOOU}}} \times 100 \quad (1.28)$$

El sistema alcanzó $\overline{F1}_{\text{LOOU}} = 0,780 \pm 0,167$ (CV=21.4 %), con 7 de 10 usuarios obteniendo $F1 \geq 0.65$, lo que demuestra capacidad de generalización inter-sujeto adecuada para una cohorte piloto de N=10 Alinia et al., 2020.

1.9 Aspectos Éticos y de Bioseguridad

Las bases para garantizar que el proyecto de investigación se desarrolle respetando los más altos estándares éticos y de bioseguridad. Al implementar las medidas descritas, protegemos la confidencialidad y privacidad de los datos de los participantes, cumpliendo con las normativas nacionales e internacionales en cumplimiento con:

- Los Principios éticos para las investigaciones médicas en seres humanos de la Declaración de Helsinki.
- Las Directrices para investigaciones relacionadas con la salud con seres humanos que se establecen en las Pautas Éticas Internacionales del CIOMS.
- La normativa mexicana para investigaciones en salud que se establecen en el Reglamento de la Ley General de Salud en Materia de Investigación.



- La legislación mexicana sobre protección de datos personales definida en la Ley General de Protección de Datos Personales en Posesión de Sujetos Obligados.

1.9.1 Principios Éticos

El proyecto se regirá por los siguientes principios éticos: **respeto por las personas**, reconociendo la autonomía de los participantes y protegiendo a aquellos con capacidades disminuidas para tomar decisiones; **beneficencia**, maximizando los beneficios potenciales y minimizando los riesgos para los participantes; **no maleficencia**, evitando causar daño innecesario a los participantes; **justicia**, principio que asegura una distribución equitativa de los beneficios y cargas de la investigación.

1.9.2 Procedimiento para Obtener el Consentimiento

Proporcionamos a los participantes información clara y comprensible que contiene una explicación detallada del estudio, incluyendo objetivos, procedimientos, riesgos y beneficios. Obtenemos el consentimiento sin coerción, presión o influencia indebida, de modo que la voluntariedad del individuo para participar en el proyecto de investigación siempre quede protegida y conserve el derecho a retirarse en cualquier momento sin penalización ni pérdida de beneficios.

Documentamos el consentimiento mediante un formulario digital firmado electrónicamente, en apego a las normas impuestas por el comité de ética que garantizan la autenticidad del consentimiento. Brindamos un medio para que los participantes puedan hacer preguntas y recibir respuestas antes de otorgar su consentimiento, dejando evidencia documental de que el participante ha leído y comprendido el formulario, y que ha dado su consentimiento de manera voluntaria.

1.9.3 Contenido del Formulario de Consentimiento

Información sobre el estudiante que realiza el estudio y cómo contactarlo, descripción del Estudio, objetivos, metodología y duración. Procedimientos a detalle de lo que se espera del participante, posibles inconvenientes y ventajas de participar. Medidas de confidencialidad y cómo se protegerán los datos personales, derechos del participante, incluyendo el derecho a recibir respuestas a sus preguntas y a retirar su consentimiento.

1.9.4 Evaluación de Riesgos

Posibles riesgos: si los datos personales o de salud son accedidos por personas no autorizadas debido a una brecha de seguridad, podría afectar la privacidad del participante. Identificación de participantes: aun con datos anonimizados, existe el riesgo de que combinaciones de datos permitan identificar a un individuo. Ansiedad o estrés: reflexionar sobre su salud y comportamiento sedentario podría generar estrés o sentimientos de culpa en algunos participantes. Autopercepción negativa: los resultados del cuestionario

SF-36 podrían afectar la percepción de bienestar si los puntajes son bajos. Dependencia tecnológica: promover el uso continuo de dispositivos podría incrementar la dependencia en la tecnología. Malinterpretación de datos: sin una adecuada explicación, los participantes podrían malinterpretar sus datos biométricos, llevando a decisiones inapropiadas sobre su salud.

Medidas de Mitigación: asegurar la protección de datos, implementando medidas robustas de seguridad para almacenar y manejar los datos. Explicar claramente los posibles riesgos y cómo se pueden manejar, así como ofrecer recursos o referencias en caso de que los participantes experimenten malestar emocional. Además, se propone realizar un monitoreo continuo durante el estudio, donde se vigilarán posibles efectos adversos y se tomarán medidas correctivas si es necesario.

1.9.5 Protección de Grupos Vulnerables

Los criterios de inclusión y exclusión del estudio han sido definidos para asegurar que no se incluyan grupos vulnerables. Esto evidencia que se ha considerado su protección y que el estudio ha sido diseñado para minimizar riesgos asociados.

1.9.6 Confidencialidad y Privacidad de los Datos

Basamos el manejo de los datos personales en los siguientes principios: **licitud y transparencia**, recopilamos y procesamos los datos de manera legal y transparente. Los utilizamos únicamente para los fines específicos del estudio, limitando la finalidad. Solo recopilamos los datos necesarios y pertinentes, garantizamos que fueran precisos y actualizados, y los protegimos contra accesos no autorizados, pérdidas o daños; de esta forma preservamos su integridad y confidencialidad. Gestionamos el control de accesos de manera que solo el equipo de investigación tuvo acceso a los datos, con permisos asignados según roles y responsabilidades.

Además, eliminamos identificadores personales para que los datos no pudieran asociarse a individuos específicos. Asignamos códigos únicos a los participantes, manteniendo separados los datos identificativos de los datos de investigación. Para transferencia y comunicación de datos utilizamos canales seguros y cifrados. Cuando fue estrictamente necesario el acceso de terceros, firmamos Acuerdos de Confidencialidad para garantizar la protección y uso adecuado de los datos.

1.9.7 Política de Retención y Eliminación Segura

Conservaremos los datos personales únicamente durante el tiempo necesario para los fines del estudio y respetando las normas interpuestas por el comité de ética.



1.9.8 Derechos de los Participantes

Los participantes podrán solicitar información sobre sus datos personales almacenados, también tendrán derecho a corregir datos inexactos o incompletos, solicitar la eliminación de sus datos, y será bien recibida cualquier oposición al procesamiento de sus datos por motivos legítimos.

1.9.9 Cumplimiento de Normativas y Legislación

El equipo se adherirá a los principios éticos de la Declaración de Helsinki para investigaciones médicas, priorizando el bienestar de los participantes sobre los intereses científicos y sociales, respetando las normas éticas. También se cumplirán las pautas éticas internacionales del CIOMS (Consejo de Organizaciones Internacionales de las Ciencias Médicas) que han sido contempladas y declaradas en este documento para salvaguardar los derechos y bienestar de los participantes. Todo esto en acatamiento al reglamento de la ley general de salud en materia de investigación, que solicita el registro del proyecto aprobado por un comité de ética en investigación reconocido.

Además, por la naturaleza de esta investigación nos exime a cumplir también con Ley General de Protección de Datos Personales en Posesión de Sujetos Obligados, donde los participantes en el proyecto serán responsables del manejo adecuado de los datos personales. Proporcionamos un aviso detallado a los participantes sobre cómo manejaremos sus datos, las medidas de seguridad implementadas, las medidas técnicas y organizativas para proteger los datos, los criterios de inclusión y exclusión definidos, las instrucciones claras sobre cómo participar y utilizar los dispositivos de monitoreo, el manejo de datos, el análisis de los datos, la divulgación de resultados, intención de publicaciones y si compartimos datos con otros investigadores.

1.9.10 Plan de Contingencia y Manejo de Incidentes

Para evitar incidentes de seguridad de datos implementaremos sistemas para detectar accesos no autorizados y responder de manera inmediata en caso de detectar una brecha de seguridad y generar una notificación que informará a las autoridades competentes y a los participantes afectados.

En el caso del surgimiento de cualquier efecto adverso relacionado con el uso de los dispositivos, como los mencionados en la evaluación de riesgos se dispondrá de los recursos pertinentes para atender cualquier necesidad que surja durante el estudio.

1.10 Financiamiento y Lugar Donde Se Realizará El Proyecto

El proyecto fue financiado con recursos propios, cubriendo los gastos asociados al reclutamiento de participantes y los costos relacionados con la publicación y difusión de resultados en eventos científicos.

1.10.1 Reproducibilidad Computacional

Para garantizar la reproducibilidad completa de los análisis, documentamos a continuación las especificaciones técnicas del entorno computacional:

Entorno de software:.

- *Python* 3.10+ (lenguaje de programación)
- *scikit-learn* 1.3+ (*clustering K-Means*, métricas de rendimiento)
- *pandas* 2.0+ (manipulación y agregación de datos)
- *numpy* 1.24+ (operaciones numéricas y matriciales)
- *matplotlib* 3.7+ (visualizaciones científicas)
- *scipy* 1.11+ (pruebas estadísticas no paramétricas)

Parámetros de reproducibilidad:.

- **Semilla aleatoria global:** `random_state=42` para todas las operaciones estocásticas (*K-Means*, PCA, particiones de validación)
- **Parámetros K-Means:** `n_init=10` (inicializaciones), `max_iter=300` (iteraciones máximas), `algorithm='lloyd'`
- **Umbral de decisión:** $\tau = 0,30$ (optimizado para maximizar *F1-Score* global)

Los scripts de análisis completos están disponibles bajo solicitud para fines de auditoría científica y replicación metodológica, en cumplimiento con las políticas de ciencia abierta y transparencia de datos Wilkinson et al., 2016.

1.10.2 Lugar de Ejecución

El proyecto se llevó a cabo en la Facultad de Medicina y Ciencias Biomédicas, en el laboratorio LIIACOM, donde se dispone de la infraestructura y el acompañamiento académico adecuados para la gestión del proyecto. Esta institución brindó las facilidades de espacio, equipo de cómputo y asesoría necesaria para la realización de las etapas de recolección de datos, validación de instrumentos, análisis estadístico y elaboración de informes científicos.

Resultados

Este capítulo presenta los hallazgos empíricos del estudio, siguiendo la secuencia metodológica establecida. Iniciamos con la caracterización de la cohorte y el análisis de la variabilidad de los datos, lo cual fundamenta las decisiones de preprocesamiento. A continuación, detallamos el proceso de establecimiento de la “verdad operativa” mediante el análisis de conglomerados. Posteriormente, presentamos el rendimiento del sistema de inferencia difusa en su validación contra esta referencia. Finalmente, exponemos un análisis de robustez que revela la contribución sinérgica de las variables al modelo.

2.1 Caracterización de la Cohorte y Análisis de Variabilidad de Datos

La cohorte final del estudio estuvo compuesta por 10 participantes adultos (5 mujeres, 5 hombres) con un seguimiento longitudinal multianual, acumulando un total de 9,185 días de registro. Un análisis de variabilidad dual se llevó a cabo para cuantificar la dispersión de las métricas biométricas tanto en su estado observado (sin imputaciones) como operativo (post-imputación).

Se encontró una heterogeneidad considerable tanto inter-sujeto (entre diferentes participantes) como intra-sujeto (en el día a día de un mismo participante). El coeficiente de variación (CV) para métricas clave como los minutos de ejercicio diario superó el 100 %, lo cual indica una alta irregularidad en los patrones de actividad incluso después de la imputación jerárquica. Este comportamiento motivó el uso de estadísticos robustos (mediana e IQR) y fundamenta la interpretación posterior de los perfiles detectados mediante clustering.

Como observamos, algunos usuarios exhiben patrones más consistentes (CV más bajos) que otros. Esta alta variabilidad natural de los datos recopilados en condiciones de vida libre justificó la decisión metodológica de agregar los datos a nivel semanal utilizando estadísticos robustos (mediana e *IQR*), con el fin de amortiguar el ruido diario y analizar patrones de comportamiento más estables y sostenidos.


2.2 Establecimiento de la Verdad Operativa: Análisis de Conglomerados

Previo al análisis de conglomerados, se verificó la ausencia de multicolinealidad severa entre las ocho características semanales seleccionadas. La Figura 2.1 muestra la matriz de correlación de Pearson entre variables: todas presentaron un Factor de Inflación de la Varianza (VIF) inferior a 2.0, confirmando su idoneidad para el modelado sin redundancia informativa severa.

Posteriormente, realizamos un barrido de K (de 2 a 6 conglomerados) para determinar la partición más adecuada de los datos. Como observamos en la Figura 2.2, el coeficiente de Silhouette alcanzó su máximo en $K = 2$ ($S=0.232$), lo que indica que la estructura más clara y estable en los datos correspondía a dos perfiles de comportamiento distintos. El método del codo complementó esta decisión mostrando una

Figura 2.1


Matriz de correlación de características para clustering



inflexión en $K = 2$.

Figura 2.2

Determinación de K óptimo mediante Silhouette y método del codo



El análisis de componentes principales (PCA) confirmó visualmente esta estructura bimodal. La Figura 2.3 muestra la proyección de las semanas en el espacio reducido de dos componentes principales: el PC1 (37 % de varianza explicada) separa claramente los dos grupos, estando fuertemente influenciado por las variables de actividad y gasto calórico.

Los perfiles de estos dos conglomerados se analizaron estadísticamente para su caracterización clínica. Como ilustra la Figura 2.4, el Conglomerado 0 (“Bajo Sedentarismo”) presentó valores de mediana significativamente más altos en Actividad_relativa_p50 y Superavit_calorico_basal_p50 en comparación con el Conglomerado 1 (“Alto Sedentarismo”). Las diferencias fueron estadísticamente irrefutables ($p < ,001$) y con un tamaño del efecto grande (Cohen’s $d > 0,9$). Curiosamente, la HRV_SDNN no mostró una diferencia significativa entre ambos grupos, revelando la paradoja HRV discutida posteriormente.

La Tabla 2.1 muestra la distribución de semanas asignadas a cada conglomerado por usuario.

La asignación de cada una de las 1,337 semanas válidas a uno de estos dos conglomerados se constituyó como la “verdad operativa”: una clasificación objetiva y empírica utilizada como referencia para la validación del sistema de inferencia difusa.


2.3 Rendimiento del Sistema de Inferencia Difusa

El rendimiento del modelo difuso se evaluó mediante su concordancia con la clasificación de la verdad operativa. Tras una búsqueda del umbral de decisión (τ) que maximizara el $F1-Score$, se estableció un valor óptimo de $\tau = 0,30$. Con este umbral, el sistema difuso alcanzó un rendimiento global robusto, con un $F1-Score$ de 0.840, una Exactitud de 0.740 y una alta Sensibilidad ($Recall$) de 0.976.

El análisis por participante reveló una heterogeneidad en el rendimiento, con un $F1-Score$ que osciló entre 0.215 y 0.997. Usuarios con patrones de comportamiento más estables mostraron una concordancia

Figura 2.3

Biplot de componentes principales mostrando separación bimodal



Tabla 2.1

Distribución de Semanas por Conglomerado y Usuario

Usuario	Cluster Alto Sed (%)	Cluster Bajo Sed (%)	Diferencia absoluta (%)
u1	99.3	0.7	98.7
u2	85.7	14.3	71.4
u3	11.3	88.7	77.3
u4	71.4	28.6	42.9
u5	64.3	35.7	28.6
u6	82.0	18.0	64.0
u7	94.7	5.3	89.5
u8	27.7	72.3	44.5
u9	84.2	15.8	68.5
u10	80.9	19.1	61.8

Figura 2.4

Perfiles biométricos de los dos conglomerados identificados



muy alta (ej. u1, u7), mientras que aquellos con mayor variabilidad intra-semanal presentaron mayores discrepancias. Estos resultados evidencian áreas de oportunidad para la personalización futura del modelo.

La ?? presenta los resultados de la validación cruzada Leave-One-User-Out (*LOUO*) por usuario.

Tabla 2.2

Rendimiento del Sistema Difuso por Usuario (Validación LOUO)

Usuario	Semanas	% Obs.*	Acc	Prec	Rec	F1	MCC	τ	TP	FP	TN	FN
u1	159	100	0.987	0.987	1.000	0.994	0.000	0.2	157	2	0	0
u2	8	100	0.500	0.800	0.571	0.667	-0.293	0.2	4	1	0	3
u3	141	100	0.397	0.432	0.739	0.545	0.076	0.1	51	67	5	18
u4	15	100	0.733	0.733	1.000	0.846	0.302	0.4	11	4	0	0
u5	15	100	0.733	0.714	1.000	0.833	0.000	0.4	10	4	1	0
u6	303	100	0.515	0.513	0.994	0.677	0.093	0.1	154	146	2	1
u7	117	100	0.957	0.957	1.000	0.978	0.387	0.45	111	5	1	0
u8	192	100	0.391	0.417	0.714	0.526	0.064	0.1	65	91	10	26
u9	302	100	0.745	0.747	0.977	0.847	0.304	0.1	213	72	12	5
u10	133	100	0.797	0.797	1.000	0.887	0.000	0.4	106	27	0	0

Nota: % Obs.* = Porcentaje de datos observados (sin imputación). Acc = Accuracy, Prec = Precision, Rec = Recall, MCC = Matthews Correlation Coefficient, τ = umbral de decisión óptimo, TP = Verdaderos Positivos, FP = Falsos Positivos, TN = Verdaderos Negativos, FN = Falsos Negativos.

2.3.1 Posicionamiento en el Contexto de Estudios con Validación LOUO

La Tabla 2.3 posiciona el desempeño del sistema en el contexto de estudios recientes con cohortes de tamaño comparable que emplean validación *LOUO*/LOSO (Leave-One-Subject-Out) en dominios de salud con *wearables*.

El *F1-Score* de 0.780 ± 0.167 (CV=21.4 %) es comparable a los mejores resultados reportados (Kaveh et al., 2024; Ricotti et al., 2023), pero destaca por tres características distintivas:

1. **Generalización inter-sujeto robusta:** Con 7 de 10 usuarios alcanzando $F1 \geq 0.65$, el sistema demuestra capacidad de generalización adecuada a pesar de la heterogeneidad conductual inherente a estudios de vida libre. El coeficiente de variación (CV=21.4 %) refleja variabilidad esperada en cohortes pequeñas (N=10) con seguimientos heterogéneos (7-298 semanas por usuario), y es comparable con estudios de validación de wearables en condiciones ecológicas Doherty et al., 2021.
2. **Parsimonia del modelo:** El sistema emplea 4 variables de entrada, significativamente menos que las 10-20 características típicas en la literatura de clasificación de actividad con acelerometría Alinia et al., 2020. Esta simplicidad facilita interpretabilidad clínica y reducción de costos computacionales.

Tabla 2.3

Comparación de Validación LOUO/LOSO en Cohortes Pequeñas con Wearables (2018-2025)

Estudio	Dominio	N	Métrica	Valor	CV %
Alinia 2020	Actividad física	10	<i>Accuracy</i>	0.812	6.3 %
Mullick 2022	Depresión	37	<i>F1-Score</i>	0.650	NR
Crozat 2025	Conteo pasos	7	MAPE	13.6 %	NR
Ricotti 2023	Progresión DMD	21	R ²	0.900	NR
Kaveh 2024	Somnolencia	9	<i>Accuracy</i>	0.933	NR
Este estudio	Sedentarismo	10	F1-Score	0.780	21.4 %

Nota: NR = No reportado. DMD = Distrofia Muscular de Duchenne. CV % = Coeficiente de variación del desempeño entre folds. Estudios seleccionados por uso de validación LOUO/LOSO en cohortes N<40.

- 3. Transparencia metodológica:** Reportamos el rendimiento completo (*F1-Score* $\pm$ SD) por usuario (ver ??), práctica infrecuente en literatura actual. Estudios como Mullick *et al.*. Mullick et al., 2022 y Crozat *et al.*. Crozat et al., 2025 reportan métricas globales sin desglose por participante, limitando la evaluación de heterogeneidad de respuesta.

Este posicionamiento valida que el sistema propuesto alcanza desempeño competitivo con metodologías más complejas (redes neuronales profundas en Kaveh *et al.*. Kaveh et al., 2024), preservando la ventaja de interpretabilidad inherente a los sistemas difusos basados en reglas.

La Tabla 2.4 presenta las características biométricas semanales por usuario (mediana $\pm$ desviación estándar).

Tabla 2.4

Características Biométricas Semanales por Usuario (Mediana $\pm$ DE)

Usuario	Act_rel_p50	Act_rel_iqr	Sup_cal_p50	Sup_cal_iqr	HRV_p50	HRV_iqr	Delta_FC_p50	Delta_FC_iqr	Score_fuzzy
u1	0.083 (± 0.029)	0.041 (± 0.027)	22.839 (± 5.172)	9.327 (± 5.760)	54.995 (± 6.304)	11.373 (± 4.877)	37.046 (± 4.039)	8.615 (± 4.647)	0.644 (± 0.211)
u2	0.161 (± 0.028)	0.072 (± 0.043)	33.069 (± 4.957)	16.296 (± 6.997)	40.651 (± 6.816)	7.654 (± 2.997)	40.711 (± 4.800)	9.118 (± 6.176)	0.334 (± 0.334)
u3	0.145 (± 0.049)	0.096 (± 0.038)	46.009 (± 11.031)	25.709 (± 14.350)	34.696 (± 8.376)	12.893 (± 7.845)	57.413 (± 8.047)	11.451 (± 4.718)	0.465 (± 0.250)
u4	0.163 (± 0.057)	0.089 (± 0.039)	21.362 (± 6.943)	7.941 (± 3.238)	38.662 (± 6.757)	11.192 (± 7.132)	49.250 (± 4.205)	12.780 (± 6.044)	0.719 (± 0.196)
u5	0.163 (± 0.057)	0.089 (± 0.039)	31.987 (± 10.396)	11.891 (± 4.848)	38.662 (± 6.757)	11.192 (± 7.132)	49.250 (± 4.205)	12.780 (± 6.044)	0.683 (± 0.271)
u6	0.175 (± 0.037)	0.070 (± 0.067)	23.772 (± 6.138)	11.973 (± 6.419)	33.882 (± 4.741)	8.661 (± 4.479)	46.296 (± 6.173)	9.523 (± 4.477)	0.638 (± 0.221)
u7	0.118 (± 0.038)	0.054 (± 0.052)	20.218 (± 4.929)	8.763 (± 5.960)	46.169 (± 7.903)	13.076 (± 6.134)	38.499 (± 4.882)	8.382 (± 4.037)	0.735 (± 0.243)
u8	0.166 (± 0.027)	0.049 (± 0.023)	47.287 (± 14.047)	27.491 (± 12.703)	62.822 (± 7.063)	14.273 (± 6.826)	35.075 (± 5.101)	10.307 (± 5.315)	0.385 (± 0.214)
u9	0.111 (± 0.028)	0.049 (± 0.028)	35.047 (± 7.665)	14.946 (± 14.963)	55.583 (± 10.210)	15.152 (± 7.463)	45.301 (± 4.819)	8.411 (± 4.422)	0.552 (± 0.180)
u10	0.091 (± 0.033)	0.054 (± 0.037)	25.162 (± 9.817)	15.957 (± 11.648)	52.707 (± 6.727)	11.811 (± 5.773)	41.633 (± 5.305)	10.129 (± 4.776)	0.612 (± 0.184)

Nota: Act_rel = Actividad relativa, Sup_cal = Superávit calórico basal, HRV = Variabilidad de frecuencia cardíaca (SDNN), Delta_FC = Delta cardíaco, Score_fuzzy = Puntuación del sistema difuso. Valores expresados como mediana ($\pm$ desviación estándar).


2.4 Análisis de Robustez y Contribución Sinérgica de las Variables

Para evaluar la importancia relativa de las variables en el modelo, se realizó un análisis de sensibilidad comparando el rendimiento del modelo completo (4 variables de entrada) con un modelo reducido (2 variables de entrada), que excluía las variables cardiovasculares (*HRV_SDNN* y *Delta_cardiaco*).

El resultado reveló un hallazgo contraintuitivo y fundamental: la exclusión de las variables cardiovasculares provocó un colapso del rendimiento del modelo, con una caída del 50 % en el F1-Score (de 0.840 a 0.420). La Figura 2.5 ilustra esta dependencia crítica mediante un gráfico de barras agrupadas que compara las cuatro métricas principales (F1-Score, Precision, Recall, MCC) entre ambos modelos. Los resultados evidencian el impacto devastador de la exclusión de variables cardiovasculares sobre todas las dimensiones del rendimiento.

Figura 2.5

Análisis de robustez: modelo completo vs. modelo reducido



Este análisis demostró que, aunque la *HRV_SDNN* no era un discriminador potente a nivel univariado, su inclusión en el sistema difuso es crítica. Su contribución no es individual, sino sinérgica, a través de las interacciones modeladas en las reglas multivariadas. Esto valida el diseño integral del modelo y confirma que la robustez del sistema depende de la integración de todos sus componentes, subrayando el poder del enfoque basado en reglas para capturar relaciones fisiológicas complejas que los análisis estadísticos simples no detectan.

2.4.1 Paradoja HRV: Debilidad Univariada, Fortaleza Multivariada

El análisis de las variables cardiovasculares reveló un hallazgo contraintuitivo de alta relevancia metodológica, que denominaremos “Paradoja HRV”. Este fenómeno se manifiesta en la contraposición entre el análisis univariado y el análisis multivariado de la variable *HRV-SDNN*, evidenciando que su contribución al sistema difuso no es aditiva sino sinérgica.

Análisis Univariado: la prueba de Mann-Whitney U para *HRV-SDNN* entre los dos conglomerados resultó no significativa ($U = 184,180$, $p = 0.562$, Cohen’s $d = 0.051$), indicando que esta variable no discrimina los grupos de manera independiente. Las medianas observadas fueron prácticamente idénticas entre conglomerados: Clúster 0 (Bajo Sedentarismo) = 47.71 ms versus Clúster 1 (Alto Sedentarismo) = 49.45 ms, con una diferencia absoluta de apenas 1.74 ms (3.6 % de la mediana global). El tamaño del efecto despreciable ($d = 0.051$) confirma la ausencia de diferenciación clínicamente relevante en términos univariados.

Análisis Multivariado mediante Ablación: Sin embargo, el análisis de ablación demostró que la exclusión de las variables cardiovasculares (*HRV-SDNN* y Delta_cardíaco) del sistema difuso provocó un colapso del rendimiento del modelo, con una caída del 50 % en el F1-Score (de 0.840 a 0.420, $p < 0.001$). Esta degradación masiva del desempeño evidencia que *HRV-SDNN* es crítica para la capacidad clasificatoria del sistema, a pesar de su aparente irrelevancia en análisis univariado.

Interpretación fisiológica de la paradoja: Este hallazgo evidencia que *HRV-SDNN* no actúa como *predictor independiente*, sino como *modificador de efecto* en interacción con otras variables biométricas. La *HRV* opera como modulador contextual de la respuesta cardiovascular al sedentarismo: mientras que Delta_cardíaco captura la *magnitud* de la respuesta al ejercicio (cuántos latidos aumenta la frecuencia cardíaca al caminar), *HRV-SDNN* caracteriza su *variabilidad temporal*, reflejando el tono autonómico cardiovascular Laborde et al., 2017; Task Force ESC/NASPE, 1996.

La Task Force de la European Society of Cardiology Task Force ESC/NASPE, 1996 establece que *SDNN* refleja la actividad combinada de los sistemas simpático (activación, estrés) y parasimpático (relajación, recuperación). En el contexto del sedentarismo, la Regla R3 del sistema difuso (“Si *HRV* es Baja Y Delta es Alto $\rightarrow$ Sedentarismo Alto”) identifica un subgrupo específico de individuos con desacondicionamiento cardiovascular: tono vagal reducido (*HRV* baja) con respuesta exagerada de frecuencia cardíaca al caminar (Delta alto), patrón que no sería detectado mediante análisis univariado de ninguna de las dos variables por separado.

Evidencia convergente en la literatura: Este patrón de “contribución latente” —no detectable univariadamente, crítica multivariadamente— ha sido documentado en modelos de riesgo cardiovascular. Soares-Miranda *et al.*. Soares-Miranda et al., 2014 reportan que variables con baja carga univariada resultan indispensables para capturar interacciones no-lineales, fenómeno denominado “redundancia parcial contextual”. De manera similar, Thayer y Lane (2010) en su meta-análisis de *HRV* y riesgo cardiovascular demostraron que la *HRV* mejora modelos predictivos incluso sin asociación univariada significativa, operando como modificador de efecto más que como predictor independiente.

Implicación metodológica: Este hallazgo valida la elección de un sistema difuso, cuyas reglas basadas en operadores AND (intersecciones de conjuntos difusos) capturan sinergias que los análisis estadísticos tradicionales (ANOVA, Mann-Whitney) —diseñados para detectar efectos aditivos— no pueden identificar. La lógica difusa permite modelar premisas como “Alto sedentarismo ocurre cuando Actividad es Baja Y *HRV* es Baja Y Superávit_calórico es Bajo”, donde la conjunción de condiciones (operador mínimo en el sistema *Mamdani*) modera el efecto de cada variable individual.

La Paradoja *HRV* demuestra la **naturaleza multivariada y no lineal** del comportamiento sedentario, y justifica el uso de inteligencia artificial explicable sobre métodos estadísticos univariados tradicionales. Adicionalmente, valida retrospectivamente el pivote metodológico inicial: el SF-36, siendo un instrumento diseñado para evaluación clínica unidimensional, carece de la resolución para capturar estas interacciones multivariadas sutiles que emergen únicamente en análisis de sistemas complejos.

2.4.2 Validación Convergente Exploratoria con SF-36

Un subconjunto de 8 participantes completó el cuestionario SF-36 al finalizar el seguimiento, lo que permitió un análisis exploratorio de validación convergente entre el índice *fuzzy* y métricas de calidad de vida percibida. Aunque el diseño final no se centró en esta correlación (ver pivote metodológico, Sección ??), los resultados aportan contexto sobre la relación entre comportamiento objetivo y autopercepción de salud.

Hallazgos principales:

- **Salud Mental (SM):** Correlación moderada-fuerte con mediana *fuzzy* ($\rho=0.765$, $p=0.027$), estadísticamente significativa. Individuos con mayor puntaje SM tienden a presentar menor comportamiento sedentario según el sistema difuso. Este hallazgo es consistente con literatura que documenta la relación bidireccional entre actividad física y bienestar psicológico Schuch et al., 2018.
- **Salud General (SG):** Correlación débil-moderada no significativa ($\rho=0.537$, $p=0.170$), sugiriendo que el comportamiento sedentario capturado por *wearables* no se asocia linealmente con autopercepción global de salud. Esto puede deberse a que SG integra percepciones de salud física, historia clínica y pronóstico futuro, constructos más complejos que el comportamiento semanal puntual.
- **Rol Físico (RF):** Correlación no significativa ($\rho=-0.247$, $p=0.555$), con dirección contraintuitiva (negativa), potencialmente explicada por fenómenos de compensación. Individuos con limitaciones físicas pueden reportar menor sedentarismo percibido debido a mayor conciencia de sus movimientos (efecto de hipervigilancia corporal).

Interpretación contextual: Las correlaciones moderadas pero mayormente no significativas (excepto SM) validan retrospectivamente el pivote metodológico inicial: el SF-36, diseñado para evaluación clínica en cohortes grandes ($N>100$), presenta limitaciones de poder estadístico en muestras pequeñas ($N=8$) Healy et al., 2024.

Healy *et al.*. Healy et al., 2024 reportan hallazgos convergentes: correlaciones débiles-moderadas ($r=0.3-0.5$, no significativas) entre cuestionarios de actividad física y métricas objetivas de *wearables* en cohortes $N<15$. Esto sugiere que la **autopercepción** de actividad y el **comportamiento objetivo** capturado por sensores representan constructos relacionados pero no intercambiables, con divergencias atribuibles a sesgos de discapacidad social, error de memoria y diferentes ventanas temporales de evaluación (SF-36 evalúa últimas 4 semanas; nuestro sistema evalúa semanas individuales).

Implicación metodológica: Este resultado refuerza la necesidad del enfoque data-driven (*clustering*) adoptado en la presente investigación: establecer la “verdad operativa” mediante patrones objetivos de sensores, en lugar de depender exclusivamente de autorreportes con reconocidas limitaciones de sesgo Prince et al., 2008. Prince *et al.* documentan concordancia limitada ($Kappa<0.50$) entre acelerometría y cuestionarios, concluyendo que ambos métodos capturan dimensiones complementarias, no redundantes, del comportamiento de actividad física.


2.5 Tesis

La principal aportación de esta investigación es el desarrollo y la validación de un sistema experto, basado en lógica difusa, capaz de clasificar con alta fiabilidad (*F1-Score LOUO* = 0.780) los patrones de comportamiento sedentario semanal a partir de datos biométricos multivariados, longitudinales y recopilados en condiciones de vida libre. Demostramos la constatación de la hipótesis de investigación al confirmar que el modelo interpretable, fundamentado en reglas de conocimiento clínico, converge significativamente con una clasificación objetiva derivada de un análisis de conglomerados no supervisado.

Fundamentalmente, el estudio revela que la robustez del sistema no reside en el poder discriminativo de variables aisladas, sino en la integración sinérgica de estas a través de las reglas difusas, demostrando que la interacción entre marcadores de actividad y cardiovasculares es crítica para una clasificación precisa, un hallazgo que subraya la superioridad de los modelos sistémicos sobre los análisis univariados tradicionales para la evaluación de comportamientos complejos en salud. La Figura 2.6 sintetiza visualmente el sistema completo, mostrando el flujo desde la captura de datos biométricos mediante *wearables* hasta la clasificación final mediante el sistema de inferencia difusa.

Figura 2.6

Arquitectura del sistema de clasificación de sedentarismo mediante lógica difusa



Referencias

- Alinia, P., Samadani, A., Milosevic, M., Ghasemzadeh, H., & Parvaneh, S. (2020). Pervasive Lying Posture Tracking [F1=98.2 % $\pm$ 6.2 % (CV=6.3 %) mejor caso]. *Sensors*, 20(20), 5953. <https://doi.org/10.3390/s20205953>
- Apple Inc. (2024). HealthKit Documentation.
- Bolger, N., & Laurenceau, J.-P. (2013). Intensive Longitudinal Methods: An Introduction to Diary and Experience Sampling Research [Diseños longitudinales intensivos para muestras pequeñas].
- Canalys. (2024). Global wearable band market up 0.2 % in Q2 2024 as basic watches take biggest share yet.
- Chicco, D., & Jurman, G. (2020). The advantages of the Matthews correlation coefficient (MCC) over F1 score and accuracy in binary classification evaluation. *BMC Genomics*, 21(1), 6. <https://doi.org/10.1186/s12864-019-6413-7>
- Crozat, F., Pohl, J., Easthope Awai, C., Bauer, C. M., & Kuster, R. P. (2025). Every Step Counts—How Can We Accurately Count Steps with Wearable Sensors During Activities of Daily Living in Individuals with Neurological Conditions? *Sensors*, 25(18), 5657. <https://doi.org/10.3390/s25185657>
- Doherty, A., Smith-Byrne, K., Ferreira, T., et al. (2021). GWAS identifies 14 loci for device-measured physical activity and sleep duration. *Nature Communications*, 9(1), 5257. <https://doi.org/10.1038/s41467-018-07743-4>
- Gaur, V. (2024). Apple Health Data Analysis. <https://github.com/vinayakgaur/Apple-Health-Data-Analysis>
- Harris, J. A., & Benedict, F. G. (1918). A Biometric Study of Human Basal Metabolism [Ecuación clásica de TMB (Tasa Metabólica Basal)]. *Proceedings of the National Academy of Sciences*, 4(12), 370-373. <https://doi.org/10.1073/pnas.4.12.370>
- Healy, S., Patterson, F., Biddle, S. J., Dumuid, D., Glorieux, I., Olds, T., Woods, C., Bauman, A. E., Gába, A., Herring, M. P., Kastelic, K., Lachapelle, U., Volpe, S. L., Tomat, S. B., & Pedisic, Z. (2024). It's about time to exercise: development of the Exercise Participation Explained in Relation to Time (EXPERT) model. *British Journal of Sports Medicine*, 58(19), 1131-1144. <https://doi.org/10.1136/bjsports-2024-108500>
- Henriksen, A., Woldaregay, A. Z., Muzny, M., Hartvigsen, G., Hopstock, L. A., & Grimsgaard, S. (2021). *Replication data for Using Fitness Trackers and Smartwatches to Measure Physical Activity in Research*. <https://doi.org/10.18710/6ZWC9Z>

- Ho, W. T., Yang, Y. J., & Li, T. C. (2022). Accuracy of wrist-worn wearable devices for determining exercise intensity. *Digital Health*, 8, 20552076221124393. <https://doi.org/10.1177/20552076221124393>
- Kaveh, R., Schwendeman, C., Pu, L., Arias, A. C., & Muller, R. (2024). Wireless ear EEG to monitor drowsiness. *Nature Communications*, 15(1), 6520. <https://doi.org/10.1038/s41467-024-48682-7>
- Laborde, S., Mosley, E., & Thayer, J. F. (2017). Heart rate variability and cardiac vagal tone in psychophysiological research – Recommendations for experiment planning, data analysis, and data reporting. *Frontiers in Psychology*, 8, 213. <https://doi.org/10.3389/fpsyg.2017.00213>
- Mamdani, E. H., & Assilian, S. (1975). An experiment in linguistic synthesis with a fuzzy logic controller. *International Journal of Man-Machine Studies*, 7(1), 1-13. [https://doi.org/10.1016/S0020-7373\(75\)80002-2](https://doi.org/10.1016/S0020-7373(75)80002-2)
- Mullick, T., Radovic, A., Shaaban, S., & Doryab, A. (2022). Predicting Depression in Adolescents Using Mobile and Wearable Sensors: Multimodal Machine Learning–Based Exploratory Study. *JMIR Formative Research*, 6(6), e35807. <https://doi.org/10.2196/35807>
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
- Pinto, A. J., Bergouignan, A., Dempsey, P. C., Roschel, H., Owen, N., Gualano, B., & Dunstan, D. W. (2023). Physiology of sedentary behavior. *Physiological Reviews*, 103(4), 2561-2622. <https://doi.org/10.1152/physrev.00022.2022>
- Prince, S. A., Adamo, K. B., Hamel, M. E., Hardt, J., Gorber, S. C., & Tremblay, M. (2008). A comparison of direct versus self-report measures for assessing physical activity in adults: A systematic review. *International Journal of Behavioral Nutrition and Physical Activity*, 5, 56. <https://doi.org/10.1186/1479-5868-5-56>
- Riebe, D., Ehrman, J. K., Liguori, G., & Magal, M. (2018). *ACSM's Guidelines for Exercise Testing and Prescription* (10th) [Guía oficial del ACSM para prescripción de ejercicio]. American College of Sports Medicine.
- Ross, T. J. (2010). *Fuzzy Logic with Engineering Applications* (3rd). John Wiley & Sons Ltd.
- Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20, 53-65. [https://doi.org/10.1016/0377-0427\(87\)90125-7](https://doi.org/10.1016/0377-0427(87)90125-7)
- Schrack, J. A., Cooper, R., Koster, A., Shiroma, E. J., Murabito, J. M., Rejeski, W. J., Ferrucci, L., & Harris, T. B. (2018). Using heart rate and accelerometry to define quantity and intensity

- of physical activity in older adults. *The Journals of Gerontology: Series A*, 73(5), 668-675. <https://doi.org/10.1093/gerona/gly029>
- Schuch, F. B., Vancampfort, D., Firth, J., Rosenbaum, S., Ward, P. B., Silva, E. S., Hallgren, M., Ponce De Leon, A., Dunn, A. L., Deslandes, A. C., Fleck, M. P., Carvalho, A. F., & Stubbs, B. (2018). Physical Activity and Incident Depression: A Meta-Analysis of Prospective Cohort Studies [Relación bidireccional entre actividad física y bienestar psicológico]. *American Journal of Psychiatry*, 175(7), 631-648. <https://doi.org/10.1176/appi.ajp.2018.17111194>
- Soares-Miranda, L., Sattelmair, J., Chaves, P., Duncan, G. E., Siscovick, D. S., Stein, P. K., & Mozaffarian, D. (2014). Physical activity and heart rate variability in older adults: The cardiovascular health study. *Circulation*, 129(21), 2100-2110. <https://doi.org/10.1161/CIRCULATIONAHA.113.005361>
- Sokolova, M., & Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, 45(4), 427-437. <https://doi.org/10.1016/j.ipm.2009.03.002>
- Task Force ESC/NASPE. (1996). Heart rate variability: Standards of measurement, physiological interpretation and clinical use. *Circulation*, 93(5), 1043-1065. <https://doi.org/10.1161/01.CIR.93.5.1043>
- Wilkinson, M. D., Dumontier, M., Aalbersberg, I. J., Appleton, G., Axton, M., Baak, A., Blomberg, N., Boiten, J.-W., da Silva Santos, L. B., Bourne, P. E., Bouwman, J., Brookes, A. J., Clark, T., Crosas, M., Dillo, I., Dumon, O., Edmunds, S., Evelo, C. T., Finkers, R., ... Mons, B. (2016). The FAIR Guiding Principles for scientific data management and stewardship. *Scientific Data*, 3, 160018. <https://doi.org/10.1038/sdata.2016.18>
- World Health Organization. (2020). *WHO Guidelines on Physical Activity and Sedentary Behaviour* (inf. téc.). World Health Organization. Geneva, Switzerland. <https://www.who.int/publications/i/item/9789240015128>
- Yamada, Y., Yoshida, T., Yokoyama, K., Watanabe, Y., Miyake, M., Yamagata, E., Yamada, M., Kimura, M., & Kyoto-Kameoka Study Group. (2019). Accuracy of 12 wearable devices for estimating physical activity energy expenditure using a metabolic chamber and the doubly labeled water method: Validation study. *JMIR mHealth and uHealth*, 7(8), e13938. <https://doi.org/10.2196/13938>
- Zadeh, L. A. (1965). Fuzzy sets. *Information and Control*, 8(3), 338-353. [https://doi.org/10.1016/S0019-9958\(65\)90241-X](https://doi.org/10.1016/S0019-9958(65)90241-X)