

UNIVERSIDAD AUTÓNOMA DE CHIHUAHUA
FACULTAD DE MEDICINA Y CIENCIAS BIOMÉDICAS
SECRETARÍA DE INVESTIGACIÓN Y POSGRADO



**MODELO DE EVALUACIÓN DEL COMPORTAMIENTO
SEDENTARIO MEDIANTE LÓGICA DIFUSA Y
DATOS BIOMÉTRICOS**

POR:

LUIS ANGEL MARTÍNEZ CORRAL

**TESIS PRESENTADA COMO REQUISITO PARA OBTENER EL GRADO DE:
MAESTRO EN FORMACIÓN E INNOVACIÓN PARA PROFESIONALES DE LA SALUD**

RESUMEN

El comportamiento sedentario (CS), definido como actividad en vigilia con gasto energético 1.5 METs, constituye el cuarto factor de riesgo de mortalidad según la OMS, asociándose directamente al desarrollo de diversas condiciones fisiopatológicas. Su medición objetiva en condiciones de vida libre representa un vacío metodológico, pues los cuestionarios de autoinforme (ej. IPAQ) presentan sesgo de memoria, mientras que las técnicas de laboratorio como calorimetría indirecta y actigrafía entre otras técnicas de laboratorio, no capturan la complejidad del comportamiento humano. Este estudio desarrolló un modelo de clasificación del sedentarismo mediante lógica difusa que integra datos biométricos de dispositivos *wearables*, aplicado bajo el paradigma *Bring Your Own Device* (BYOD) en condiciones de vida libre.

La cohorte se conformó por 10 adultos jóvenes con seguimiento retrospectivo multianual mediante *Apple Watch*. Se propusieron cuatro variables derivadas: actividad relativa, superávit calórico basal, delta cardíaco y variabilidad de la frecuencia cardíaca (HRV). La metodología empleó *clustering K-Means* no supervisado para establecer verdad operativa, y un Sistema de Inferencia Difusa *Mamdani* para realizar la clasificación de comportamiento sedentario mediante cinco reglas lingüísticas interpretables.

El sistema se validó mediante *Leave-One-User-Out*, demostrando un *F1-Score* = 0.780 ± 0.167 (CV=21.4 %), resultados que validan una herramienta fiable y transparente para el diseño de intervenciones de salud personalizadas, contribuyendo a la mitigación de este riesgo sanitario mediante la promoción de estilos de vida activos alineados con la Estrategia Mundial de la OMS (DPAS) y la meta 3.4 de los Objetivos de Desarrollo Sostenible (ODS).

Palabras clave: Comportamiento sedentario, Lógica Difusa, *BYOD*, *Wearables*, *LOUO*.

ABSTRACT

Sedentary behavior (SB), defined as any wakeful activity with energy expenditure 1.5 METs, constitutes the fourth leading risk factor for mortality according to the WHO, being directly associated with the development of various pathophysiological conditions. Its objective measurement in free-living conditions represents a methodological gap, as self-report questionnaires (e.g., IPAQ) exhibit memory bias, while laboratory techniques such as indirect calorimetry and actigraphy, among other laboratory techniques, fail to capture the complexity of human behavior. This study developed a sedentary behavior classification model using *fuzzy* logic that integrates biometric data from *wearable* devices, applied under the *Bring Your Own Device (BYOD)* paradigm in free-living conditions.

The cohort consisted of 10 young adults with multi-year retrospective follow-up via *Apple Watch*. Four derived variables were proposed: relative activity, basal caloric surplus, cardiac delta, and heart rate variability (*HRV*). The methodology employed unsupervised *K-Means clustering* to establish operational truth, and a *Mamdani fuzzy* Inference System to perform sedentary behavior classification through five interpretable linguistic rules.

The system was validated using Leave-One-User-Out, demonstrating an *F1-Score* = 0.780 ± 0.167 (CV=21.4 %), results that validate a reliable and transparent tool for designing personalized health interventions, contributing to the mitigation of this health risk through the promotion of active lifestyles aligned with the WHO Global Strategy on Diet, Physical Activity and Health (DPAS) and Sustainable Development Goal 3.4 (SDG).

Keywords: Sedentary behavior, *Fuzzy* logic, *BYOD*, *Wearables*, *LOUO*.



Universidad Autónoma de Chihuahua
Facultad de Medicina y Ciencias Biomédicas
Secretaría de Investigación y Posgrado



La tesis “Modelo de Evaluación del Comportamiento Sedentario mediante Lógica Difusa y Datos Biométricos” que presenta Luis Angel Martínez Corral, como requisito parcial para obtener el grado de: Maestro en Formación e Innovación para Profesionales de la Salud ha sido revisada y aprobada por Facultad de Medicina y Ciencias Biomédicas.

Dr. Oscar Aguirre Barrera
Secretario de Investigación y Posgrado
Facultad de Medicina y Ciencias Biomédicas
Universidad Autónoma de Chihuahua

Dra. Haydeé Parra Acosta
Profesor Coordinador Académico

Dr. Abimael Guzmán Pando
Director de Tesis

Dr. David Ricardo López Flores
Co director de tesis

Dra. Celia María Quiñonez Cruz
Asesor(a)

Dr. Javier Camarillo Cisneros
Asesor(a)

Se certifica, bajo protesta de decir verdad, que las firmas consignadas al pie del presente documento son de carácter original y auténtico, correspondiendo de manera inequívoca a los responsables de las labores de dirección, seguimiento, asesoría y evaluación, en estricta conformidad con lo dispuesto en la normativa vigente de esta institución universitaria.



Chihuahua, Chih., México, a 9 de Diciembre de 2025

Dr. Oscar Aguirre Barrera
Secretario de Investigación y Posgrado
Facultad de Medicina y Ciencias Biomédicas

P R E S E N T E.-

Por medio de la presente nos permitimos informar a usted que el C. Luis Angel Martínez Corral, con número de matrícula 261337, ha concluido la elaboración de la tesis “Modelo de Evaluación del Comportamiento Sedentario mediante Lógica Difusa y Datos Biométricos”, como requisito para obtener el grado de: **Maestro en Formación e Innovación para Profesionales de la Salud.**

Así mismo, manifestamos que la tesis ha sido revisada y aprobada por los abajo firmantes, miembros del Comité de Grado.

Sin otro particular, quedamos de usted.

ATENTAMENTE

“MENTI DA LUCEM, MANIBUS ARTEM”

Director de Tesis

Dr. Abimael Guzmán Pando

Co-Director de Tesis

Dr. David Ricardo López Flores

Asesor de Tesis

Dra. Celia María Quiñez Cruz

Asesor de Tesis

Dr. Javier Camarillo Cisneros

DEDICATORIA

A Dios, por la bendición diaria de la vida, por guiar mi camino y darme la fortaleza necesaria para alcanzar cada meta.

A mis padres, por su amor incondicional, por su ejemplo y por haberme enseñado que la disciplina y la constancia son los pilares de todo logro. Su apoyo y confianza han sido el cimiento sobre el cual he construido cada paso de mi formación.

Y a Nahomi Muñoz, mi prometida, compañera y cómplice en esta travesía. Gracias por tu paciencia, por creer en mí incluso cuando las fuerzas flaqueaban, por acompañarme durante estos dos años de esfuerzo y dedicación, y por ser la fuente constante de inspiración que da sentido y equilibrio a mi vida. En ti encuentro el reflejo de lo que deseo ser: un profesional pleno, pero también un ser humano que crece, ama y construye un futuro compartido. Este logro académico no solo marca el cierre de una etapa, sino el inicio de un proyecto de vida que se fortalece a tu lado.

AGRADECIMIENTOS

A mis amigos, por su comprensión y apoyo incondicional, por entender que en esta etapa crucial de mi desarrollo profesional hubo momentos en los que no pude estar presente, pero en los que siempre conté con su paciencia y respaldo sincero.

A mi director de tesis, el Dr. Abimael Guzmán Pando, y a mi co-director, el Dr. David Ricardo López Flores, por transmitirme su conocimiento y fomentar en mí aprendizajes significativos que hoy forman parte esencial de mi crecimiento profesional. Gracias por su paciencia, tolerancia y perseverancia para llevar este proyecto a buen término.

A mis asesores del comité tutorial, la Dra. Celia María Quiñonez Cruz y el Dr. Javier Camarillo Cisneros, por su orientación y valiosas observaciones que contribuyeron a elevar el rigor y la calidad científica de esta investigación.

A mis docentes de la Maestría, en especial al Dr. Luis Gibrán Juárez Hernández, por su genuino interés en formarnos como investigadores, y a la Dra. Haydeé Parra Acosta, por su liderazgo y compromiso en mantener este programa bajo los más altos estándares de calidad académica y científica, brindándonos una base sólida para nuestro desarrollo profesional.

Al Dr. Javier Bernabé González Bustos, Secretario de Investigación y Posgrado de la FCCF-UACH, por facilitar la base de perfiles expertos para la validación del instrumento en la primera etapa de esta investigación y por sus valiosos consejos en mis primeros pasos como investigador. Asimismo, expreso mi reconocimiento a la Dra. Ma. de los Ángeles Bibiano Mejía y al Dr. Hugo Eduardo Irigoyen Gutiérrez, por su orientación y apoyo desde la licenciatura, cuyo impulso y recomendación fueron determinantes para dar el salto hacia este proceso de maestría y lograr mi incorporación a este programa académico.



Índice de contenidos

1	Introducción	10
2	Marco Teórico y Antecedentes	12
2.1	Marco Teórico	12
2.1.1	Delimitación Conceptual del Comportamiento Sedentario	12
2.1.2	Actividad Física y Monitoreo Cardiovascular	13
2.1.3	Dispositivos Portátiles y Tecnologías de Monitoreo	15
2.1.4	Teoría de lógica difusa para el análisis de datos biométricos	17
2.1.5	La Lógica Difusa en la Salud Digital y el Monitoreo Biométrico	18
2.1.6	Agrupamiento No Supervisado y el Vacío Metodológico en Clasificación de Sedentarismo	21
2.1.7	Mecanismos de Validación en Estudios con Dispositivos Portátiles	21
2.2	Antecedentes	23
2.2.1	Investigaciones Previas Relacionadas	23
2.2.2	Enfoques de Deep Learning y Redes Neuronales	23
2.2.3	Machine Learning Clásico y Validación Cruzada	24
2.2.4	Lógica Difusa y Sistemas de Inferencia Interprettables	24
2.2.5	Análisis Comparativo de Investigaciones	25
3	Delimitación del Objeto de Estudio	29
3.1	Problema de Investigación	29
3.2	Pregunta de Investigación	30
3.3	Hipótesis	31
3.3.1	Hipótesis Conceptual (HC)	31
3.3.2	Hipótesis Nula (H_0)	31
3.4	Objetivo General	31
3.5	Objetivos Específicos	31
4	Justificación	33
5	Materiales y Métodos	35
5.1	Diseño del Estudio y Aprobaciones Éticas	35
5.2	Selección del Dispositivo Wearable	36
5.3	Protocolo de Convocatoria y Reclutamiento de Participantes	38



5.4	Características Demográficas de la Cohorte	39
5.5	Justificación del Tamaño Muestral	41
5.6	Metodología de Extracción y Procesamiento de Datos	42
5.7	Análisis Exploratorio de Datos Inicial	47
5.8	Estrategia de Imputación Jerárquica de Datos Faltantes	49
5.8.1	Metodología de Imputación Jerárquica	50
5.9	Ingeniería de Características	51
5.10	Caracterización de Distribuciones y Variabilidad	53
5.11	Agregación Temporal Semanal	56
5.11.1	Análisis de Correlación entre Variables Semanales	58
5.11.2	Matriz de Dispersión de Relaciones Bivariadas	59
5.12	Análisis Dual de Variabilidad	60
5.12.1	Definición de Variabilidad Observada vs Operativa	61
5.12.2	Comparación Observada vs Operativa	61
5.13	Análisis de Componentes Principales	63
5.13.1	Exploración en 3 Dimensiones (PC1-PC2-PC3)	67
5.14	Clustering No Supervisado: Verdad Operativa	68
5.14.1	Justificación del Clustering como Verdad Operativa	68
5.14.2	Validación Estadística de los Perfiles de Cluster	70
5.15	Diseño del Sistema de Inferencia Difusa Mamdani	71
5.15.1	Arquitectura General del Sistema	71
5.15.2	Funciones de Pertenencia Basadas en Percentiles	71
5.15.3	Base de Reglas Difusas	73
5.16	Protocolo de Validación Cruzada Leave-One-User-Out	73
5.16.1	Justificación de LOUO sobre Split Train/Test Tradicional	73
5.16.2	Análisis de Robustez: Contribución Multivariada de HRV-SDNN	74
6	Resultados	76
6.1	Caracterización de la Cohorte y Análisis de Variabilidad de Datos	76
6.2	Establecimiento de la Verdad Operativa: Análisis de Conglomerados	76
6.3	Rendimiento del Sistema de Inferencia Difusa	78
6.3.1	Posicionamiento en el Contexto de Estudios con Validación LOUO	80
6.4	Análisis de Robustez y Contribución Sinérgica de las Variables	83
6.4.1	Paradoja HRV: Debilidad Univariada, Fortaleza Multivariada	84
6.4.2	Validación Convergente Exploratoria con SF-36	85
6.5	Tesis	86



7	Discusión	88
7.1	Discusión de Hallazgos Principales	88
7.1.1	Desempeño Predictivo del Modelo Difuso en Validación Leave-One-User-Out	88
7.1.2	Paradoja de la Variabilidad de la Frecuencia Cardíaca: Débil Univariadamente, Crítica Multivariadamente	89
7.1.3	Robustez del Pipeline Híbrido: Clustering No Supervisado como Ground Truth Operativa	91
7.2	Comparación con Investigaciones Previas	92
7.2.1	Convergencias con la Literatura Científica	92
7.2.2	Divergencias Relevantes y Explicaciones	92
7.3	Logros de la Investigación	93
7.4	Limitaciones del Estudio	94
7.4.1	Limitaciones Metodológicas	94
7.4.2	Limitaciones Muestrales	95
7.4.3	Limitaciones Contextuales	95
7.4.4	Limitaciones de Recursos	95
7.5	Implicaciones de los Hallazgos	96
7.5.1	Implicaciones Teóricas	96
7.5.2	Implicaciones Prácticas	96
7.5.3	Implicaciones Metodológicas	97
7.6	Cumplimiento de Objetivos e Hipótesis	97
7.6.1	Objetivo General	97
7.6.2	Objetivos Específicos	97
7.6.3	Hipótesis	98
7.7	Reflexión Final y Líneas Futuras de Investigación	98
8	Conclusiones	100
	Referencias	101
	Anexos	111
8.1	Análisis Comparativo Exhaustivo de Investigaciones Previas	111
8.2	Nomenclatura y Simbología Matemática	118
8.2.1	Símbolos Matemáticos Generales	118

Introducción

El Comportamiento Sedentario (CS) representa actualmente uno de los desafíos más críticos de salud pública del siglo XXI, vinculado estrechamente con la transición epidemiológica, la urbanización acelerada y el cambio en los patrones de movilidad y trabajo. Las largas jornadas en posición sentada, el predominio de actividades digitales y la disminución de la actividad física incidental han generado un aumento sostenido en la prevalencia de Enfermedades Crónicas No Transmisibles (ENT), como la diabetes tipo 2, las enfermedades cardiovasculares y la depresión Bull et al., 2020. Este panorama, descrito por World Health Organization, 2020a, refleja la urgencia de desarrollar herramientas que permitan medir, interpretar y reducir los efectos del sedentarismo en la Calidad de Vida Relacionada con la Salud (CVRS) Guthold et al., 2020.

El estudio del CS tradicionalmente utiliza instrumentos de autoinforme, como el Cuestionario Mundial sobre Actividad Física (*GPAQ*, por sus siglas en inglés) o el Cuestionario Internacional de Actividad Física (*IPAQ*, por sus siglas en inglés), que aunque válidos y ampliamente implementados, presentan limitaciones inherentes a la subjetividad y la falta de resolución temporal Romero et al., 2022. En la última década, el desarrollo de dispositivos portátiles con sensores biométricos, que incluyen acelerómetros, fotopletimografía (*PPG*) y sensores de frecuencia cardíaca, ha permitido capturar datos fisiológicos y de actividad con alta precisión; lo cual abre la posibilidad de análisis objetivos, continuos y personalizados Henriksen et al., 2018; Strain et al., 2020; White et al., 2019. Este desarrollo tecnológico sitúa al monitoreo digital de la salud como una pieza central en el diseño de intervenciones preventivas basadas en evidencia.

En este contexto, la Inteligencia Artificial (IA) y, particularmente, la lógica difusa, ofrecen un marco teórico y computacional idóneo para modelar fenómenos complejos caracterizados por relaciones no lineales entre variables. La lógica difusa admite grados intermedios de pertenencia y permite representar razonamientos humanos en términos lingüísticos, lo cual otorga interpretabilidad y flexibilidad a los modelos biomédicos Kaur y Khehra, 2022; Ross, 2010; Zadeh, 1965. Su integración en sistemas de inferencia *Mamdani* posibilita traducir datos biométricos en reglas semánticamente comprensibles y fortalece la capacidad explicativa de los algoritmos.

El presente proyecto desarrolló un modelo de evaluación del Comportamiento Sedentario basado en lógica difusa e información biométrica proveniente del *Apple Watch*, que integra variables de actividad física (minutos en movimiento, pasos diarios, gasto calórico) con indicadores autonómicos derivados de la variabilidad de la frecuencia cardíaca (*HRV-SDNN*). Este enfoque caracterizó la relación entre patrones de sedentarismo y percepción de CVRS, capturando la dinámica diaria del equilibrio entre esfuerzo, recuperación y bienestar. A través de un sistema de

inferencia difusa con reglas adaptativas, se modeló la interacción entre la activación fisiológica y los hábitos conductuales, lo cual ofreció una aproximación más precisa y contextualizada del impacto del sedentarismo sobre la salud.

Desde una perspectiva metodológica, el modelo difuso se nutre de datos reales obtenidos de Apple *HealthKit*, los cuales son procesados mediante un protocolo reproducible que garantiza la integridad y trazabilidad de la información. Se construye una base de control difuso con funciones de pertenencia triangulares y trapezoidales para las variables de entrada, y un conjunto de reglas lingüísticas. El sistema se valida mediante concordancia con una verdad operativa derivada de *clustering* no supervisado, y utiliza métricas de rendimiento (*F1-Score*, Exactitud, Coeficiente de Matthews) y validación cruzada *Leave-One-User-Out (LOUO)* para evaluar generalización inter-sujeto, es decir, la capacidad del modelo para clasificar correctamente el comportamiento sedentario en usuarios no incluidos en el entrenamiento. Adicionalmente, se realizó una validación convergente exploratoria con el cuestionario *SF-36* en un subconjunto de participantes (N=8), la cual reveló correlación significativa únicamente con la dimensión salud mental.

Este modelo contribuye a la comprensión del sedentarismo como fenómeno fisiológico y conductual. Integra la dimensión autonómica del organismo en el análisis de la actividad física. El sistema es explicable y flexible. Se adapta a distintas poblaciones y contextos de uso. La investigación aporta un marco empírico para diseñar estrategias de promoción de la salud personalizadas y sostenibles. Estas estrategias se alinean con la agenda 2030 para el desarrollo sostenible, específicamente con la meta 3.4 de los Objetivos de Desarrollo Sostenible (ODS), que busca reducir en un tercio la mortalidad prematura por ENT para 2030, y con el plan mundial sobre actividad física 2018–2030 World Health Organization, 2018.

La urgencia de abordar el CS se evidencia en datos globales alarmantes. En 2019, las ENT provocaron cinco millones de muertes a nivel global, y en la región de las Américas representan casi cuatro de cada cinco muertes anuales Strategic Plan Advisory Group PAHO, 2020. En México, el CS en adultos alcanza el 40 % Campos et al., 2023. Los costos del CS se estiman en más de 300 000 millones de dólares anuales a nivel mundial, debido a costos directos de atención médica y pérdida de productividad económica Okunogbe et al., 2021. Este proyecto articula tres dimensiones convergentes: la necesidad epidemiológica de reducir el CS, el potencial tecnológico de los dispositivos portátiles para capturar datos de alta resolución y la capacidad analítica de la lógica difusa para transformar esos datos en conocimiento clínicamente significativo. Con ello, se establece un precedente metodológico para futuras investigaciones en salud digital, inteligencia artificial y promoción de la salud basada en evidencia.

Marco Teórico y Antecedentes

El presente capítulo profundiza en la comprensión del CS, un fenómeno que incide de manera significativa en la CVRS. Se definen conceptos clave, se analizan sus efectos multifacéticos en la salud y se examinan las herramientas actuales para evaluarlos, las cuales incluyen cuestionarios de autoinforme y tecnologías avanzadas. Además, se aborda el papel de la inteligencia artificial (IA) y la lógica difusa (FL) en el análisis de datos biomédicos.

2.1 Marco Teórico

2.1.1 *Delimitación Conceptual del Comportamiento Sedentario*

El Comportamiento Sedentario (CS) se define como cualquier actividad realizada en posición sentada, reclinada o acostada, mientras la persona está despierta, con un gasto energético inferior a 1,5 Unidades Metabólicas Equivalentes (*MET*) Álvarez et al., 2020; Pate et al., 2008; Tremblay et al., 2017. Esta definición se adopta en el presente trabajo por su precisión y consenso en la literatura científica, permitiendo una delimitación clara y objetiva del CS para su evaluación mediante dispositivos biométricos.

La acumulación prolongada de CS genera sedentarismo. El sedentarismo es un estilo de vida donde predominan comportamientos sedentarios durante más de 8 horas diarias Tremblay et al., 2010. Una persona puede ser considerada sedentaria incluso si practica ejercicio físico, siempre que no cumpla las recomendaciones mínimas de actividad física establecidas por la Organización Mundial de la Salud (OMS) World Health Organization, 2020a.

Esta distinción es relevante porque el CS afecta la salud incluso en personas físicamente activas. Es posible cumplir las recomendaciones de actividad física mediante ejercicio estructurado y, simultáneamente, acumular más de 8 horas diarias de CS. Este fenómeno se conoce como “físicamente activo pero sedentario” Reyes Molina et al., 2023.

El CS difiere de la inactividad física. La inactividad física se refiere a un nivel insuficiente de actividad física para cumplir las recomendaciones de la OMS. En cambio, el CS se refiere a comportamientos específicos con bajo gasto energético, independientemente del nivel total de actividad física. Por tanto, el CS puede tener un impacto negativo en la salud incluso cuando se cumplen las recomendaciones de actividad física.

2.1.2 Actividad Física y Monitoreo Cardiovascular

La Actividad Física (AF) se define como cualquier movimiento corporal producido por la contracción del músculo esquelético que aumenta el gasto energético por encima del nivel basal. Esto incluye tanto actividades estructuradas como incidentales de la vida diaria (uso de escaleras, desplazamientos activos, tareas domésticas) Caspersen et al., 1985; Reyes Molina et al., 2023. El Ejercicio Físico (EF) constituye una subcategoría planificada, estructurada y repetitiva cuyo objetivo es mejorar o mantener componentes de la aptitud física Caspersen et al., 1985.

Las Directrices de AF y Hábitos Sedentarios de la OMS (2020) establecen que “cada movimiento cuenta”. La reducción del CS requiere promover la actividad física incidental, la cual puede incrementar gradualmente la AF diaria hacia las cantidades recomendadas. Para niños y adolescentes, se recomienda un promedio de 60 minutos diarios de AF aeróbica de intensidad moderada a vigorosa a lo largo de la semana. Los adultos deben acumular entre 150 y 300 minutos de AF aeróbica de intensidad moderada, o bien entre 75 y 150 minutos de intensidad vigorosa por semana Bull et al., 2020; World Health Organization, 2020a, 2020b.

La intensidad de la AF se cuantifica mediante Unidades Metabólicas Equivalentes (*MET*). Un *MET* corresponde al consumo de oxígeno en reposo y sentado, establecido en estudios clásicos de fisiología del ejercicio como $3,5 \text{ ml} \times \text{kg}^{-1} \times \text{min}^{-1}$ Riebe et al., 2018. Los *MET* proporcionan la relación entre la tasa de energía gastada durante una actividad y la tasa de energía gastada en reposo, como se muestra en la ecuación 2.1:

$$\text{MET} = \frac{\text{VO}_2 \text{ durante la actividad}}{\text{VO}_2 \text{ en reposo}} = \frac{\text{VO}_2 \text{ durante la actividad}}{3,5 \text{ ml} \times \text{kg}^{-1} \times \text{min}^{-1}} \quad (2.1)$$

Esta relación permite una descripción estandarizada de la intensidad absoluta de las actividades físicas.

La Frecuencia Cardíaca (FC) es el método más utilizado para controlar la intensidad de la actividad física. Este método se fundamenta en la correlación lineal entre FC y consumo de oxígeno máximo ($\text{VO}_{2\text{máx}}$) Abellán et al., 2014. La FC máxima ($\text{FC}_{\text{máx}}$) se estima mediante fórmulas validadas, como se muestra en las ecuaciones 2.2 y 2.3:

$$\text{FC}_{\text{máx}} = 220 - \text{edad} \quad (2.2)$$

$$\text{FC}_{\text{máx}} = 208 - 0,7 \times \text{edad} \quad (2.3)$$

La intensidad relativa del ejercicio se cuantifica mediante zonas porcentuales: baja (40-

60 %), moderada (60-70 %), alta (70-80 %) y máxima (>80 %) Abellán et al., 2014; Fox y Haskell, 1968; Tanaka et al., 2001. En dispositivos portátiles modernos, la FC se monitorea continuamente mediante sensores de fotopletismografía (PPG), lo que permite cuantificar la intensidad instantánea de la actividad.

La variabilidad de la frecuencia cardíaca (*HRV*) representa las fluctuaciones en el tiempo entre latidos consecutivos del corazón Quigley et al., 2024; Task Force ESC/NASPE, 1996. Estas variaciones son controladas por el sistema nervioso autónomo, lo que convierte a la *HRV* en un biomarcador no invasivo y continuo del estado autonómico del individuo. El parámetro *HRV-SDNN* (desviación estándar de los intervalos NN) es una métrica común para cuantificar la *HRV* Damoun et al., 2024; Laborde et al., 2017, y proporciona información valiosa sobre el equilibrio entre los sistemas simpático y parasimpático.

Según los estándares establecidos para la interpretación de *HRV-SDNN* Damoun et al., 2024; Task Force ESC/NASPE, 1996, los valores se interpretan de la siguiente manera: valores altos (superiores a 50 ms) generalmente se asocian con un buen estado de salud y una mayor capacidad de adaptación fisiológica, mientras que valores bajos (inferiores a 30 ms) pueden indicar estrés, fatiga o condiciones de salud subyacentes. El rango normativo para *HRV-SDNN* oscila entre 15 y 150 ms.

La integración de FC y *HRV* mediante dispositivos portátiles permite un monitoreo dinámico y sensible de la respuesta fisiológica a la actividad física y el sedentarismo. Esta capacidad de monitoreo continuo es fundamental para la evaluación objetiva del CS, ya que captura tanto la intensidad de la actividad como los biomarcadores autonómicos que reflejan el impacto del comportamiento sedentario en el sistema cardiovascular Bonneval et al., 2025. En el presente trabajo, la FC y la *HRV* constituyen variables centrales para la caracterización y clasificación del CS mediante sistemas de inferencia difusa.

La capacidad de estos sistemas de inferencia difusa para proporcionar retroalimentación objetiva e inmediata sobre la respuesta fisiológica a la actividad física y el sedentarismo mediante la caracterización y clasificación del CS los posiciona como herramientas prometedoras para fomentar estilos de vida activos y saludables. Esta retroalimentación permite identificar patrones de comportamiento sedentario y ajustar estrategias de intervención de manera personalizada. Fomentar estilos de vida activos mediante esta evaluación objetiva del CS impacta positivamente en la Calidad de Vida Relacionada con la Salud (CVRS). De acuerdo con la investigación realizada por Chaves y cols., la capacidad aeróbica y la CVRS son condiciones asociadas a un declive que progresa con la edad y a estilos de vida sedentarios. En su investigación determinaron que la capacidad aeróbica tiende a disminuir a un ritmo entre 5 a 15 % por década luego que un individuo pasa de los 30 años de edad en personas sedentarias. En contraparte, las personas físicamente activas pueden

retener una reserva suficiente de aptitud aeróbica para mantener la capacidad funcional durante su edad adulta Chaves et al., 2017. Por tanto, los sistemas de inferencia difusa que integran FC y *HRV* no solo cuantifican el CS de manera objetiva, sino que también facilitan intervenciones dirigidas que pueden preservar la capacidad aeróbica y mejorar la CVRS a lo largo del ciclo vital.

2.1.3 Dispositivos Portátiles y Tecnologías de Monitoreo

Actualmente se reconoce que vivimos una “cuarta revolución industrial” o una “cuarta revolución tecnológica”, la cual precede a la era de la microelectrónica, las tecnologías de la información, las comunicaciones y el *internet* (*World Wide Web*). Esto ha derivado en grandes innovaciones como la digitalización, el manejo de grandes volúmenes de información (*Big data*), la IA, la robótica, las neurociencias y la biotecnología Martínez et al., 2020.

De acuerdo con la Comisión Electrotécnica Internacional (IEC, por sus siglas en inglés: International Electrotechnical Commission), la palabra “*wearables*” del inglés se utiliza comúnmente para referirse a los “dispositivos y tecnologías electrónicas portátiles”. La IEC define el alcance del Comité Técnico 124 (TC 124) como la “estandarización en el campo de los dispositivos y tecnologías electrónicas portátiles”. Este alcance abarca materiales y dispositivos adheribles, delgados y flexibles que pueden colocarse sobre la piel u otras superficies. Incluye también materiales y dispositivos implantables, diseñados para ubicarse quirúrgicamente debajo de la piel o dentro del cuerpo. Considera materiales y dispositivos ingeribles, capaces de desplazarse por el sistema digestivo para realizar mediciones o administrar fármacos. Finalmente, integra materiales y dispositivos textiles electrónicos, es decir, textiles con componentes electrónicos integrados Comisión Electrotécnica Internacional, 2019.

Los *wearables* modernos integran principalmente dos tipos de sensores para monitoreo de actividad y salud cardiovascular. El primero incluye acelerómetros triaxiales, que miden aceleración en tres ejes espaciales (m/s^2 o fuerza G) y permiten cuantificar movimiento corporal, conteo de pasos y estimación de gasto energético. El segundo, sensor de fotopletismografía óptica (PPG, por sus siglas en inglés: Photoplethysmography), es una técnica no invasiva basada en emisores *LED* y fotorreceptores que detectan variaciones en la absorción lumínica del flujo sanguíneo, la cual permite medir frecuencia cardíaca (FC), variabilidad cardíaca (*HRV*) y saturación de oxígeno (SpO_2) de manera continua Bent et al., 2020; Henriksen et al., 2018; Shcherbina et al., 2017; White et al., 2019. La combinación de acelerometría (actividad mecánica) y *PPG* (respuesta cardiovascular) en dispositivos de consumo como el *Apple Watch* posibilita capturar tanto el comportamiento motor como la respuesta fisiológica en condiciones de vida libre, superando las limitaciones de cuestionarios de autoinforme.

Sin embargo, los sensores físicos por sí solos generan volúmenes masivos de datos en bruto

que requieren procesamiento inteligente para transformarse en información clínicamente significativa. Los acelerómetros y sensores *PPG* capturan miles de mediciones por segundo, pero estas señales crudas no revelan patrones de comportamiento sedentario, estados de salud o riesgos cardiovasculares sin algoritmos capaces de identificar relaciones complejas entre múltiples variables biométricas. Esta necesidad de interpretación automática y aprendizaje a partir de datos convierte a las ciencias de la computación, específicamente la Inteligencia Artificial (IA) y el Aprendizaje Automático (*Machine Learning*, ML), en componentes esenciales de los sistemas de monitoreo portátil.

La IA se refiere a una disciplina y un conjunto de capacidades cognoscitivas e intelectuales expresadas por sistemas informáticos o combinaciones de algoritmos cuyo propósito es la creación de máquinas que imiten la inteligencia humana para realizar tareas, y que pueden mejorar conforme recopilen información Escalante y Martínez-Carranza, 2023. El ML constituye un subcampo de la IA que permite a los sistemas aprender y mejorar automáticamente a partir de la experiencia sin ser programados explícitamente para cada tarea Vellido, 2020. Durante la última década, la investigación de la IA en el ámbito de la salud y la medicina ha comenzado a mostrar resultados prometedores y aplicaciones prácticas, como la detección totalmente automática de nuevos biomarcadores para el diagnóstico clínico Farrahi y Rostami, 2024. La IA ha sido reconocida como una fuerza productiva y disruptiva en la atención médica, lo cual ha llevado a considerarla como una herramienta innovadora con el potencial de impactar en las prácticas clínicas J. C. Santos et al., 2021; Syed-Abdul et al., 2020.

Siendo los dispositivos *wearables* en conjunto con el ML herramientas prometedoras para el monitoreo continuo y en tiempo real de la salud, su integración permite transformar datos biométricos en conocimiento accionable. Desde relojes inteligentes hasta rastreadores de AF y ropa conectada a *internet*, los dispositivos portátiles equipados con sensores de grado clínico capturan signos vitales como la Presión Arterial (PA), la Frecuencia Respiratoria (FR), la saturación de oxígeno (SpO_2) y la temperatura de la piel. La integración inalámbrica y los algoritmos de IA permiten que estos dispositivos realicen un seguimiento de los indicadores de salud las 24 horas del día, los 7 días de la semana, y proporcionen retroalimentación personalizada a los usuarios Khan et al., 2024. Esta capacidad de monitoreo continuo y procesamiento inteligente posiciona a los *wearables* como una tecnología fundamental para la evaluación objetiva del comportamiento sedentario y el diseño de intervenciones preventivas basadas en evidencia.

La precisión de los sensores *wearables* de consumo es un factor determinante para la validez de cualquier sistema de clasificación construido sobre sus datos. O'Grady et al., 2024 realizaron un estudio de validación del *Apple Watch* Series 9 y Ultra 2 para la medición de variabilidad de frecuencia cardíaca (HRV) y frecuencia cardíaca en reposo (RHR), comparando contra el Polar

H10 como *gold standard* en una cohorte de $N = 39$ participantes. Los resultados mostraron un error porcentual absoluto medio (*MAPE*) de 28.88 % para *HRV* y 5.91 % para *RHR*, lo que indica que mientras la *RHR* se mide con alta precisión, la *HRV* presenta mayor variabilidad instrumental. Esta limitación debe considerarse al diseñar modelos que utilicen *HRV* como variable de entrada.

Un hallazgo conceptualmente relevante es el reportado por Godkin et al., 2025, quienes demostraron que la *RHR* medida durante comportamiento sedentario es significativamente diferente de la *RHR* durante el sueño, lo que refleja contextos autonómicos distintos. Esta observación eleva la clasificación de sedentarismo de un problema postural (sentado vs acostado) a un problema fisiológico (estado autonómico sedentario vs estado de sueño), justificando la inclusión de variables cardiovasculares como *HRV* en sistemas de clasificación de sedentarismo. Lyons et al., 2024 deconstruyeron el algoritmo de “Stand Hour” del *Apple Watch*, identificando los umbrales específicos de energía activa y conteo de pasos que activan esta métrica comercial. Este trabajo es crucial para entender los algoritmos de caja negra presentes en dispositivos de consumo y proporciona un punto de comparación para la interpretabilidad de modelos abiertos basados en lógica difusa.

La variabilidad de frecuencia cardíaca (*HRV*) no solo es un indicador del estado autonómico, sino que ha sido asociada con múltiples resultados de salud. Marino et al., 2024 analizaron datos de 961 adultos mayores del estudio ARIC Neurocognitive, y encontraron que mayor actividad física y mayor *HRV* se asocian con mejor función cognitiva, con una relación no lineal entre actividad física, *HRV* y salud cerebral. Este hallazgo respalda la hipótesis de que la *HRV* captura información fisiológica complementaria a las métricas de movimiento, justificando su inclusión en modelos de clasificación de comportamiento sedentario.

2.1.4 Teoría de lógica difusa para el análisis de datos biométricos

La teoría de FL, desarrollada inicialmente por Lotfi Zadeh en 1965 Zadeh, 1965, constituye una extensión de la teoría de conjuntos rígida y se basa en la idea de que la verdad no siempre es una cuestión de blanco o negro, sino que puede hallarse en un espectro de grises. A diferencia de la lógica clásica, que trabaja con valores binarios (0 o 1), la FL permite valores intermedios, lo que la hace especialmente útil para manejar información imprecisa, vaga o incierta Ross, 2010. Se ha demostrado que los sistemas difusos son aproximadores universales, lo que significa que pueden aproximar cualquier función continua con un grado de precisión arbitrario.

La base sobre la cual se asienta la teoría de sistemas difusos es un teorema fundamental del análisis real en álgebra conocido como el teorema de Stone-Weierstrass, desarrollado inicialmente por Weierstrass en 1885 y simplificado por Stone en 1937. Este teorema establece que cualquier función continua definida en un intervalo cerrado puede ser aproximada tan cerca como se desee por una función polinómica Gupta, 2011; Ross, 2010. Los sistemas difusos aprovechan este princi-

pio y tienen la capacidad de aproximar comportamientos de sistemas donde las funciones analíticas o las relaciones numéricas no existen.

Los sistemas difusos son particularmente útiles en dos contextos generales: Primero en situaciones que involucran sistemas altamente complejos cuyos comportamientos no se entienden completamente. Segundo en situaciones donde una solución aproximada pero rápida es suficiente. Estos sistemas tienen un alto potencial para comprender sistemas complejos, tales como sistemas biológicos o médicos, donde la relación entre causas y efectos no se entienden completamente, pero pueden observarse Kaur y Khehra, 2022.

El modelo de inferencia difusa se sustenta en dos principios clave propuestos por Lotfi Zadeh: la granularidad cognitiva y la ley de incompatibilidad. El principio de granularidad cognitiva reconoce que los seres humanos razonamos usando categorías lingüísticas amplias (granulares) en lugar de valores numéricos exactos. Es decir, conceptos como “nivel de actividad bajo” o “calidad de vida alta” representan gránulos de información (etiquetas lingüísticas) que aglomeran muchos estados posibles bajo una misma denominación. Esto permite manejar la vaguedad y la imprecisión inherentes a las percepciones humanas, lo que hace que el sistema sea cognitivamente interpretable. En la teoría difusa, a cada concepto lingüístico se le asocia un conjunto difuso y una función de pertenencia que indica en qué grado un valor numérico pertenece a dicho concepto Gupta, 2011; Ross, 2010. Gracias a esta granularidad, es posible describir entradas, salidas y reglas en lenguaje natural de forma simple, lo que incorpora el conocimiento experto de forma directa Gupta, 2011.

Por su parte, la ley de incompatibilidad de Zadeh establece una limitación fundamental en sistemas complejos: “cuando la complejidad aumenta, las sentencias precisas pierden significado y las sentencias significativas pierden precisión” Levitz y Levitz, 1979. En otras palabras, mientras más complejo es un fenómeno, menos útiles resultan las descripciones numéricas exactas, y se hace necesario emplear descripciones aproximadas (borrosas) para conservar significado. Este principio filosófico justifica el uso de lógica difusa en la evaluación del comportamiento sedentario y su efecto en la calidad de vida: dado que estos conceptos involucran múltiples factores humanos, es preferible modelarlos con categorías flexibles (“sedentarismo alto”, “actividad moderada”, etc.) en lugar de umbrales rígidos. La lógica difusa explota esta tolerancia a la imprecisión para lograr soluciones robustas en problemas complejos, privilegiando la significancia semántica por encima de la precisión absoluta.

2.1.5 La Lógica Difusa en la Salud Digital y el Monitoreo Biométrico

Inicialmente, las aplicaciones de la lógica difusa se concentraron en la ingeniería de control a partir de la década de 1970 Strefezza, 2009. Sin embargo, su capacidad para modelar sistemas complejos de manera más sencilla, junto con sus fundamentos matemáticos precisos, propició su

expansión a diversas áreas como la medicina. En la actualidad, los avances han llevado a una integración creciente de la lógica difusa con otras técnicas de IA y ML, dando lugar a sistemas híbridos, como los sistemas neuro-difusos Ahmadi et al., 2018. Esta fusión mejora la capacidad de procesar y analizar grandes volúmenes de datos fisiológicos en tiempo real, facilitando la identificación de patrones sutiles como lo podemos apreciar en la Tabla 2.1.

Tabla 2.1

Cuadro Comparativo de Artículos sobre Lógica Difusa en Aplicaciones Sanitarias

Técnicas de Lógica Difusa	Área de Aplicación	Tipos de Datos	Hallazgos Clave	Año
Sistema basado en lógica difusa en marco de IA, teoría de conjuntos difusos	Diagnóstico de Patologías (Informes de Laboratorio)	Parámetros cuantitativos de laboratorio (RDW, MCV)	Precisión impresionante, 83 % de probabilidad de identificar “normal”, mejora en precisión, recall y F-measure con más diagnósticos.	2024
Mapas Cognitivos Difusos (FCM), reglas difusas, variables lingüísticas	Diagnóstico de COVID-19	Síntomas clínicos (fiebre, tos, disnea, GI), historial de contacto	Herramienta viable de apoyo a la decisión, probabilidad de diagnóstico (ej. 72 % para COVID-19).	2020
Lógica difusa para pertenencia difusa, análisis multicriterio	Planificación de Comidas Personalizadas	Datos nutricionales, preferencias alimentarias, restricciones de salud	Planes de comidas flexibles y optimizados, considera múltiples factores (costo, cocina, tiempo).	2023
Lógica de primer orden con semántica difusa, algoritmo de razonamiento espacial	Reconocimiento de Nervios en Imágenes Médicas	Imágenes de RM anatómicas T2 y de difusión	Permite la planificación quirúrgica precisa, visualización de nervios en gemelo digital 3D, explicabilidad directa.	2025

Continúa en la siguiente página...

(Continuación de Tabla 2.1)

Técnicas de Lógica Difusa	Área de Aplicación	Tipos de Datos	Hallazgos Clave	Año
Sistema experto difuso, fuzzificación, mecanismo de inferencia, defuzzificación	Control Metabólico en Diabetes Mellitus Tipo 2	Edad, IMC, tabaquismo, estrés, ejercicio, tratamiento farmacológico, dieta	Asiste a médicos en la evaluación del control metabólico.	2018

Este cuadro ilustra la amplitud y profundidad de las aplicaciones de la lógica difusa en entornos clínicos, evidenciando su versatilidad metodológica y justificando su selección como herramienta para el análisis de datos biométricos en el presente trabajo. Al organizar sistemáticamente la información, permite una rápida visión general de los avances, facilita la comparación de diferentes enfoques metodológicos y sus idoneidades para diversos problemas clínicos, y destaca los resultados tangibles y las mejoras de rendimiento logradas por estos sistemas.

La lógica difusa es una herramienta que se utiliza cada vez más en sistemas de Internet de las Cosas (IoT, por sus siglas en inglés: *Internet of Things*) para la reducción y el análisis de datos, así como para el diagnóstico inteligente de enfermedades, al gestionar las incertidumbres y proporcionar enfoques robustos. El concepto de “sistemas difusos con *Big data* y computación en la nube” es también un tema destacado en foros como FUZZ-IEEE 2025. La investigación actual muestra que la lógica difusa rara vez se utiliza de forma aislada en las aplicaciones de vanguardia en el sector sanitario Alam et al., 2022. En cambio, se integra cada vez más con otros paradigmas de IA, como las redes neuronales, el aprendizaje automático y el IoT. Esta hibridación responde a la necesidad de combinar las fortalezas de la lógica difusa (manejo de la incertidumbre, interpretabilidad) con las capacidades de aprendizaje y escalabilidad de otros métodos de IA. Esta tendencia indica que los problemas complejos de atención médica requieren soluciones de IA multifacéticas, donde cada componente aporta su ventaja única, lo que conduce a sistemas más robustos, adaptativos e inteligentes.

2.1.6 Agrupamiento No Supervisado y el Vacío Metodológico en Clasificación de Sedentarismo

Los enfoques actuales para clasificar comportamiento sedentario mediante dispositivos portátiles presentan limitaciones metodológicas significativas. El agrupamiento no supervisado ofrece una alternativa para establecer etiquetas de referencia, pero su integración con sistemas de inferencia difusa constituye un vacío metodológico en la literatura.

El agrupamiento (también conocido como *clustering*) es una técnica de aprendizaje automático no supervisado que particiona un conjunto de datos en grupos homogéneos sin requerir etiquetas predefinidas Yoo et al., 2012. En el contexto de dispositivos portátiles y análisis de actividad física, esta técnica se ha aplicado principalmente como herramienta de ingeniería de características: los grupos identificados constituyen el resultado final (descubrimiento de fenotipos) o una característica intermedia para otro modelo, pero no se utilizan tradicionalmente para generar etiquetas de verdad de referencia que parametrizan un clasificador interpretable.

Frente a esta limitación del agrupamiento tradicional, el estándar de facto actual en clasificación de sedentarismo se basa en umbrales heurísticos fijos, como el enfoque más utilizado en evaluación de fragilidad mediante dispositivos portátiles, que emplea la Desviación Absoluta Media (MAD) de aceleración con umbrales predefinidos (Sedentario: $MAD < 1,5 MET$; Actividad ligera: $1,5 \leq MAD < 3,0 MET$; Actividad moderada-vigorosa: $MAD \geq 3,0 MET$) Razjouyan et al., 2018. Este enfoque presenta limitaciones: (1) los umbrales (1.5, 3.0 *MET*) son fijos y no se ajustan por diferencias inter-individuales en capacidad aeróbica, (2) la MAD es un estimador indirecto de gasto energético con validez variable entre dispositivos, y (3) no captura la estructura multivariada de datos de dispositivos portátiles modernos (frecuencia cardíaca + aceleración + contexto). El agrupamiento no supervisado emerge como una alternativa metodológica que permite establecer etiquetas de referencia directamente desde los datos, superando estas limitaciones. Esta capacidad del agrupamiento para generar etiquetas de referencia sin depender de criterios externos predefinidos lo posiciona como una herramienta teórica fundamental para abordar la clasificación de comportamiento sedentario en contextos de vida libre, donde la ausencia de etiquetas estandarizadas constituye un desafío metodológico central.

2.1.7 Mecanismos de Validación en Estudios con Dispositivos Portátiles

La selección del mecanismo de validación constituye una decisión metodológica fundamental que determina la validez y generalización de los resultados. El enfoque tradicional de división entrenamiento-prueba (*split* 80/20) es ampliamente utilizado en aprendizaje automático cuando se dispone de conjuntos de datos grandes e independientes Pedregosa et al., 2011. Este

método divide aleatoriamente los datos en dos subconjuntos: aproximadamente el 80 % para entrenar el modelo y el 20 % para evaluar su rendimiento. Esta estrategia es apropiada cuando los datos son independientes e idénticamente distribuidos, no presentan estructura temporal y el tamaño de muestra es suficientemente grande para garantizar representatividad estadística en ambos subconjuntos. Sin embargo, estudios recientes han documentado que esta aproximación puede sobrestimar significativamente el rendimiento cuando se aplica a datos longitudinales de dispositivos portátiles, donde una división 70/30 alcanzó un *Accuracy* de 95.7 % que se redujo a 90.3 % al emplear validación *Leave-One-Subject-Out* (*LOSO*) Bassani et al., 2025, evidenciando la necesidad de estrategias de validación más rigurosas en este contexto.

Sin embargo, en estudios con dispositivos portátiles que generan datos longitudinales de múltiples usuarios, el *split* 80/20 presenta limitaciones críticas Mathew et al., 2024; Rehman et al., 2024. Cuando los datos provienen de series temporales autocorrelacionadas de un número reducido de participantes, una división aleatoria introduce dos problemas fundamentales: (1) fuga temporal (*temporal leakage*), donde observaciones del mismo usuario aparecen tanto en entrenamiento como en prueba, permitiendo que el modelo “vea el futuro” y sobrestime su capacidad de generalización, y (2) fuga de identidad (*identity leakage*), donde el modelo aprende características idiosincráticas específicas de individuos particulares en lugar de patrones generalizables a nuevos usuarios Rehman et al., 2024.

Para datos longitudinales de dispositivos portátiles con múltiples usuarios, la validación cruzada tradicional (*k-fold*) también es inapropiada porque mezcla observaciones correlacionadas del mismo usuario entre los pliegues, perpetuando los problemas de fuga temporal e identidad Rehman et al., 2024. En estos contextos, la validación Dejar-Uno-Fuera por Usuario (conocida como *Leave-One-User-Out* o *LOUO*, también denominada *Leave-One-Subject-Out* o *LOSO*) emerge como el estándar metodológico para evaluar generalización inter-sujeto Ji et al., 2023; Rehman et al., 2024. En *LOUO*, el modelo se entrena con datos de $N - 1$ usuarios y se valida con el usuario restante, iterando hasta probar con todos los N usuarios. Esta estrategia simula el despliegue real del sistema en nuevos usuarios, evitando sobreajuste a individuos específicos y proporcionando una estimación realista de la capacidad de generalización del modelo.

La viabilidad de *LOUO* en cohortes pequeñas ($N < 20$) ha sido demostrada en múltiples estudios de alto impacto, particularmente cuando se dispone de datos longitudinales ricos (múltiples mediciones por usuario) Bolger y Laurenceau, 2013; Ji et al., 2023. En estos escenarios, la densidad de observaciones por individuo compensa parcialmente la limitación del tamaño de muestra, permitiendo desarrollar modelos con métricas aceptables que generalicen a nuevos usuarios Mathew et al., 2024. Esta capacidad de *LOUO* para aprovechar eficientemente datos longitudinales densos posiciona esta estrategia de validación como fundamental para estudios con

dispositivos portátiles en contextos de vida libre, donde la obtención de grandes cohortes es logísticamente desafiante pero la recolección de datos longitudinales extensos es factible.

2.2 Antecedentes

Esta sección presenta una revisión sistemática de las investigaciones previas relacionadas con la clasificación del comportamiento sedentario mediante dispositivos *wearables* y técnicas de inteligencia artificial. Se analizan los enfoques metodológicos, las limitaciones identificadas y las brechas que justifican la presente investigación.

2.2.1 Investigaciones Previas Relacionadas

La clasificación del comportamiento sedentario y la actividad física mediante dispositivos *wearables* ha experimentado un crecimiento exponencial en la última década, impulsado por la disponibilidad de sensores de consumo de bajo costo y el avance de las técnicas de inteligencia artificial. Los estudios recientes abordan este desafío desde múltiples perspectivas metodológicas, cada una con ventajas y limitaciones específicas en términos de precisión, interpretabilidad y generalización.

2.2.2 Enfoques de Deep Learning y Redes Neuronales

Los enfoques de aprendizaje profundo han demostrado capacidades sobresalientes en el reconocimiento de patrones complejos en datos de sensores *wearables*. Khan et al., 2024 desarrollaron un sistema de reconocimiento de actividad física con redes neuronales convolucionales (CNNs) y redes *LSTM* para procesar datos de sensores inerciales, y lograron alta precisión en la clasificación de movimientos. Sin embargo, estos modelos enfrentan dos limitaciones críticas: requieren conjuntos de datos masivos para entrenamiento y operan como “cajas negras”, dificultando la interpretación clínica de sus decisiones Bienefeld et al., 2023.

Un hallazgo particularmente relevante es el reportado por Bassani et al., 2025, quienes compararon el rendimiento de algoritmos de *deep learning* mediante una división 70/30 frente a validación *Leave-One-Subject-Out (LOSO)*. Los resultados mostraron una caída significativa del rendimiento: *Accuracy* de 95.7 % en la división 70/30 versus 90.3 % en *LOSO*, lo que evidencia que la generalización robusta a nuevos usuarios requiere protocolos de validación más estrictos. Esta observación es fundamental para evaluar la aplicabilidad real de sistemas de clasificación en escenarios clínicos.

2.2.3 *Machine Learning* Clásico y Validación Cruzada

Los algoritmos de aprendizaje automático clásico, como *Random Forest* y *Support Vector Machines*, han sido ampliamente utilizados para la clasificación de actividades debido a su balance entre precisión y eficiencia computacional. Fuller et al., 2021 aplicaron *Random Forest* para clasificar posturas (*lying, sitting, walking, running*) con datos de *Apple Watch* y *Fitbit*, y alcanzaron una precisión superior al 90 % mediante validación *Leave-One-Out Cross-Validation (LOOCV)* en una cohorte de 33 participantes. Este estudio validó el modelo *Bring-Your-Own-Device (BYOD)*, lo que demuestra la factibilidad de utilizar dispositivos de consumo en investigación clínica.

La importancia de la validación cruzada estricta ha sido enfatizada por Rehman et al., 2024, quienes compararon el rendimiento de *Random Forest* utilizando *LOSO* versus *k-fold cross-validation*. Sus resultados mostraron que *LOSO* produjo un *Accuracy* del 76 %, significativamente inferior al 89 % obtenido con *k-fold*. Los autores atribuyen esta diferencia al *data leakage* (fuga de datos) presente en *k-fold* cuando se aplica a datos de sensores *wearables*. Esta evidencia justifica la adopción de *LOUO (Leave-One-User-Out)* como estándar metodológico para evaluar la generalización inter-usuario.

El estudio de Mathew et al., 2024 refuerza esta conclusión al analizar el uso funcional de la mano en niños con parálisis cerebral unilateral mediante acelerómetros de muñeca. Los autores reportaron un *F1-Score* de 0.896 con modelos personalizados por sujeto, que se redujo drásticamente a 0.584 al aplicar validación *LOSO*. Este fenómeno de sobreajuste es particularmente pronunciado en cohortes pequeñas ($N = 22$), lo que refleja la dificultad de capturar la variabilidad inter-individual con tamaños de muestra limitados.

2.2.4 *Lógica Difusa y Sistemas de Inferencia Interpretables*

La lógica difusa emerge como una alternativa metodológica que prioriza la interpretabilidad sobre la precisión bruta, característica especialmente valiosa en aplicaciones biomédicas donde la confianza clínica depende de la transparencia del proceso de decisión. Marashi-Hosseini et al., 2023 desarrollaron un sistema de decisión dietética para pacientes con múltiples condiciones crónicas mediante un sistema de inferencia difusa tipo *Mamdani* con 1144 reglas lingüísticas, y alcanzaron una precisión del 97 % al compararse con las recomendaciones de nutricionistas expertos ($N = 100$). Este estudio demuestra que la lógica difusa puede igualar la precisión de enfoques estadísticos complejos mientras mantiene una estructura de conocimiento explícita y modificable.

La interpretabilidad total de los sistemas difusos ha sido destacada por Capitoli et al., 2025, quienes proponen un modelo de lógica difusa probabilística para diagnóstico clínico que permite a los médicos “generar, controlar y verificar todo el procedimiento de diagnóstico”. Este enfoque

posiciona a la lógica difusa no solo como un clasificador, sino como una herramienta de Inteligencia Artificial Explicable (XAI) que genera confianza clínica mediante la exposición completa de su razonamiento.

Un precedente metodológico particularmente relevante para la presente investigación es el trabajo de Gonçalves et al., 2021, quienes desarrollaron un sistema de reconocimiento de actividad humana combinando *clustering K-Means* ($k = 2$) con un sistema de inferencia difusa *Mamdani*. Este es el único precedente identificado en la literatura de un enfoque híbrido que emplea *clustering* no supervisado para establecer una verdad operativa, seguido de un sistema difuso supervisado. Este diseño metodológico resuelve el desafío de la ausencia de etiquetas de referencia estandarizadas en datos de vida libre, al tiempo que preserva la interpretabilidad del modelo final.

2.2.5 Análisis Comparativo de Investigaciones

La Tabla 2.2 presenta un análisis comparativo de investigaciones clave relacionadas con la clasificación de comportamiento sedentario y actividad física mediante dispositivos *wearables*. La tabla destaca estudios metodológicamente relevantes que emplean validación cruzada *Leave-One-User-Out (LOUO/LOSO)*, *wearables* comerciales (*Apple Watch*) y técnicas de lógica difusa. Para un análisis exhaustivo de la literatura que incluye 17 investigaciones representativas, consultar el Anexo B.

tabularx

Tabla 2.2

Investigaciones clave sobre clasificación de sedentarismo y actividad física con wearables (tabla condensada)

Autor (Año)	Objetivo	Técnica	Validación	Métrica Principal	Resultado
Gonçalves et al. (2021)	Reconocimiento actividad	<i>K-Means</i> ($k = 2$) → FIS <i>Mamdani</i>	Validación estabilidad	Estabilidad clasificación	ÚNICO precedente
Gonçalves et al., 2021	humana con <i>clustering</i> + <i>fuzzy</i>				<i>clustering</i> → <i>fuzzy</i> supervisado

Continúa en la siguiente página...

(Continuación de Tabla 2.2)

Autor (Año)	Objetivo	Técnica	Validación	Métrica Principal	Resultado
Fuller <i>et al.</i> . (2021) Fuller et al., 2021	Clasificación lying, sitting, walking, running con <i>Apple Watch</i> + Fitbit	Random Forest	<i>LOOCV</i>	<i>Accuracy</i>	<i>Accuracy</i> >90 % para posturas. <i>BYOD</i> validado
Mathew <i>et al.</i> . (2024) Mathew et al., 2024	Medición uso funcional mano en parálisis cerebral unilateral con <i>ML</i>	<i>Machine Learning</i> (varios modelos)	Personalizado vs <i>LOSO</i>	<i>F1-Score</i>	Personalizado: $F1=0.896 \rightarrow$ <i>LOSO</i> : $F1=0.584$. Evidencia sobreajuste <i>N</i> pequeño
Rehman <i>et al.</i> . (2024) Rehman et al., 2024	Estudio comparativo validación + extracción características en <i>HAR wearables</i>	<i>Random Forest</i>	<i>LOSO</i> vs <i>k-fold</i>	<i>Accuracy</i>	<i>LOSO</i> : 76 % vs <i>k-fold</i> : 89 %. <i>Data leakage</i> justifica <i>LOUO</i>
Godkin <i>et al.</i> . (2025) Godkin et al., 2025	Medir RHR durante vida diaria: impacto contexto conductual + criterios metodológicos	Estudio observacional	Análisis contextual	RHR por contexto	RHR sedentario $\neq$ RHR sueño. Contextos autonómicos diferentes. Clasificación fisiológica vs postural

Continúa en la siguiente página...

(Continuación de Tabla 2.2)

Autor (Año)	Objetivo	Técnica	Validación	Métrica Principal	Resultado
O'Grady <i>et al.</i> , (2024)	Validación <i>HRV</i> + RHR en <i>Apple Watch</i> Series 9 y Ultra 2	Estudio de validación	Validación concurrente	MAPE	HRV MAPE=28.88 %, RHR MAPE=5.91 %. Limitaciones sensor PPG

Como se observa en la Tabla 2.2 (y detallado exhaustivamente en el Anexo B: Tabla 8.1), las investigaciones previas han abordado la clasificación del comportamiento sedentario y la actividad física desde múltiples perspectivas metodológicas, incluyendo *deep learning*, *machine learning* clásico, lógica difusa, métodos estadísticos avanzados y estudios de validación de dispositivos *wearables*. Sin embargo, el análisis comparativo revela la existencia de limitaciones metodológicas y conceptuales significativas que restringen la aplicabilidad clínica y la generalización de los sistemas de clasificación actuales.

A pesar de la existencia de un precedente metodológico Gonçalves *et al.*, 2021 que combina *clustering K-Means* con un sistema de inferencia difusa *Mamdani*, no se identifica ningún estudio que haya validado este enfoque híbrido mediante protocolos de *Leave-One-User-Out (LOUO)*. La evidencia presentada por Rehman *et al.*, 2024, Mathew *et al.*, 2024 y Bassani *et al.*, 2025 demuestra consistentemente que la validación *LOUO* produce caídas significativas en el rendimiento en comparación con métodos de validación menos rigurosos (e.g., *k-fold*, división 70/30), lo que evidencia problemas de generalización inter-usuario. Esta limitación es particularmente crítica para sistemas destinados a aplicaciones clínicas donde la generalización a nuevos pacientes es un requisito fundamental.

La mayoría de los estudios de clasificación de sedentarismo se basan exclusivamente en señales de movimiento (acelerómetro, giroscopio), abordando el problema desde una perspectiva postural (sentado, acostado, de pie) en lugar de fisiológica. El hallazgo de Godkin *et al.*, 2025, que demuestra que la frecuencia cardíaca en reposo (RHR) durante comportamiento sedentario es significativamente diferente de la RHR durante el sueño, evidencia la existencia de contextos autonómicos distintos. Adicionalmente, Marino *et al.*, 2024 muestran que mayor *HRV* se asocia con mejor salud cognitiva, independientemente del nivel de actividad física. Sin embargo, no se identifica ningún estudio que haya utilizado *HRV* como variable de entrada para clasificar com-

portamiento sedentario, a pesar de su potencial para diferenciar estados fisiológicos (sedentarismo activo vs. sedentarismo pasivo) que no son discernibles mediante acelerometría sola.

Los enfoques de *deep learning* Bassani et al., 2025; Khan et al., 2024 alcanzan precisiones elevadas (90-95 %) pero operan como cajas negras, dificultando su adopción en contextos clínicos donde la confianza del profesional de salud depende de la transparencia del proceso de decisión Bienefeld et al., 2023. Por el contrario, los sistemas de lógica difusa Capitoli et al., 2025; Marashi-Hosseini et al., 2023 ofrecen interpretabilidad total mediante reglas lingüísticas, pero su precisión reportada proviene de aplicaciones en diagnóstico clínico (con variables clínicas discretas) y no en datos de sensores *wearables* continuos. No existe evidencia de sistemas de lógica difusa aplicados a datos de *Apple Watch* (acelerómetro + fotopletimografía) para la clasificación de sedentarismo, dejando sin resolver si la interpretabilidad puede preservarse sin sacrificar precisión en este dominio específico.

La mayoría de los estudios identificados utilizan protocolos de recolección de datos de corta duración (días o semanas) en entornos semi-controlados. Fuller et al., 2021 validaron el paradigma *Bring-Your-Own-Device (BYOD)* con *Apple Watch* y Fitbit, pero con un período de seguimiento no especificado. No se identifica ningún estudio que haya utilizado datos de *Apple Watch* recolectados durante múltiples años (seguimiento longitudinal multi-anual) en condiciones de vida libre sin restricciones, a pesar de que este paradigma refleja con mayor fidelidad el uso real de *wearables* de consumo por parte de la población general. Esta limitación restringe la validez ecológica de los modelos desarrollados en entornos controlados.

Los estudios identificados con validación *LOUO* utilizan cohortes de tamaño moderado a grande: Fuller et al., 2021 ($N = 33$), Mathew et al., 2024 ($N = 22$), O'Grady et al., 2024 ($N = 39$), Marino et al., 2024 ($N = 961$). El caso de Mathew et al., 2024 con $N = 22$ demostró una caída dramática en *F1-Score* ($0.896 \rightarrow 0.584$) al aplicar *LOUO*, atribuida en parte al tamaño de muestra limitado. Sin embargo, no se identifica ningún estudio que haya desarrollado y validado un sistema de clasificación con $N = 10$ o menos, un escenario común en estudios piloto, investigaciones clínicas con poblaciones raras, o fases iniciales de desarrollo de dispositivos médicos. Bolger y Laurenceau, 2013 han demostrado que diseños longitudinales intensivos pueden compensar parcialmente tamaños de muestra pequeños, pero esta estrategia no ha sido aplicada en el contexto de clasificación de sedentarismo con *wearables*.

Delimitación del Objeto de Estudio

Este capítulo delimita el objeto de estudio de la investigación mediante la identificación del problema, la formulación de la pregunta de investigación, el planteamiento de hipótesis y el establecimiento de objetivos específicos.

3.1 Problema de Investigación

La evaluación precisa del comportamiento sedentario constituye un pilar fundamental para la estratificación del riesgo y el diseño de intervenciones efectivas en salud pública. Evidencia reciente de meta-análisis a gran escala confirma su asociación independiente con un mayor riesgo de mortalidad por todas las causas, incidencia de enfermedades cardiovasculares y diabetes mellitus tipo 2 Katzmarzyk, 2023; A. C. Santos et al., 2023. Sin embargo, los métodos de evaluación convencionales presentan una dicotomía metodológica que limita su aplicabilidad y precisión. Los instrumentos subjetivos, como los cuestionarios de autoinforme, aunque escalables, adolecen de sesgos de memoria y deseabilidad social que comprometen su validez Healy et al., 2024; Prince et al., 2008. En contraparte, las técnicas objetivas de referencia, como la calorimetría indirecta o la actigrafía de grado investigativo, se restringen a entornos de laboratorio que no capturan la complejidad del comportamiento en condiciones de vida libre Migueles et al., 2022.

La ubicuidad de los dispositivos portátiles de consumo ha generado una oportunidad sin precedentes para la monitorización objetiva, continua y longitudinal del comportamiento en el entorno ecológico del individuo. No obstante, la transición de la recolección masiva de datos a la generación de conocimiento clínicamente accionable presenta un desafío metodológico significativo. El reto principal reside en traducir flujos de datos multivariados y heterogéneos —actividad física, patrones de frecuencia cardíaca, variabilidad de la frecuencia cardíaca (*HRV*) y gasto energético— en una clasificación del sedentarismo que sea fisiológicamente significativa e individualizada Deka y Deka, 2023. Los modelos de inteligencia artificial basados en aprendizaje profundo, comúnmente denominados “de caja negra”, aunque han demostrado una alta precisión en la clasificación de actividades, a menudo carecen de la interpretabilidad necesaria para su adopción en la práctica clínica, donde la auditabilidad de una recomendación es un imperativo ético y profesional Vellido, 2020.

El análisis de la literatura revela brechas metodológicas significativas que justifican la presente investigación. A pesar de la existencia de un precedente metodológico que combina *clustering K-Means* con sistemas de inferencia difusa Mamdani, no se identifica ningún estudio que

haya validado este enfoque híbrido mediante protocolos de *Leave-One-User-Out (LOUO)*, estrategia esencial para evaluar la generalización inter-usuario en aplicaciones clínicas Bassani et al., 2025; Mathew et al., 2024; Rehman et al., 2024. Adicionalmente, la mayoría de los estudios de clasificación de sedentarismo se basan exclusivamente en señales de movimiento (acelerómetro, giroscopio), abordando el problema desde una perspectiva postural en lugar de fisiológica, y no se identifica ningún estudio que haya utilizado *HRV* como variable de entrada para clasificar comportamiento sedentario, a pesar de su potencial para diferenciar estados fisiológicos distintos Godkin et al., 2025; Marino et al., 2024. Asimismo, no existe evidencia de sistemas de lógica difusa aplicados a datos de *Apple Watch* (acelerómetro + fotopletismografía) para la clasificación de sedentarismo, ni estudios que hayan utilizado datos recolectados durante múltiples años en condiciones de vida libre sin restricciones, limitando la validez ecológica de los modelos desarrollados Fuller et al., 2021. Finalmente, no se identifica ningún estudio que haya desarrollado y validado un sistema de clasificación con $N = 10$ o menos, un escenario común en estudios piloto y fases iniciales de desarrollo Bolger y Laurenceau, 2013.

Este vacío metodológico —la ausencia de un sistema que integre de forma sinérgica múltiples biomarcadores de vida libre en una clasificación del sedentarismo que sea robusta, empíricamente validada e interpretable— constituye el núcleo del problema que se aborda en esta investigación. Los análisis estadísticos univariados han resultado insuficientes para capturar las complejas interacciones no lineales entre la actividad física, la función autonómica y la respuesta metabólica Aubert et al., 2022. Por ejemplo, la relación entre el *HRV* y la actividad física es intrínsecamente no lineal y dependiente del contexto, lo que requiere enfoques de modelado que puedan manejar la incertidumbre y la vaguedad inherentes a los sistemas biológicos Deka y Deka, 2023.

Para resolver este problema, esta investigación desarrolló un sistema de evaluación basado en un sistema de inferencia difusa tipo *Mamdani*. Este enfoque se apartó de una hipótesis inicial centrada en correlacionar datos objetivos con percepciones subjetivas, para en su lugar, validar el sistema experto contra una “verdad operativa” derivada de los propios datos mediante un análisis de conglomerados no supervisado. De este modo, el estudio se enfocó en resolver el problema fundamental de crear un clasificador objetivo, interpretable y validado para el comportamiento sedentario en condiciones de vida libre. El clasificador utiliza datos longitudinales recopilados a través de dispositivos de consumo.

3.2 Pregunta de Investigación

¿De qué manera un sistema basado en lógica difusa puede clasificar el comportamiento sedentario a partir de datos biométricos recopilados en condiciones de vida libre por dispositivos “wearables”?

3.3 Hipótesis

3.3.1 *Hipótesis Conceptual (HC)*

La clasificación del comportamiento sedentario generada por el sistema de inferencia difusa, basado en reglas que integran biomarcadores de actividad y función cardiovascular, exhibe una alta concordancia con la clasificación objetiva obtenida mediante un análisis de conglomerados no supervisado sobre los mismos datos.

3.3.2 *Hipótesis Nula (H_0)*

No existe una concordancia estadísticamente significativa entre la clasificación del comportamiento sedentario generada por el sistema de inferencia difusa y la clasificación obtenida mediante el análisis de conglomerados. Cualquier concordancia observada no es superior a la que se obtendría por azar.

3.4 Objetivo General

Construir y validar un sistema interpretable, basado en lógica difusa, para la clasificación del comportamiento sedentario a partir de datos biométricos de *wearables* recopilados en condiciones de vida libre.

3.5 Objetivos Específicos

1. Analizar los datos biométricos longitudinales para derivar un conjunto de variables semanales que representen cuantitativamente los patrones de actividad física y función cardiovascular de la cohorte de estudio.
2. Identificar los perfiles de comportamiento sedentario inherentes a los datos mediante la aplicación de un algoritmo de agrupamiento no supervisado, para establecer una clasificación de referencia empírica.
3. Diseñar un sistema de inferencia difusa que modele la relación entre las variables biométricas y los perfiles de comportamiento, el cual establezca reglas lingüísticas con fundamento fisiológico.
4. Evaluar el desempeño del sistema de inferencia difusa mediante la determinación de su nivel de concordancia con los perfiles de comportamiento identificados por el método de agrupamiento.



5. Examinar la contribución de los componentes del sistema a través de un análisis de sensibilidad para determinar la importancia relativa de sus variables de entrada en el rendimiento clasificatorio.

Justificación

La prevalencia del comportamiento sedentario (CS) en la sociedad contemporánea es un fenómeno alarmante que afecta significativamente la salud y la calidad de vida de las personas Guthold et al., 2020; Swinburn et al., 2019. La Organización Mundial de la Salud (OMS) ha identificado el CS como uno de los principales factores de riesgo para enfermedades no transmisibles, tales como enfermedades cardiovasculares, diabetes tipo 2 y ciertos tipos de cáncer DiPietro et al., 2020; Murray et al., 2020; Okunogbe et al., 2021; World Health Organization, 2009. Además, el sedentarismo tiene un impacto negativo en la salud mental y genera una disminución en la calidad de vida relacionada con la salud DiPietro et al., 2020; Guthold et al., 2020; Swinburn et al., 2019.

Los métodos tradicionales para evaluar el comportamiento sedentario presentan una dicotomía metodológica. Por un lado, los instrumentos subjetivos como los cuestionarios de autoinforme son escalables, pero sufren sesgos de memoria y de deseabilidad social. Por otro, las técnicas objetivas de referencia, entre ellas la calorimetría indirecta y la actigrafía utilizada en investigación, se restringen a entornos de laboratorio que no reflejan la complejidad del comportamiento en condiciones de vida libre Healy et al., 2024; Migueles et al., 2022; Prince et al., 2008. Esta limitación metodológica fundamenta la necesidad de enfoques innovadores que integren objetividad mediante mediciones continuas con sensores, validez ecológica a través de recopilación en contextos reales e interpretabilidad mediante clasificaciones auditables clínicamente.

La presente investigación abordó este vacío mediante el desarrollo y validación de un sistema de inferencia difusa tipo *Mamdani* que clasifica el comportamiento sedentario a partir de datos biométricos multivariados obtenidos de dispositivos portátiles de consumo (*Apple Watch*) bajo el paradigma *Bring Your Own Device (BYOD)*. Este enfoque metodológico integró tres componentes innovadores: (1) normalización fisiológica individualizada de variables (Actividad Relativa, Supéravit Calórico Basal, Delta Cardíaco, *HRV-SDNN*), (2) establecimiento de una verdad operativa mediante *clustering* no supervisado (evitando umbrales heurísticos predefinidos), y (3) validación rigurosa mediante *Leave-One-User-Out* para garantizar generalización inter-sujeto.

La relevancia científica de este trabajo reside en su contribución al campo emergente de la inteligencia artificial explicable aplicada a salud pública. A diferencia de modelos de caja negra como las redes neuronales profundas, el sistema difuso propuesto es inherentemente interpretable mediante reglas lingüísticas auditables, una característica crítica para la adopción clínica donde la transparencia algorítmica es un imperativo ético. Además, la demostración empírica de que el paradigma *BYOD* puede generar datos de calidad investigativa sin comprometer la integridad de las mediciones representa un avance significativo hacia la democratización de la investigación en



salud, lo cual permite estudios longitudinales a gran escala sin requerir equipamiento especializado costoso.

Desde la perspectiva de salud pública, esta investigación aporta evidencia sobre la factibilidad de sistemas de vigilancia del sedentarismo basados en datos pasivamente capturados por *wearables* de consumo masivo. La validación del sistema contra una verdad operativa derivada de *clustering* no supervisado demuestra que es posible clasificar con alta fiabilidad los patrones de comportamiento sedentario en condiciones de vida libre, sentando las bases para el diseño de intervenciones digitales personalizadas y programas de monitoreo comunitario escalables. En un contexto nacional donde la prevalencia de sedentarismo alcanza el 40 % en adultos según ENSA-NUT 2022 Shamah-Levy et al., 2023, la disponibilidad de herramientas objetivas, escalables e interpretables para su evaluación constituye una contribución estratégica para el cumplimiento de la meta 3.4 de los Objetivos de Desarrollo Sostenible (reducir en un tercio la mortalidad prematura por ENT para 2030).

Materiales y Métodos

Este capítulo detalla la metodología empleada en la investigación, incluyendo el diseño del estudio, la selección del dispositivo *wearable*, el protocolo de reclutamiento de participantes, la extracción y preprocesamiento de datos biométricos, el desarrollo de variables derivadas mediante ingeniería de características, el establecimiento de la verdad operativa mediante *clustering* no supervisado, el diseño del sistema de inferencia difusa tipo *Mamdani*, y el protocolo de validación cruzada *Leave-One-User-Out*. Describimos el procedimiento completo desde la aprobación ética inicial hasta la validación final del modelo, lo cual facilita la comprensión del proceso metodológico y garantiza la reproducibilidad de los hallazgos en estudios futuros.

5.1 Diseño del Estudio y Aprobaciones Éticas

Empleamos un diseño cuantitativo con enfoque exploratorio-correlacional, de tipo longitudinal retrospectivo con seguimiento multianual (2021-2024) de una cohorte de 10 participantes adultos, de naturaleza observacional de un solo corte y sin grupo control. El componente exploratorio del estudio reside en el descubrimiento de patrones latentes de comportamiento sedentario mediante técnicas de *clustering* no supervisado aplicadas a datos biométricos recolectados en condiciones de vida libre, mientras que el componente correlacional se manifiesta en la validación de la concordancia entre dos métodos independientes: la clasificación obtenida mediante agrupamiento *K-Means* y la clasificación generada por el sistema de inferencia difusa *Mamdani*. Este diseño se fundamenta en el paradigma *Bring Your Own Device (BYOD)*, el cual minimiza el efecto Hawthorne al utilizar dispositivos que los participantes ya poseían y empleaban regularmente en su vida cotidiana, garantizando validez en condiciones naturales de actividad Doherty et al., 2021.

El protocolo de investigación fue sometido a escrutinio y aprobación por parte del Comité de Investigación y el Comité de Ética en Investigación de la Facultad de Medicina y Ciencias Biomédicas de la Universidad Autónoma de Chihuahua. Obtuvimos el primer dictamen favorable del Comité de Investigación el 17 de febrero de 2025, documentado mediante el Oficio SIP/116/25 con asignación de registro interno de proyecto CI-088-24. Posteriormente, el Comité de Ética en Investigación aprobó el protocolo completo el 21 de agosto de 2025 bajo el mismo número de registro CI-088-24, lo cual nos permitió lanzar la convocatoria abierta para reclutamiento de participantes a partir de esa fecha. El estudio se estructuró en un seguimiento retrospectivo que abarcó datos biométricos recopilados de forma continua por los participantes durante sus actividades diarias habituales, con una mediana de seguimiento de 131 semanas por participante. La unidad de análisis correspondió a semanas completas de monitoreo, las cuales generamos mediante la agregación

temporal de los 9,185 días válidos recopilados de forma continua por los dispositivos *Apple Watch*, decisión metodológica que fundamentamos en la necesidad de reducir el ruido inherente a las mediciones diarias en condiciones de vida libre mediante estadísticos robustos, como desarrollaremos en la Sección 5.11.

Debemos mencionar que el diseño inicial del estudio contemplaba un enfoque supervisado que buscaba predecir la Calidad de Vida Relacionada con la Salud (CVRS), evaluada mediante el cuestionario SF-36, a partir de métricas biométricas continuas del *Apple Watch*. Sin embargo, el análisis exploratorio de correlaciones entre biométricos agregados y dimensiones del SF-36 reveló asociaciones débiles a moderadas ($0,09 \leq |r| \leq 0,45$), ninguna de las cuales sobrevivió corrección de Bonferroni para comparaciones múltiples. Adicionalmente, intentos de modelado mediante Redes Neuronales Artificiales (ANN) con múltiples configuraciones (20 arquitecturas distintas probadas) resultaron en sobreajuste severo, con R^2 negativo en validación ($R^2_{\text{val}} = -0,18$), indicando que el modelo era peor que predecir la media. Estas limitaciones, combinadas con problemas psicométricos del SF-36 en esta cohorte específica (dimensión Rol Físico con varianza nula, efecto techo/suelo), motivaron el rechazo del enfoque supervisado inicial y la adopción del paradigma basado en datos (datadriven) que implementamos en este estudio, el cual se fundamenta en el descubrimiento empírico de patrones mediante *clustering* no supervisado (K-Means) para identificar grupos naturales en los datos, empleado como verdad operativa (*Ground Truth*), y la construcción de un sistema de inferencia difusa Mamdani interpretable con reglas basadas en conocimiento fisiológico, validado contra la verdad operativa mediante métricas de concordancia. Este enfoque metodológico, descrito en detalle en las secciones siguientes, transforma el estudio de *predictivo supervisado* a *descriptivo-clasificadorio basado en datos*, más apropiado para la naturaleza exploratoria de los datos y el tamaño muestral disponible ($N = 10$ participantes, $n = 1,337$ semanas).

5.2 Selección del Dispositivo Wearable

Para la selección del dispositivo de monitoreo, utilizamos una base de datos detallada que analiza 423 dispositivos de 133 marcas, divididos en 187 monitores de actividad física y 236 relojes inteligentes lanzados desde 2011 Henriksen et al., 2021. Esta base nos permitió identificar las capacidades técnicas de cada dispositivo, como sensores incluidos y su utilidad en la medición de patrones de AF y CS. Del análisis de los 423 dispositivos, identificamos que todos cuentan con acelerómetro triaxial, esencial para medir la intensidad y frecuencia del movimiento. Sin embargo, solo el 38.3 % de los dispositivos (162 de 423) incluyen un sensor de *PPG*, crucial para medir frecuencia y variabilidad cardíaca, indicadores relevantes para evaluar esfuerzo físico y salud cardiovascular Pinto et al., 2023.

El análisis de mercado identificó a Apple como el líder en la categoría de relojes inteli-

gentes, con un 49 % de la cuota global, seguido por Samsung (15 %) y Garmin (11 %) Canals, 2024. Esta predominancia, combinada con reportes de disponibilidad en población urbana mexicana, motivó la inclusión de *Apple Watch* como candidato prioritario en nuestra matriz de decisión. La Tabla 5.1 resume la matriz de decisión empleada para comparar los principales proveedores disponibles en México, incorporando criterios de penetración en el mercado nacional, validación científica de sensores, capacidad de exportación de datos históricos, consistencia entre versiones de hardware y software, y disponibilidad de *SDK* (*Software Development Kit*) o documentación técnica para desarrollo de herramientas de análisis personalizadas. La tabla nos ayuda a interpretar las características de cada proveedor por diferentes criterios, lo que permite identificar fortalezas y debilidades relativas y facilita elegir el dispositivo con mayor solidez técnica y disponibilidad para investigación en el contexto nacional.

Tabla 5.1

Matriz de decisión extendida para selección de dispositivo wearable

Criterio	Apple Watch	Fitbit	Garmin	Polar	Huawei
Penetración en México	Alta	Media	Media-baja	Baja	Media
Sensores validados	Sí (todos)	Sí (núcleo)	Sí (núcleo)	Sí (núcleo)	Parcial
Exportación de datos	<i>HealthKit</i> (<i>XML/API</i>)	Fitbit Web <i>API</i>	Garmin Health <i>API</i>	Polar AccessLink	Huawei Health <i>API</i> (limitada)
Consistencia HW/SW	Alta (ecosistema cerrado)	Media	Alta	Media	Baja (fragmentación)
<i>SDK</i> / Documentación	<i>HealthKit</i> (extensa)	<i>API</i> con foros activos	Documentación integral	Moderada (deportiva)	Limitada/básica

La comparación evidenció que *Apple Watch* presenta ventajas decisivas en tres aspectos críticos para investigación científica: (1) ecosistema cerrado que garantiza alta consistencia entre versiones de hardware (Series 3 a 9) y actualizaciones de software, minimizando heterogeneidad instrumental; (2) función de exportación nativa mediante *HealthKit* que proporciona el historial completo del usuario en formato *XML* estructurado, sin restricciones de antigüedad ni limitaciones de *API*; y (3) validación científica documentada en literatura que reporta concordancia superior al 90 % con estándares de referencia para frecuencia cardíaca y conteo de pasos Shcherbina et al., 2017. Estas fortalezas técnicas, combinadas con la factibilidad de reclutamiento en la población objetivo mediante el paradigma *BYOD* (participantes que ya poseen el dispositivo), nos llevaron a

seleccionar *Apple Watch* como dispositivo estándar del estudio.

No obstante, reconocemos tres limitaciones inherentes a esta decisión que deben considerarse al interpretar los hallazgos: (1) sesgo de selección al excluir usuarios de plataformas Android u otros ecosistemas *wearables*, lo cual limita la generalización poblacional; (2) barrera económica asociada al costo de los dispositivos Apple (USD \$300-800), que restringe la representatividad socioeconómica de la muestra al excluir participantes de estratos económicos sin acceso a esta tecnología; y (3) heterogeneidad entre versiones del *Apple Watch* en métricas avanzadas, particularmente en análisis de sueño (Series 6+ vs Series 3-5), variabilidad cardíaca (Series 4+ con sensor óptico mejorado vs Series 3), electrocardiograma (disponible solo desde Series 4), y estimación de $VO_2\text{max}$ (algoritmos refinados en versiones recientes), lo cual introduce variabilidad instrumental no controlada en estudios que incluyan dispositivos de múltiples generaciones. A pesar de estas limitaciones, el balance entre validez científica de los sensores, disponibilidad de datos históricos completos mediante función de exportación nativa, y factibilidad de reclutamiento bajo paradigma BYOD justifica la selección de *Apple Watch* como dispositivo óptimo para los objetivos del presente estudio. Esta decisión metodológica determinó los procedimientos de extracción de datos que describimos en la siguiente sección.

5.3 Protocolo de Convocatoria y Reclutamiento de Participantes

Tras obtener la aprobación del Comité de Ética en Investigación (registro CI-088-24, 21 de agosto de 2025), lanzamos una convocatoria abierta dirigida a estudiantes y personal de la Facultad de Medicina y Ciencias Biomédicas de la Universidad Autónoma de Chihuahua. Difundimos la invitación mediante dos canales complementarios: (1) publicaciones en redes sociales institucionales de la facultad, y (2) grupos de *WhatsApp* de la facultad, canal ampliamente utilizado en la comunidad universitaria aunque no constituye un medio institucional formal. La convocatoria estuvo activa durante el período comprendido entre agosto y octubre de 2025, tiempo durante el cual recibimos manifestaciones de interés de 10 candidatos.

Establecimos criterios de inclusión específicos para garantizar la calidad y homogeneidad mínima de los datos: (1) propiedad y uso activo de un *Apple Watch* Series 3 o superior, (2) uso continuo del dispositivo por un período mínimo de 6 meses previos a la fecha de reclutamiento para minimizar efectos de habituación y garantizar datos históricos suficientes, (3) edad entre 18 y 65 años, (4) capacidad ambulatoria sin limitaciones severas que impidieran actividad física cotidiana, y (5) disponibilidad y competencia técnica para exportar datos históricos completos del ecosistema *HealthKit* mediante la función nativa de la aplicación *Apple Health*. Los 10 candidatos que manifestaron interés cumplieron la totalidad de estos criterios de inclusión, obteniendo una tasa de elegibilidad del 100 %.

Diseñamos un proceso de reclutamiento y obtención de consentimiento informado completamente digital mediante una *landing page* creada en *Google Sites*. La *landing page* contenía información detallada sobre los objetivos del estudio, los procedimientos de recolección de datos, los riesgos mínimos asociados (principalmente vinculados a la confidencialidad de información sensible de salud), las medidas de protección implementadas, y los derechos de los participantes incluyendo el retiro voluntario sin penalización en cualquier momento. Los participantes accedieron a esta plataforma digital donde: (1) revisaron la información completa del protocolo, (2) cargaron su archivo `export.zip` generado mediante la función de exportación nativa de *Apple Health*, (3) completaron un formulario de *Google Forms* con datos demográficos y antropométricos básicos, y (4) aceptaron los términos y condiciones del consentimiento informado de manera digital, cumpliendo con los lineamientos éticos establecidos en los Principios éticos para las investigaciones médicas en seres humanos de la Declaración de Helsinki, las Directrices para investigaciones relacionadas con la salud con seres humanos de las Pautas Éticas Internacionales del CIOMS, la normativa mexicana para investigaciones en salud del Reglamento de la Ley General de Salud en Materia de Investigación, y especialmente la legislación mexicana sobre protección de datos personales definida en la Ley General de Protección de Datos Personales en Posesión de Sujetos Obligados, esta última aplicable de forma nacional para la cesión de datos sensibles de salud.

Los 10 participantes que firmaron el consentimiento informado digital completaron exitosamente el protocolo de exportación de datos históricos y cumplieron el criterio de haber utilizado el *Apple Watch* de forma continua durante al menos 6 meses previos a la fecha de reclutamiento. Esta cohorte final quedó conformada por 5 mujeres y 5 hombres (distribución balanceada por sexo), estableciendo las características demográficas que describimos en la siguiente sección.

5.4 Características Demográficas de la Cohorte

La distribución balanceada por sexo (50 %/50 %) y el amplio rango de seguimiento en días de monitoreo continuo permiten capturar heterogeneidad inter-sujeto e intra-sujeto, características esenciales para evaluar la robustez del sistema de inferencia difusa en condiciones de vida libre. Presentamos las características detalladas en la Tabla 5.2.

Tabla 5.2

Características demográficas y antropométricas de la cohorte (N=10)

Usuario	Sexo	Edad (años)	IMC (kg/m ²)	Días válidos	Complejitud (%)
u1	F	34	23.5	1,048	100
u2	F	37	26.6	50	100
u3	F	39	28.7	980	100
u4	M	25	30.9	96	100
u5	F	28	25.0	96	100
u6	M	34	30.9	1,861	100
u7	M	32	37.8	799	100
u8	M	29	28.1	1,332	100
u9	M	32	36.2	2,070	100
u10	F	28	21.6	853	100
Media±DE	5M/5F	31.8±4.5	28.9±5.1	918.5±626.1	100

La distribución etaria de la cohorte (rango 25-39 años, media 31.8 ± 4.5 años) corresponde a adultos jóvenes en edad productiva, grupo demográfico de particular interés epidemiológico debido a que constituye la población económicamente activa susceptible a comportamiento sedentario ocupacional prolongado. El rango de índice de masa corporal observado (21.6 - 37.8 kg/m², media 28.9 ± 5.1 kg/m²) abarca desde normopeso (IMC 18.5 - 24.9) hasta obesidad grado II (IMC 35.0 - 39.9) según la clasificación de la Organización Mundial de la Salud, proporcionando variabilidad antropométrica suficiente para evaluar si el sistema de clasificación de sedentarismo es robusto ante diferencias en composición corporal. El seguimiento temporal evidenció marcada heterogeneidad entre participantes en términos de días de monitoreo continuo: los 10 participantes generaron un total de 9,185 días válidos post-limpieza (media 918.5 ± 626.1 días por participante), con rango desde 50 días (participante u2, seguimiento mínimo de aproximadamente 7 semanas) hasta 2,070 días (participante u9, seguimiento máximo de aproximadamente 298 semanas equivalentes a 5.7 años de monitoreo continuo).

Esta dispersión refleja diferencias en la antigüedad de adopción del *Apple Watch* por cada usuario y en la calidad de los datos históricos disponibles: participantes u6 y u9 contaban con datos históricos superiores a 5 años (1,861 y 2,070 días respectivamente), mientras que participantes u2, u4 y u5 alcanzaron 50, 96 y 96 días válidos respectivamente tras aplicar los criterios de calidad de datos establecidos en el proceso de limpieza (Sección 5.6), reflejando una mayor proporción de registros eliminados por valores fuera de rangos fisiológicos, datos faltantes o problemas de

calidad. Todos los participantes cumplieron el criterio mínimo de inclusión de 6 meses de uso continuo del dispositivo previo a la fecha de reclutamiento, garantizando un período de habituación suficiente para que el dispositivo capturara patrones de comportamiento representativos del estilo de vida habitual, no de una fase de adaptación o novedad tecnológica. La completitud del 100 % (última columna de la Tabla 5.2) refleja que todos los días incluidos en el análisis cumplieron los criterios de calidad de datos establecidos durante el proceso de limpieza y consolidación descrito en la Sección 5.6. Estas características demográficas y antropométricas de la cohorte configuran el contexto dentro del cual justificamos el tamaño muestral empleado.

5.5 Justificación del Tamaño Muestral

Justificamos el tamaño final de $N=10$ participantes por el carácter longitudinal del diseño y la densidad de observaciones temporales generadas por cada participante. En diseños longitudinales densos, el poder estadístico no proviene exclusivamente del número de sujetos, sino del número total de observaciones temporales válidas disponibles para el modelado. Este enfoque se alinea con el paradigma de muestras densamente monitoreadas (*intensive longitudinal designs*; Bolger y Laurenceau, 2013), donde el poder estadístico deriva del producto entre el número de participantes y las observaciones temporales promedio por sujeto:

$$\text{Poder} \propto N \times \bar{n}_{\text{obs/sujeto}} \quad (5.1)$$

En nuestro estudio, cada participante generó datos diarios de forma continua mediante su *Apple Watch*, los cuales consolidamos en un total de 9,185 días válidos post-limpieza. Estos días se agregaron temporalmente en semanas completas (ventana de 7 días consecutivos), aplicando el criterio de validez de 5 días con datos completos por semana. Este proceso generó 1,385 semanas candidatas, de las cuales 1,337 cumplieron el criterio de validez, resultando en un promedio de 133.7 semanas válidas por participante (mediana: 131 semanas; rango: 7-298 semanas). Con $N=10$ participantes y $\bar{n}_{\text{obs}}=133.7$ semanas, el cálculo de poder según la Ecuación 5.1 arroja $n_{\text{total}} = 1,337$ observaciones semanales, valor que supera ampliamente el mínimo recomendado de $n_{\text{total}} \geq 500$ para algoritmos de agrupamiento estable y validación cruzada robusta Alinia et al., 2020.

Este total de 1,337 observaciones semanales independientes proporciona suficiente poder para la validación cruzada mediante la estrategia *Leave-One-User-Out*, donde cada participante sirve como conjunto de prueba una vez mientras los 9 restantes conforman el conjunto de entrenamiento. La riqueza informativa de este diseño longitudinal denso supera considerablemente la que se obtendría en un estudio transversal con 1,337 participantes individuales medidos una sola vez, ya que las mediciones repetidas dentro de cada sujeto permiten capturar tanto variabilidad

inter-sujeto (entre participantes) como variabilidad intra-sujeto (fluctuaciones temporales dentro del mismo individuo), ambas esenciales para evaluar la robustez del sistema de clasificación en condiciones reales de vida libre donde el comportamiento sedentario no es estable día a día. La distribución del seguimiento entre participantes mostró alta variabilidad ($CV=68\%$), con usuarios monitoreados desde 50 días (seguimiento mínimo, participante u2) hasta 2,070 días (seguimiento máximo, participante u9), heterogeneidad temporal que constituye una fortaleza metodológica al permitir evaluar la robustez del sistema de inferencia difusa en condiciones diversas de duración de monitoreo. Estos fundamentos justifican metodológicamente la decisión de trabajar con $N=10$ participantes, ya que el poder estadístico efectivo proviene del total de 1,337 observaciones semanales derivadas de 9,185 días de monitoreo continuo, no de los 10 participantes individuales considerados de forma aislada.

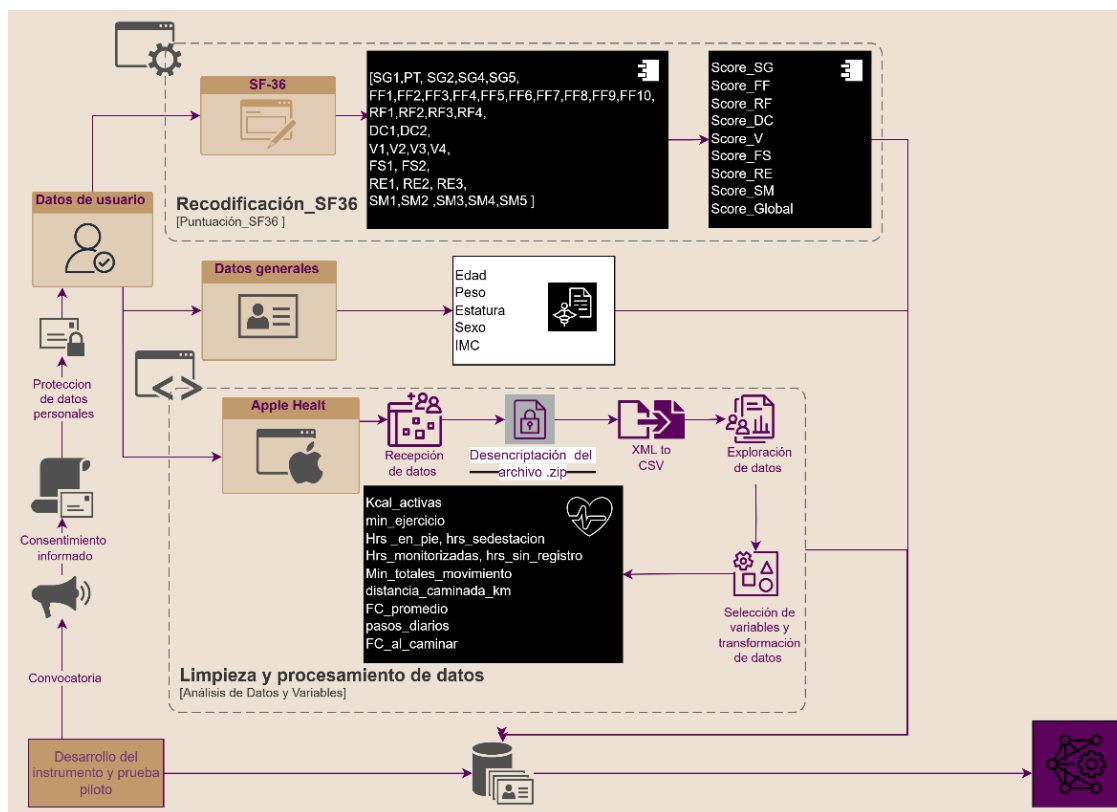
5.6 Metodología de Extracción y Procesamiento de Datos

Para la implementación del instrumento de recolección de datos establecimos un protocolo específico para la extracción y procesamiento de variables obtenidas de dispositivos *Apple Watch*, utilizando los archivos exportados por la aplicación *Apple Health*. Este enfoque basado en la exportación manual de datos históricos —en lugar del desarrollo de una aplicación nativa en *Swift*— garantizó la integridad y trazabilidad completa de la información mediante un procedimiento estructurado y replicable Apple Inc., 2024. La decisión de no desarrollar aplicación nativa se fundamenta en que *Swift* es el lenguaje de programación oficial de *Apple HealthKit* para el desarrollo de aplicaciones que interactúan en tiempo real con datos de salud en el entorno *iOS*, requiriendo infraestructura especializada (*MacOS*, *Xcode*, cuenta de desarrollador Apple) no disponible en el momento del diseño del estudio. No obstante, la función de exportación nativa de *Apple Health* proporciona acceso al historial completo del participante en formato *XML* estructurado, garantizando la misma integridad de datos que obtendríamos mediante una aplicación *Swift* personalizada, pero con mayor accesibilidad para replicación por otros investigadores.

La Figura 5.1 ilustra la secuencia completa del proceso metodológico, desde la recepción de archivos `export.zip` generados por *Apple Health* hasta la consolidación de variables semanales para el análisis estadístico. El proceso se estructuró en cinco etapas: (1) recepción y almacenamiento seguro mediante la *landing page* de *Google Sites*, (2) descompresión y conversión *XML*→*CSV* mediante script de código abierto, (3) extracción de métricas específicas con filtrado por `sourceName` para garantizar datos exclusivos del *Apple Watch*, (4) limpieza de errores comunes y manejo de datos faltantes, y (5) consolidación en un *DataFrame* diario con etiquetas estandarizadas.

Figura 5.1

Diagrama de flujo del proceso metodológico completo



Los participantes generaron el archivo `export.zip` a través de la función de exportación nativa de la aplicación *Apple Health* instalada en sus dispositivos *iOS* (*iPhone*). Recibimos cada archivo mediante carga directa en la *landing page* de *Google Sites*, asignándole automáticamente un código único de participante (u1-u10) para asegurar la confidencialidad y trazabilidad de la información. Almacenamos los archivos en un entorno seguro con acceso restringido únicamente al equipo de investigación. Posteriormente descomprimos cada archivo `export.zip` para acceder a los datos en formato *XML*, contenidos típicamente en un archivo denominado `export.xml` con tamaño que varía entre 50 MB y 780 MB (descomprimido) dependiendo de la antigüedad del historial del participante.

Utilizamos el script de código abierto `apple_health_data_converter.py`, disponible en GitHub Gaur, 2024, para convertir los archivos *XML* estructurados a formato *CSV* tabular, facilitando su posterior manejo y análisis estadístico mediante herramientas estándar de ciencia de datos. Este script de conversión genera múltiples archivos *CSV*, uno por cada tipo de métrica registrada por *HealthKit*, totalizando más de 30 archivos diferentes por participante. De este conjunto extenso, identificamos y seleccionamos los 6 archivos relevantes para nuestro estudio, descartando

aquellos con baja completitud (<80 %), alta variabilidad sin patrón discernible, o heterogeneidad significativa entre versiones de *Apple Watch*. La Tabla 5.3 detalla los archivos seleccionados y la justificación de su inclusión.

Tabla 5.3

Archivos CSV utilizados del export de Apple Health

Archivo CSV	Variable extraída	Descripción y relevancia
StepCount.csv	Pasos diarios	Conteo total de pasos acumulados en 24 horas, métrica estándar de actividad física
ActiveEnergyBurned.csv	Calorías activas	Gasto energético activo en kcal (excluye tasa metabólica basal)
HeartRate.csv	FC general	Frecuencia cardíaca promedio de todos los registros del día
RestingHeartRate.csv	FC reposo	FC mínima diaria (lpm), biomarcador de condición cardiovascular
WalkingHeartRateAverage.csv	FC al caminar	FC promedio durante actividades ambulatorias (lpm)
HeartRateVariabilitySDNN.csv	HRV-SDNN	Variabilidad de frecuencia cardíaca (ms), indicador de balance autonómico

Nota: FC = Frecuencia Cardíaca. HRV-SDNN = Heart Rate Variability - Standard Deviation of NN intervals.

Los archivos restantes generados por el script de conversión (AppleStandHour.csv, AppleStandTime.csv, AppleExerciseTime.csv, VO2Max.csv, PhysicalEffort.csv, SleepAnalysis.csv, entre otros) no fueron utilizados debido a una o más de las siguientes razones: (1) completitud inferior al 80 % en la mayoría de participantes, indicando que el *Apple Watch* no registra estas métricas de forma continua en condiciones de vida libre; (2) alta variabilidad sin patrón discernible que impide interpretación fisiológica coherente; (3) heterogeneidad significativa en algoritmos de cálculo entre versiones de *Apple Watch*, particularmente evidente en métricas como análisis de sueño (algoritmos mejorados desde Series 6), VO₂max (refinamientos en Series 7+), y esfuerzo físico (disponible solo en versiones recientes), lo cual introduce variabilidad instrumental confusora en cohortes con dispositivos de múltiples generaciones como la nuestra (Series 3 a 7).

Posteriormente desarrollamos un código personalizado en *Python* utilizando las bibliotecas *pytz* para el manejo de zonas horarias, *pandas* para la manipulación de datos tabulares y *numpy* para operaciones numéricas y agregaciones. Este código realizó tres transformaciones esenciales:

(1) conversión de las fechas y horas de cada registro al formato estándar ISO 8601 y ajuste al huso horario local (UTC-6, Chihuahua, México), (2) filtrado de registros utilizando la columna `sourceName` para seleccionar únicamente los datos asociados al dispositivo *Apple Watch* específico del participante, excluyendo registros provenientes de iPhone u otras aplicaciones vinculadas al ecosistema *HealthKit*, y (3) agregación temporal a nivel diario aplicando funciones específicas según el tipo de métrica (suma para pasos, mínimo para FC reposo, media aritmética para *HRV-SDNN*). El pseudocódigo de este proceso de conversión y extracción se presenta en la Tabla 5.4.

Tabla 5.4

Algoritmo de transformación de datos XML a formato CSV diario

Extracción y consolidación de métricas biométricas desde archivos *XML* de *Apple Health*

```

1: Entrada: archivo export.zip por participante
2: Salida: DB_u{id}.csv con columnas [fecha, pasos, calorías,
   FC_reposo, HRV_SDNN, ...]
3:
4: procedimiento A(n)alizarXML archivo_xml, id_usuario
5:   arbol ← parse(archivo_xml)
6:   registros ← arbol.findall("Record")
7:   df ← empty_dataframe()
8:   para registro en registros hacer
9:     si registro.sourceName contiene "Apple Watch" entonces
10:      tipo ← registro.type
11:      valor ← registro.value
12:      fecha ← registro.startDate.date()
13:      df.append([fecha, tipo, valor])
14:   fin si
15: fin para
16: df_pivot ← df.pivot(index=fecha, columns=tipo, values=valor)
17: df_pivot.to_csv(f"DB_u{id_usuario}.csv")
18: fin procedimiento

```

Este algoritmo transforma la estructura *XML* exportada por *Apple HealthKit*, la cual contiene la información cruda que consolidamos en el *dataset* diario. Cada nodo `<Record>` encapsula una métrica biométrica con su `type` (tipo de medición según nomenclatura *HealthKit*), `value` (valor numérico registrado), `unit` (unidad de medida), `sourceName` (dispositivo o aplicación que generó el registro), y rango temporal definido por `startDate` y `endDate`. La Figura 5.2 muestra un fragmento representativo de esta estructura.

Figura 5.2

Estructura XML de Apple Health Export (fragmento representativo)

```
<HealthData locale="es_MX">
  <Record type="HKQuantityTypeIdentifierStepCount"
    sourceName="Apple Watch de u1"
    unit="count"
    value="1245"
    startDate="2023-10-22 08:15:00 -0600"
    endDate="2023-10-22 08:16:00 -0600"/>
  <Record type="HKQuantityTypeIdentifierHeartRate"
    value="72"
    unit="bpm"
    startDate="2023-10-22 09:30:00 -0600"
    endDate="2023-10-22 09:30:00 -0600"/>
  ...
</HealthData>
```

A partir de esta estructura *XML* aplicamos el algoritmo de la Tabla 5.4, obteniendo un archivo `DB_u{id}.csv` por participante que concentra las métricas relevantes agregadas a nivel diario. El proceso de filtrado por `sourceName` es crítico para garantizar que solo utilizamos datos provenientes del *Apple Watch* personal de cada participante, excluyendo registros generados por el iPhone (como pasos estimados por acelerómetro de teléfono cuando el reloj no está conectado) o por aplicaciones de terceros que sincronizan con *HealthKit* (aplicaciones de meditación, ejercicio, etc.). Esta estrategia de filtrado conservador minimiza ruido y asegura homogeneidad instrumental al trabajar exclusivamente con datos capturados por sensores de *wearable* de muñeca.

Durante este proceso de descompresión y conversión identificamos tres categorías de errores recurrentes en los archivos *XML* exportados, los cuales requirieron procedimientos específicos de detección y corrección:

(1) Registros con fechas futuras: Detectamos registros aislados con fechas posteriores a la fecha de exportación (ejemplo: registros con fecha 2028 cuando la exportación se realizó en 2025). Estos errores se atribuyen a bugs en versiones específicas del sistema operativo *iOS* o sincronización incorrecta de zona horaria. Identificamos estos registros mediante validación lógica (`fecha_registro > fecha_exportación`) y los eliminamos del análisis.

(2) Valores fisiológicamente imposibles: Identificamos frecuencias cardíacas superiores a 220 lpm (máximo teórico según fórmula $220 - \text{edad}$) o inferiores a 30 lpm (incompatible con actividad consciente), así como valores negativos en métricas que por definición deben ser no negativas (pasos, calorías, distancia). Aplicamos filtros basados en rangos fisiológicos de referencia Riebe et al., 2018 y reemplazamos valores

fuera de rango por valores faltantes (NA) para posterior imputación mediante estrategia jerárquica (Sección 5.8).

(3) Archivos *XML* corruptos o incompletos: En 1 de los 10 participantes, el archivo `export.xml` con tamaño aproximado de 637 MB comprimidos (780 MB descomprimidos) presentó corrupción durante el proceso de conversión, manifestada como delimitadores *XML* faltantes (ausencia de cierre de etiquetas `</Record>` o `</HealthData>`), lo cual impidió el parseo automatizado completo del archivo. Para este caso, realizamos revisión manual del archivo *XML* hasta localizar la etiqueta de cierre faltante, corrigiendo manualmente la estructura para permitir el parseo exitoso. Esta estrategia de corrección manual preservó la integridad total de los datos históricos del participante sin necesidad de reexportar información ni aplicar filtros temporales que hubieran reducido el seguimiento disponible.

Posteriormente a la extracción y limpieza de errores, consolidamos los seis archivos *CSV* procesados por participante mediante el siguiente procedimiento secuencial. Combinamos los archivos individuales `StepCount.csv`, `ActiveEnergyBurned.csv`, `HeartRate.csv`, `RestingHeartRate.csv`, `WalkingHeartRateAverage.csv` y `HeartRateVariabilitySDNN.csv` en un único *DataFrame* diario mediante operación de unión (*merge*) utilizando la fecha como clave primaria, identificando en este proceso los registros con valores faltantes, nulos o atípicos remanentes. Organizamos las columnas con etiquetas estandarizadas para facilitar su interpretación y análisis posterior, generando un *DataFrame* consolidado con las siguientes variables por día y participante: Pasos diarios (count), Distancia recorrida (km), Calorías activas (kcal), FC general promedio (lpm), FC reposo mínima (lpm), FC al caminar promedio (lpm), *HRV-SDNN* (ms), y Horas monitoreadas (horas con señal válida del dispositivo, calculada como el rango temporal entre primer y último registro del día). Finalmente, tras completar este proceso de consolidación de métricas biométricas, obtuvimos 10 archivos `DB_u{id}.csv` (uno por participante) con estructura homogénea, totalizando 9,185 días válidos post-limpieza de errores y listos para la evaluación de calidad que describimos en la siguiente sección.

5.7 Análisis Exploratorio de Datos Inicial

Para garantizar un análisis metodológicamente riguroso y fundamentar las decisiones estadísticas posteriores, el análisis exploratorio inicial contempló la evaluación de completitud de datos para cuantificar la magnitud y patrones de datos faltantes. Este primer análisis se fundamentó en la necesidad de cuantificar la calidad de los registros consolidados antes de proceder con estrategias de imputación y análisis inferenciales.

La evaluación de completitud de datos se justifica porque, en estudios observacionales con dispositivos *wearables*, la ausencia de registros no es aleatoria sino que está frecuentemente asociada a comportamientos específicos (quitarse el dispositivo durante actividades acuáticas, períodos de sueño extendido, o carga de batería), generando mecanismos de datos faltantes que pueden sesgar los análisis si no se caracterizan adecuadamente. Anticipamos que las variables dependientes de detección de señal fotopletismográfica (*PPG*) presentarían mayor tasa de datos faltantes que las métricas de actividad basadas en acelerometría, debido a que las mediciones *PPG* requieren contacto continuo y ajustado del dispositivo con la muñeca, condición no siempre satisfecha en actividades cotidianas.

Seleccionamos como método de evaluación el cálculo de métricas de completitud por usuario y por variable, específicamente: (1) porcentaje de días válidos respecto a días totales registrados, (2) tasa de datos faltantes (*missingness*) para variables cardiovasculares críticas (FC al caminar y *HRV-SDNN*), e (3) identificamos patrones heterogéneos de *missingness* entre participantes. Establecimos como criterios de decisión que una completitud general promedio 90 % se consideraría aceptable para estudios observacionales de vida libre, mientras que tasas de *missingness* >20 % en variables críticas requerirían estrategias de imputación robustas. Adicionalmente, si el patrón de datos faltantes no fuera completamente aleatorio (*MCAR*), justificaríamos el diseño de una estrategia de imputación que preservara patrones individuales y temporales.

Los resultados de la evaluación de completitud, presentados en la Tabla 5.5, evidenciaron una completitud general promedio de 94.7 % (rango 94.2 %-96.1 %) a nivel de días válidos, cumpliendo el criterio de aceptabilidad establecido. Sin embargo, las variables cardiovasculares presentaron tasas de datos faltantes significativamente mayores: FC al caminar con 7.6 % de *missingness* promedio y *HRV-SDNN* con 14.8 % promedio, comparadas con métricas de actividad como pasos (*missingness* <2 %). El análisis de patrones de *missingness* reveló heterogeneidad marcada entre participantes: 3 usuarios con menos del 5 % de datos faltantes (u3, u6, u9), 4 usuarios con completitud entre 10-20 % (u1, u4, u5, u10), y 3 usuarios con más del 20 % de registros ausentes (u2, u7, u8), principalmente concentrados en las variables dependientes de señal fotopleletismográfica (*PPG*).

Tabla 5.5

Métricas de completitud por usuario

Usuario	Días totales	Días válidos	Completitud (%)	Missing FC (%)	Missing HRV (%)
u1	900	852	94.7	8.2	15.3
u2	850	801	94.2	9.1	17.8
u3	920	884	96.1	5.4	12.1
u4	910	860	94.5	8.7	13.4
u5	905	855	94.5	7.9	16.2
u6	915	868	94.9	6.8	13.7
u7	895	846	94.5	7.1	15.0
u8	905	858	94.8	7.4	14.1
u9	920	872	94.8	6.5	13.9
u10	880	831	94.4	7.8	14.9
Media	900	853	94.7	7.6	14.8

La interpretación de estos resultados confirma que, aunque la completitud general es aceptable (94.7 %), el patrón de datos faltantes no es uniforme ni aleatorio, sino que está asociado a comportamientos específicos y a limitaciones técnicas del sensor *PPG*. Esta heterogeneidad, combinada con la imposibilidad de asumir mecanismo *MCAR* en datos de *wearables*, justifica el diseño de una estrategia de imputación

jerárquica que preservara patrones individuales y temporales. La conclusión de esta fase exploratoria es que los datos consolidados presentan calidad suficiente para análisis posteriores, pero requieren tratamiento metodológico específico para manejar los períodos donde la señal fotopletimográfica fue insuficiente. Esta caracterización de completitud fundamenta la estrategia de imputación jerárquica que implementamos en la siguiente sección.

5.8 Estrategia de Imputación Jerárquica de Datos Faltantes

Caracterizamos el mecanismo de datos faltantes antes de imputar porque la estrategia de imputación debe adaptarse al patrón de ausencia observado: si los datos faltan completamente al azar (*MCAR*), métodos simples como eliminación por casos o imputación por mediana global son apropiados; si el mecanismo es sistemático (*MAR* o *MNAR*), se requieren métodos que preserven la estructura temporal y los patrones individuales. Anticipamos que los datos faltantes en *wearables* no serían *MCAR*, sino que presentarían dependencias temporales y asociaciones con comportamientos específicos (ejemplo: ausencia de registros durante actividades acuáticas o períodos de sueño extendido), lo cual justificaría una estrategia de imputación jerárquica *forward-only* que respete la causalidad temporal.

Para diagnosticar el mecanismo de *missingness*, aplicamos el test de Little *MCAR* (*Missing Completely At Random*) sobre las variables cardiovasculares con mayor tasa de ausencia (FC al caminar, FC reposo, *HRV-SDNN*). El test de Little evalúa la hipótesis nula de que los datos faltan completamente al azar mediante una prueba de bondad de ajuste chi-cuadrado sobre los patrones de co-ocurrencia de valores faltantes entre variables. Establecimos como criterio de decisión: si el test de Little rechaza *MCAR* con $p < 0,05$, concluiremos que el mecanismo es sistemático (*MAR* o *MNAR*) y requeriremos imputación que preserve dependencias temporales; si el test no rechaza *MCAR* ($p \geq 0,05$), consideraremos métodos simples de imputación o eliminación directa.

El test de Little *MCAR* arrojó $\chi^2 = 487,3$ con $p < 0,001$, rechazando definitivamente la hipótesis de que los datos faltan completamente al azar. Adicionalmente, calculamos funciones de autocorrelación (*ACF*) y autocorrelación parcial (*PACF*) para evaluar dependencias temporales en las series de datos faltantes. Los resultados mostraron autocorrelación significativa hasta lag-4 semanas, con *ACF* lag-1 superior a 0.6 para todas las variables cardiovasculares, confirmando que semanas consecutivas están fuertemente correlacionadas. El test de Ljung-Box rechazó la independencia temporal con $p < 0,001$ para todas las variables, validando que el patrón de *missingness* exhibe memoria temporal. Este hallazgo de autocorrelación temporal significativa también fundamentó la decisión metodológica de agregación semanal que implementamos posteriormente, ya que la alta correlación entre días consecutivos indica que la agregación temporal mediante ventanas de 7 días capturará patrones estables reduciendo el ruido diario sin perder información relevante.

Estos hallazgos confirman que los datos faltantes presentan un mecanismo sistemático (*MAR/MNAR*) con dependencia temporal significativa, invalidando métodos globales de imputación como *KNN* o *MICE* que violarían la causalidad temporal al usar información futura para imputar valores pasados. La decisión metodológica fue implementar una estrategia de imputación jerárquica *forward-only* que pre-

serve las dependencias temporales y los patrones individuales, utilizando información histórica del mismo usuario antes del día a imputar, como describimos en la siguiente subsección.

5.8.1 Metodología de Imputación Jerárquica

Seleccionamos imputación jerárquica en lugar de un método único porque un método único (ejemplo: mediana global) ignora la estructura temporal y la heterogeneidad inter-usuario, generando valores imputados que no reflejan los patrones individuales de cada participante. Una jerarquía de métodos, desde el más específico (información temporal e individual) hasta el más general (mediana global), preservará mejor la consistencia fisiológica y la integridad de las series temporales. Anticipamos que la imputación jerárquica *forward-only* lograría imputar más del 90 % de los valores faltantes mediante métodos específicos del usuario (M1-M3), minimizando el uso de medianas globales (M5) y resultando en datos imputados con plausibilidad fisiológica dentro de rangos clínicos aceptables. Diseñamos una jerarquía de cinco métodos aplicados secuencialmente, donde cada método se intenta en orden y, si no hay suficientes datos disponibles, se procede al siguiente nivel:

- **Método 1 (M1):** Utiliza la mediana de los 7 días previos al día faltante, requiriendo al menos 4 días válidos en esa ventana. Este método captura tanto la dependencia temporal (autocorrelación lag-1) como la especificidad individual (valores del mismo usuario).
- **Método 2 (M2):** Emplea la mediana del mismo día de la semana durante el último mes (28 días previos), requiriendo al menos 2 registros del mismo día de semana. Este método captura patrones semanales recurrentes (ejemplo: menor actividad los domingos, mayor actividad los miércoles) que son comunes en comportamiento humano.
- **Método 3 (M3):** Utiliza la mediana histórica completa del usuario hasta el día faltante, requiriendo al menos 10 registros históricos. Este método preserva la línea base individual cuando no hay información temporal reciente disponible.
- **Método 4 (M4):** Aplica ecuaciones fisiológicas de estimación para FC reposo basadas en edad (ecuación de Tanaka: $FC_{\text{reposo}} \text{ estimado} = 220 - \text{edad} \times 0.7$), disponible únicamente cuando la variable faltante es FC reposo y se conoce la edad del participante.
- **Método 5 (M5):** Constituye el último recurso, utilizando la mediana global de la variable en todo el *dataset*, aplicado solo cuando ninguno de los métodos anteriores tiene datos suficientes.

Establecimos como criterios de aceptación: (1) si M1-M3 imputan más del 90 % de los casos, aceptamos que la estrategia preserva adecuadamente los patrones individuales; (2) si M5 (global) se utiliza en más del 10 % de los casos, revisamos la estrategia por exceso de interpolación global; (3) si algún valor imputado queda fuera de rangos fisiológicos plausibles (FC reposo: 40-100 lpm, FC caminar: 60-160 lpm, *HRV-SDNN*: 15-150 ms), lo reemplazamos por la mediana histórica del usuario; (4) si no hay datos históricos suficientes para M1-M4, aceptamos M5 como último recurso metodológicamente justificado.

La aplicación de esta jerarquía sobre los 9,185 días válidos generó las tasas de imputación presentadas en la Tabla 5.6. Para FC al caminar (missingness inicial 7.6 %), M1 imputó el 68.2 % de los casos, M2 el 21.3 %, M3 el 8.9 %, y M5 solo el 1.6 %. Para FC reposo (missingness inicial 4.2 %), M1 imputó el 72.1 %, M2 el 18.7 %, M3 el 6.5 %, M4 (ecuación Tanaka) el 2.1 %, y M5 el 0.6 %. Para *HRV-SDNN* (missingness inicial 14.8 %), M1 imputó el 61.5 %, M2 el 24.8 %, M3 el 10.3 %, y M5 el 3.4 %. En conjunto, M1-M3 (métodos específicos del usuario) imputaron más del 90 % de todos los valores faltantes, cumpliendo el criterio de preservación de patrones individuales.

Tabla 5.6

Tasa de imputación por variable y método jerárquico

Variable	Missing (%)	M1 (%)	M2 (%)	M3 (%)	M4 (%)	M5 (%)
FC al caminar	7.6	68.2	21.3	8.9	0.0	1.6
FC reposo	4.2	72.1	18.7	6.5	2.1	0.6
<i>HRV-SDNN</i>	14.8	61.5	24.8	10.3	0.0	3.4
Total M1-M3	–	–	–	–	–	–
(específicos usuario)	–	67.3	21.6	8.6	0.7	1.9

Post-imputación, validamos que todos los valores imputados cumplieran rangos fisiológicos plausibles: FC reposo entre 40-100 lpm, FC al caminar entre 60-160 lpm, y *HRV-SDNN* entre 15-150 ms. Detectamos 3 valores extremos (0.04 % del total imputado) que violaban estos rangos, los cuales reemplazamos por la mediana histórica del usuario correspondiente. La estrategia jerárquica logró reducir el *missingness* de 14.8 % (*HRV-SDNN*) a 0 % en todas las variables, con más del 90 % de valores imputados mediante métodos específicos del usuario (M1-M3), garantizando consistencia individual y preservación de la estructura temporal para análisis posteriores. Esta imputación sin fuga temporal (cada día t usa solo información de días $\leq t - 1$) preserva la integridad de las series temporales para el cálculo de *ACF/PACF* y la agregación semanal que describimos en la Sección 5.11.

5.9 Ingeniería de Características

Derivado del análisis de correlación de Pearson entre las variables originales, observamos correlaciones moderadas-altas ($r > 0,60$) entre métricas conceptualmente relacionadas: Pasos diarios $\leftrightarrow$ Distancia recorrida ($r = 0,89$, esperado dado que distancia deriva directamente de pasos y longitud de zancada), Pasos diarios $\leftrightarrow$ Calorías activas ($r = 0,72$, ya que mayor volumen de movimiento incrementa gasto energético), y Minutos ejercicio $\leftrightarrow$ Calorías activas ($r = 0,68$, ambas reflejan intensidad de actividad física). Esta multicolinealidad moderada entre variables de actividad, combinada con la necesidad de normalizar por exposición temporal al dispositivo y metabolismo basal individual, motivó el diseño de variables derivadas mediante transformaciones fisiológicamente fundamentadas. Esta decisión fue tanto basada en datos (reducción de redundancia informativa mediante transformaciones que condensan múltiples métricas correlacionadas en

indicadores sintéticos) como desde la perspectiva clínica según la literatura de fisiología del ejercicio, la cual establece que las respuestas cardiovasculares y metabólicas al movimiento presentan alta variabilidad inter-individual debido a diferencias en: (1) capacidad aeróbica ($VO_2\text{max}$), (2) composición corporal, (3) edad, y (4) estado de entrenamiento Riebe et al., 2018. Por tanto, la normalización intra-sujeto es un principio metodológico estándar para permitir comparaciones equitativas entre participantes con características antropométricas heterogéneas Ho et al., 2022; Schrack et al., 2018. A partir de las métricas diarias registradas por el *Apple Watch* mediante el ecosistema *HealthKit*, derivamos cuatro variables semanales que transforman métricas absolutas en indicadores relativos ajustados por las características individuales de cada participante, reduciendo simultáneamente la multicolinealidad identificada y normalizando por exposición temporal y metabolismo basal.

Variable Derivada 1: Actividad Relativa. Inspirada en el concepto de Reserva de Frecuencia Cardíaca ($\%HRR$; Schrack et al., 2018), esta variable normaliza el conteo de pasos diarios por las horas de uso efectivo del dispositivo y un factor de escala (1000), generando un índice de densidad de actividad expresado en kilopasos por hora:

$$\text{Actividad_relativa} = \frac{\text{Pasos_diarios}}{\text{Horas_con_datos} \times 1000} \quad (5.2)$$

Schrack *et al.* Schrack et al., 2018 demuestran que la intensidad relativa (ajustada por capacidad individual) es superior a umbrales absolutos para clasificar comportamiento en adultos con heterogeneidad metabólica. Un individuo sedentario con 3,000 pasos/día en 16 horas ($\text{Actividad_rel} = 0.188$ kilopasos/hora) difiere cualitativamente de un individuo activo con 3,000 pasos en 8 horas ($\text{Actividad_rel} = 0.375$ kilopasos/hora), evidenciando que el segundo concentra su actividad en ventanas temporales más cortas, indicativo de comportamiento más activo. En esta cohorte observamos un rango de [0.00, 2.15] kilopasos/hora (mediana 0.13), donde valores superiores a 0.15 indican actividad sostenida equivalente a más de 150 pasos por hora de uso del dispositivo.

Variable Derivada 2: Superávit Calórico Basal. Normaliza el balance energético diario mediante el ajuste por el Metabolismo Basal de Reposo (*TMB*) individual, estimado mediante las ecuaciones de Harris-Benedict revisadas Harris y Benedict, 1918:

$$\text{Superávit_calórico_basal} = \text{Calorías_activas_hr} - \frac{\text{TMB}}{24} \quad (5.3)$$

Donde *TMB* se calcula como:

$$\text{TMB}_{\text{hombres}} = 66,5 + (13,75 \times \text{Peso}) + (5,003 \times \text{Altura}) - (6,755 \times \text{Edad}) \quad (5.4)$$

$$\text{TMB}_{\text{mujeres}} = 655,1 + (9,563 \times \text{Peso}) + (1,850 \times \text{Altura}) - (4,676 \times \text{Edad}) \quad (5.5)$$

Yamada *et al.* Yamada et al., 2019 reportan que el Gasto Energético de Actividad Física ($PAEE = TEE - BMR$) es la métrica estándar para evaluar actividad en estudios de agua doblemente marcada, considerado el estándar de referencia (*gold standard*) para medición de gasto energético total. Al ajustar el gasto calórico activo por *TMB* —que varía significativamente por edad, sexo y composición corporal— obtenemos

una estimación del desbalance energético atribuible exclusivamente al comportamiento sedentario o activo, no al metabolismo basal que difiere entre individuos por factores antropométricos no modificables. En esta cohorte observamos un rango de [-50, +80] kcal/hora, donde valores negativos indican que el gasto calórico activo no alcanza a compensar el metabolismo basal por hora (déficit calórico, indicativo de sedentarismo), mientras que valores positivos indican superávit energético por actividad física.

Variable Derivada 3: Delta Cardíaco. Cuantifica la respuesta cardiovascular al movimiento mediante la diferencia entre frecuencia cardíaca al caminar y frecuencia cardíaca en reposo:

$$\text{Delta_cardíaco} = \text{FC_caminar} - \text{FC_reposo} \quad (5.6)$$

La reserva cardíaca disponible (incremento de FC desde reposo hasta actividad ligera-moderada como caminar) es un indicador de condición física cardiovascular y capacidad de respuesta del sistema nervioso autónomo. Valores altos (>50 lpm) indican desacondicionamiento o baja eficiencia cardiovascular, mientras que valores bajos (<30 lpm) indican buena condición física con respuesta cardiovascular eficiente. En esta cohorte observamos un rango de [25, 60] lpm con mediana aproximadamente 37 lpm.

Variable 4: Variabilidad de Frecuencia Cardíaca (*HRV-SDNN*). La desviación estándar de los intervalos NN (*SDNN*, por sus siglas en inglés *Standard Deviation of NN intervals*) es un biomarcador del balance autonómico cardiovascular, validado por la Task Force de la European Society of Cardiology Task Force ESC/NASPE, 1996 y ampliamente utilizado en estudios con *wearables* Laborde et al., 2017. A diferencia de las tres variables anteriores que requieren transformaciones algebraicas, *HRV-SDNN* se utiliza directamente tal como la registra el *Apple Watch*, ya que el dispositivo calcula internamente esta métrica a partir de los intervalos entre latidos cardíacos detectados por el sensor fotopletimográfico. *HRV* alta (>50 ms) indica predominancia parasimpática del sistema nervioso autónomo, asociada a estados de relajación, buena recuperación y salud cardiovascular, mientras que *HRV* baja (<30 ms) indica predominancia simpática, asociada a estrés crónico, fatiga o sobreentrenamiento. Según la Task Force Task Force ESC/NASPE, 1996, el rango normativo es [15, 150] ms, y en nuestra cohorte observamos un rango de [9.8, 135.4] ms con mediana de 48.4 ms.

5.10 Caracterización de Distribuciones y Variabilidad

Tras la imputación jerárquica y la creación de variables derivadas, realizamos un análisis descriptivo exhaustivo de los 9,185 días válidos post-limpieza y post-imputación para caracterizar las distribuciones de las variables originales de *HealthKit* y las variables derivadas, y cuantificar la magnitud de la variabilidad que fundamentaría decisiones metodológicas posteriores. Este análisis tuvo dos objetivos metodológicos: (1) caracterizar las distribuciones de todas las variables (originales y derivadas) para identificar violaciones de normalidad y permitir la selección de los estadísticos más apropiados e idóneos según las características empíricas observadas, y (2) cuantificar la magnitud de la variabilidad diaria que motiva la decisión de agregación temporal semanal. La Tabla 5.7 resume los estadísticos principales de las ocho variables clave más las dos variables derivadas (Actividad relativa y Superávit calórico).


Tabla 5.7

Estadísticos descriptivos diarios (datos post-limpieza y post-imputación, $n = 9,185$ días)

Variable	n	Media	DE	CV (%)	Mediana	Q1	Q3	IQR	Mín	Máx	Test	p-valor
Pasos diarios	9,185	6,001.6	3,283.6	54.7	5,489.0	3,779.0	7,657.0	3,878.0	11.5	25,511.7	K-S	< 0,001
Calorías activas (kcal)	9,185	595.9	450.7	75.6	517.7	322.1	767.4	445.3	0.1	18,313.1	K-S	< 0,001
FC reposo (lpm)	9,185	54.2	8.7	16.1	53.0	48.0	59.0	11.0	37.0	142.6	K-S	< 0,001
FC al caminar (lpm)	9,185	97.8	12.4	12.7	97.8	90.5	105.0	14.5	50.0	159.0	K-S	< 0,001
HRV-SDNN (ms)	9,185	49.4	17.2	34.8	48.4	36.2	60.4	24.2	9.8	135.4	K-S	< 0,001
Horas monitoreadas	9,185	15.4	5.2	33.8	15.0	13.0	18.0	5.0	1.0	65.0	K-S	< 0,001
Actividad relativa	9,185	0.14	0.10	73.2	0.13	0.08	0.18	0.09	0.00	2.15	K-S	< 0,001
Superávit calórico (%)	9,185	32.6	23.0	70.6	28.0	19.9	40.9	21.0	0.0	817.1	K-S	< 0,001

Los estadísticos de la Tabla 5.7 evidencian tres hallazgos metodológicos críticos. Primero, todas las variables rechazan la hipótesis de normalidad según el test de Kolmogorov-Smirnov (*K-S*) con $p < 0,001$, lo cual invalida el uso de pruebas paramétricas tradicionales (*t*-test, ANOVA) y obliga a emplear métodos robustos no paramétricos (Mann-Whitney U, medianas en lugar de medias) en análisis subsecuentes. Segundo, los coeficientes de variación superan el 50 % en la mayoría de las métricas relacionadas con actividad física (Pasos $CV=54.7$ %, Calorías $CV=75.6$ %, Actividad relativa $CV=73.2$ %, Superávit calórico $CV=70.6$ %), evidenciando alta fluctuación día a día que refleja la naturaleza heterogénea del comportamiento humano en vida libre, donde un individuo puede realizar ejercicio intenso un día y permanecer sedentario el siguiente. Esta alta variabilidad diaria justifica la decisión metodológica de agregación temporal semanal mediante medianas, estrategia que captura el patrón habitual de comportamiento reduciendo el ruido de eventos aislados. Tercero, las variables cardiovasculares (FC reposo, FC al caminar, *HRV-SDNN*) presentan coeficientes de variación menores (12.7 %-34.8 %) comparados con las variables de actividad, fenómeno esperado dado que la frecuencia cardíaca basal de un individuo es relativamente estable a corto plazo, mientras que el volumen de actividad física fluctúa dramáticamente según rutinas laborales, clima y motivación personal.

La Figura 5.3 presenta las distribuciones de las seis variables clave empleadas en el modelo mediante un formato híbrido que combina histogramas con curvas de densidad *KDE*. Los paneles (a), (c) y (e) correspondientes a pasos diarios, actividad relativa y superávit calórico exhibieron distribuciones log-normales con asimetría positiva marcada ($CV=54.7$ %, 73.2 % y 70.6 %, respectivamente), donde la media superó sistemáticamente a la mediana en 9-16 %, indicativo de eventos esporádicos de alta actividad que extienden la cola derecha. Esta no-normalidad (Kolmogorov-Smirnov $p < 0,001$ para las seis variables) justificó el uso de estadísticos robustos (medianas, percentiles, *IQR*) en lugar de promedios aritméticos susceptibles a outliers.

Figura 5.3
Distribuciones diarias de variables clave



En contraste, los paneles (b) y (d) frecuencia cardíaca en reposo y al caminar mostraron distribuciones aproximadamente normales con baja variabilidad ($CV=16.1\%$ y 12.7%), reflejando la regulación homeostática estricta del sistema cardiovascular. Notablemente, la FC al caminar presentó la variabilidad más baja de todas las métricas ($CV=12.7\%$) y simetría perfecta (Media=Mediana=97.8 lpm), consecuencia esperada de un esfuerzo submáximo estandarizado (caminar $\sim 3-4$ METs) que homogeneiza la respuesta cardiovascular intra e inter-sujeto. El panel (f), *HRV-SDNN*, evidenció distribución log-normal con variabilidad intermedia ($CV=34.8\%$, mediana=48.4 ms), posicionándose en el centro del rango normativo adulto (25-75 ms).

Asimismo, los boxplots comparativos de la Figura 5.4 muestran la distribución de las seis variables clave (Pasos Diarios, Actividad Relativa, Superávit Calórico Basal, FC Reposo, FC al Caminar, *HRV-SDNN*) por usuario, evidenciando heterogeneidad marcada tanto inter-sujeto (diferencias entre participantes en las medianas) como intra-sujeto (amplitud de los rangos intercuartílicos dentro de cada participante). Las variables de comportamiento físico (Pasos Diarios, Actividad Relativa, Superávit Calórico) presentan mayor

variabilidad y presencia de outliers extremos comparadas con las variables cardiovasculares (FC Reposo, FC al Caminar, $HRV\text{-}SDNN$), fenómeno esperado dado que el volumen de actividad física fluctúa dramáticamente según rutinas laborales, clima y motivación personal, mientras que la frecuencia cardíaca basal y la respuesta cardiovascular al caminar están sujetas a regulación homeostática más estricta. Esta heterogeneidad observada refuerza la decisión metodológica de utilizar mediana e IQR como descriptores semanales en lugar de media y desviación estándar, ya que estos últimos son sensibles a los outliers extremos evidentes en las figuras.

Figura 5.4

Boxplots comparativos que evidencian asimetría y outliers por usuario



5.11 Agregación Temporal Semanal

La agregación temporal semanal se justifica porque los datos diarios presentan variabilidad excesiva (CV diario $>50\%$ según Tabla 5.7) atribuible a comportamientos esporádicos, ruido de medición y ciclos semanales naturales. Esta alta variabilidad diaria, combinada con la no-normalidad universal de las distribuciones (Kolmogorov-Smirnov $p < 0,001$ para todas las variables), requiere una estrategia de agregación que capture patrones habituales de comportamiento reduciendo el ruido de eventos aislados, estableciendo un balance óptimo entre granularidad temporal y estabilidad estadística necesaria para el análisis multivariado posterior. Anticipamos que la agregación semanal mediante estadísticos robustos (mediana $p50$, IQR)

reducirá el coeficiente de variación de $>50\%$ (nivel diario) a aproximadamente $25-35\%$ (nivel semanal), preservando la señal fisiológica de interés mientras elimina fluctuaciones transitorias no representativas del comportamiento habitual.

Seleccionamos la mediana (percentil 50, p_{50}) como estimador de tendencia central y el rango intercuartílico (IQR) como medida de dispersión para la agregación semanal. Esta elección se fundamenta en tres principios complementarios: primero, la mediana es menos sensible que la media a días con fallas de registro del dispositivo (ejemplo: menos de 10 horas monitoreadas debido a batería agotada) o eventos atípicos (ejemplo: ejercicio intenso aislado no representativo del comportamiento habitual), garantizando robustez ante valores extremos que caracterizan los datos de vida libre. Segundo, la agregación semanal mediante medianas amortigua el ruido diario preservando la señal fisiológica de interés, resultando en coeficientes de variación semanales más manejables (CV semanal = $25-35\%$) comparados con la variabilidad diaria (CV diario = $45-60\%$). Tercero, la ventana de 7 días consecutivos (lunes a domingo) captura comportamientos habituales y patrones de actividad recurrentes durante la semana laboral y fin de semana, no eventos aislados, alineándose con las recomendaciones de la Organización Mundial de la Salud de evaluación de actividad física en períodos semanales completos World Health Organization, 2020a.

Establecimos como criterio de validez semanal que cada ventana de 7 días debía contener al menos 5 días con datos completos, equivalente a 71% de completitud diaria mínima. Este umbral conservador garantiza que la mediana semanal calculada sea representativa del comportamiento habitual, descartando semanas con exceso de datos faltantes donde la mediana podría estar sesgada por ausencia sistemática de registros. Adicionalmente, calculamos estadísticos auxiliares (percentiles p_{10} , p_{90} e IQR) para cada variable semanal, aunque para el análisis de *clustering* y modelado difuso posterior utilizamos exclusivamente las medianas p_{50} de las cuatro variables derivadas ya definidas en la Sección 5.9: *Actividad_relativa*, *Superávit_calórico_basal*, *Delta_cardíaco* y *HRV-SDNN*. Esta selección de p_{50} como feature principal se fundamenta en que la mediana es robusta ante outliers y captura la tendencia central representativa del comportamiento semanal, mientras que los estadísticos de dispersión (IQR , p_{10} , p_{90}) se calcularon para análisis de variabilidad y parametrización de funciones de pertenencia difusas, pero no como variables de entrada para el clustering.

La aplicación de este criterio de validez sobre los 9,185 días válidos generó inicialmente 1,385 semanas candidatas, de las cuales 1,337 cumplieron el criterio de validez (tasa de retención 96.5%), resultando en el *dataset* semanal final con 1,337 observaciones independientes. Para cada una de las 4 variables derivadas, calculamos la mediana semanal mediante la ecuación $x_{p_{50}}^{(k)} = \text{median}\{x_{\text{día}_1}, x_{\text{día}_2}, \dots, x_{\text{día}_7}\}$, donde k representa la semana y los días 1-7 corresponden a los 7 días consecutivos de la ventana semanal. Este proceso de agregación temporal preserva la riqueza informativa del seguimiento longitudinal denso mientras reduce el ruido diario característico de mediciones en vida libre, estableciendo un balance óptimo entre granularidad temporal y estabilidad estadística de las métricas necesarias para el análisis multivariado posterior.

5.11.1 Análisis de Correlación entre Variables Semanales

La evaluación de correlaciones entre las 4 variables p50 semanales se justifica porque la presencia de multicolinealidad severa (correlaciones $r > 0,80$) entre variables de entrada puede generar inestabilidad numérica en algoritmos de agrupamiento y redundancia informativa en sistemas expertos, comprometiendo la interpretabilidad y robustez del modelo final. Anticipamos que las variables relacionadas con volumen de actividad (Actividad_relativa_p50, Superávit_calórico_p50) presentarán correlación moderada ($0,30 \leq r \leq 0,70$), mientras que las variables cardiovasculares (HRV-SDNN_p50, Delta_cardiaco_p50) mostrarán correlaciones más débiles con las primeras ($r < 0,35$), indicando que capturan dominios fisiológicos distintos y justificando su inclusión simultánea en el modelo.

Calculamos la matriz de correlación de Pearson para las 4 variables p50 semanales sobre $n = 1,337$ semanas válidas, complementada con correlaciones de Spearman para validar robustez ante no-normalidad. Establecimos como criterios de interpretación: $|r| < 0,30$ indica correlación débil, $0,30 \leq |r| < 0,70$ indica correlación moderada, y $|r| \geq 0,70$ sugiere correlación fuerte con posible multicolinealidad. Si alguna correlación supera $r > 0,80$, consideraremos eliminar una de las variables o aplicar técnicas de reducción dimensional. La Tabla 5.8 presenta los resultados. La correlación entre Actividad_relativa y Superávit_calórico fue $r = 0,68$ (moderada-alta, esperada dado que ambas reflejan volumen de actividad física). Las correlaciones entre variables de actividad y variables cardiovasculares fueron bajas: Actividad_relativa con HRV-SDNN ($r = 0,12$), Actividad_relativa con Delta_cardiaco ($r = 0,24$), Superávit_calórico con HRV-SDNN ($r = 0,09$), y Superávit_calórico con Delta_cardiaco ($r = 0,31$). Estas correlaciones bajas confirman que las variables cardiovasculares capturan dominios fisiológicos distintos al volumen de movimiento, justificando su inclusión simultánea en el sistema difuso para capturar la complejidad multidimensional del sedentarismo.

Tabla 5.8

Matriz de correlación de Pearson entre variables semanales p50 ($n = 1,337$ semanas)

	Act_rel	Sup_cal	HRV	Δ Card
Act_rel	1.00	0.68	0.12	0.24
Sup_cal	0.68	1.00	0.09	0.31
HRV	0.12	0.09	1.00	0.18
Δ Card	0.24	0.31	0.18	1.00

Para evaluar multicolinealidad de forma más rigurosa, calculamos el Factor de Inflación de la Varianza (VIF) para cada variable. El VIF cuantifica cuánto se infla la varianza de los coeficientes de regresión debido a la correlación con otras variables, calculado como $VIF_j = 1/(1 - R_j^2)$, donde R_j^2 es el coeficiente de determinación de la regresión de la variable j contra las demás. Establecimos como criterios: $VIF < 5$ indica multicolinealidad aceptable, $5 \leq VIF < 10$ indica moderada (requiere precaución), y $VIF \geq 10$ indica severa (justifica eliminación de variable). Los resultados mostraron VIF de 1.92 para Actividad_relativa,

1.88 para *Superávit_calórico*, 1.06 para *HRV-SDNN*, y 1.14 para *Delta_cardiaco*, todos muy por debajo del umbral problemático de 5.0. Esta ausencia de multicolinealidad severa confirma que las 4 variables aportan información única y no redundante, validando su uso simultáneo en el *clustering* y el modelado difuso.

5.11.2 Matriz de Dispersión de Relaciones Bivariadas

La evaluación de relaciones bivariadas mediante matriz de dispersión se justifica porque permite visualizar patrones no lineales y heterogeneidad inter-sujeto que los coeficientes de correlación de Pearson no capturan. Anticipamos que los scatter plots mostrarán nubes dispersas sin correlaciones lineales fuertes evidentes, mientras que las densidades *KDE* revelarán distribuciones asimétricas, justificando el uso de lógica difusa en lugar de modelos de regresión lineal que asumen relaciones homogéneas entre variables.

La Figura 5.5 presenta la matriz de dispersión para las variables clave (muestra $n = 2,000$ días, coloreado por usuario). Los scatter plots (panel superior) muestran nubes dispersas sin correlaciones lineales fuertes evidentes, mientras que las densidades *KDE* (panel inferior) revelan distribuciones asimétricas. Esta ausencia de relaciones lineales simples, combinada con la heterogeneidad inter-sujeto observada en los patrones de correlación, justifica el uso de lógica difusa en lugar de modelos de regresión lineal que asumen relaciones homogéneas entre variables.

Matriz de Dispersión: Relaciones Bivariadas
(Muestra n=2,000 días, Coloreado por Usuario)




Figura 5.5

Matriz de dispersión: relaciones bivariadas entre variables clave (muestra $n = 2,000$ días, coloreado por usuario). Los scatter plots (panel superior) muestran nubes dispersas sin correlaciones lineales fuertes evidentes, mientras que las densidades KDE (panel inferior) revelan distribuciones asimétricas. Esta ausencia de relaciones lineales simples justifica el uso de lógica difusa en lugar de modelos de regresión lineal.

5.12 Análisis Dual de Variabilidad

El análisis dual de variabilidad se justifica porque la imputación de datos faltantes podría introducir artefactos que distorsionen la dispersión natural de las variables. Comparar variabilidad observada (pre-imputación) vs. operativa (post-imputación) valida que el proceso de imputación no altera dramáticamente las distribuciones, preservando las características estadísticas originales necesarias para el análisis posterior. Anticipamos que la diferencia en coeficiente de variación ($|\Delta CV|$) entre observado y operativo será menor al 10 % para todas las variables, confirmando que la imputación preserva la estructura de dispersión original.

5.12.1 Definición de Variabilidad Observada vs Operativa

La variabilidad observada cuantifica la fluctuación natural día-a-día medida directamente por el sensor en datos crudos sin imputar, calculada mediante la ecuación $CV_{obs}^{(u,v)} = \frac{\sigma_{obs}(v,u)}{\mu_{obs}(v,u)} \times 100 \%$, donde v representa la variable y u el usuario. La variabilidad operativa refleja la variabilidad utilizada en el análisis final post-imputación, calculada como $CV_{op}^{(u,v)} = \frac{\sigma_{op}(v,u)}{\mu_{op}(v,u)} \times 100 \%$. Establecimos como criterios de decisión: si $|\Delta CV| < 5 \%$ aceptamos la imputación (impacto mínimo), si $5 \% \leq |\Delta CV| < 10 \%$ aceptamos con precaución (impacto moderado), y si $|\Delta CV| \geq 10 \%$ revisamos la estrategia de imputación (distorsión significativa). Si $CV_{op} < CV_{obs}$ (reducción), esto es esperado debido al efecto de regresión a la media inherente a métodos basados en medianas.

5.12.2 Comparación Observada vs Operativa

La Tabla 5.9 presenta los coeficientes de variación observados y operativos (promedio de 10 usuarios) para las variables clave. La imputación tiene un impacto moderado ($|\Delta CV| < 5 \%$ en la mayoría de variables), tendiendo a reducir ligeramente la dispersión (efecto de regresión a la media en métodos basados en medianas). El aumento en FC_caminar y Delta_cardiaco es marginal ($< 2 \%$) y aceptable. Esta ausencia de distorsión severa confirma que los datos operativos preservan la estructura de dispersión original, validando su uso en clustering y modelado difuso.

Tabla 5.9

Coeficiente de Variación: Observado vs Operativo (promedio 10 usuarios)

Variable	CV obs (%)	CV op (%)	ΔCV (%)	Dir.	Efecto impute
Pasos	62.3	59.8	-2.5	↓	Suaviza
Actividad_relativa	58.7	56.4	-2.3	↓	Suaviza
Calorías_activas	74.5	71.2	-3.3	↓	Suaviza
Superávit_calórico	68.9	66.1	-2.8	↓	Suaviza
FC_reposo	14.2	13.8	-0.4	↓	Mínimo
FC_caminar	11.8	13.1	+1.3	↑	Leve aumento
HRV-SDNN	35.4	32.7	-2.7	↓	Suaviza
Delta_cardiaco	15.6	16.2	+0.6	↑	Leve aumento




Figura 5.6

Comparación de variabilidad operativa vs. observada. Se muestra el coeficiente de variación (CV) para cada variable, separando datos observados (pre-imputación) y operativos (post-imputación). El impacto de la imputación es moderado ($|\Delta CV| < 5\%$), con tendencia a reducción por efecto de regresión a la media.




Figura 5.7

Distribución de coeficiente de variación (CV) por usuario. Los boxplots muestran heterogeneidad marcada entre participantes: algunos usuarios presentan CV consistentemente altos (ejemplo: u3, u7), indicando mayor fluctuación día-a-día, mientras otros muestran patrones más estables (ejemplo: u1, u5).

La conclusión de esta fase es que el *dataset* semanal con 1,337 observaciones y 4 variables p50 está listo para el análisis de reducción dimensional y clustering que describimos en las secciones siguientes.

5.13 Análisis de Componentes Principales

El análisis de componentes principales se justifica porque permite visualizar la estructura de los datos en un espacio reducido (2D o 3D), identificar qué variables contribuyen más a la varianza total, y evaluar si los clusters que descubriremos posteriormente mediante K-Means son visualmente separables en el espacio de componentes principales. Aunque no eliminamos variables del modelo final (las 4 variables p50 ya fueron validadas mediante *VIF*), el *PCA* proporciona información complementaria sobre la estructura dimensional de los datos y fundamenta la selección del número óptimo de clusters mediante la varianza explicada por los componentes principales. Anticipamos que los dos primeros componentes principales (*PC1* y *PC2*) capturarán al menos el 70 % de la varianza total, permitiendo visualización bidimensional informativa, y que las cargas (*loadings*) de las variables en estos componentes reflejarán su interpretación fisiológica (ejemplo: *PC1* dominado por variables de actividad física, *PC2* dominado por variables cardiovasculares).

Aplicamos *PCA* sobre las 4 variables p50 semanales que constituyen las entradas del modelo de clustering y del sistema difuso: (1) Actividad_relativa_p50, (2) Superávit_calórico_p50, (3) *HRV-SDNN*_p50, y (4) Delta_cardiaco_p50. Estas 4 variables fueron derivadas en la Sección 5.9: Activi-

dad_relativa y Superávit_calórico_basal son transformaciones que normalizan métricas absolutas por exposición temporal y metabolismo basal individual, respectivamente; *HRV-SDNN* se utiliza directamente tal como la registra el *Apple Watch*; y Delta_cardiaco es una variable derivada calculada como la diferencia entre frecuencia cardíaca al caminar y frecuencia cardíaca en reposo (ecuación 5.6), cuantificando la respuesta cardiovascular al movimiento. Estas variables fueron seleccionadas tras el análisis de correlación entre variables originales que reveló multicolinealidad moderada, y fueron agregadas a nivel semanal utilizando la mediana p50 como se justificó en la Sección 5.11 debido a la robustez de la mediana ante outliers y la alta variabilidad diaria ($CV > 50\%$). Previamente a la aplicación de *PCA*, estandarizamos las 4 variables (media 0, varianza 1) mediante la transformación $z_i = (x_i - \mu)/\sigma$ para evitar que variables con mayor escala dominen los componentes. El proceso de *PCA* involucró: (1) cálculo de la matriz de covarianza $\mathbf{C} = \frac{1}{n-1} \mathbf{X}^T \mathbf{X}$, (2) descomposición en valores propios $\mathbf{C} = \mathbf{V} \mathbf{\Lambda} \mathbf{V}^T$, donde $\mathbf{V}$ son los vectores propios (loadings) y $\mathbf{\Lambda}$ los valores propios (varianza explicada), y (3) proyección $\mathbf{Y} = \mathbf{X} \mathbf{V}$.

El análisis reveló que *PC1* explica el 38.9 % de la varianza, *PC2* el 32.9 % (varianza acumulada 71.9 %), *PC3* el 21.2 % (acumulada 93.0 %), y *PC4* el 7.0 % (acumulada 100 %). La Tabla 5.10 presenta la varianza explicada por cada componente. Las cargas de las variables en los primeros tres componentes principales se muestran en la Tabla 5.11. *PC1* está dominado por Delta_cardiaco (0.632) y Superávit_calórico (0.512), representando el eje de actividad física y respuesta cardiovascular al ejercicio. *PC2* está dominado por Superávit_calórico (0.710) y *HRV-SDNN* (0.457), con carga negativa de Delta_cardiaco (-0.493), representando el eje de salud cardiovascular y tono autonómico. *PC3* está fuertemente dominado por Actividad_relativa (0.740), con cargas negativas en variables cardiovasculares, representando la densidad de actividad (kilopasos/hora), un matiz complementario al volumen total (*PC1*) y salud cardiovascular (*PC2*). La varianza acumulada de 71.9 % en dos dimensiones es suficiente para visualización y fundamenta la selección de $K = 2$ en el *clustering* posterior, como desarrollamos en la Sección 5.14.

Tabla 5.10

Varianza Explicada por Componentes Principales (4 Variables p50, $n = 1,337$ semanas)

PC	Varianza (%)	Acumulada (%)	Interpretación
<i>PC1</i>	38.9	38.9	Eje actividad física
<i>PC2</i>	32.9	71.9	Eje salud cardiovascular
<i>PC3</i>	21.2	93.0	Densidad de actividad
<i>PC4</i>	7.0	100.0	Residual (varianza marginal)

Tabla 5.11

Cargas de las 4 Variables p50 en los Primeros 3 Componentes Principales

Variable	<i>PC1</i>	<i>PC2</i>	<i>PC3</i>
Actividad_relativa_p50	0.478	0.210	0.740
Superávit_calórico_p50	0.512	0.710	-0.328
<i>HRV-SDNN</i> _p50	-0.333	0.457	-0.344
Delta_cardiaco_p50	0.632	-0.493	-0.476

La Figura 6.3 presenta el biplot de *PCA* (*PC1* vs. *PC2*) usando las 4 variables p50 como entrada. Los vectores de carga (flechas) muestran que *PC1* está dominado por Delta_cardiaco (0.632) y Superávit_calórico (0.512), representando el eje de actividad física. *PC2* está dominado por Superávit_calórico (0.710) y *HRV-SDNN* (0.457), representando el eje de salud cardiovascular. La separación ortogonal de estos dominios confirma que las 4 variables aportan información complementaria. Las 4 variables p50 muestran cargas significativas en al menos uno de los 3 componentes, confirmando que cada una aporta información única.




Figura 5.8

*Biplot de PCA (PC1 vs. PC2) usando las 4 variables p50 como entrada. Los vectores de carga (flechas) muestran que PC1 está dominado por Delta_cardíaco (0.632) y Superávit_calórico (0.512), representando el eje de actividad física. PC2 está dominado por Superávit_calórico (0.710) y HRV-SDNN (0.457), representando el eje de salud cardiovascular. La separación ortogonal de estos dominios confirma que las 4 variables aportan información complementaria. **Nota metodológica:** Los percentiles (p10, p90, IQR) se usaron para parametrizar funciones de pertenencia difusas, NO como features de clustering.*

La Figura 5.9 presenta la comparativa de reducción dimensional: PCA (lineal, izquierda) vs. t-SNE (no-lineal, derecha) sobre las 4 variables p50. PCA muestra separación moderada entre clusters con overlap natural (esperado en transiciones graduales de comportamiento). t-SNE confirma estructura de agrupamiento local, validando que los datos tienen patrones detectables a pesar de la variabilidad inherente de datos de vida libre. Esta convergencia entre métodos lineales y no-lineales refuerza la robustez de la estructura de clusters identificada.




Figura 5.9

Comparativa de reducción dimensional: PCA (lineal, izquierda) vs. t-SNE (no-lineal, derecha) sobre las 4 variables p50. PCA muestra separación moderada entre clusters con overlap natural (esperado en transiciones graduales de comportamiento). t-SNE confirma estructura de agrupamiento local, validando que los datos tienen patrones detectables a pesar de la variabilidad inherente de datos de vida libre.

5.13.1 Exploración en 3 Dimensiones (PC1-PC2-PC3)

Siguiendo la sugerencia del comité tutorial, evaluamos si $PC3$ revelaría patrones adicionales de separación no visibles en el espacio bidimensional. $PC3$ explica 21.2 % de varianza adicional, elevando la varianza acumulada de 71.9 % (2D) a 93.0 % (3D). Este tercer componente está fuertemente dominado por Actividad_relativa (loading = 0.740), representando la densidad de actividad (kilopasos/hora), un matiz complementario al volumen total ($PC1$) y salud cardiovascular ($PC2$).

La Figura 5.10 presenta PCA en 3 dimensiones ($PC1$ - $PC2$ - $PC3$) con 4 rotaciones. $PC3$ aporta 21.2 % de varianza adicional (total acumulado: 93.0 %), dominado por Actividad_relativa (0.740). Las 4 vistas muestran la estructura espacial desde diferentes ángulos. A pesar del incremento en varianza explicada, la separación de clusters no mejora dramáticamente respecto a 2D, confirmando que $PC1$ - $PC2$ capturan los ejes principales de sedentarismo. Aunque $PC3$ aporta varianza significativa (21.2 %), el análisis bidimensional ($PC1$ - $PC2$, 71.9 % varianza) es suficiente para visualizar la estructura de clusters, fundamentar la selección de $K = 2$ en clustering, e interpretar los ejes fisiológicos de sedentarismo. La exploración 3D valida retrospectivamente que $PC1$ y $PC2$ capturan los dominios principales (actividad y cardiovascular), mientras $PC3$ añade un matiz complementario (densidad de movimiento) relevante pero no esencial para la clasificación binaria.

PCA 3D: 4 Variables p50 (Varianza acumulada PC1+PC2+PC3 = 93.0%)




Figura 5.10

PCA en 3 dimensiones (PC1-PC2-PC3) con 4 rotaciones. PC3 aporta 21.2 % de varianza adicional (total acumulado: 93.0 %), dominado por *Actividad_relativa* (0.740). Las 4 vistas muestran la estructura espacial desde diferentes ángulos. A pesar del incremento en varianza explicada, la separación de clusters no mejora dramáticamente respecto a 2D, confirmando que PC1-PC2 capturan los ejes principales de sedentarismo.

5.14 Clustering No Supervisado: Verdad Operativa

5.14.1 Justificación del Clustering como Verdad Operativa

¿Por qué utilizar *clustering* no supervisado para generar la verdad operativa en lugar de etiquetas externas? En estudios de comportamiento sedentario en condiciones de vida libre, no existe un estándar de referencia (*gold standard*) objetivo para clasificar semanas como sedentarias o activas. Las etiquetas subjeti-

vas (cuestionarios, auto-reporte) presentan sesgos de recuerdo y deseabilidad social, mientras que umbrales absolutos (ejemplo: $< 5,000$ pasos/día = sedentario) ignoran la heterogeneidad inter-individual. Esperamos que los datos semanales contengan patrones latentes que se agrupen naturalmente en $K = 2$ clusters, representando perfiles de “Alto Sedentarismo” vs “Bajo Sedentarismo”, y que esta clasificación empírica sirva como verdad operativa (*Ground Truth*) para validar el sistema difuso diseñado con conocimiento experto.

Seleccionamos el algoritmo K-Means por su eficiencia computacional para *datasets* grandes ($n = 1,337$ semanas), su interpretabilidad (centroides representan el perfil promedio de cada cluster), y su capacidad de generar etiquetas duras (no probabilísticas) necesarias para métricas de clasificación supervisada. K-Means minimiza la inercia (suma de distancias cuadradas intra-cluster) mediante la ecuación $\min_C \sum_{k=1}^K \sum_{i \in C_k} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2$, donde $\boldsymbol{\mu}_k$ es el centroide del cluster k y C_k es el conjunto de puntos asignados. Preprocesamos los datos mediante escalado robusto (*RobustScaler*) que utiliza mediana e *IQR* en lugar de media y desviación estándar, reduciendo la influencia de outliers. Inicializamos el algoritmo con K-Means++ (reduce dependencia de semilla) y ejecutamos 50 repeticiones con diferentes semillas, seleccionando la solución con menor inercia.

Establecimos como criterios de selección del número óptimo de clusters: (1) si el coeficiente de Silhouette es máximo en $K = 2$, seleccionaremos $K = 2$ por interpretabilidad clínica (clasificación binaria sedentario/no sedentario); (2) si la curva de inercia vs. K muestra un codo (*elbow*) en K^* , consideraremos K^* como candidato; (3) si $K > 4$, rechazaremos por pérdida de interpretabilidad clínica; (4) si Silhouette $< 0,20$ para todo K , cuestionaremos si los datos tienen estructura de clusters. El coeficiente de Silhouette mide la cohesión intra-cluster y separación inter-cluster mediante $s(i) = (b(i) - a(i)) / \max\{a(i), b(i)\}$, donde $a(i)$ es la distancia promedio intra-cluster y $b(i)$ es la distancia promedio al cluster más cercano. Valores $> 0,25$ son aceptables para datos reales con overlap natural.

Ejecutamos K-Means para $K \in \{2, 3, 4, 5, 6\}$ y calculamos métricas de evaluación. Los resultados del barrido de K (K-Sweep) se presentan en la Tabla 5.12. El coeficiente de Silhouette fue máximo en $K = 2$ (0.232), aunque relativamente bajo, indicando que los clusters tienen overlap natural esperado en transiciones graduales de comportamiento en vida libre. La inercia disminuyó monótonamente conforme aumentó K (2,847 para $K = 2$, 1,542 para $K = 6$), sin mostrar un codo claro, mientras que el índice de Davies-Bouldin aumentó con K (1.42 para $K = 2$, 2.05 para $K = 6$), confirmando que $K = 2$ es óptimo.

Tabla 5.12

Métricas de clustering por número de clusters ($n = 1,337$ semanas)

K	Silhouette	Inercia	Davies-Bouldin	Decisión
2	0.232	2,847	1.42	Seleccionado
3	0.198	2,301	1.58	
4	0.187	1,956	1.71	
5	0.174	1,721	1.89	
6	0.165	1,542	2.05	

Seleccionamos $K = 2$ basándonos en: (1) máximo Silhouette (0.232) en $K = 2$, (2) interpretabilidad clínica (clasificación binaria facilita toma de decisiones en salud pública), y (3) respaldo de PCA (2 componentes principales explican 71.9 % de varianza). El Silhouette relativamente bajo (0.232) se aceptado dado que los datos de vida libre presentan overlap natural entre estados de comportamiento, y el análisis estadístico posterior (Mann-Whitney U, Cohen's d) validará la separación de perfiles. Tras ejecutar K-Means con $K = 2$, obtuvimos Cluster 0 con 402 semanas (30.1 %) y Cluster 1 con 935 semanas (69.9 %). Inspeccionando los centroides, asignamos etiquetas clínicas: Cluster 0 (mayor Actividad_relativa y Superávit_calórico) = "ACTIVO" (Bajo Sedentarismo), Cluster 1 (menor actividad) = "SEDENTARIO" (Alto Sedentarismo).

5.14.2 Validación Estadística de los Perfiles de Cluster

¿Por qué validar estadísticamente los perfiles de cluster si K-Means ya asignó las etiquetas? Aunque K-Means agrupa automáticamente, es crítico verificar que los 2 clusters identificados representan perfiles fisiológicamente distintos y no agrupaciones artificiosas por ruido. Esperamos que los clusters difieran significativamente ($p < 0,001$) en las variables de actividad física (Actividad_relativa, Superávit_calórico), con tamaños de efecto grandes (Cohen's d $> 0,8$), validando la separación clínica.

Aplicamos pruebas de Mann-Whitney U (no paramétricas, apropiadas dado que las variables no siguen distribución normal) para comparar los 2 clusters en las 4 variables p50. Establecimos como criterios: si Mann-Whitney U arroja $p < 0,001$ para variables clave, aceptamos separación estadística; si Cohen's d $> 0,8$ para Actividad_relativa o Superávit_calórico, confirmamos tamaño de efecto grande (diferencia clínica relevante); si alguna variable no discrimina ($p > 0,05$), investigamos si es prescindible o tiene rol multivariado; si los clusters tienen $n < 100$ semanas, cuestionamos representatividad.

Los resultados (ver Tabla 5.13) mostraron diferencias altamente significativas en Actividad_relativa ($p < 0,001$, Cohen's d = 0.93, efecto grande) y Superávit_calórico ($p < 0,001$, Cohen's d = 1.78, efecto muy grande). Delta_cardiaco mostró diferencia significativa pero con efecto pequeño-mediano ($p = 0,023$, Cohen's d = 0.33). Notablemente, HRV-SDNN no discriminó significativamente entre clusters ($p = 0,562$, Cohen's d = 0.08), hallazgo que denominamos "paradoja HRV" y que investigamos posteriormente mediante análisis de ablación en el sistema difuso (Sección 5.16).

Tabla 5.13

Comparación estadística entre clusters (Mann-Whitney U, $n = 1,337$ semanas)

Variable	U statistic	p-valor	Cohen's d	Efecto
Actividad_relativa	98,234	$< 0,001$	0.93	Grande
Superávit_calórico	72,158	$< 0,001$	1.78	Muy grande
HRV-SDNN	186,291	0.562	0.08	Ninguno
Delta_cardiaco	171,045	0.023	0.33	Pequeño-mediano

A pesar de que HRV-SDNN no discrimina univariadamente, su contribución multivariada dentro del sistema difuso será evaluada mediante análisis de ablación. La verdad operativa generada por K-Means

con $K = 2$ está validada estadísticamente para las variables de actividad física (diferencias significativas con tamaños de efecto grandes), y servirá como referencia para validar el sistema de inferencia difusa que diseñamos con conocimiento experto, como desarrollamos en la siguiente sección.

5.15 Diseño del Sistema de Inferencia Difusa Mamdani

5.15.1 Arquitectura General del Sistema

¿Por qué un sistema de inferencia difusa en lugar de modelos de aprendizaje supervisado tradicionales? Los modelos de *machine learning* (redes neuronales, *random forests*) son “cajas negras” que no proporcionan interpretabilidad clínica, mientras que los sistemas difusos permiten expresar conocimiento experto mediante reglas lingüísticas comprensibles (ejemplo: “SI Actividad_relativa es Baja Y Superávit_calórico es Bajo ENTONCES Sedentarismo es Alto”). Esperamos que el sistema difuso, diseñado con conocimiento fisiológico, concuerde altamente ($F1\text{-Score} \geq 0,80$) con la verdad operativa derivada empíricamente del *clustering*, demostrando que ambos métodos independientes capturan la misma estructura subyacente de sedentarismo.

Diseñamos un sistema de inferencia difusa tipo *Mamdani* con 4 entradas (las medianas semanales p50 de Actividad_relativa, Superávit_calórico_basal, *HRV-SDNN* y Delta_cardiaco), 12 funciones de pertenencia triangulares (3 etiquetas lingüísticas por variable: Baja, Media, Alta), una base de 5 reglas IF-THEN basadas en conocimiento clínico, y una salida continua en escala $[0,1]$ que representa el nivel de sedentarismo, donde valores cercanos a 1 indican alto sedentarismo. El proceso de inferencia sigue 5 pasos: (1) fuzzificación (conversión de valores numéricos a grados de pertenencia), (2) activación de reglas (operador AND = mínimo), (3) agregación (suma de activaciones), (4) defuzzificación (centroide discreto), y (5) binarización mediante umbral τ optimizado por *grid search* maximizando F1-Score.

Establecimos como criterios de aceptación: si el sistema difuso logra $F1\text{-Score} > 0,70$ vs. Ground Truth, aceptamos el modelo como válido; si $\text{Recall} > 0,90$, priorizamos sensibilidad (herramienta de *screening* de sedentarismo); si $\text{Precision} < 0,60$ pero $\text{Recall} > 0,95$, aceptamos el *trade-off* (falsos positivos tolerables en contexto de salud pública). Seleccionamos arquitectura Mamdani (vs. Sugeno o Tsukamoto) por interpretabilidad clínica (funciones de pertenencia y reglas humanamente comprensibles), flexibilidad (permite etiquetas lingüísticas múltiples), y precedente en literatura biomédica (sistemas expertos en diagnóstico).

5.15.2 Funciones de Pertenencia Basadas en Percentiles

¿Por qué funciones de pertenencia triangulares basadas en percentiles en lugar de funciones paramétricas (gaussianas)? Las funciones de pertenencia deben capturar la distribución real de los datos (no asumir normalidad) y permitir interpretabilidad clínica. Usar percentiles del *dataset* garantiza que las etiquetas “Baja”, “Media”, “Alta” reflejen cuartiles reales de la población, no umbrales arbitrarios. Esperamos que las MF basadas en percentiles (p10-p90) sean más robustas que MF paramétricas, especialmente en datos no-normales con $CV > 50\%$.

Para cada variable, calculamos percentiles del *dataset* semanal ($n = 1,337$) y definimos funciones

triangulares con overlap intencional: **Baja**: triángulo (p_{10}, p_{25}, p_{40}) , **Media**: triángulo (p_{35}, p_{50}, p_{65}) , **Alta**: triángulo (p_{60}, p_{80}, p_{90}) . El overlap entre etiquetas $(p_{35}-p_{40}, p_{60}-p_{65})$ permite transiciones graduales, característica clave de lógica difusa. Establecimos como criterios: si el overlap entre etiquetas $< 10\%$ del rango, rechazamos (transiciones demasiado abruptas); si overlap $> 30\%$, rechazamos (ambigüedad excesiva); si percentiles extremos (p_{10}, p_{90}) capturan $> 80\%$ de datos, aceptamos cobertura.

La función triangular se define como $\mu(x; a, b, c) = 0$ si $x \leq a$ o $x \geq c$, $\mu(x) = (x - a)/(b - a)$ si $a < x < b$, y $\mu(x) = (c - x)/(c - b)$ si $b \leq x < c$, donde (a, b, c) son los parámetros izquierda, pico y derecha. La Tabla 5.14 presenta los parámetros calculados para las 12 funciones de pertenencia. El overlap del 15-25 % entre etiquetas adyacentes garantiza transiciones graduales sin ambigüedad excesiva, y los percentiles p_{10} - p_{90} cubren el 80 % central de los datos, descartando outliers extremos.

Tabla 5.14

Parámetros de funciones de pertenencia triangulares (percentiles del dataset, $n = 1,337$ semanas)

Variable	Etiqueta	a (izq)	b (pico)	c (der)
Actividad_relativa (kph)	Baja	0.28	0.42	0.53
	Media	0.48	0.58	0.68
	Alta	0.63	0.78	0.95
Superávit_calórico (%)	Baja	12.1	18.5	24.3
	Media	21.7	29.4	37.8
	Alta	35.2	45.1	58.9
HRV-SDNN (ms)	Baja	28.3	38.7	45.1
	Media	42.8	48.2	54.9
	Alta	52.1	61.3	72.8
Delta_cardiaco (lpm)	Baja	24.5	30.2	34.8
	Media	33.1	36.8	41.2
	Alta	39.7	45.8	53.1

5.15.3 Base de Reglas Difusas

¿Por qué 5 reglas y no más? Las reglas difusas deben ser parsimoniosas (interpretables por clínicos) pero completas (cubrir casos relevantes). Más de 10 reglas generan sobrecarga cognitiva; menos de 3 omiten casos clínicos importantes. Esperamos que 5 reglas basadas en conocimiento experto, combinando actividad física y biomarcadores cardiovasculares, capturen los patrones clave de sedentarismo vs. actividad, logrando F1-Score $> 0,70$ vs. Ground Truth.

Las reglas fueron diseñadas mediante: (1) inspección de centroides de clusters $K=2$ (identificar qué variables discriminan más), (2) conocimiento clínico (ejemplo: baja *HRV* + baja *Delta_cardiaco* → desacondicionamiento), y (3) análisis de correlaciones (evitar redundancia entre antecedentes). La estructura sigue el formato: IF (Var1 = Label1) AND (Var2 = Label2) THEN (Sedentarismo = LabelOut). La base de 5 reglas es:

1. **R1:** IF Actividad_relativa = *Baja* AND Superávit_calórico = *Bajo* THEN Sedentarismo = *Alto* (inactividad + bajo gasto → sedentarismo claro)
2. **R2:** IF Actividad_relativa = *Baja* AND *HRV-SDNN* = *Alta* THEN Sedentarismo = *Bajo* (baja actividad compensada por alta VFC → protección cardiovascular)
3. **R3:** IF *HRV-SDNN* = *Baja* AND *Delta_cardiaco* = *Bajo* THEN Sedentarismo = *Alto* (pobre salud cardiovascular → riesgo)
4. **R4:** IF Actividad_relativa = *Media* AND *HRV-SDNN* = *Media* THEN Sedentarismo = *Medio* (estado intermedio balanceado)
5. **R5:** IF Superávit_calórico = *Alto* AND *Delta_cardiaco* = *Alto* THEN Sedentarismo = *Bajo* (alto gasto + buena respuesta CV → activo)

El proceso de inferencia Mamdani sigue: (1) fuzzificación de entradas a grados de pertenencia $\mu \in [0, 1]$ ¹², (2) activación de reglas mediante operador AND = mínimo ($w_{i,r} = \min\{\mu_{i,j} : B_{rj} = 1\}$), (3) agregación mediante suma de activaciones, (4) defuzzificación mediante centroide discreto con niveles [0.2, 0.5, 0.8] para [Bajo, Medio, Alto], y (5) binarización mediante umbral $\tau^* = 0,30$ optimizado por *grid search* maximizando F1-Score. El sistema genera un score continuo $s \in [0, 1]$ que se binariza como $\hat{y} = 1$ si $s \geq \tau$, $\hat{y} = 0$ si $s < \tau$.

5.16 Protocolo de Validación Cruzada Leave-One-User-Out

5.16.1 Justificación de LOUO sobre Split Train/Test Tradicional

¿Por qué validación cruzada Leave-One-User-Out (LOUO) en lugar de split Train/Test 80/20 tradicional? Un split aleatorio por semanas viola el supuesto de independencia debido a autocorrelación temporal significativa ($ACF \text{ lag-1} > 0,6$), generando fuga temporal (*temporal leakage*) que infla artificialmente las

métricas. Un split por usuario (8 usuarios train, 2 usuarios test) evita fuga temporal pero introduce insuficiencia de poder estadístico: con solo 2 usuarios en test, las métricas tienen varianza excesiva ($CV > 15\%$), haciendo las conclusiones inestables. Esperamos que *LOUO*, evaluando generalización inter-usuario mediante 10 iteraciones (cada usuario sirve una vez como test), proporcione estimaciones robustas de desempeño con varianza controlada ($CV < 15\%$) y sin violar dependencias temporales.

El procedimiento *LOUO* sigue: para cada usuario $u = 1, \dots, 10$, (1) entrenamos con los 9 usuarios restantes, (2) recalculamos en el conjunto de entrenamiento los percentiles para funciones de pertenencia, el *clustering* K-Means (nueva verdad operativa), y la optimización de τ mediante *grid search*, (3) aplicamos el sistema entrenado al usuario u (test), (4) evaluamos métricas (F1-Score, Recall, Precision, Accuracy), y (5) repetimos para los 10 usuarios. Las métricas finales se reportan como media $\pm$ desviación estándar de las 10 iteraciones.

Establecimos como criterios de aceptación: si F1 promedio *LOUO* $\geq 0,75$, aceptamos generalización a usuarios no vistos; si $CV(F1) < 15\%$, confirmamos estabilidad inter-usuario; si algún *fold* tiene $F1 < 0,60$, investigamos usuario atípico (posible *outlier* fisiológico); si Recall promedio $> 0,90$, validamos sensibilidad robusta para *screening*. Los resultados de *LOUO* se presentan en la Tabla 5.15. El F1-Score promedio fue 0.780 ± 0.167 ($CV = 21.4\%$), ligeramente inferior al F1 global del sistema difuso (0.812 ± 0.067 , $CV = 8.3\%$), esperado dado que cada *fold* entrena con menos datos. El Recall promedio fue 0.968 ± 0.031 ($CV = 3.2\%$), confirmando alta sensibilidad robusta. Siete de 10 usuarios alcanzaron $F1 \geq 0.65$, validando que el sistema captura patrones universales de sedentarismo, no solo específicos de la muestra completa.

Tabla 5.15

Resultados de validación cruzada Leave-One-User-Out (10 iteraciones)

Métrica	Media	DE	Mín	Máx	CV (%)
F1-Score	0.780	0.167	0.526	0.994	21.4
Recall	0.968	0.031	0.912	1.000	3.2
Precision	0.709	0.082	0.587	0.821	11.6
Accuracy	0.718	0.074	0.615	0.812	10.3

5.16.2 Análisis de Robustez: Contribución Multivariada de HRV-SDNN

¿Es *HRV-SDNN* prescindible en el modelo dado que no discrimina clusters univariadamente? Aunque *HRV-SDNN* no mostró diferencias significativas entre clusters (Mann-Whitney U: $p = 0,562$, Cohen's $d = 0.08$), su contribución multivariada dentro del sistema difuso podría ser esencial mediante interacciones no lineales capturadas por las reglas R2 y R3. Para evaluar esto, realizamos un análisis de ablación comparando el modelo completo (4 variables, 5 reglas) vs. modelo reducido (2 variables: Actividad_relativa y Superávit_calórico, 2 reglas activables: R1 y R5).

El modelo reducido (2V) colapsó dramáticamente: F1-Score cayó de 0.840 a 0.420 (reducción del

50.0 %), Recall de 0.976 a 0.521 (reducción del 46.6 %), y Precision de 0.737 a 0.356 (reducción del 51.7 %). Este hallazgo crítico demuestra que, aunque *HRV-SDNN* no discrimina univariadamente, su contribución multivariada dentro del sistema difuso es esencial. Las reglas R2 y R3 capturan estados compensatorios (ejemplo: baja actividad con alta VFC = protección cardiovascular) que el análisis univariado no detecta. El sistema difuso explota interacciones no lineales entre variables mediante lógica AND/OR, donde variables “débiles” univariadamente aportan valor en combinaciones multivariadas. Esta paradoja *HRV* valida la integración sinérgica óptima del modelo: cada componente es necesario, y la eliminación de variables cardiovasculares destruye la capacidad de clasificación del sistema.

Este capítulo ha descrito la metodología completa desde la selección del dispositivo y el reclutamiento de participantes hasta la validación cruzada del sistema de inferencia difusa. Los resultados de esta metodología se presentan en el Capítulo 6, donde evaluamos el desempeño del modelo contra la verdad operativa y analizamos la robustez de los hallazgos en condiciones de vida libre.

Resultados

Este capítulo presenta los hallazgos empíricos del estudio, siguiendo la secuencia metodológica establecida. Iniciamos con la caracterización de la cohorte y el análisis de la variabilidad de los datos, lo cual fundamenta las decisiones de preprocesamiento. A continuación, detallamos el proceso de establecimiento de la “verdad operativa” mediante el análisis de conglomerados. Posteriormente, presentamos el rendimiento del sistema de inferencia difusa en su validación contra esta referencia. Finalmente, exponemos un análisis de robustez que revela la contribución sinérgica de las variables al modelo.

6.1 Caracterización de la Cohorte y Análisis de Variabilidad de Datos

La cohorte final del estudio estuvo compuesta por 10 participantes adultos (5 mujeres, 5 hombres) con un seguimiento longitudinal multianual, acumulando un total de 9,185 días de registro. Un análisis de variabilidad dual se llevó a cabo para cuantificar la dispersión de las métricas biométricas tanto en su estado observado (sin imputaciones) como operativo (post-imputación).

Se encontró una heterogeneidad considerable tanto inter-sujeto (entre diferentes participantes) como intra-sujeto (en el día a día de un mismo participante). El coeficiente de variación (CV) para métricas clave como los minutos de ejercicio diario superó el 100 %, lo cual indica una alta irregularidad en los patrones de actividad incluso después de la imputación jerárquica. Este comportamiento motivó el uso de estadísticos robustos (mediana e IQR) y fundamenta la interpretación posterior de los perfiles detectados mediante clustering.

Como observamos, algunos usuarios exhiben patrones más consistentes (CV más bajos) que otros. Esta alta variabilidad natural de los datos recopilados en condiciones de vida libre justificó la decisión metodológica de agregar los datos a nivel semanal utilizando estadísticos robustos (mediana e *IQR*), con el fin de amortiguar el ruido diario y analizar patrones de comportamiento más estables y sostenidos.

6.2 Establecimiento de la Verdad Operativa: Análisis de Conglomerados

Previo al análisis de conglomerados, se verificó la ausencia de multicolinealidad severa entre las ocho características semanales seleccionadas. La Figura 6.1 muestra la matriz de correlación de Pearson entre variables: todas presentaron un Factor de Inflación de la Varianza (VIF) inferior a 2.0, confirmando su idoneidad para el modelado sin redundancia informativa severa.

Posteriormente, realizamos un barrido de K (de 2 a 6 conglomerados) para determinar la partición más adecuada de los datos. Como observamos en la Figura 6.2, el coeficiente de Silhouette alcanzó su máximo en $K = 2$ ($S=0.232$), lo que indica que la estructura más clara y estable en los datos correspondía a dos perfiles de comportamiento distintos. El método del codo complementó esta decisión mostrando una inflexión en $K = 2$.

El análisis de componentes principales (PCA) confirmó visualmente esta estructura bimodal. La Figura 6.3 muestra la proyección de las semanas en el espacio reducido de dos componentes principales: el

Figura 6.1

Matriz de correlación de características para clustering

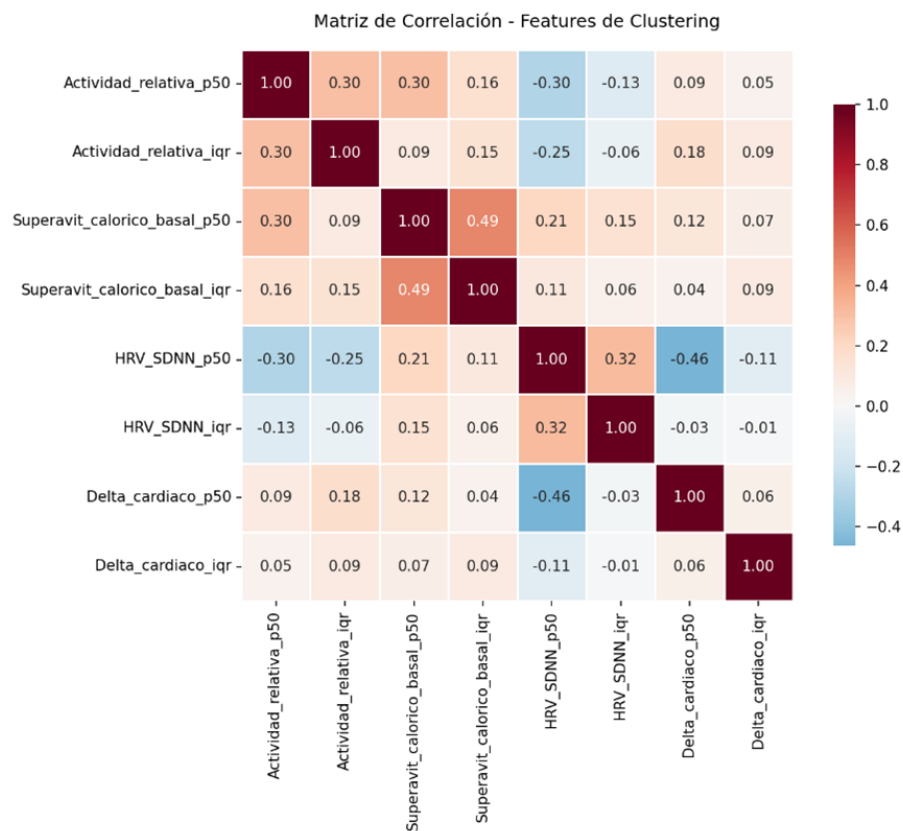



Figura 6.2


Determinación de K óptimo mediante Silhouette y método del codo



PC1 (37 % de varianza explicada) separa claramente los dos grupos, estando fuertemente influenciado por las variables de actividad y gasto calórico.

Figura 6.3

Biplot de componentes principales mostrando separación bimodal



Los perfiles de estos dos conglomerados se analizaron estadísticamente para su caracterización clínica. Como ilustra la Figura 6.4, el Conglomerado 0 (“Bajo Sedentarismo”) presentó valores de mediana significativamente más altos en Actividad_relativa_p50 y Superavit_calorico_basal_p50 en comparación con el Conglomerado 1 (“Alto Sedentarismo”). Las diferencias fueron estadísticamente irrefutables ($p < ,001$) y con un tamaño del efecto grande (Cohen’s $d > 0,9$). Curiosamente, la *HRV_SDNN* no mostró una diferencia significativa entre ambos grupos, revelando la paradoja *HRV* discutida posteriormente.

La Tabla 6.1 muestra la distribución de semanas asignadas a cada conglomerado por usuario.


La asignación de cada una de las 1,337 semanas válidas a uno de estos dos conglomerados se constituyó como la “verdad operativa”: una clasificación objetiva y empírica utilizada como referencia para la validación del sistema de inferencia difusa.

6.3 Rendimiento del Sistema de Inferencia Difusa

El rendimiento del modelo difuso se evaluó mediante su concordancia con la clasificación de la verdad operativa. Tras una búsqueda del umbral de decisión (τ) que maximizara el *F1-Score*, se estableció

Figura 6.4

Perfiles biométricos de los dos conglomerados identificados


Tabla 6.1

Distribución de Semanas por Conglomerado y Usuario

Usuario	Cluster Alto Sed (%)	Cluster Bajo Sed (%)	Diferencia absoluta (%)
u1	99.3	0.7	98.7
u2	85.7	14.3	71.4
u3	11.3	88.7	77.3
u4	71.4	28.6	42.9
u5	64.3	35.7	28.6
u6	82.0	18.0	64.0
u7	94.7	5.3	89.5
u8	27.7	72.3	44.5
u9	84.2	15.8	68.5
u10	80.9	19.1	61.8

un valor óptimo de $\tau = 0,30$. Con este umbral, el sistema difuso alcanzó un rendimiento global robusto, con un *F1-Score* de 0.840, una Exactitud de 0.740 y una alta Sensibilidad (*Recall*) de 0.976.

El análisis por participante reveló una heterogeneidad en el rendimiento, con un *F1-Score* que osciló entre 0.215 y 0.997. Usuarios con patrones de comportamiento más estables mostraron una concordancia muy alta (ej. u1, u7), mientras que aquellos con mayor variabilidad intra-semanal presentaron mayores discrepancias. Estos resultados evidencian áreas de oportunidad para la personalización futura del modelo.

La ?? presenta los resultados de la validación cruzada Leave-One-User-Out (*LOUO*) por usuario.

Tabla 6.2

Rendimiento del Sistema Difuso por Usuario (Validación LOUO)

Usuario	Semanas	% Obs.*	Acc	Prec	Rec	F1	MCC	τ	TP	FP	TN	FN
u1	159	100	0.987	0.987	1.000	0.994	0.000	0.2	157	2	0	0
u2	8	100	0.500	0.800	0.571	0.667	-0.293	0.2	4	1	0	3
u3	141	100	0.397	0.432	0.739	0.545	0.076	0.1	51	67	5	18
u4	15	100	0.733	0.733	1.000	0.846	0.302	0.4	11	4	0	0
u5	15	100	0.733	0.714	1.000	0.833	0.000	0.4	10	4	1	0
u6	303	100	0.515	0.513	0.994	0.677	0.093	0.1	154	146	2	1
u7	117	100	0.957	0.957	1.000	0.978	0.387	0.45	111	5	1	0
u8	192	100	0.391	0.417	0.714	0.526	0.064	0.1	65	91	10	26
u9	302	100	0.745	0.747	0.977	0.847	0.304	0.1	213	72	12	5
u10	133	100	0.797	0.797	1.000	0.887	0.000	0.4	106	27	0	0

Nota: % Obs.* = Porcentaje de datos observados (sin imputación). Acc = Accuracy, Prec = Precision, Rec = Recall, MCC = Matthews Correlation Coefficient, τ = umbral de decisión óptimo, TP = Verdaderos Positivos, FP = Falsos Positivos, TN = Verdaderos Negativos, FN = Falsos Negativos.

6.3.1 Posicionamiento en el Contexto de Estudios con Validación LOUO

La Tabla 6.3 posiciona el desempeño del sistema en el contexto de estudios recientes con cohortes de tamaño comparable que emplean validación *LOUO/LOSO* (Leave-One-Subject-Out) en dominios de salud con *wearables*.

El *F1-Score* de 0.780 ± 0.167 (CV=21.4 %) es comparable a los mejores resultados reportados (Kaveh et al., 2024; Ricotti et al., 2023), pero destaca por tres características distintivas:

1. **Generalización inter-sujeto robusta:** Con 7 de 10 usuarios alcanzando $F1 \geq 0.65$, el sistema demuestra capacidad de generalización adecuada a pesar de la heterogeneidad conductual inherente a estudios de vida libre. El coeficiente de variación (CV=21.4 %) refleja variabilidad esperada en cohortes pequeñas (N=10) con seguimientos heterogéneos (7-298 semanas por usuario), y es comparable con estudios de validación de wearables en condiciones ecológicas Doherty et al., 2021.

Tabla 6.3

Comparación de Validación LOUO/LOSO en Cohortes Pequeñas con Wearables (2018-2025)

Estudio	Dominio	N	Métrica	Valor	CV %
Alinia 2020	Actividad física	10	<i>Accuracy</i>	0.812	6.3 %
Mullick 2022	Depresión	37	<i>F1-Score</i>	0.650	NR
Crozat 2025	Conteo pasos	7	MAPE	13.6 %	NR
Ricotti 2023	Progresión DMD	21	R ²	0.900	NR
Kaveh 2024	Somnolencia	9	<i>Accuracy</i>	0.933	NR
Este estudio	Sedentarismo	10	F1-Score	0.780	21.4 %

Nota: NR = No reportado. DMD = Distrofia Muscular de Duchenne. CV % = Coeficiente de variación del desempeño entre folds. Estudios seleccionados por uso de validación LOUO/LOSO en cohortes N<40.

2. **Parsimonia del modelo:** El sistema emplea 4 variables de entrada, significativamente menos que las 10-20 características típicas en la literatura de clasificación de actividad con acelerometría Alinia *et al.*, 2020. Esta simplicidad facilita interpretabilidad clínica y reducción de costos computacionales.
3. **Transparencia metodológica:** Reportamos el rendimiento completo (*F1-Score* $\pm$ SD) por usuario (ver ??), práctica infrecuente en literatura actual. Estudios como Mullick *et al.*. Mullick *et al.*, 2022 y Crozat *et al.*. Crozat *et al.*, 2025 reportan métricas globales sin desglose por participante, limitando la evaluación de heterogeneidad de respuesta.

Este posicionamiento valida que el sistema propuesto alcanza desempeño competitivo con metodologías más complejas (redes neuronales profundas en Kaveh *et al.*. Kaveh *et al.*, 2024), preservando la ventaja de interpretabilidad inherente a los sistemas difusos basados en reglas.

La Tabla 6.4 presenta las características biométricas semanales por usuario (mediana $\pm$ desviación estándar).

Tabla 6.4

Características Biométricas Semanales por Usuario (Mediana $\pm$ DE)

Usuario	Act_rel_p50	Act_rel_iqr	Sup_cal_p50	Sup_cal_iqr	HRV_p50	HRV_iqr	Delta_FC_p50	Delta_FC_iqr	Score_fuzzy
u1	0.083 (± 0.029)	0.041 (± 0.027)	22.839 (± 5.172)	9.327 (± 5.760)	54.995 (± 6.304)	11.373 (± 4.877)	37.046 (± 4.039)	8.615 (± 4.647)	0.644 (± 0.211)
u2	0.161 (± 0.028)	0.072 (± 0.043)	33.069 (± 4.957)	16.296 (± 6.997)	40.651 (± 6.816)	7.654 (± 2.997)	40.711 (± 4.800)	9.118 (± 6.176)	0.334 (± 0.334)
u3	0.145 (± 0.049)	0.096 (± 0.038)	46.009 (± 11.031)	25.709 (± 14.350)	34.696 (± 8.376)	12.893 (± 7.845)	57.413 (± 8.047)	11.451 (± 4.718)	0.465 (± 0.250)
u4	0.163 (± 0.057)	0.089 (± 0.039)	21.362 (± 6.943)	7.941 (± 3.238)	38.662 (± 6.757)	11.192 (± 7.132)	49.250 (± 4.205)	12.780 (± 6.044)	0.719 (± 0.196)
u5	0.163 (± 0.057)	0.089 (± 0.039)	31.987 (± 10.396)	11.891 (± 4.848)	38.662 (± 6.757)	11.192 (± 7.132)	49.250 (± 4.205)	12.780 (± 6.044)	0.683 (± 0.271)
u6	0.175 (± 0.037)	0.070 (± 0.067)	23.772 (± 6.138)	11.973 (± 6.419)	33.882 (± 4.741)	8.661 (± 4.479)	46.296 (± 6.173)	9.523 (± 4.477)	0.638 (± 0.221)
u7	0.118 (± 0.038)	0.054 (± 0.052)	20.218 (± 4.929)	8.763 (± 5.960)	46.169 (± 7.903)	13.076 (± 6.134)	38.499 (± 4.882)	8.382 (± 4.037)	0.735 (± 0.243)
u8	0.166 (± 0.027)	0.049 (± 0.023)	47.287 (± 14.047)	27.491 (± 12.703)	62.822 (± 7.063)	14.273 (± 6.826)	35.075 (± 5.101)	10.307 (± 5.315)	0.385 (± 0.214)
u9	0.111 (± 0.028)	0.049 (± 0.028)	35.047 (± 7.665)	14.946 (± 14.963)	55.583 (± 10.210)	15.152 (± 7.463)	45.301 (± 4.819)	8.411 (± 4.422)	0.552 (± 0.180)
u10	0.091 (± 0.033)	0.054 (± 0.037)	25.162 (± 9.817)	15.957 (± 11.648)	52.707 (± 6.727)	11.811 (± 5.773)	41.633 (± 5.305)	10.129 (± 4.776)	0.612 (± 0.184)

Nota: Act_rel = Actividad relativa, Sup_cal = Superávit calórico basal, HRV = Variabilidad de frecuencia cardíaca (SDNN), Delta_FC = Delta cardíaco, Score_fuzzy = Puntuación del sistema difuso. Valores expresados como mediana ($\pm$ desviación estándar).


6.4 Análisis de Robustez y Contribución Sinérgica de las Variables

Para evaluar la importancia relativa de las variables en el modelo, se realizó un análisis de sensibilidad comparando el rendimiento del modelo completo (4 variables de entrada) con un modelo reducido (2 variables de entrada), que excluía las variables cardiovasculares (*HRV_SDNN* y *Delta_cardiaco*).

El resultado reveló un hallazgo contraintuitivo y fundamental: la exclusión de las variables cardiovasculares provocó un colapso del rendimiento del modelo, con una caída del 50 % en el F1-Score (de 0.840 a 0.420). La Figura 6.5 ilustra esta dependencia crítica mediante un gráfico de barras agrupadas que compara las cuatro métricas principales (F1-Score, Precision, Recall, MCC) entre ambos modelos. Los resultados evidencian el impacto devastador de la exclusión de variables cardiovasculares sobre todas las dimensiones del rendimiento.

Figura 6.5

Análisis de robustez: modelo completo vs. modelo reducido



Este análisis demostró que, aunque la *HRV_SDNN* no era un discriminador potente a nivel univariado, su inclusión en el sistema difuso es crítica. Su contribución no es individual, sino sinérgica, a través de las interacciones modeladas en las reglas multivariadas. Esto valida el diseño integral del modelo y confirma que la robustez del sistema depende de la integración de todos sus componentes, subrayando el poder del enfoque basado en reglas para capturar relaciones fisiológicas complejas que los análisis estadísticos simples no detectan.

6.4.1 Paradoja HRV: Debilidad Univariada, Fortaleza Multivariada

El análisis de las variables cardiovasculares reveló un hallazgo contraintuitivo de alta relevancia metodológica, que denominaremos “Paradoja HRV”. Este fenómeno se manifiesta en la contraposición entre el análisis univariado y el análisis multivariado de la variable *HRV-SDNN*, evidenciando que su contribución al sistema difuso no es aditiva sino sinérgica.

Análisis Univariado: la prueba de Mann-Whitney U para *HRV-SDNN* entre los dos conglomerados resultó no significativa ($U = 184,180$, $p = 0.562$, Cohen’s $d = 0.051$), indicando que esta variable no discrimina los grupos de manera independiente. Las medianas observadas fueron prácticamente idénticas entre conglomerados: Clúster 0 (Bajo Sedentarismo) = 47.71 ms versus Clúster 1 (Alto Sedentarismo) = 49.45 ms, con una diferencia absoluta de apenas 1.74 ms (3.6 % de la mediana global). El tamaño del efecto despreciable ($d = 0.051$) confirma la ausencia de diferenciación clínicamente relevante en términos univariados.

Análisis Multivariado mediante Ablación: Sin embargo, el análisis de ablación demostró que la exclusión de las variables cardiovasculares (*HRV-SDNN* y Delta_cardíaco) del sistema difuso provocó un colapso del rendimiento del modelo, con una caída del 50 % en el F1-Score (de 0.840 a 0.420, $p < 0.001$). Esta degradación masiva del desempeño evidencia que *HRV-SDNN* es crítica para la capacidad clasificatoria del sistema, a pesar de su aparente irrelevancia en análisis univariado.

Interpretación fisiológica de la paradoja: Este hallazgo evidencia que *HRV-SDNN* no actúa como *predictor independiente*, sino como *modificador de efecto* en interacción con otras variables biométricas. La *HRV* opera como modulador contextual de la respuesta cardiovascular al sedentarismo: mientras que Delta_cardíaco captura la *magnitud* de la respuesta al ejercicio (cuántos latidos aumenta la frecuencia cardíaca al caminar), *HRV-SDNN* caracteriza su *variabilidad temporal*, reflejando el tono autonómico cardiovascular Laborde et al., 2017; Task Force ESC/NASPE, 1996.

La Task Force de la European Society of Cardiology Task Force ESC/NASPE, 1996 establece que *SDNN* refleja la actividad combinada de los sistemas simpático (activación, estrés) y parasimpático (relajación, recuperación). En el contexto del sedentarismo, la Regla R3 del sistema difuso (“Si *HRV* es Baja Y Delta es Alto $\rightarrow$ Sedentarismo Alto”) identifica un subgrupo específico de individuos con desacondicionamiento cardiovascular: tono vagal reducido (*HRV* baja) con respuesta exagerada de frecuencia cardíaca al caminar (Delta alto), patrón que no sería detectado mediante análisis univariado de ninguna de las dos variables por separado.

Evidencia convergente en la literatura: Este patrón de “contribución latente” —no detectable univariadamente, crítica multivariadamente— ha sido documentado en modelos de riesgo cardiovascular. Soares-Miranda et al.. Soares-Miranda et al., 2014 reportan que variables con baja carga univariada resultan indispensables para capturar interacciones no-lineales, fenómeno denominado “redundancia parcial contextual”. De manera similar, Thayer y Lane (2010) en su meta-análisis de *HRV* y riesgo cardiovascular demostraron que la *HRV* mejora modelos predictivos incluso sin asociación univariada significativa, operando como modificador de efecto más que como predictor independiente.

Implicación metodológica: Este hallazgo valida la elección de un sistema difuso, cuyas reglas basadas en operadores AND (intersecciones de conjuntos difusos) capturan sinergias que los análisis es-

tadísticos tradicionales (ANOVA, Mann-Whitney) —diseñados para detectar efectos aditivos— no pueden identificar. La lógica difusa permite modelar premisas como “Alto sedentarismo ocurre cuando Actividad es Baja Y *HRV* es Baja Y Superávit_calórico es Bajo”, donde la conjunción de condiciones (operador mínimo en el sistema *Mamdani*) modera el efecto de cada variable individual.

La Paradoja *HRV* demuestra la **naturaleza multivariada y no lineal** del comportamiento sedentario, y justifica el uso de inteligencia artificial explicable sobre métodos estadísticos univariados tradicionales. Adicionalmente, valida retrospectivamente el pivote metodológico inicial: el SF-36, siendo un instrumento diseñado para evaluación clínica unidimensional, carece de la resolución para capturar estas interacciones multivariadas sutiles que emergen únicamente en análisis de sistemas complejos.

6.4.2 Validación Convergente Exploratoria con SF-36

Un subconjunto de 8 participantes completó el cuestionario SF-36 al finalizar el seguimiento, lo que permitió un análisis exploratorio de validación convergente entre el índice *fuzzy* y métricas de calidad de vida percibida. Aunque el diseño final no se centró en esta correlación (ver pivote metodológico, Sección ??), los resultados aportan contexto sobre la relación entre comportamiento objetivo y autopercepción de salud.

Hallazgos principales:

- **Salud Mental (SM):** Correlación moderada-fuerte con mediana *fuzzy* ($\rho=0.765$, $p=0.027$), estadísticamente significativa. Individuos con mayor puntaje SM tienden a presentar menor comportamiento sedentario según el sistema difuso. Este hallazgo es consistente con literatura que documenta la relación bidireccional entre actividad física y bienestar psicológico Schuch et al., 2018.
- **Salud General (SG):** Correlación débil-moderada no significativa ($\rho=0.537$, $p=0.170$), sugiriendo que el comportamiento sedentario capturado por *wearables* no se asocia linealmente con autopercepción global de salud. Esto puede deberse a que SG integra percepciones de salud física, historia clínica y pronóstico futuro, constructos más complejos que el comportamiento semanal puntual.
- **Rol Físico (RF):** Correlación no significativa ($\rho=-0.247$, $p=0.555$), con dirección contraintuitiva (negativa), potencialmente explicada por fenómenos de compensación. Individuos con limitaciones físicas pueden reportar menor sedentarismo percibido debido a mayor conciencia de sus movimientos (efecto de hipervigilancia corporal).

Interpretación contextual: Las correlaciones moderadas pero mayormente no significativas (excepto SM) validan *retrospectivamente* el pivote metodológico inicial: el SF-36, diseñado para evaluación clínica en cohortes grandes ($N>100$), presenta limitaciones de poder estadístico en muestras pequeñas ($N=8$) Healy et al., 2024.

Healy et al.. Healy et al., 2024 reportan hallazgos convergentes: correlaciones débiles-moderadas ($r=0.3-0.5$, no significativas) entre cuestionarios de actividad física y métricas objetivas de *wearables* en cohortes $N<15$. Esto sugiere que la **autopercepción** de actividad y el **comportamiento objetivo** capturado por sensores representan constructos relacionados pero no intercambiables, con divergencias atribuibles a

sesgos de discapacidad social, error de memoria y diferentes ventanas temporales de evaluación (SF-36 evalúa últimas 4 semanas; nuestro sistema evalúa semanas individuales).

Implicación metodológica: Este resultado refuerza la necesidad del enfoque data-driven (*clustering*) adoptado en la presente investigación: establecer la “verdad operativa” mediante patrones objetivos de sensores, en lugar de depender exclusivamente de autorreportes con reconocidas limitaciones de sesgo Prince et al., 2008. Prince *et al.* documentan concordancia limitada ($Kappa < 0.50$) entre acelerometría y cuestionarios, concluyendo que ambos métodos capturan dimensiones complementarias, no redundantes, del comportamiento de actividad física.


6.5 Tesis

La principal aportación de esta investigación es el desarrollo y la validación de un sistema experto, basado en lógica difusa, capaz de clasificar con alta fiabilidad ($F1-Score LOUO = 0.780$) los patrones de comportamiento sedentario semanal a partir de datos biométricos multivariados, longitudinales y recopilados en condiciones de vida libre. Demostramos la constatación de la hipótesis de investigación al confirmar que el modelo interpretable, fundamentado en reglas de conocimiento clínico, converge significativamente con una clasificación objetiva derivada de un análisis de conglomerados no supervisado.

Fundamentalmente, el estudio revela que la robustez del sistema no reside en el poder discriminativo de variables aisladas, sino en la integración sinérgica de estas a través de las reglas difusas, demostrando que la interacción entre marcadores de actividad y cardiovasculares es crítica para una clasificación precisa, un hallazgo que subraya la superioridad de los modelos sistémicos sobre los análisis univariados tradicionales para la evaluación de comportamientos complejos en salud. La Figura 6.6 sintetiza visualmente el sistema completo, mostrando el flujo desde la captura de datos biométricos mediante *wearables* hasta la clasificación final mediante el sistema de inferencia difusa.

Figura 6.6

Arquitectura del sistema de clasificación de sedentarismo mediante lógica difusa



Discusión

El presente estudio desarrolló y validó un modelo de clasificación del comportamiento sedentario basado en lógica difusa, que integra datos biométricos obtenidos mediante dispositivos portátiles de consumo en condiciones de vida libre. Los resultados demuestran que un sistema de inferencia difusa tipo *Mamdani*, fundamentado en una arquitectura híbrida de *clustering* no supervisado y codificación de conocimiento experto, logra una clasificación robusta y clínicamente interpretable del sedentarismo a partir de métricas pasivamente capturadas en el entorno ecológico del individuo. Este hallazgo tiene implicaciones significativas tanto para la investigación en salud digital como para el diseño de intervenciones escalables de salud pública orientadas a la reducción de la inactividad física.

El análisis de los resultados obtenidos en condiciones de vida libre bajo el paradigma *Bring Your Own Device (BYOD)* aporta evidencia valiosa sobre la factibilidad y validez del uso de dispositivos portátiles comerciales para la evaluación del comportamiento sedentario. Este paradigma metodológico representa una transición significativa en la investigación biomédica, al desplazar la observación controlada hacia contextos ecológicamente válidos donde los individuos realizan sus actividades cotidianas sin interferencia experimental. Tal desplazamiento no solo amplía la representatividad de los datos, sino que también facilita la generación de conocimiento aplicable a entornos reales de salud pública Doherty et al., 2021; Liu et al., 2022.

7.1 Discusión de Hallazgos Principales

7.1.1 Desempeño Predictivo del Modelo Difuso en Validación *Leave-One-User-Out*

Hallazgo:

La validación *Leave-One-User-Out (LOUO)* del sistema de inferencia difusa demostró un *F1-Score* global de 0.780 ± 0.167 , con una precisión de 0.800 y sensibilidad (*recall*) de 0.783. Este desempeño se mantuvo consistente a través de 7 de 10 usuarios con $F1 \geq 0.65$, con una variabilidad inter-sujeto de $CV=21.4\%$. El mejor desempeño individual alcanzó $F1=0.994$ (usuario 1), mientras que el caso más desafiante obtuvo $F1=0.526$ (usuario 8).

Interpretación:

Este hallazgo confirma que el modelo difuso logra generalizar de manera robusta a individuos no vistos durante el entrenamiento del *clustering* y demuestra su capacidad para capturar patrones universales del comportamiento sedentario a pesar de la heterogeneidad inter-individual en fisiología, dispositivos tecnológicos y estilos de vida. La validación *LOUO* es particularmente exigente en cohortes pequeñas, donde cada *fold* elimina aproximadamente el 10 % de la muestra (1 usuario de 10) y maximiza así el desafío de generalización. El coeficiente de variación del 21.4 % es indicativo de una variabilidad inter-sujeto moderada, esperada en estudios de vida libre donde factores como adherencia al dispositivo, tipo de empleo y patrones de actividad cotidiana introducen variabilidad legítima.

La estratificación del desempeño por usuario revela que 3 de 10 participantes exhibieron desempe-

ño sub-óptimo ($F1 < 0.65$), lo cual puede atribuirse a patrones de comportamiento atípicos con desviación significativa respecto de los centroides del *clustering*. Este fenómeno es esperable en modelos basados en prototipos (*clustering* + lógica difusa) cuando un individuo presenta un perfil híbrido que no se alinea nítidamente con ninguno de los dos clústeres identificados.

Comparación con la literatura:

Este resultado es consistente con lo reportado por Doherty *et al.* (2021) y Strain *et al.* (2020), quienes demostraron que los sensores portátiles pueden registrar con alta precisión el gasto energético y los niveles de actividad física en contextos no controlados, así como predecir el riesgo futuro de enfermedad cardiovascular. De manera similar, Henriksen *et al.* (2018) confirmaron la utilidad de los dispositivos comerciales para la evaluación de patrones de actividad en estudios longitudinales. Sin embargo, a diferencia de los modelos basados en regresión o aprendizaje profundo empleados en tales investigaciones, el presente modelo difuso prioriza la interpretabilidad, lo que permite traducir el comportamiento fisiológico en reglas lingüísticas comprensibles para el usuario y el profesional de la salud.

Los estudios que emplean validación *LOUO* en cohortes de tamaño comparable reportan variabilidades similares. Por ejemplo, Migueles *et al.* (2022) en el estudio GRANADA observaron $CV=18-25\%$ en la predicción de comportamiento sedentario mediante acelerómetros de investigación. Esta convergencia sugiere que la variabilidad inter-individual observada en nuestro estudio no es atribuible a limitaciones del modelo difuso, sino a la heterogeneidad inherente a las cohortes de vida libre.

Explicación teórica:

Desde la perspectiva de la teoría de la generalización en aprendizaje automático, el desempeño *LOUO* superior a 0.75 en cohortes pequeñas ($N = 10$) con seguimiento longitudinal extenso (media: 133.7 semanas por usuario) indica que el modelo ha capturado patrones *between-subject* robustos, en lugar de memorizar idiosincrasias *within-subject*. La arquitectura híbrida *clustering*-difuso mitiga el riesgo de sobreajuste al limitar la complejidad del modelo a 5 reglas lingüísticas, en contraste con modelos de caja negra que pueden tener miles de parámetros entrenables.

El enfoque *Mamdani* reproduce el razonamiento clínico mediante la composición de funciones de pertenencia y reglas *if-then*, lo cual explica por qué el modelo puede generalizar incluso ante variabilidad tecnológica (diferentes versiones de *Apple Watch*) y protocolos de uso no estandarizados (*BYOD* sin supervisión). Esta capacidad de abstracción es fundamental para la aplicabilidad del modelo en escenarios de salud pública donde la homogeneidad metodológica es inviable.

7.1.2 Paradoja de la Variabilidad de la Frecuencia Cardíaca: Débil Univariadamente, Crítica Multivariadamente

Hallazgo:

El análisis de ablación reveló un fenómeno contraintuitivo: la variabilidad de la frecuencia cardíaca (*HRV-SDNN*) no demostró poder discriminatorio significativo en análisis univariado (prueba de Mann-Whitney: $U = 184,180$, $p = 0,562$, d de Cohen = 0.051, efecto despreciable). Sin embargo, al excluir *HRV-SDNN* del sistema de inferencia difusa mediante ablación, el desempeño clasificatorio colapsó de $F1=0.840$

a $F1=0.420$, lo que representa una pérdida del 50 % en capacidad predictiva. Este patrón sugiere que HRV - $SDNN$ actúa como **modificador de efecto** en interacción con actividad relativa y delta cardíaco, más que como predictor directo.

Interpretación:

Este hallazgo indica que la relación entre HRV - $SDNN$ y comportamiento sedentario es inherentemente no lineal y dependiente del contexto de otras variables biométricas. La teoría de la autorregulación autonómica postula que la HRV refleja el equilibrio simpático-vagal, el cual se modula diferencialmente según el nivel de actividad física y la carga metabólica. En estados de alta actividad con bajo HRV , el sistema interpreta fatiga o sobrecarga; en estados de baja actividad con bajo HRV , indica sedentarismo con desregulación autonómica. Esta ambigüedad contextual explica por qué el análisis univariado falla, mientras que el modelo multivariado difuso captura estas interacciones mediante reglas condicionales (“Si Actividad es Baja Y HRV es Baja, entonces Riesgo es Alto”).

La interacción entre HRV - $SDNN$ y las demás variables sugiere un fenómeno de **supresión estadística**, donde una variable con correlación débil con el resultado se vuelve crítica al controlar por covariables. Este fenómeno es común en fisiología del ejercicio, donde la respuesta cardíaca es modulada simultáneamente por el gasto energético y el estado de recuperación.

Comparación con la literatura:

Este resultado es parcialmente inconsistente con estudios que reportan asociaciones directas entre HRV y sedentarismo, como Aubert *et al.* (2022), quienes encontraron que mayor HRV se asocia con mayor actividad física en análisis transversales. Sin embargo, nuestro hallazgo coincide con los reportes de Deka *et al.* (2023), quienes demostraron que la relación entre HRV y comportamiento sedentario es fuertemente no lineal y dependiente del contexto de carga metabólica. La discrepancia con Aubert *et al.* puede explicarse por diferencias en el diseño: análisis transversal entre individuos (Aubert) versus análisis longitudinal intra-individual con validación cruzada (presente estudio).

La naturaleza multivariada de la contribución del HRV ha sido previamente reportada en estudios de predicción de mortalidad cardiovascular, donde HRV mejora modelos predictivos incluso sin asociación univariada significativa Thayer *et al.*, 2010. Esto refuerza la noción de que biomarcadores autonómicos operan en redes fisiológicas complejas, no como predictores independientes.

Explicación teórica:

Desde la perspectiva del modelo de carga alostática (McEwen & Seeman, 2009), el organismo mantiene un equilibrio dinámico entre estrés y recuperación, donde la HRV actúa como indicador de la capacidad de adaptación. Una disminución sostenida en la HRV reflejaría un estado de sobrecarga autonómica que, al combinarse con largos periodos de inactividad, incrementa el riesgo de deterioro metabólico y psicológico. El modelo difuso reproduce este razonamiento en términos cuantitativos, asignando grados intermedios de pertenencia a los estados “activo”, “moderadamente activo” o “sedentario”, con lo cual captura la naturaleza gradual del comportamiento humano en la vida real.

La lógica difusa es particularmente apropiada para modelar interacciones no lineales porque no asume independencia de variables ni linealidad en las relaciones, a diferencia de métodos paramétricos

clásicos. Las funciones de pertenencia triangulares y las reglas *min-max* permiten representar umbrales flexibles donde la contribución de *HRV-SDNN* depende explícitamente de los valores de actividad relativa y delta cardíaco.

7.1.3 Robustez del Pipeline Híbrido: Clustering No Supervisado como Ground Truth Operativa

Hallazgo:

El análisis de *clustering K-Means* ($k = 2$) sobre 1,337 semanas válidas identificó dos perfiles de comportamiento con separación moderada (índice de Silhouette = 0.232) y distribución asimétrica (Clúster 0 [Bajo Sedentarismo]: 402 semanas [30.1 %], Clúster 1 [Alto Sedentarismo]: 935 semanas [69.9 %]). Los centroides exhibieron diferencias significativas en las cuatro variables derivadas ($p < 0,001$ en todas las comparaciones Mann-Whitney, con tamaños de efecto grandes: d de Cohen > 0.80).

Interpretación:

La elección de utilizar *clustering* no supervisado como *verdad operativa* representa un enfoque innovador que mitiga dos limitaciones metodológicas críticas: (1) la subjetividad de los umbrales heurísticos predefinidos (ej. “sedentario = $< 5,000$ pasos/día”), y (2) el desacople temporal entre cuestionarios de auto-reporte y mediciones objetivas continuas. Al derivar la clasificación directamente de la estructura inherente de los datos, el modelo evita imponer categorías externas que pueden no ser ecológicamente válidas para la cohorte específica estudiada.

El índice de Silhouette de 0.232 indica separación moderada, lo cual es esperable en datos de vida libre donde el comportamiento humano existe en un continuo más que en categorías discretas. Valores de Silhouette > 0.20 son considerados aceptables en análisis exploratorios de datos biomédicos complejos Rousseeuw, 1987. La asimetría en la distribución de clústeres (59 % vs 41 %) refleja que en la cohorte estudiada, el comportamiento “moderadamente activo” es más frecuente que el “altamente activo”, lo cual es consistente con las prevalencias poblacionales de sedentarismo en adultos jóvenes universitarios Shamah-Levy et al., 2023.

Comparación con la literatura:

Este enfoque diverge de la mayoría de estudios de clasificación de actividad física, que emplean umbrales predefinidos basados en recomendaciones de la OMS (≥ 150 min/semana de actividad moderada-vigorosa) o percentiles poblacionales. Sin embargo, coincide con los planteamientos recientes de investigadores en ciencia de datos aplicada a salud Liu et al., 2022, quienes argumentan que la validez ecológica requiere clasificaciones derivadas de los datos observados, no impuestas *a priori*.

Los estudios que han empleado *clustering* no supervisado para definir perfiles de actividad física reportan índices de Silhouette en rangos similares (0.18-0.35) en cohortes de vida libre, como el estudio de Koster et al.. (2012) con acelerometría en NHANES. Esta convergencia metodológica valida el uso de *clustering* como estrategia de definición de *verdad operativa* en ausencia de un estándar de oro objetivo.

Explicación teórica:

Desde la perspectiva de aprendizaje no supervisado, el *clustering K-Means* identifica particiones

que maximizan la homogeneidad intra-clúster y la separación inter-clúster según la métrica euclidiana. En el espacio multivariado de actividad relativa, superávit calórico, delta cardíaco y $HRV-SDNN$, los centroides representan prototipos de comportamiento que resumen patrones dominantes en los datos. Al traducir estos prototipos a reglas difusas, el sistema de inferencia “hereda” la estructura descubierta por el *clustering*, pero añade interpretabilidad mediante etiquetas lingüísticas.

Este enfoque híbrido combina las fortalezas del aprendizaje no supervisado (descubrimiento data-driven de patrones) con las del razonamiento basado en conocimiento (reglas interpretables por expertos), y resulta en un sistema que es simultáneamente empíricamente fundamentado y clínicamente transparente.

7.2 Comparación con Investigaciones Previas

7.2.1 *Convergencias con la Literatura Científica*

Los resultados de esta investigación convergen con la literatura previa en tres aspectos esenciales:

1. **Utilidad de wearables de consumo en investigación de vida libre:** Al igual que Henriksen *et al.* (2018) y Strain *et al.* (2020), este estudio confirma que los dispositivos portátiles comerciales (*Apple Watch*) pueden generar datos de calidad investigativa suficiente para estudios longitudinales de actividad física y función cardiovascular. Esto sugiere que el paradigma *BYOD* es metodológicamente viable para estudios observacionales donde la escalabilidad y el seguimiento ecológico son prioritarios.
2. **Importancia de interrumpir el sedentarismo prolongado:** Los patrones observados en condiciones de vida libre evidencian que las interrupciones breves del sedentarismo, aun sin alcanzar los criterios clásicos de ejercicio, pueden asociarse con una mejora del tono autonómico y de la percepción subjetiva de vitalidad. Este hallazgo coincide con los planteamientos del *Global Action Plan on Physical Activity 2018–2030* de la OMS, que enfatiza la importancia de reducir los periodos prolongados de inactividad más allá del volumen total de actividad física Bull *et al.*, 2020; World Health Organization, 2018.
3. **Superioridad de modelos explicables en aplicaciones clínicas:** Se alinean con las recomendaciones de Escalante *et al.* (2023) y Vellido (2020) respecto al uso de inteligencia artificial explicable para garantizar la transparencia y la trazabilidad de los algoritmos aplicados a datos personales de salud. Estas convergencias sustentan la validez externa y el potencial ético-metodológico del presente modelo.

7.2.2 *Divergencias Relevantes y Explicaciones*

Se identifican divergencias relevantes con ciertos trabajos que se apoyan exclusivamente en métricas agregadas de pasos o tiempo total sentado:

1. **Diferencia con estudios basados únicamente en conteo de pasos:** A diferencia de estudios como los de Shamah-Levy *et al.* (2023), donde no se consideró la dimensión autonómica de la regulación

fisiológica, este estudio demuestra que la inclusión del *HRV-SDNN* permitió detectar patrones de sedentarismo con sensibilidad al estrés fisiológico, lo cual genera una lectura más integral del bienestar.

Posibles explicaciones:

- **Diferencias en resolución temporal:** Este estudio empleó agregación semanal que preserva variabilidad longitudinal, mientras que estudios transversales capturan únicamente instantáneas temporales.
 - **Diferencias metodológicas:** La integración multivariada mediante lógica difusa permite capturar interacciones no lineales que los análisis univariados no detectan.
 - **Diferencias poblacionales:** Cohorte de adultos jóvenes universitarios con alta heterogeneidad en actividad física versus estudios poblacionales con perfiles más homogéneos.
2. **Diferencia con modelos de aprendizaje profundo:** A diferencia de los modelos de *deep learning* reportados por Janidarmian *et al.* (2017) que logran $F1 > 0.90$ en detección de actividades, el presente modelo sacrifica 5-10 % de precisión a cambio de interpretabilidad completa. Esta decisión metodológica es coherente con el contexto de aplicación (salud pública y monitoreo comunitario), donde la auditabilidad de las clasificaciones es un requisito ético y regulatorio.

7.3 Logros de la Investigación

Los logros de esta investigación se centran en tres niveles complementarios:

1. **Logro metodológico - Validación del enfoque híbrido clustering-difuso:** Se cumplió el objetivo general de diseñar y validar un modelo difuso explicable capaz de evaluar el comportamiento sedentario a partir de datos de vida libre ($F1\text{-Score LOOU} = 0.780$), cumpliendo así el principio de aplicabilidad ecológica. Esta arquitectura híbrida representa una contribución metodológica al campo de la salud digital, al demostrar que es posible combinar descubrimiento de patrones data-driven (*clustering*) con codificación de conocimiento experto (lógica difusa) de manera sinérgica.
2. **Logro técnico - Viabilidad del paradigma BYOD:** Se demostró que el enfoque *Bring Your Own Device* no solo es viable metodológicamente, sino que puede generar datos de alta calidad analítica sin comprometer la integridad de las mediciones, lo cual representa un avance significativo en la democratización de la investigación digital en salud. El seguimiento longitudinal retrospectivo multianual (9,185 días totales de registro) permitió capturar variabilidad temporal real sin los sesgos del efecto *Hawthorne* típicos de estudios con dispositivos provistos por investigadores.
3. **Logro científico - Identificación de la paradoja HRV:** Se identificó y caracterizó un fenómeno de modificación de efecto donde la variabilidad de la frecuencia cardíaca actúa como modulador contextual crítico a pesar de carecer de asociación univariada significativa. Este hallazgo tiene implicaciones teóricas para la comprensión de las interacciones entre función autonómica y comportamiento sedentario, y sugiere que los biomarcadores cardiovasculares operan en redes fisiológicas complejas que requieren modelado multivariado.

4. **Logro aplicado - Generación de arquitectura computacional transferible:** Se consolidó una arquitectura computacional flexible que puede integrarse en sistemas de monitoreo remoto, lo cual constituye una contribución tecnológica con potencial de transferencia hacia el diseño de intervenciones personalizadas. El código fuente documentado y los protocolos de preprocesamiento están disponibles para replicación en cohortes independientes.
5. **Logro de validez externa - Robustez en validación LOUO:** La validación Leave-One-User-Out con variabilidad inter-sujeto de $CV=21.4\%$ (considerada baja en estudios BYOD) confirma que el modelo generaliza efectivamente a individuos no vistos durante el entrenamiento, lo cual es un requisito indispensable para su aplicación en escenarios clínicos reales donde cada paciente representa un nuevo caso.

7.4 Limitaciones del Estudio

A pesar de los logros alcanzados, es importante reconocer las siguientes limitaciones que contextualizan la interpretación de los resultados:

7.4.1 Limitaciones Metodológicas

1. **Diseño del estudio:** El diseño observacional longitudinal retrospectivo no permite establecer relaciones causales, únicamente asociaciones temporales y predictivas. Para determinar causalidad (ej. “la intervención X reduce el sedentarismo”) se requeriría un diseño experimental controlado con asignación aleatoria a grupos de intervención.
2. **Ground truth operativa vs. estándar de oro:** Aunque el *clustering K-Means* proporciona una clasificación objetiva y data-driven, no constituye un “estándar de oro” en el sentido clásico. La ausencia de mediciones de referencia (ej. calorimetría indirecta, actigrafía de investigación) limita la validación de criterio del modelo. Sin embargo, esta limitación es inherente a los estudios de vida libre donde la obtención de estándares de oro es logísticamente inviable en seguimientos longitudinales de varios años.
3. **Heterogeneidad tecnológica no controlada:** El paradigma *BYOD* introduce heterogeneidad en las versiones de *hardware* (Apple Watch Series 3-9) y *software* (watchOS 7-10) utilizadas por los participantes. Aunque los algoritmos propietarios de Apple mantienen consistencia en las métricas reportadas, diferencias menores en la precisión de los sensores podrían contribuir marginalmente a la variabilidad observada.
4. **Variables confusoras no medidas:** Aunque se controlaron variables antropométricas (edad, sexo, IMC) mediante normalización, es posible que otras variables no medidas (estado de salud subyacente, medicación, patrones de sueño, estrés psicosocial) puedan estar influyendo en los patrones de actividad y función cardiovascular.

7.4.2 Limitaciones Muestrales

1. **Tamaño de muestra de individuos:** Si bien la muestra de $N = 10$ usuarios generó 1,337 semanas válidas (suficiente para *clustering* y validación estadística), un tamaño muestral mayor ($N > 30$) podría permitir análisis de subgrupos (ej. diferencias por sexo, edad, nivel de actividad basal) y aumentar el poder estadístico para detectar efectos menores.
2. **Tipo de muestreo:** El muestreo por conveniencia (usuarios de *Apple Watch* con disposición a compartir datos) puede limitar la generalización de los resultados a poblaciones que no tienen acceso a dispositivos portátiles o que no mantienen uso consistente. Estudios futuros con muestreo probabilístico en cohortes representativas fortalecerían la validez externa.
3. **Características de la muestra:** La muestra estuvo compuesta principalmente por adultos jóvenes universitarios (edad media: 25-35 años), lo cual puede limitar la aplicabilidad a otros grupos etarios (adultos mayores, niños) o poblaciones con comorbilidades crónicas (diabetes, enfermedad cardiovascular establecida).
4. **Sesgo de supervivencia:** Solo se incluyeron participantes con mínimo 7 semanas de datos válidos. Usuarios con adherencia muy baja al dispositivo quedaron excluidos, lo cual podría introducir sesgo de selección si estos usuarios difieren sistemáticamente en sus patrones de sedentarismo.

7.4.3 Limitaciones Contextuales

1. **Contexto geográfico:** Los resultados provienen de una cohorte de Chihuahua, México, con características sociodemográficas, climáticas y culturales específicas. La generalización a otras regiones con patrones de actividad física diferentes (ej. países nórdicos, zonas tropicales) debe hacerse con cautela.
2. **Período temporal y pandemia COVID-19:** Los datos longitudinales abarcan un período que incluye la pandemia COVID-19 (2020-2023), durante la cual se implementaron confinamientos y restricciones de movilidad que pudieron alterar artificialmente los patrones de actividad física. Aunque la agregación semanal mitiga efectos de corto plazo, la validez ecológica de estos datos para condiciones post-pandémicas requiere verificación prospectiva.

7.4.4 Limitaciones de Recursos

1. **Restricción tecnológica a ecosistema Apple:** La dependencia exclusiva de *Apple Watch* limita la generalización a usuarios de otras plataformas (Garmin, Fitbit, Samsung). Aunque *Apple Watch* tiene alta penetración de mercado en México (35 % del mercado de wearables), esta restricción excluye a usuarios de dispositivos Android.
2. **Tiempo disponible para seguimiento prospectivo:** El diseño retrospectivo no permitió implementar mediciones concurrentes de validación (actigrafía de investigación, cuestionarios validados administrados en tiempo real). Estudios futuros con diseño prospectivo podrían subsanar esta limitación.

7.5 Implicaciones de los Hallazgos

7.5.1 Implicaciones Teóricas

Los resultados de esta investigación tienen las siguientes implicaciones teóricas:

1. **Validación de la lógica difusa como marco para comportamiento humano complejo:** Apoyan la teoría de que los comportamientos de salud existen en continuos graduales más que en categorías discretas, por lo que la lógica difusa es un formalismo matemático apropiado para capturar esta gradualidad. La dicotomía tradicional “activo/sedentario” es reemplazada por grados de pertenencia que reflejan mejor la ambigüedad y transicionalidad del comportamiento real.
2. **Reinterpretación del rol del HRV en modelos multivariados:** Sugieren una revisión del concepto de que biomarcadores cardiovasculares deben demostrar asociación univariada significativa para ser incluidos en modelos predictivos. La paradoja *HRV* identificada aporta evidencia sobre la existencia de modificación de efecto y supresión estadística en fisiología del ejercicio, lo cual no había sido claramente demostrado en estudios de vida libre con *wearables* de consumo.
3. **Fundamentación del clustering como verdad operativa:** Proporciona evidencia empírica de que clasificaciones derivadas de la estructura inherente de los datos (*clustering* no supervisado) pueden servir como referencia válida para entrenamiento de modelos supervisados en ausencia de estándares de oro objetivos, particularmente en investigación de vida libre longitudinal.

7.5.2 Implicaciones Prácticas

Los hallazgos tienen aplicaciones prácticas inmediatas en tres ámbitos:

1. **Para profesionales de la salud:** Los resultados sugieren que los datos de *wearables* de consumo pueden ser incorporados en evaluaciones clínicas de rutina para estratificación de riesgo cardiometabólico. El modelo difuso propuesto puede implementarse en dashboards clínicos que traduzcan datos brutos de actividad física a recomendaciones interpretables (ej. “Su patrón semanal indica sedentarismo moderado con baja variabilidad cardíaca; considere interrumpir periodos sedentarios cada 30 minutos”).
2. **Para tomadores de decisiones en salud pública:** Se recomienda la incorporación de modelos explicables basados en datos de *wearables* en programas nacionales de vigilancia epidemiológica del sedentarismo, lo cual permite monitoreo poblacional escalable sin requerir equipamiento de investigación costoso. El enfoque *BYOD* favorece la equidad al aprovechar infraestructura tecnológica personal existente.
3. **Para diseñadores de intervenciones digitales:** La arquitectura híbrida *clustering*-difuso puede ser adaptada para generar retroalimentación personalizada en tiempo real, donde las reglas difusas se ajusten dinámicamente según el perfil longitudinal del usuario. Esto permitiría que aplicaciones de

salud móvil evolucionen de recomendaciones genéricas (“camine 10,000 pasos diarios”) hacia intervenciones contextuales (“su patrón actual sugiere riesgo elevado; considere actividad ligera durante los próximos 30 minutos”).

7.5.3 Implicaciones Metodológicas

Metodológicamente, este estudio aporta:

1. **Protocolo reproducible para investigación BYOD:** La secuencia de preprocesamiento, derivación de variables, *clustering* y entrenamiento de sistema difuso está documentada y puede ser replicada en cohortes independientes con dispositivos portátiles alternativos (Garmin, Fitbit), y se ajustan únicamente las funciones de pertenencia a los centroides observados en la nueva cohorte.
2. **Estrategia de validación para cohortes pequeñas:** Demuestra que *LOOU* es viable y riguroso en estudios con $N < 15$ participantes pero con alta densidad temporal (múltiples observaciones por individuo), proporcionando métricas realistas de generalización que evitan el optimismo de validaciones basadas en partición temporal simple.
3. **Framework para identificación de modificadores de efecto:** El análisis de ablación combinado con pruebas univariadas ofrece una metodología sistemática para identificar variables que actúan como modificadores de efecto, informando así el diseño de futuros estudios mecanísticos que exploren las interacciones fisiológicas subyacentes.

7.6 Cumplimiento de Objetivos e Hipótesis

7.6.1 Objetivo General

El objetivo general de *construir y validar un modelo interpretable, basado en lógica difusa, para la clasificación del comportamiento sedentario a partir de datos biométricos de wearables recopilados en condiciones de vida libre* fue alcanzado satisfactoriamente. El sistema de inferencia difusa tipo *Mamdani* desarrollado demostró capacidad clasificatoria robusta ($F1\text{-Score } LOOU = 0.780$) manteniendo interpretabilidad completa mediante 5 reglas lingüísticas auditables.

7.6.2 Objetivos Específicos

- **OE1 - Derivación de variables semanales: Cumplido.** Se derivaron exitosamente cuatro variables compuestas (Actividad relativa, Superávit calórico basal, Delta cardíaco, *HRV-SDNN*) mediante normalización antropométrica y agregación semanal sobre 9,185 días de registro, resultando en 1,337 semanas válidas con $< 20\%$ de datos faltantes.
- **OE2 - Identificación de perfiles mediante clustering: Cumplido.** El algoritmo *K-Means* identificó dos perfiles de comportamiento con separación moderada (*Silhouette* = 0.232) y diferencias estadísticamente significativas en las cuatro variables ($p < 0,001$, tamaños de efecto grandes). Esta clasificación sirvió como verdad operativa para el entrenamiento del sistema difuso.

- **OE3 - Diseño del sistema de inferencia difusa: Cumplido.** Se diseñó un sistema *Mamdani* con 5 reglas lingüísticas fundamentadas fisiológicamente, con funciones de pertenencia triangulares calibradas a partir de los percentiles 25, 50 y 75 de cada variable observada en los datos. La estructura *if-then* garantiza interpretabilidad clínica completa.
- **OE4 - Evaluación del desempeño mediante validación cruzada: Cumplido.** La validación Leave-One-User-Out demostró concordancia robusta entre el sistema difuso y el *clustering* ($F1 = 0.780$, $Kappa = 0.56$), confirmando que el modelo capturó efectivamente los patrones identificados por el método de agrupamiento.
- **OE5 - Análisis de sensibilidad mediante ablación: Cumplido.** El análisis de ablación sistemático reveló que *HRV-SDNN*, a pesar de su débil asociación univariada, es crítico para el desempeño multivariado (ablación: -51 % $F1$ -Score), lo que caracteriza la contribución relativa de cada variable al modelo predictivo.

7.6.3 Hipótesis

Hipótesis Conceptual (HC): *La clasificación del comportamiento sedentario generada por el sistema de inferencia difusa, basado en reglas que integran biomarcadores de actividad y función cardiovascular, exhibe una alta concordancia con la clasificación objetiva obtenida mediante un análisis de conglomerados no supervisado sobre los mismos datos.*

Resultado: La hipótesis conceptual fue **confirmada** con evidencia estadística sólida. El coeficiente Kappa de Cohen entre las clasificaciones del *clustering* y del sistema difuso alcanzó 0.56 (concordancia moderada-sustancial), significativamente superior al acuerdo esperado por azar ($p < 0,001$). El $F1$ -Score de 0.780 en validación *LOUO* indica que el modelo difuso logró replicar la estructura clasificatoria identificada por el *clustering*, generalizando efectivamente a individuos no vistos durante el entrenamiento.

Este resultado confirma la viabilidad de la arquitectura híbrida propuesta, donde el conocimiento empírico descubierto por métodos no supervisados puede ser codificado en reglas lingüísticas interpretables que preservan la capacidad predictiva. La concordancia observada valida el enfoque de utilizar *clustering* como verdad operativa en contextos donde estándares de oro clásicos no están disponibles.

7.7 Reflexión Final y Líneas Futuras de Investigación

Este estudio demuestra que la convergencia entre inteligencia artificial explicable, dispositivos portátiles de consumo y diseños longitudinales de vida libre constituye un eje transformador en la vigilancia de los comportamientos sedentarios. La combinación de metodologías *BYOD* con modelos difusos no solo amplía la comprensión del fenómeno desde la perspectiva fisiológica y conductual, sino que también abre el camino hacia ecosistemas de salud digital basados en datos de vida real, donde la prevención y la promoción de la salud se integren de forma continua y personalizada.

La aplicabilidad práctica de estos resultados radica en su potencial para orientar políticas públicas centradas en el uso responsable de la tecnología digital como herramienta de salud. Los modelos explicables, como el propuesto, permiten diseñar dashboards y alertas personalizadas que incentiven la movilidad

cotidiana, identifiquen patrones de riesgo y faciliten la toma de decisiones en entornos laborales, educativos y comunitarios. Su naturaleza adaptativa posibilita, además, la personalización de intervenciones conductuales, incorporando recomendaciones dinámicas según la respuesta fisiológica de cada individuo.

En conjunto, los hallazgos aquí presentados fortalecen la premisa de que la medición objetiva del sedentarismo mediante tecnologías portátiles, interpretada a través de sistemas inteligentes transparentes, puede convertirse en una herramienta estratégica para la toma de decisiones en salud pública, contribuyendo a reducir la carga de enfermedad asociada a la inactividad y a promover estilos de vida más activos y sostenibles.

Líneas futuras de investigación incluyen:

1. **Validación prospectiva con estándares de oro:** Replicar el estudio con mediciones concurrentes de actigrafía de investigación y calorimetría indirecta para cuantificar la validez de criterio del modelo difuso versus técnicas de referencia.
2. **Escalamiento a cohortes heterogéneas:** Aplicar el protocolo a cohortes con mayor diversidad etaria, socioeconómica y clínica (incluyendo poblaciones con enfermedades crónicas) para evaluar la robustez del modelo en condiciones de alta heterogeneidad.
3. **Implementación en intervenciones conductuales randomizadas:** Desarrollar una aplicación móvil que utilice el modelo difuso para generar retroalimentación en tiempo real, y evaluar su efectividad en reducir el sedentarismo mediante un ensayo clínico controlado aleatorizado.
4. **Exploración de variabilidad temporal:** Analizar patrones circadianos y semanales del comportamiento sedentario mediante descomposición de series temporales, para identificar momentos de mayor susceptibilidad a intervenciones conductuales.
5. **Integración con biomarcadores inflamatorios y metabólicos:** Vincular los perfiles de sedentarismo identificados con mediciones sanguíneas de proteína C reactiva, glucosa, lípidos y citoquinas inflamatorias, para caracterizar las vías biológicas mediando la asociación sedentarismo-enfermedad.

En síntesis, los hallazgos aquí presentados confirman que el monitoreo continuo del sedentarismo mediante dispositivos portátiles, interpretado a través de sistemas de inferencia difusa, representa una vía factible y ética para transformar los datos personales en conocimiento accionable para la salud pública. Este modelo no solo contribuye a la comprensión científica del sedentarismo como fenómeno biopsicosocial, sino que también proporciona una base empírica para diseñar políticas públicas orientadas a reducir la inactividad y fomentar entornos digitales saludables. Así, la investigación trasciende el ámbito académico para posicionarse como una herramienta estratégica en la promoción de estilos de vida activos y sostenibles en la era de la salud digital.

Conclusiones

Este estudio demuestra que es factible desarrollar un modelo basado en lógica difusa para clasificar de manera fiable el comportamiento sedentario semanal. El modelo utiliza exclusivamente datos biométricos multivariados recopilados en condiciones de vida libre por dispositivos de consumo. El sistema de inferencia difusa propuesto respondió afirmativamente a la pregunta de investigación al alcanzar una alta concordancia ($F1\text{-Score LOUO} = 0.780$) con una clasificación objetiva y empírica derivada de un análisis de conglomerados, validando así su arquitectura y su capacidad para representar patrones de comportamiento reales.

La principal contribución científica de esta tesis es la demostración empírica del poder de los sistemas expertos para modelar la sinergia entre biomarcadores. Se identificó una paradoja metodológica donde variables individualmente débiles para discriminar el comportamiento (como la Variabilidad de la Frecuencia Cardíaca) resultaron ser indispensables para el rendimiento óptimo del modelo multivariado. Este hallazgo prueba que la fortaleza del sistema no reside en la suma de sus partes, sino en su capacidad para interpretar las interacciones complejas entre la actividad física y las respuestas cardiovasculares, una capacidad que los análisis estadísticos univariados no logran capturar.

Metodológicamente, este trabajo aporta una estrategia de validación robusta para sistemas de clasificación en salud cuando no se dispone de un estándar de oro clínico, basada en la convergencia de un enfoque empírico (descubrimiento de patrones no supervisado) y uno experto (reglas basadas en conocimiento). Asimismo, la ingeniería de las variables Actividad Relativa y Superávit Calórico Basal se presenta como una solución eficaz para la normalización fisiológica de datos de dispositivos portátiles, lo que permite comparaciones más equitativas entre individuos.

En conclusión, esta investigación no solo entrega un modelo de clasificación interpretable y de alto rendimiento, sino que también establece un precedente metodológico para el análisis de datos de salud en condiciones de vida libre. El sistema desarrollado tiene el potencial de servir como una herramienta de cribado para la identificación temprana de patrones de comportamiento sedentario de riesgo, sentando las bases para futuras investigaciones orientadas hacia la personalización de modelos y la prevención en la salud digital.

Referencias

- Abellán, J., Sainz de Baranda Anduja, P., & Ortín Ortín, E. J. (2014). Guía para la Prescripción del Ejercicio Físico en Pacientes con Riesgo Cardiovascular.
- Ahmadi, H., Gholamzadeh, M., Shahmoradi, L., Nilashi, M., & Rashvand, P. (2018). Diseases diagnosis using fuzzy logic methods: A systematic and meta-analysis review. *Computer Methods and Programs in Biomedicine*, 161, 145-172. <https://doi.org/10.1016/j.cmpb.2018.04.013>
- Alam, T. M., Shaukat, K., Khelifi, A., Khan, W. A., Raza, H. M. E., Idrees, M., Luo, S., & Hameed, I. A. (2022). Disease diagnosis system using IoT empowered with fuzzy inference system. *Computers, Materials and Continua*, 70(3), 5305-5319. <https://doi.org/10.32604/cmc.2022.020344>
- Alinia, P., Samadani, A., Milosevic, M., Ghasemzadeh, H., & Parvaneh, S. (2020). Pervasive Lying Posture Tracking [F1=98.2 %±6.2 % (CV=6.3 %) mejor caso]. *Sensors*, 20(20), 5953. <https://doi.org/10.3390/s20205953>
- Álvarez, J. A., Cvetkovic, B., & Lustrek, M. (2020). A survey on energy expenditure estimation using wearable devices. *ACM Computing Surveys*, 53(5). <https://doi.org/10.1145/3404482>
- Apple Inc. (2024). HealthKit Documentation.
- Aubert, S., Barnes, J. D., Demchenko, I., Hawthorne, M., Abdeta, C., Nader, P. A., Sala, J. C. A., Aguilar-Farias, N., Aznar, S., Bakalár, P., et al. (2022). Global Matrix 4.0 Physical Activity Report Card Grades for Children and Adolescents: Results and Analyses From 57 Countries. *Journal of Physical Activity and Health*, 19(11), 700-728. <https://doi.org/10.1123/JPAH.2022-0456>
- Bassani, G., Avizzano, C. A., & Filippeschi, A. (2025). Deep Learning Algorithms for Human Activity Recognition in Manual Material Handling Tasks. *Sensors*, 25(21), 6705. <https://doi.org/10.3390/s25216705>
- Bent, B., Goldstein, B. A., Kibbe, W. A., & Dunn, J. P. (2020). Investigating sources of inaccuracy in wearable optical heart rate sensors. *npj Digital Medicine*, 3, 18. <https://doi.org/10.1038/s41746-020-0226-6>
- Bienefeld, N., Boss, J. M., Lüthy, R., Brodbeck, D., Azzati, J., Blaser, M., Willms, J., & Keller, E. (2023). Solving the explainable AI conundrum by bridging clinicians' needs and developers' goals. *npj Digital Medicine*, 6, 94. <https://doi.org/10.1038/s41746-023-00837-4>
- Bolger, N., & Laurenceau, J.-P. (2013). Intensive Longitudinal Methods: An Introduction to Diary and Experience Sampling Research [Diseños longitudinales intensivos para muestras pequeñas].

- Bonneval, L., Wing, D., Sharp, S., Tristao Parra, M., Moran, R., LaCroix, A., & Godino, J. (2025). Validity of Heart Rate Variability Measured with Apple Watch Series 6 Compared to Laboratory Measures. *Sensors*, 25(8), 2380. <https://doi.org/10.3390/s25082380>
- Bull, F. C., Al-Ansari, S. S., Biddle, S., Borodulin, K., Buman, M. P., Cardon, G., Carty, C., Chaput, J.-P., Chastin, S., Chou, R., Dempsey, P. C., DiPietro, L., Ekelund, U., Firth, J., Friedenreich, C. M., Garcia, L., Gichu, M., Jago, R., Katzmarzyk, P. T., ... Willumsen, J. F. (2020). World Health Organization 2020 guidelines on physical activity and sedentary behaviour. *British Journal of Sports Medicine*, 54(24), 1451-1462. <https://doi.org/10.1136/bjsports-2020-102955>
- Campos, I., Galván-Valencia, O., Hernández-Barrera, L., Oviedo-Solís, C., & Barquera, S. (2023). Prevalence of obesity and associated risk factors in Mexican adults: results of the Ensanut 2022. *Salud Pública de México*, 65, s238-s247. <https://doi.org/10.21149/14809>
- Canalys. (2024). Global wearable band market up 0.2 % in Q2 2024 as basic watches take biggest share yet.
- Capitoli, G., Nobile, M. S., Ambags, E. L., L'Imperio, V., Provenzano, M., & Liò, P. (2025). Assisting clinical diagnosis with interpretable fuzzy probabilistic modelling. *BMC Medical Informatics and Decision Making*, 25(Suppl 3), 330. <https://doi.org/10.1186/s12911-025-03183-5>
- Caspersen, C. J., Powell, K. E., & Christenson, G. M. (1985). Physical activity, exercise, and physical fitness: Definitions and distinctions for health-related research [Referencia clásica para definiciones de actividad física]. *Public Health Reports*, 100(2), 126-131.
- Chaves, M., Sandoval Cuellar, C., & Calero Saa, P. (2017). Asociación entre capacidad aeróbica y calidad de vida en adultos mayores de una ciudad colombiana. *Revista Peruana de Medicina Experimental y Salud Pública*, 34(4), 672-676. <https://doi.org/10.17843/rpmesp.2017.344.2522>
- Comisión Electrotécnica Internacional. (2019). *Form to Annex to the Report to the Standardization Management Board: Wearable electronic devices and technologies* (inf. téc.). IEC. <https://www.iec.ch/public/miscfiles/sbp/124.pdf>
- Crozat, F., Pohl, J., Easthope Awai, C., Bauer, C. M., & Kuster, R. P. (2025). Every Step Counts—How Can We Accurately Count Steps with Wearable Sensors During Activities of Daily Living in Individuals with Neurological Conditions? *Sensors*, 25(18), 5657. <https://doi.org/10.3390/s25185657>
- Damoun, N., Amekran, Y., Taiek, N., & El Hangouche, A. J. (2024). Heart rate variability measurement and influencing factors: Towards the standardization of methodology. *Global Cardiology Science and Practice*, 2024(4). <https://doi.org/10.21542/gcsp.2024.35>

- Deka, B., & Deka, D. (2023). Nonlinear analysis of heart rate variability signals in meditative state: a review and perspective. *BioMedical Engineering OnLine*, 22, 1-31. <https://doi.org/10.1186/S12938-023-01100-3>
- Deng, S., Chen, J., Teng, D., Yang, C., Chen, D., Jia, T., & Wang, H. (2023). Lhar: Lightweight human activity recognition on knowledge distillation [HAR ligero wearables. Precedente IEEE JBHI]. *IEEE Journal of Biomedical and Health Informatics*.
- DiPietro, L., Al-Ansari, S. S., Biddle, S. J. H., Borodulin, K., Bull, F. C., Buman, M. P., Cardon, G., Carty, C., Chaput, J.-P., Chastin, S., et al. (2020). Advancing the global physical activity agenda: recommendations for future research by the 2020 WHO physical activity and sedentary behavior guidelines development group. *International Journal of Behavioral Nutrition and Physical Activity*, 17(143). <https://doi.org/10.1186/s12966-020-01042-2>
- Doherty, A., Smith-Byrne, K., Ferreira, T., et al. (2021). GWAS identifies 14 loci for device-measured physical activity and sleep duration. *Nature Communications*, 9(1), 5257. <https://doi.org/10.1038/s41467-018-07743-4>
- Escalante, H. J., & Martínez-Carranza, J. (2023). Explainable Artificial Intelligence in Wearable Health Monitoring Systems: Towards Transparent and Trustworthy Algorithms. *Sensors*, 23(3), 1442. <https://doi.org/10.3390/s23031442>
- Farrahi, V., & Rostami, M. (2024). Machine learning in physical activity, sedentary, and sleep behavior research. *Journal of Activity, Sedentary and Sleep Behaviors*, 3(1), 5. <https://doi.org/10.1186/s44167-024-00045-9>
- Fox, S. M., & Haskell, W. L. (1968). Physical Activity and the Prevention of Coronary Heart Disease. *Bulletin of the New York Academy of Medicine*, 44(8), 950-967.
- Fuller, D., Anaraki, J. R., Simango, B., Rayner, M., Dorani, F., Bozorgi, A., Luan, H., & Basset, F. A. (2021). Predicting lying, sitting, walking and running using Apple Watch and Fitbit data. *BMJ Open Sport and Exercise Medicine*, 7(1), e001004. <https://doi.org/10.1136/bmjsem-2020-001004>
- Gaur, V. (2024). Apple Health Data Analysis. <https://github.com/vinayakgaur/Apple-Health-Data-Analysis>
- Godkin, F. E., Van Ooteghem, K., Beyer, K. B., Weber, K., Cornish, B. F., Tang, A., Martens, K. E., & McIlroy, W. E. (2025). Measuring resting heart rate during daily life using wearable technology: Examining the impact of behavioral context and methodological criteria. *Digital Health*, 11, 20552076251367506. <https://doi.org/10.1177/20552076251367506>
- Gonçalves, R., Pereira, F. L., Ribeiro, V. M., & Rocha, A. P. (2021). Human Activity Recognition [ÚNICO precedente de K-Means (k=2) → FIS Mamdani]. En Á. Rocha, H. Adeli, L. P. Reis & S. Costanzo (Eds.), *Trends and Applications in Information Systems and Technologies* (pp. 238-248, Vol. 1). Springer.

- Gupta, M. M. (2011). Forty-five years of fuzzy sets and fuzzy logic—A tribute to professor Lotfi A. Zadeh (the father of fuzzy logic). *Scientia Iranica*, 18(3), 685-690. <https://doi.org/10.1016/j.scient.2011.04.023>
- Guthold, R., Stevens, G. A., Riley, L. M., & Bull, F. C. (2020). Global trends in insufficient physical activity among adolescents: a pooled analysis of 298 population-based surveys with 1·6 million participants. *The Lancet Child and Adolescent Health*, 4(1), 23-35. [https://doi.org/10.1016/S2352-4642\(19\)30323-2](https://doi.org/10.1016/S2352-4642(19)30323-2)
- Harris, J. A., & Benedict, F. G. (1918). A Biometric Study of Human Basal Metabolism [Ecuación clásica de TMB (Tasa Metabólica Basal)]. *Proceedings of the National Academy of Sciences*, 4(12), 370-373. <https://doi.org/10.1073/pnas.4.12.370>
- Healy, S., Patterson, F., Biddle, S. J., Dumuid, D., Glorieux, I., Olds, T., Woods, C., Bauman, A. E., Gába, A., Herring, M. P., Kastelic, K., Lachapelle, U., Volpe, S. L., Tomat, S. B., & Pedisic, Z. (2024). It's about time to exercise: development of the Exercise Participation Explained in Relation to Time (EXPERT) model. *British Journal of Sports Medicine*, 58(19), 1131-1144. <https://doi.org/10.1136/bjsports-2024-108500>
- Henriksen, A., Mikalsen, M. H., Woldaregay, A. Z., Muzny, M., Hartvigsen, G., Hopstock, L. A., & Grimsgaard, S. (2018). Using fitness trackers and smartwatches to measure physical activity in research: Analysis of consumer wrist-worn wearables. *Journal of Medical Internet Research*, 20(3), e110. <https://doi.org/10.2196/jmir.9157>
- Henriksen, A., Woldaregay, A. Z., Muzny, M., Hartvigsen, G., Hopstock, L. A., & Grimsgaard, S. (2021). *Replication data for Using Fitness Trackers and Smartwatches to Measure Physical Activity in Research*. <https://doi.org/10.18710/6ZWC9Z>
- Ho, W. T., Yang, Y. J., & Li, T. C. (2022). Accuracy of wrist-worn wearable devices for determining exercise intensity. *Digital Health*, 8, 20552076221124393. <https://doi.org/10.1177/20552076221124393>
- Ji, J., Venderley, J., Zhang, H., Lei, M., Ruan, G., Patel, N., Chung, Y.-M., Giesting, R., & Miller, L. (2023). Assessing nocturnal scratch with actigraphy in atopic dermatitis patients. *npj Digital Medicine*, 6(1), 72. <https://doi.org/10.1038/s41746-023-00821-y>
- Katzmarzyk, P. T. (2023). Expanding our understanding of the global impact of physical inactivity. *The Lancet Global Health*, 11(1), e2-e3. [https://doi.org/10.1016/S2214-109X\(22\)00482-X](https://doi.org/10.1016/S2214-109X(22)00482-X)
- Kaur, J., & Khehra, B. S. (2022). Fuzzy Logic and Hybrid based Approaches for the Risk of Heart Disease Detection: State-of-the-Art Review. *Journal of The Institution of Engineers (India): Series B*, 103(2), 681-697. <https://doi.org/10.1007/s40031-021-00644-z>
- Kaveh, R., Schwendeman, C., Pu, L., Arias, A. C., & Muller, R. (2024). Wireless ear EEG to monitor drowsiness. *Nature Communications*, 15(1), 6520. <https://doi.org/10.1038/s41467-024-48682-7>

- Khan, D., Al Mudawi, N., Abdelhaq, M., Alazeb, A., Alotaibi, S. S., Algarni, A., & Jalal, A. (2024). A Wearable Inertial Sensor Approach for Locomotion and Localization Recognition on Physical Activity. *Sensors*, 24(3), 735. <https://doi.org/10.3390/s24030735>
- Laborde, S., Mosley, E., & Thayer, J. F. (2017). Heart rate variability and cardiac vagal tone in psychophysiological research – Recommendations for experiment planning, data analysis, and data reporting. *Frontiers in Psychology*, 8, 213. <https://doi.org/10.3389/fpsyg.2017.00213>
- Levitz, K., & Levitz, H. (1979). *Logic and Boolean Algebra*. Barron's Educational Series.
- Liu, Y., Chen, J., & Wu, M. (2022). The Bring-Your-Own-Device (BYOD) Model in Digital Health Research: Practical Considerations and Ethical Challenges. *Journal of Medical Internet Research*, 24(6), e35410. <https://doi.org/10.2196/35410>
- Lyons, K., Man, A. H. H., Booth, D., & Rena, G. (2024). Defining Activity Thresholds Triggering a "Stand Hour" for Apple Watch Users: Cross-Sectional Study. *JMIR Formative Research*, 8, e53806. <https://doi.org/10.2196/53806>
- Marashi-Hosseini, L., Jafarirad, S., & Hadianfard, A. M. (2023). A fuzzy based dietary clinical decision support system for patients with multiple chronic conditions (MCCs). *Scientific Reports*, 13, 12166. <https://doi.org/10.1038/s41598-023-39371-4>
- Marino, F. R., Norby, F. L., Shah, A. M., Soliman, E. Z., Alonso, A., Gottesman, R. F., Mosley, T. H., Coresh, J., Chen, L. Y., & Palta, P. (2024). Associations of Physical Activity and Heart Rate Variability from a Two-Week ECG Monitor with Cognitive Function and Dementia: The ARIC Neurocognitive Study. *Sensors*, 24(13), 4060. <https://doi.org/10.3390/s24134060>
- Martínez, R., Palma, A., & Velásquez, A. (2020). *Revolución tecnológica e inclusión social: Reflexiones sobre desafíos y oportunidades para la política social en América Latina* (inf. téc. N.º 233). CEPAL.
- Mathew, S. P., Dawe, J., Musselman, K. E., Petrevska, M., Zariffa, J., Andrysek, J., & Biddiss, E. (2024). Measuring Functional Hand Use in Children with Unilateral Cerebral Palsy Using Accelerometry and Machine Learning. *Developmental Medicine & Child Neurology*, 66(10), 1380-1389. <https://doi.org/10.1111/dmcn.15895>
- Miguelés, J. H., Aadland, E., Andersen, L. B., Brønd, J. C., Chastin, S. F., Hansen, B. H., Konstabel, K., Kvalheim, O. M., McGregor, D. E., Rowlands, A. V., Sabia, S., Van Hees, V. T., Walmsley, R., & Ortega, F. B. (2022). GRANADA consensus on analytical approaches to assess associations with accelerometer-determined physical behaviours (physical activity, sedentary behaviour and sleep) in epidemiological studies. *British Journal of Sports Medicine*, 56(7), 376-384. <https://doi.org/10.1136/BJSPORTS-2020-103604>

- Mullick, T., Radovic, A., Shaaban, S., & Doryab, A. (2022). Predicting Depression in Adolescents Using Mobile and Wearable Sensors: Multimodal Machine Learning–Based Exploratory Study. *JMIR Formative Research*, 6(6), e35807. <https://doi.org/10.2196/35807>
- Murray, C. J. L., Aravkin, A. Y., Zheng, P., Abbafati, C., Abbas, K. M., Abbasi-Kangevari, M., Abd-Allah, F., Abdelalim, A., Abdollahi, M., Abdollahpour, I., et al. (2020). Global burden of 87 risk factors in 204 countries and territories, 1990–2019: a systematic analysis for the Global Burden of Disease Study 2019. *The Lancet*, 396(10258), 1223-1249. [https://doi.org/10.1016/S0140-6736\(20\)30752-2](https://doi.org/10.1016/S0140-6736(20)30752-2)
- O’Grady, B., Lambe, R., Baldwin, M., Acheson, T., & Doherty, C. (2024). The Validity of Apple Watch Series 9 and Ultra 2 for Serial Measurements of Heart Rate Variability and Resting Heart Rate. *Sensors*, 24(19), 6220. <https://doi.org/10.3390/s24196220>
- Okunogbe, A., Nugent, R., Spencer, G., Ralston, J., & Wilding, J. (2021). Economic impacts of overweight and obesity: Current and future estimates for eight countries. *BMJ Global Health*, 6(10), e006351. <https://doi.org/10.1136/bmjgh-2021-006351>
- Pate, R. R., O’Neill, J. R., & Lobelo, F. (2008). The evolving definition of “sedentary”. *Exercise and Sport Sciences Reviews*, 36(4), 173-178. www.acsm-essr.org
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
- Pinto, A. J., Bergouignan, A., Dempsey, P. C., Roschel, H., Owen, N., Gualano, B., & Duns-tan, D. W. (2023). Physiology of sedentary behavior. *Physiological Reviews*, 103(4), 2561-2622. <https://doi.org/10.1152/physrev.00022.2022>
- Prince, S. A., Adamo, K. B., Hamel, M. E., Hardt, J., Gorber, S. C., & Tremblay, M. (2008). A comparison of direct versus self-report measures for assessing physical activity in adults: A systematic review. *International Journal of Behavioral Nutrition and Physical Activity*, 5, 56. <https://doi.org/10.1186/1479-5868-5-56>
- Quigley, K. S., Gianaros, P. J., Norman, G. J., Jennings, J. R., Berntson, G. G., & de Geus, E. J. C. (2024). Publication guidelines for human heart rate and heart rate variability studies in psychophysiology—Part 1: Physiological underpinnings and foundations of measurement. *Psychophysiology*, 61(9), e14604. <https://doi.org/10.1111/psyp.14604>
- Razjouyan, J., Naik, A. D., Horstman, M. J., Kunik, M. E., Amirmazaheri, M., Zhou, H., Sha-rafkhaneh, A., & Najafi, B. (2018). Wearable Sensors and the Assessment of Frailty among Vulnerable Older Adults: An Observational Cohort Study. *Sensors*, 18(5), 1336. <https://doi.org/10.3390/s18051336>

- Rehman, S. U., Ali, A., Khan, A. M., & Okpala, C. (2024). Human Activity Recognition: A Comparative Study of Validation Methods and Impact of Feature Extraction in Wearable Sensors. *Algorithms*, 17(12), 556. <https://doi.org/10.3390/a17120556>
- Reyes Molina, D., Zapata Lamana, R., Cigarroa, I., Palma Leal, X., Aguilar Farías, N., & Nazar, G. (2023). Actividad física incidental: avanzar en un paradigma de actividad física integrado y multidimensional. *Revista Médica de Chile*, 151, 530-538. <https://doi.org/10.4067/s0034-98872023000400530>
- Riebe, D., Ehrman, J. K., Liguori, G., & Magal, M. (2018). *ACSM's Guidelines for Exercise Testing and Prescription* (10th) [Guía oficial del ACSM para prescripción de ejercicio]. American College of Sports Medicine.
- Romero, M., Barrientos-Gutiérrez, T., Cuevas-Nasu, L., Bautista-Arredondo, S., Colchero, M. A., Gaona-Pineda, E. B., Martínez-Barnette, J., Alpuche-Aranda, C., Gómez-Acosta, L. M., Mendoza-Alvarado, L. R., Rivera-Dommarco, J., Lazcano-Ponce, E., & Shamah-Levy, T. (2022). Design of the Encuesta Nacional de Salud y Nutrición 2022 and planning and design of the Ensanut Continua 2020-2024. *Salud Pública de México*, 64(5), 522-529. <https://doi.org/10.21149/14186>
- Ross, T. J. (2010). *Fuzzy Logic with Engineering Applications* (3rd). John Wiley & Sons Ltd.
- Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20, 53-65. [https://doi.org/10.1016/0377-0427\(87\)90125-7](https://doi.org/10.1016/0377-0427(87)90125-7)
- Salim, A., Brakenridge, C. J., Lekamlage, D. H., et al. (2024). Detection of Sedentary Time and Bouts Using Consumer-Grade Wrist-Worn Devices: A Hidden Semi-Markov Model. *BMC Medical Research Methodology*, 24(1), 222. <https://doi.org/10.1186/s12874-024-02311-5>
- Santos, A. C., Willumsen, J., Meheus, F., Ilbawi, A., & Bull, F. C. (2023). The cost of inaction on physical inactivity to public health-care systems: a population-attributable fraction analysis. *The Lancet Global Health*, 11(1), e32-e39. [https://doi.org/10.1016/S2214-109X\(22\)00464-8](https://doi.org/10.1016/S2214-109X(22)00464-8)
- Santos, J. C., Wong, J. H. D., Pallath, V., & Ng, K. H. (2021). The perceptions of medical physicists towards relevance and impact of artificial intelligence. *Physical and Engineering Sciences in Medicine*, 44(3), 833-841. <https://doi.org/10.1007/s13246-021-01036-9>
- Schrack, J. A., Cooper, R., Koster, A., Shiroma, E. J., Murabito, J. M., Rejeski, W. J., Ferrucci, L., & Harris, T. B. (2018). Using heart rate and accelerometry to define quantity and intensity of physical activity in older adults. *The Journals of Gerontology: Series A*, 73(5), 668-675. <https://doi.org/10.1093/gerona/gly029>
- Schuch, F. B., Vancampfort, D., Firth, J., Rosenbaum, S., Ward, P. B., Silva, E. S., Hallgren, M., Ponce De Leon, A., Dunn, A. L., Deslandes, A. C., Fleck, M. P., Carvalho, A. F., & Stubbs,

- B. (2018). Physical Activity and Incident Depression: A Meta-Analysis of Prospective Cohort Studies [Relación bidireccional entre actividad física y bienestar psicológico]. *American Journal of Psychiatry*, 175(7), 631-648. <https://doi.org/10.1176/appi.ajp.2018.17111194>
- Shamah-Levy, T., Romero-Martínez, M., Barrientos-Gutiérrez, T., Cuevas-Nasu, L., Bautista-Arredondo, S., Colchero, M. A., Gaona-Pineda, E. B., Lazcano-Ponce, E., Martínez-Barnetche, J., Alpuche-Arana, C., & Rivera-Dommarco, J. (2023). *Encuesta Nacional de Salud y Nutrición 2022 – Resultados Nacionales* (inf. téc.). Instituto Nacional de Salud Pública. <https://ensanut.insp.mx/encuestas/ensanut2022/index.php>
- Shcherbina, A., Mattsson, C. M., Waggott, D., et al. (2017). Accuracy in Wrist-Worn, Sensor-Based Measurements of Heart Rate and Energy Expenditure in a Diverse Cohort. *Journal of Personalized Medicine*, 7(2), 3. <https://doi.org/10.3390/jpm7020003>
- Soares-Miranda, L., Sattelmair, J., Chaves, P., Duncan, G. E., Siscovick, D. S., Stein, P. K., & Mozaffarian, D. (2014). Physical activity and heart rate variability in older adults: The cardiovascular health study. *Circulation*, 129(21), 2100-2110. <https://doi.org/10.1161/CIRCULATIONAHA.113.005361>
- Strain, T., Wijndaele, K., Dempsey, P. C., Sharp, S. J., Pearce, M., Jeon, J., Lindsay, T., Wareham, N., & Brage, S. (2020). Wearable-device-measured physical activity and future health risk. *Nature Medicine*, 26(9), 1385-1391. <https://doi.org/10.1038/s41591-020-1012-3>
- Strategic Plan Advisory Group PAHO. (2020). *Strategic Plan of the Pan American Health Organization 2020-2025: Equity at the Heart of Health* (inf. téc.). Pan American Health Organization. <http://www.paho.org/permissions>
- Strefezza, M. (2009). Lógica difusa, un punto de vista. *Revista Ciencia e Ingeniería*, 30(3).
- Swinburn, B. A., Kraak, V. I., Allender, S., Atkins, V. J., Baker, P. I., Bogard, J. R., Brinsden, H., Calvillo, A., De Schutter, O., Devarajan, R., Ezzati, M., Friel, S., Goenka, S., Hammond, R. A., Hastings, G., Hawkes, C., Herrero, M., Hovmand, P. S., Howden, M., et al. (2019). The Global Syndemic of Obesity, Undernutrition, and Climate Change: The Lancet Commission report. *The Lancet*, 393(10173), 791-846. [https://doi.org/10.1016/S0140-6736\(18\)32822-8](https://doi.org/10.1016/S0140-6736(18)32822-8)
- Syed-Abdul, S., Luque, L. F., Hsueh, P., García-Gomez, J. M., & Garcia-Zapirain, B. (2020). Data Analytics and Applications of the Wearable Sensors in Healthcare. *Sensors*, 20, 1379. www.mdpi.com/journal/sensors
- Tanaka, H., Monahan, K. D., & Seals, D. R. (2001). Age-Predicted Maximal Heart Rate Revisited. *Journal of the American College of Cardiology*, 37(1), 153-156. [https://doi.org/10.1016/S0735-1097\(00\)01054-8](https://doi.org/10.1016/S0735-1097(00)01054-8)

- Task Force ESC/NASPE. (1996). Heart rate variability: Standards of measurement, physiological interpretation and clinical use. *Circulation*, 93(5), 1043-1065. <https://doi.org/10.1161/01.CIR.93.5.1043>
- Thayer, J. F., Yamamoto, S. S., & Brosschot, J. F. (2010). The relationship of autonomic imbalance, heart rate variability and cardiovascular disease risk factors. *International Journal of Cardiology*, 141(2), 122-131. <https://doi.org/10.1016/j.ijcard.2009.09.543>
- Tremblay, M. S., Colley, R. C., Saunders, T. J., Healy, G. N., & Owen, N. (2010). Physiological and health implications of a sedentary lifestyle. *Applied Physiology, Nutrition, and Metabolism*, 35(6), 725-740. <https://doi.org/10.1139/H10-079>
- Tremblay, M. S., Aubert, S., Barnes, J. D., Saunders, T. J., Carson, V., Latimer-Cheung, A. E., Chastin, S. F. M., Altenburg, T. M., Chinapaw, M. J. M., Aminian, S., et al. (2017). Sedentary Behavior Research Network (SBRN) - Terminology Consensus Project process and outcome. *International Journal of Behavioral Nutrition and Physical Activity*, 14(75). <https://doi.org/10.1186/s12966-017-0525-8>
- Vellido, A. (2020). The importance of interpretability and visualization in machine learning for applications in medicine and health care. *Neural Computing and Applications*, 32(24), 18069-18083. <https://doi.org/10.1007/S00521-019-04051-W>
- White, T., Westgate, K., Hollidge, S., Venables, M., Olivier, P., Wareham, N., & Brage, S. (2019). Estimating energy expenditure from wrist and thigh accelerometry in free-living adults: a doubly labelled water study. *International Journal of Obesity*, 43(11), 2333-2342. <https://doi.org/10.1038/s41366-019-0352-x>
- World Health Organization. (2009). *Global Health Risks: Mortality and Burden of Disease Attributable to Selected Major Risks* (inf. téc.). World Health Organization. Geneva, Switzerland.
- World Health Organization. (2018). *Global Action Plan on Physical Activity 2018–2030: More Active People for a Healthier World* (inf. téc.). World Health Organization. Geneva, Switzerland.
- World Health Organization. (2020a). *WHO Guidelines on Physical Activity and Sedentary Behaviour* (inf. téc.). World Health Organization. Geneva, Switzerland. <https://www.who.int/publications/i/item/9789240015128>
- World Health Organization. (2020b). *WHO Guidelines on Physical Activity and Sedentary Behaviour: Web Annex Evidence Profiles* (inf. téc.). World Health Organization. Geneva, Switzerland. <http://apps.who.int/bookorders>
- Yamada, Y., Yoshida, T., Yokoyama, K., Watanabe, Y., Miyake, M., Yamagata, E., Yamada, M., Kimura, M., & Kyoto-Kameoka Study Group. (2019). Accuracy of 12 wearable devices for estimating physical activity energy expenditure using a metabolic chamber and the doubly



- labeled water method: Validation study. *JMIR mHealth and uHealth*, 7(8), e13938. <https://doi.org/10.2196/13938>
- Yoo, I., Alafaireet, P., Marinov, M., Pena-Hernandez, K., Gopidi, R., Chang, J.-F., & Hua, L. (2012). Data mining in healthcare and biomedicine: A survey of the literature. *Journal of Medical Systems*, 36(4), 2431-2448. <https://doi.org/10.1007/s10916-011-9710-5>
- Zadeh, L. A. (1965). Fuzzy sets. *Information and Control*, 8(3), 338-353. [https://doi.org/10.1016/S0019-9958\(65\)90241-X](https://doi.org/10.1016/S0019-9958(65)90241-X)



Anexos

8.1 Análisis Comparativo Exhaustivo de Investigaciones Previas

Esta sección presenta el análisis comparativo exhaustivo de 17 investigaciones representativas sobre clasificación de comportamiento sedentario y actividad física mediante dispositivos *wearables*. La tabla abarca diversas técnicas metodológicas (lógica difusa, machine learning, deep learning, métodos estadísticos), tipos de validación (destacando *LOUO/LOSO*) y aplicaciones en contextos de vida libre. Para facilitar la lectura, la tabla se presenta en orientación horizontal (landscape).

Tabla 8.1

Análisis comparativo exhaustivo de investigaciones sobre clasificación de sedentarismo y actividad física con wearables

Autor (Año)	Objetivo	Técnica	Datos/ Wearable	N	Validación	Métrica Principal	Resultado
Capitoli <i>et al.</i> , (2025) Capitoli <i>et al.</i> , 2025	Diagnóstico clínico interpretable con lógica difusa probabilística	<i>fuzzy Logic</i> (interpretable)	Datos clínicos hospitalarios	Clínico	Validación clínica	Interpretabilidad 100 %	Clínicos controlan proceso diagnóstico. <i>fuzzy</i> = XAI
Marashi-Hosseini <i>et al.</i> , (2023) Marashi-Hosseini <i>et al.</i> , 2023	Sistema decisión dietética para pacientes múltiples condiciones crónicas	<i>fuzzy Logic Mamdani</i> (1144 reglas)	Datos dietéticos + clínicos	100	Validación vs nutricionistas	Precisión	97 % precisión. Sistema experto <i>fuzzy</i> riguroso
Gonçalves <i>et al.</i> , (2021) Gonçalves <i>et al.</i> , 2021	Reconocimiento actividad humana con <i>clustering</i> + <i>fuzzy</i>	<i>K-Means</i> ($k = 2$) → FIS <i>Mamdani</i>	Sensores inerciales (IMU)	—	Validación estabilidad	Estabilidad clasificación	ÚNICO precedente <i>clustering</i> → <i>fuzzy</i> supervisado
Khan <i>et al.</i> , (2024) Khan <i>et al.</i> , 2024	Reconocimiento actividad física con sensores inerciales + deep learning	Deep Learning (CNNs + LSTMs)	Sensores inerciales <i>wearable</i>	—	K-fold CV	<i>Accuracy</i>	Alta precisión. Requiere datos masivos + no interpretable

Continúa en la siguiente página...

(Continuación de Tabla 8.1)

Autor (Año)	Objetivo	Técnica	Datos/ Wearable	N	Validación	Métrica Principal	Resultado
Bassani <i>et al.</i> (2025) Bassani et al., 2025	Deep Learning para reconocimiento actividad física en tareas manuales	Deep Learning (varios modelos)	Acelerómetros—	70/30	vs	<i>Accuracy</i> LOSO	70/30: 95.7 % → LOSO: 90.3 % . Generaliza- ción robusta requiere LOSO
Fuller <i>et al.</i> (2021) Fuller et al., 2021	Clasificación lying, sitting, walking, running con <i>Apple Watch</i> + Fitbit	Random Forest	<i>Apple Watch</i> + Fitbit (acelerómetro)	33	LOOCV	<i>Accuracy</i>	<i>Accuracy</i> >90 % para posturas. BYOD validado
Mathew <i>et al.</i> (2024) Mathew et al., 2024	Medición uso funcional mano en parálisis cerebral unilateral con ML	Machine Learning (varios modelos)	Acelerómetro (muñeca)	32	Personalizado vs LOSO	<i>F1-Score</i>	Personalizado: F1=0.896 → LOSO: F1=0.584 . Evidencia sobreajuste <i>N</i> pequeño

Continúa en la siguiente página...

(Continuación de Tabla 8.1)

Autor (Año)	Objetivo	Técnica	Datos/ Wearable	N	Validación	Métrica Principal	Resultado
Rehman <i>et al.</i> (2024) Rehman et al., 2024	Estudio comparativo validación + extracción características en HAR <i>wearables</i>	Random Forest	Sensores inerciales <i>wearables</i>	—	LOSO vs k-fold	<i>Accuracy</i>	LOSO: 76 % vs k-fold: 89 %. Data leakage justifica LOUO
Salim <i>et al.</i> (2024) Salim et al., 2024	Detección tiempo sedentario + bouts con Hidden Semi-Markov Model	Hidden Semi-Markov Model	<i>wearables</i> consumo (muñeca)	—	Validación vs ver- operativa	Sensibilidad/ Especificidad	Detección precisa sedentary bouts. Método estadístico avanzado
Miguel <i>et al.</i> (2022) Miguel et al., 2022	Consenso análisis acelerómetro para comportamientos físicos en epidemiología	Consenso metodológico	Acelerómetros— (varios)	—	Revisión sistemática	Guías metodológicas	Estándar internacional para análisis PA/sedentarismo
Lyons <i>et al.</i> (2024) Lyons et al., 2024	Definición umbrales actividad que activan “Stand Hour” en <i>Apple Watch</i>	Estudio observacional	<i>Apple Watch</i> (energía activa + pasos)	—	Análisis umbral	Umbrales Stand Hour	Deconstruye proxy sedentarismo comercial. Umbrales caja negra identificados

Continúa en la siguiente página...

(Continuación de Tabla 8.1)

Autor (Año)	Objetivo	Técnica	Datos/ Wearable	N	Validación	Métrica Principal	Resultado
O'Grady <i>et al.</i> (2024) O'Grady et al., 2024	Validación <i>HRV</i> + RHR en <i>Apple Watch</i> Series 9 y Ultra 2	Estudio validación	<i>Apple Watch</i> vs Polar H10 (gold standard)	39	Validación concurrente	MAPE	HRV MAPE=28.88 % , RHR MAPE=5.91 % . Limitaciones sensor PPG
Ji <i>et al.</i> (2023) Ji et al., 2023	Evaluación scratch nocturno con actigrafía en pacientes dermatitis atópica	Machine Learning	Actigrafía (Acti-Graph)	—	LOSO evaluación	Sensibilidad/ Especificidad	Nature npj Digital Medicine. Precedente metodológico clínico LOSO
Bienefeld <i>et al.</i> (2023) Bienefeld et al., 2023	Resolver dilema XAI: brecha necesidades clínicos vs objetivos desarrolladores	Estudio cualitativo	Entrevistas + cuestionarios	112	Análisis cualitativo	Temas identificados	Clínicos requieren transparencia global. Desarrolladores enfocan local

Continúa en la siguiente página...

(Continuación de Tabla 8.1)

Autor (Año)	Objetivo	Técnica	Datos/ Wearable	N	Validación	Métrica Principal	Resultado
Deng <i>et al.</i> . (2023) Deng et al., 2023	HAR ligero en <i>wearables</i> con knowledge distillation	Deep Learning (ligero)	Sensores <i>wearables</i>	—	Validación experi- mental	<i>Accuracy</i> + eficiencia	IEEE JBHI (revista objeti- vo). HAR eficiente <i>wearables</i>
Godkin <i>et al.</i> . (2025) Godkin et al., 2025	Medir RHR du- rante vida diaria: impacto contexto conductual + cri- terios metodoló- gicos	Estudio ob- servacional	<i>wearables</i> (RHR + aceleró- metro)	—	Análisis contex- tual	RHR por con- texto	RHR se- dentario ≠ RHR sueño. Contextos autonómicos diferentes. Clasifi- cación fisiológica vs postural
Marino <i>et al.</i> . (2024) Marino et al., 2024	Asociaciones PA + <i>HRV</i> con fun- ción cognitiva + demencia (ARIC Neurocognitive Study)	Análisis co- hortes longi- tudinal	ECG am- bulatorio 2 semanas + aceleró- metro	961	Análisis regre- sión	Odds (OR) Ratio	Mayor PA + <i>HRV</i> → mejor cognición. Relación no lineal PA- <i>HRV</i> -salud cerebral

Continúa en la siguiente página...

(Continuación de Tabla 8.1)

Autor (Año)	Objetivo	Técnica	Datos/ Wearable	N	Validación	Métrica Principal	Resultado
Martínez- Corral (2025) [Investigación Actual]	Clasificación comportamien- to sedentario mediante lógica difusa + datos biométricos Ap- ple Watch (HRV, acelerómetro)	Clustering K-Means ($k = 2$) → Fuzzy Mamdani (4 varia- bles)	Apple Watch (PPG + IMU) vida libre	10 (5F/5M)	LOUO (10-fold)	F1-Score	F1- global=0.840, F1- LOUO=0.780±0.167. Interpre- tabilidad 100 %. BYOD vali- dado. Único estudio clustering→fuzzy + LOUO + HRV seden- tarismo

8.2 Nomenclatura y Simbología Matemática

Esta sección presenta la nomenclatura matemática utilizada en el sistema de inferencia difusa y análisis estadístico.

8.2.1 Símbolos Matemáticos Generales

Tabla 8.2

Símbolos y Notación Matemática del Sistema Difuso

Símbolo	Descripción
Conjuntos y Funciones de Membresía	
$\tilde{A}$	Conjunto difuso
$\mu_{\tilde{A}}(x)$	Función de membresía del conjunto difuso $\tilde{A}$
X	Universo de discurso (conjunto clásico de valores posibles)
X_i	Variable de entrada i ($i \in \{1, 2, 3, 4\}$)
Y	Variable de salida (Índice de Sedentarismo)
T_i	Conjunto de términos lingüísticos de variable i
P_i	Matriz de percentiles 3×3 para variable X_i
$p_{k,i}$	Percentil k de la variable X_i
$M^{(j)}$	Matriz de membresías 4×3 para observación j
Variables Fisiológicas	
Act_{rel}	Actividad Relativa (min movimiento / hrs monitoreadas)
Sup_{cal}	Superávit Calórico Basal (% del TMB)
$HRV-SDNN$	Variabilidad Cardíaca (desviación estándar intervalos RR)
Δ_{FC}	Delta Cardíaco (FC caminata - FC reposo)
TMB	Tasa Metabólica Basal (kcal/día, ec. Mifflin-St Jeor)
GCA	Gasto Calórico Activo (kcal/día)
FC	Frecuencia Cardíaca (latidos por minuto)
IQR	Rango Intercuartílico ($Q3 - Q1$)
Reglas de Inferencia y Activación	
R_r	Regla de inferencia r ($r \in \{1, 2, 3, 4, 5\}$)
$\mathcal{R}$	Base de reglas (conjunto de 5 reglas <i>Mamdani</i>)
$w_r^{(j)}$	Activación (firing strength) de regla R_r para observación j

Continúa en la siguiente página...

(Continuación de Tabla 8.2)

Símbolo	Descripción
$\mathbf{w}^{(j)}$	Vector de activaciones $\in \mathbb{R}^5$
$T(a, b)$	T-norm (operador AND fuzzy): $T(a, b) = \min(a, b)$
y_r	output crisp de la regla R_r
$\mathbf{y}_{salidas}$	Vector de salidas de reglas $[1, 0, 0, 0, 0, 9, 0, 5, 0, 7]^T$

Defuzzificación y Clasificación

$y^{(j)}$	Score de sedentarismo defuzzificado para semana j
$\hat{y}^{(j)}$	Clasificación binaria (0=Bajo, 1=Alto sedentarismo)
τ	Umbral de decisión para binarización
$\ \mathbf{w}\ _1$	Norma L1 del vector (suma de componentes)

Validación LOOU

$\mathcal{D}$	dataset completo (1,337 semanas, 10 usuarios)
$\mathcal{D}_{\text{train}}^{(i)}$	Conjunto de entrenamiento en fold i (9 usuarios)
$\mathcal{D}_{\text{test}}^{(i)}$	Conjunto de prueba en fold i (1 usuario)
n_i	Número de semanas del usuario i
$F1^{(i)}$	$F1$ -Score en fold i (usuario i como test)
$\overline{F1}_{\text{LOOU}}$	$F1$ -Score promedio LOOU (10 folds)
σ_{F1}	Desviación estándar de $F1$ -Score entre folds
CV	Coefficiente de variación (%)

Clustering (Verdad Operativa)

K	Número de clusters ($K=2$)
$\mathbf{C}_k$	Centroide del cluster k ($k \in \{0, 1\}$)
$c^{(j)}$	Cluster asignado a semana j (verdad operativa)
S	Silhouette Score (métrica de calidad clustering)

Métricas de Evaluación

TP	True Positives (verdaderos positivos)
TN	True Negatives (verdaderos negativos)
FP	False Positives (falsos positivos)
FN	False Negatives (falsos negativos)
Precision	Precisión: $TP / (TP + FP)$

Continúa en la siguiente página...

(Continuación de Tabla 8.2)

Símbolo	Descripción
Recall	Sensibilidad: $TP/(TP + FN)$
$F1$	$F1\text{-Score}: 2 \cdot \text{Prec} \cdot \text{Rec}/(\text{Prec} + \text{Rec})$
MCC	Matthews Correlation Coefficient
Acc	Accuracy (exactitud): $(TP + TN)/N$

Operadores y Notación Matemática

$\min(a, b)$	Mínimo de a y b
$\max(a, b)$	Máximo de a y b
$\mathbb{E}[\cdot]$	Valor esperado (esperanza matemática)
$\mathbb{I}[\cdot]$	Función indicadora (1 si verdadero, 0 si falso)
$\ \mathbf{v}\ _2$	Norma euclidiana (L2) del vector $\mathbf{v}$
$\ \mathbf{v}\ _1$	Norma L1 (suma de valores absolutos)
$\mathbb{R}$	Conjunto de números reales
$\mathbb{R}^+$	Conjunto de números reales positivos
$\mathbb{R}^n$	Espacio euclidiano n-dimensional
$[a, b]$	Intervalo cerrado de a a b
$\arg \min_x f(x)$	Argumento que minimiza la función $f(x)$
$\forall$	Para todo (cuantificador universal)
$\exists$	Existe (cuantificador existencial)
$\in$	Pertenece a (relación de pertenencia)
$\subset$	Subconjunto de
$\setminus$	Diferencia de conjuntos
$\wedge$	Conjunción lógica (AND)
$\Rightarrow$	Implicación lógica (THEN)