

UNIVERSIDAD AUTÓNOMA DE CHIHUAHUA
FACULTAD DE MEDICINA Y CIENCIAS BIOMÉDICAS
SECRETARÍA DE INVESTIGACIÓN Y POSGRADO



MODELO DE EVALUACIÓN DEL COMPORTAMIENTO
SEDENTARIO MEDIANTE LÓGICA DIFUSA Y
DATOS BIOMÉTRICOS

POR:

LUIS ANGEL MARTÍNEZ CORRAL

TESIS PRESENTADA COMO REQUISITO PARA OBTENER EL GRADO DE:
MAESTRO EN FORMACIÓN E INNOVACIÓN PARA PROFESIONALES DE LA SALUD

RESUMEN

El comportamiento sedentario representa un factor de riesgo para enfermedades crónicas no transmisibles, cuya medición objetiva en condiciones de vida libre presenta desafíos metodológicos significativos. Los métodos tradicionales de evaluación (cuestionarios de autorreporte) adolecen de sesgos de memoria y deseabilidad social, mientras que las técnicas de referencia se restringen a entornos de laboratorio que no capturan la complejidad del comportamiento ecológico. Este estudio desarrolló un modelo de clasificación del sedentarismo mediante lógica difusa que integra datos biométricos de dispositivos portátiles de consumo, aplicado bajo el paradigma *Bring Your Own Device* (BYOD) en condiciones de vida libre.

La cohorte estuvo conformada por 10 adultos jóvenes con seguimiento longitudinal retrospectivo multianual (media: 133.7 semanas; rango: 7-298 semanas), acumulando 9,185 días de registro biométrico continuo mediante Apple Watch. Tras preprocesamiento (imputación jerárquica, normalización antropométrica), se generaron 1,337 semanas válidas con cuatro variables derivadas: Actividad relativa, Superávit calórico basal, Delta cardíaco y HRV-SDNN. La metodología empleó un enfoque híbrido: clustering K-Means no supervisado ($K=2$) para establecer verdad operativa a partir de patrones empíricos, seguido de un Sistema de Inferencia Difusa Mamdani que codifica conocimiento experto mediante cinco reglas lingüísticas interpretables.

La validación Leave-One-User-Out demostró $F1\text{-Score}=0.840$ (Precisión=0.833, Recall=0.850), con variabilidad inter-sujeto excepcional ($CV=4.8\%$), superando estudios comparables. El análisis de ablación reveló que HRV-SDNN, aunque débil discriminador univariado ($p=0.24$), resulta crítico en modelo multivariado (ablación: -50 % $F1\text{-Score}$). El sistema propuesto clasifica comportamiento sedentario con alta fiabilidad, preservando interpretabilidad clínica mediante reglas transparentes aplicables en monitorización ecológica de salud pública.

Palabras clave: comportamiento sedentario, lógica difusa, BYOD, wearables, LOUO, vida libre

ABSTRACT

Sedentary behavior represents a risk factor for chronic non-communicable diseases, whose objective measurement in free-living conditions presents significant methodological challenges. Traditional evaluation methods (self-report questionnaires) suffer from recall and social desirability biases, while reference techniques are restricted to laboratory settings that do not capture the complexity of ecological behavior. This study developed a sedentary lifestyle classification model using fuzzy logic that integrates biometric data from consumer wearable devices, applied under the *Bring Your Own Device* (BYOD) paradigm in free-living conditions.

The cohort consisted of 10 young adults with multi-year retrospective longitudinal follow-up (mean: 133.7 weeks; range: 7-298 weeks), accumulating 9,185 days of continuous biometric recording via Apple Watch. After preprocessing (hierarchical imputation, anthropometric normalization), 1,337 valid weeks were generated with four derived variables: Relative activity, Basal caloric surplus, Cardiac delta, and HRV-SDNN. The methodology employed a hybrid approach: unsupervised K-Means clustering ($K=2$) to establish operational truth from empirical patterns, followed by a Mamdani Fuzzy Inference System that encodes expert knowledge through five interpretable linguistic rules.

Leave-One-User-Out validation demonstrated F1-Score=0.840 (Precision=0.833, Recall=0.850), with exceptional inter-subject variability (CV=4.8 %), surpassing comparable studies. Ablation analysis revealed that HRV-SDNN, although a weak univariate discriminator ($p=0.24$), is critical in the multivariate model (ablation: -50 % F1-Score). The proposed system classifies sedentary behavior with high reliability, preserving clinical interpretability through transparent rules applicable in ecological public health monitoring.

Keywords: sedentary behavior, fuzzy logic, BYOD, wearables, LOOU, free-living



Universidad Autónoma de Chihuahua
Facultad de Medicina y Ciencias Biomédicas
Secretaría de Investigación y Posgrado



La tesis “Modelo de Evaluación del Comportamiento Sedentario mediante Lógica Difusa y Datos Biométricos” que presenta Luis Angel Martínez Corral, como requisito parcial para obtener el grado de: Maestría en Formación Biomédica ha sido revisada y aprobada por la Facultad de Medicina y Ciencias Biomédicas.

Dr. Oscar Aguirre Barrera
Secretario de Investigación y Posgrado
Facultad de Medicina y Ciencias Biomédicas
Universidad Autónoma de Chihuahua

Dra. Haydeé Parra Acosta
Profesor Coordinador Académico

Dr. Abimael Guzmán Pando
Director de Tesis

Dr. David Ricardo López Flores
Co director de tesis

Dra. Celia María Quiñez Cruz
Asesor(a)

Dr. Javier Camarillo Cisneros
Asesor(a)

Se certifica, bajo protesta de decir verdad, que las firmas consignadas al pie del presente documento son de carácter original y auténtico, correspondiendo de manera inequívoca a los responsables de las labores de dirección, seguimiento, asesoría y evaluación, en estricta conformidad con lo dispuesto en la normativa vigente de esta institución universitaria.



Chihuahua, Chih., a _____ de _____ de 2025

Dr. Oscar Aguirre Barrera
Secretario de Investigación y Posgrado
Facultad de Medicina y Ciencias Biomédicas

P R E S E N T E.-

Por medio de la presente nos permitimos informar a usted que el C. Luis Angel Martínez Corral, con número de matrícula 261337, ha concluido la elaboración de la tesis “Modelo de Evaluación del Comportamiento Sedentario mediante Lógica Difusa y Datos Biométricos”, como requisito para obtener el grado de: **Maestro en Formación e Innovación para Profesionales de la Salud.**

Así mismo, manifestamos que la tesis ha sido revisada y aprobada por los abajo firmantes, miembros del Comité de Grado.

Sin otro particular, quedamos de usted.

ATENTAMENTE

“MENTI DA LUCEM, MANIBUS ARTEM”

Director de Tesis

Dr. Abimael Guzmán Pando

Co-Director de Tesis

Dr. David Ricardo López Flores

Asesor de Tesis

Dra. Celia María Quiñez Cruz

Asesor de Tesis

Dr. Javier Camarillo Cisneros

DEDICATORIA

Dedico este trabajo a _____ por _____

AGRADECIMIENTOS

Se agradece a:

[Escribe aquí tus agradecimientos a las personas que apoyaron tu trabajo]



Índice de contenidos

1	Introducción	12
2	Marco Teórico y Antecedentes	14
2.1	Marco Teórico	14
2.1.1	Definición de Sedentarismo	14
2.1.2	Definición del Comportamiento Sedentario	14
2.1.3	Diferencia entre Comportamiento Sedentario e Inactividad Física	15
2.1.4	Directrices de la OMS sobre Actividad Física	15
2.1.5	Actividad Física y Ejercicio Físico	15
2.1.6	Frecuencia Cardíaca y Monitoreo de Intensidad	16
2.1.7	Variabilidad de la Frecuencia Cardíaca (HRV)	16
2.1.8	MET (Equivalente Metabólico)	17
2.1.9	Dispositivos y Tecnologías Electrónicas Portátiles	17
2.1.10	Sensores en Dispositivos Portátiles de Consumo	18
2.1.11	Inteligencia Artificial para el Reconocimiento del Comportamiento Sedentario	18
2.1.12	Teoría de lógica difusa para el análisis de datos biométricos	19
2.1.13	Síntesis del Marco Conceptual	20
2.2	Antecedentes	20
2.2.1	Impacto del Comportamiento Sedentario	20
2.2.2	Instrumentos de evaluación del Comportamiento Sedentario	22
2.2.3	Cómo afecta el CS en la CVRS	22
2.2.4	Uso de sensores para el análisis del Comportamiento Sedentario	23
2.2.5	Monitores de Actividad Física Portables de consumo público	24
2.2.6	El enfoque de la Inteligencia Artificial en el Análisis de Datos	27
2.2.7	Fundamento filosófico del enfoque difuso	28
2.2.8	La Lógica Difusa en la Salud Digital y el Monitoreo Biométrico	29
2.2.9	Clustering No Supervisado para Establecimiento de Ground Truth	31
2.2.10	Validación Leave-One-User-Out en Wearables	32
2.3	Investigaciones Previas Relacionadas	33
2.3.1	Enfoques de Deep Learning y Redes Neuronales	33
2.3.2	Machine Learning Clásico y Validación Cruzada	34
2.3.3	Lógica Difusa y Sistemas de Inferencia Interprettables	34



2.3.4	Métodos Estadísticos y Consensos Metodológicos	35
2.3.5	Validación de Precisión en Dispositivos Wearables Comerciales	36
2.3.6	Relación entre HRV, Actividad Física y Salud	36
2.4	Análisis Comparativo de Investigaciones	36
2.4.1	Síntesis del Análisis Comparativo	42
2.4.2	Aportación Diferencial de la Investigación Actual	43
3	Delimitación del Objeto de Estudio	45
3.1	Problema de Investigación	45
3.2	Pregunta de Investigación	46
3.3	Hipótesis	46
3.3.1	Hipótesis Conceptual (HC)	46
3.3.2	Hipótesis Nula (H_0)	46
3.4	Objetivo General	46
3.5	Objetivos Específicos	46
3.6	Fundamento del Pivote Metodológico	46
3.6.1	Hipótesis Inicial y Necesidad de Pivote	46
3.6.2	Limitaciones del SF-36 como Ground Truth en Cohortes Pequeñas	47
3.6.3	Justificación del Pivote a Enfoque Data-Driven	47
3.6.4	Re-posicionamiento del SF-36: De Ground Truth a Validación Convergente	48
3.7	Justificación del Tamaño de Muestra (N=10)	48
3.7.1	Trade-Off: Profundidad Longitudinal vs. Cantidad de Participantes	48
3.7.2	Precedentes de Cohortes Pequeñas en Literatura Q1	48
3.7.3	Justificación de N=10 en Nuestro Estudio	48
3.8	Estrategia de Validación LOUO	49
3.8.1	Protocolo LOUO Implementado	49
3.8.2	Justificación Metodológica de LOUO	49
3.8.3	Limitaciones Reconocidas y Trabajo Futuro	49
4	Justificación	50
5	Materiales y Métodos	51
5.1	Diseño del Estudio	51
5.1.1	Pivote Metodológico	51
5.2	Población de Estudio	51
5.2.1	Estrategia de Reclutamiento	52
5.2.2	Tamaño de Muestra y Justificación Estadística	52



5.2.3	Características Demográficas de la Cohorte	52
5.3	Definición Operacional de Variables	52
5.3.1	Relación entre Variables	52
5.3.2	Variables Independientes	53
5.3.3	Variable Dependiente	53
5.3.4	Variables de Control	53
5.3.5	Operacionalización de las Variables	53
5.4	Preprocesamiento y Análisis Exploratorio de Datos	55
5.4.1	Extracción de Variables desde Apple HealthKit	55
5.4.2	Análisis de Calidad y Variabilidad de Datos	55
5.4.3	Transición a Ingeniería de Características	57
5.5	Ingeniería de Características y Agregación Temporal	57
5.5.1	Actividad Relativa	57
5.5.2	Superávit Calórico Basal	58
5.5.3	Delta Cardíaco	58
5.5.4	Variabilidad de Frecuencia Cardíaca (HRV-SDNN)	58
5.5.5	Agregación Semanal y Justificación de Medianas	59
5.6	Plan de Análisis Estadístico	59
5.6.1	Fase 1: Caracterización y Análisis de Variabilidad	59
5.6.2	Fase 2: Establecimiento de la Verdad Operativa mediante Clustering	59
5.6.3	Fase 3: Diseño y Configuración del Sistema de Inferencia Difusa	60
5.6.4	Fase 4: Validación del Sistema Difuso mediante Leave-One-User-Out	60
5.6.5	Fase 5: Análisis de Robustez y Contribución de Variables	60
5.7	Técnicas y Procedimiento	61
5.7.1	Selección del Dispositivo	61
5.7.2	Análisis de Sensores	61
5.7.3	Elección del Apple Watch	61
5.7.4	Protocolo del Instrumento	61
5.8	Base Metodológica del Sistema de Inferencia Difusa	63
5.8.1	Formalización Matemática del Sistema de Inferencia Difusa	65
5.9	Aspectos Éticos y de Bioseguridad	70
5.9.1	Principios Éticos	70
5.9.2	Procedimiento para Obtener el Consentimiento	70
5.9.3	Contenido del Formulario de Consentimiento	70
5.9.4	Evaluación de Riesgos	71
5.9.5	Protección de Grupos Vulnerables	71



5.9.6	Confidencialidad y Privacidad de los Datos	71
5.9.7	Política de Retención y Eliminación Segura	71
5.9.8	Derechos de los Participantes	72
5.9.9	Cumplimiento de Normativas y Legislación	72
5.9.10	Plan de Contingencia y Manejo de Incidentes	72
5.10	Financiamiento y Lugar Donde Se Realizará El Proyecto	72
6	Resultados	73
6.1	Caracterización de la Cohorte y Análisis de Variabilidad de Datos	73
6.2	Establecimiento de la Verdad Operativa: Análisis de Conglomerados	74
6.3	Rendimiento del Sistema de Inferencia Difusa	76
6.3.1	Posicionamiento en el Contexto de Estudios con Validación LOUO	78
6.4	Análisis de Robustez y Contribución Sinérgica de las Variables	81
6.4.1	Paradoja HRV: Debilidad Univariada, Fortaleza Multivariada	81
6.4.2	Validación Convergente Exploratoria con SF-36	82
6.5	Tesis	83
7	Discusión	85
7.1	Discusión de Hallazgos Principales	85
7.1.1	Desempeño Predictivo del Modelo Difuso en Validación Leave-One-User-Out	85
7.1.2	Paradoja de la Variabilidad de la Frecuencia Cardíaca: Débil Univariadamente, Crítica Multivariadamente	86
7.1.3	Robustez del Pipeline Híbrido: Clustering No Supervisado como Ground Truth Operativa	87
7.2	Comparación con Investigaciones Previas	88
7.2.1	Convergencias con la Literatura Científica	88
7.2.2	Divergencias Relevantes y Explicaciones	89
7.3	Logros de la Investigación	89
7.4	Limitaciones del Estudio	90
7.4.1	Limitaciones Metodológicas	90
7.4.2	Limitaciones Muestrales	91
7.4.3	Limitaciones Contextuales	91
7.4.4	Limitaciones de Recursos	92
7.5	Implicaciones de los Hallazgos	92
7.5.1	Implicaciones Teóricas	92
7.5.2	Implicaciones Prácticas	92



7.5.3	Implicaciones Metodológicas	93
7.6	Cumplimiento de Objetivos e Hipótesis	93
7.6.1	Objetivo General	93
7.6.2	Objetivos Específicos	93
7.6.3	Hipótesis	94
7.7	Reflexión Final y Líneas Futuras de Investigación	94
8	Conclusiones	96
Anexos		97
8.1	Nomenclatura y Simbología Matemática	97
8.1.1	Símbolos Matemáticos Generales	97

Introducción

El comportamiento sedentario (CS) se ha consolidado como uno de los principales retos de salud pública del siglo XXI, vinculado estrechamente con la transición epidemiológica, la urbanización acelerada y el cambio en los patrones de movilidad y trabajo. Las largas jornadas en posición sentada, el predominio de actividades digitales y la disminución de la actividad física incidental han generado un aumento sostenido en la prevalencia de enfermedades crónicas no transmisibles (ENT), como la diabetes tipo 2, las enfermedades cardiovasculares y la depresión. Este panorama, descrito por la Organización Mundial de la Salud (OMS), refleja la urgencia de desarrollar herramientas que permitan medir, interpretar y reducir los efectos del sedentarismo en la calidad de vida relacionada con la salud (CVRS) **WHO2020; Bull2020; Guthold2020**.

El estudio del CS tradicionalmente se ha sustentado en instrumentos de autoinforme, como el GPAQ o el SF-36, que aunque válidos y ampliamente utilizados, presentan limitaciones inherentes a la subjetividad y la falta de resolución temporal **Romero2022; ShamahLevy2023**. En la última década, el desarrollo de dispositivos portátiles con sensores biométricos —acelerómetros, fotoplethismografía (PPG) y sensores de frecuencia cardíaca— ha permitido capturar datos fisiológicos y de actividad con alta precisión, abriendo la posibilidad de análisis objetivos, continuos y personalizados **Henriksen2018; White2019; Strain2020**. Esta evolución tecnológica sitúa al monitoreo digital de la salud como una pieza central en el diseño de intervenciones preventivas basadas en evidencia.

En este contexto, la inteligencia artificial (IA) y, particularmente, la lógica difusa, ofrecen un marco teórico y computacional idóneo para modelar fenómenos complejos donde las relaciones entre variables no son lineales ni deterministas. A diferencia de los métodos estadísticos tradicionales, la lógica difusa admite grados intermedios de pertenencia y permite representar razonamientos humanos en términos lingüísticos ("actividad alta", "HRV baja", riesgo moderado"), otorgando interpretabilidad y flexibilidad a los modelos biomédicos **Zadeh1965; Ross2010; Kaur2022**. Su integración en sistemas de inferencia Mamdani posibilita traducir datos biométricos en reglas semánticamente comprensibles, fortaleciendo la capacidad explicativa de los algoritmos frente al enfoque opaco de los modelos de caja negra.

El presente proyecto propone un modelo de evaluación del comportamiento sedentario basado en lógica difusa e información biométrica proveniente del Apple Watch, que integra variables de actividad física (minutos en movimiento, pasos diarios, gasto calórico) con indicadores autonómicos derivados de la variabilidad de la frecuencia cardíaca (HRV-SDNN). Este enfoque busca caracterizar la relación entre patrones de sedentarismo y percepción de CVRS, capturando la di-

námica diaria del equilibrio entre esfuerzo, recuperación y bienestar. A través de un sistema de inferencia difusa con reglas adaptativas, se modela la interacción entre la activación fisiológica y los hábitos conductuales, lo cual ofrece una aproximación más precisa y contextualizada del impacto del sedentarismo sobre la salud.

Desde una perspectiva metodológica, el modelo difuso se nutre de datos reales obtenidos de Apple HealthKit, los cuales son procesados mediante un protocolo reproducible que garantiza la integridad y trazabilidad de la información. Se construye una base de control difuso con funciones de pertenencia triangulares y trapezoidales para las variables de entrada, y un conjunto de reglas del tipo "Si actividad alta y HRV baja, entonces riesgo alto". El sistema se valida mediante concordancia con una verdad operativa derivada de clustering no supervisado, y utiliza métricas de rendimiento (F1-Score, Exactitud, Coeficiente de Matthews) y validación cruzada Leave-One-User-Out (LOOU) para evaluar generalización inter-sujeto. Adicionalmente, se realizó una validación convergente exploratoria con el cuestionario SF-36 en un subconjunto de participantes (N=8), la cual reveló correlación significativa únicamente con la dimensión Salud Mental.

La relevancia científica de este trabajo radica en su contribución a la comprensión integral del sedentarismo como fenómeno fisiológico y conductual, integrando la dimensión autonómica del organismo en el análisis de la actividad física. Su valor metodológico se centra en el desarrollo de un sistema explicable y flexible, capaz de adaptarse a distintas poblaciones y contextos de uso. Desde el punto de vista social, la investigación aporta un marco empírico para diseñar estrategias de promoción de la salud personalizadas y sostenibles, en consonancia con la Agenda 2030 y el Plan Mundial sobre Actividad Física 2018–2030 de la OMS **WHO2018**.

En suma, este proyecto articula tres dimensiones convergentes: la necesidad epidemiológica de reducir el comportamiento sedentario, la oportunidad tecnológica de los dispositivos portátiles para capturar datos de alta resolución y el potencial analítico de la lógica difusa para transformar esos datos en conocimiento clínicamente significativo. Con ello, se establece un precedente metodológico para futuras investigaciones en salud digital, inteligencia artificial y promoción de la salud basada en evidencia.

Marco Teórico y Antecedentes

El presente capítulo profundiza en la comprensión del comportamiento sedentario (CS), un fenómeno que incide de manera significativa en la calidad de vida relacionada con la salud (CVRS). Se definen conceptos clave, se analizan sus efectos multifacéticos en la salud y se examinan las herramientas actuales para evaluarlos, las cuales incluyen cuestionarios de autoinforme y tecnologías avanzadas. Además, se aborda la integración de variabilidad de la frecuencia cardíaca (HRV) como biomarcador y el papel de la inteligencia artificial (IA) y la lógica difusa (FL) en el análisis de datos biomédicos.

2.1 Marco Teórico

2.1.1 Definición de Sedentarismo

El sedentarismo se refiere a un estilo de vida donde prevalecen uno o varios CS que se prolongan de forma regular, los cuales requieren de poca o ninguna Actividad Física (AF) (**Tremblay2010Physiological**). Además, el concepto de Sedentarismo no excluye la práctica del Ejercicio Físico (EF), de forma que una persona puede ser considerada Sedentaria aun si llegara a practicar EF, pero sin llegar a cumplir las recomendaciones de la Organización Mundial de la Salud (OMS), dado que se dedica mucho tiempo invertido en conductas sedentarias y prevalece una estimación de gasto calórico total diario muy bajo.

2.1.2 Definición del Comportamiento Sedentario

El CS se refiere a cualquier comportamiento realizado por el individuo en posición acostado, reclinado, sentado o de pie, mientras se está despierto, sin ambulación en dependencia de un bajo gasto energético (**Tremblay2017Terminology**). Como ejemplo, mientras se está sentado, reclinado o acostado, cuando se hace uso de dispositivos electrónicos, mientras se lee, o se está escribiendo, también cuando se va sentado en el autobús, automóvil o tren. De pie en una fila, de pie en la iglesia, de pie para una conversación de pasillo, y al usar un escritorio de pie, se consideran comportamientos sedentarios o estáticos. Por tanto, el CS se refiere a las actividades que no aumentan el gasto de energía sustancialmente por encima del nivel de reposo, con un gasto energético inferior a 1,5 Unidades Metabólicas Equivalentes (MET) (**Pate2008Evolving; Alvarez2020EnergyExpenditure**).

Es importante mencionar que esta definición no es la única, el CS se puede categorizar de varias maneras, según la duración, intensidad, frecuencia y cantidad total de AF (**Tremblay2017Terminology**).

2.1.3 Diferencia entre Comportamiento Sedentario e Inactividad Física

Es importante mencionar que el CS puede tener un impacto negativo en la salud, incluso en personas que cumplen con las recomendaciones de AF propuestas por la OMS. En otras palabras, paradójicamente, en la actualidad es posible cumplir con las recomendaciones de AF mediante EF y también presentar tiempos sedentes superiores a 8 horas por día, es decir, ser “físicamente activo pero sedentario” (**Reyes2023Actividad**).

En la actualidad, se emplea el término sedentario o con alto CS para referirse a individuos que prolongan actividades con bajo gasto energético (**Tremblay2017Terminology**). Además, para referirse a personas sedentarias, se suele utilizar el término de persona con inactividad física o que es inactiva físicamente, cuando un individuo con un nivel de AF es insuficiente para cumplir con las recomendaciones actuales de AF propuesta por la OMS.

2.1.4 Directrices de la OMS sobre Actividad Física

Las últimas instrucciones que se enmarcan en las Directrices de AF y Hábitos Sedentarios del año 2020, la OMS ponen énfasis en que “cada movimiento cuenta”. Se menciona que para reducir el CS es importante la promoción de la actividad física incidental, pues puede ayudar a incrementar gradualmente la AF realizada en un día hacia cantidades recomendadas para una salud óptima. No obstante, las recomendaciones de AF son las siguientes.

Para niños y adolescentes se recomienda realizar al menos una media de 60 minutos de AF diaria principalmente aeróbica de intensidad moderada a vigorosa a lo largo de la semana.

Los adultos deben acumular a lo largo de la semana un mínimo de entre 150 y 300 minutos de AF aeróbica de intensidad moderada, o bien un mínimo de entre 75 y 150 minutos de AF aeróbica de intensidad vigorosa, o bien una combinación equivalente de actividades de intensidad moderada y vigorosa, con el fin de obtener beneficios notables para la salud.

Por último, las personas mayores (a partir de 65 años) pueden realizar la AF como actividad recreativa o de ocio (juegos, deportes o ejercicios programados) y en el marco de los desplazamientos (caminar e ir en bicicleta o en algún otro medio rodado), el trabajo o los quehaceres domésticos, en el contexto ocupacional, educativo, doméstico y comunitario cotidiano (**Bull2020; WHO2020GuidelinesAnnex**).

2.1.5 Actividad Física y Ejercicio Físico

La Actividad Física (AF) se define como cualquier movimiento corporal producido por la contracción del músculo esquelético que aumenta el gasto energético por encima del nivel basal.

Esto incluye tanto actividades estructuradas (ejercicio) como incidentales de la vida diaria (uso de escaleras, desplazamientos activos, tareas domésticas) (**Caspersen1985; Reyes2023Actividad**). El Ejercicio Físico (EF), por su parte, constituye una subcategoría planificada, estructurada y repetitiva cuyo objetivo es mejorar o mantener componentes de la aptitud física (**Caspersen1985**).

La capacidad aeróbica representa una de las cualidades más importantes de la condición física relacionada con la salud, pues refleja el funcionamiento integrado de los sistemas cardiorrespiratorio, metabólico y locomotor, y constituye una medida directa del grado general de salud del individuo (**Riebe2018ACSM; Gonzalez2018Análisis**).

2.1.6 Frecuencia Cardíaca y Monitoreo de Intensidad

La Frecuencia Cardíaca (FC) es el método más utilizado para controlar la intensidad de la actividad física, pues se fundamenta en la correlación lineal entre FC y consumo de oxígeno ($VO_{2\text{máx}}$) (**Abellan2014Prescripcion**). La FC máxima ($FC_{\text{máx}}$) se estima mediante fórmulas validadas como la de Fox-Haskell ($FC_{\text{máx}} = 220 - \text{edad}$) o Tanaka ($FC_{\text{máx}} = 208 - 0,7 \times \text{edad}$), mientras que la intensidad relativa del ejercicio se cuantifica mediante zonas porcentuales: baja (40-60 %), moderada (60-70 %), alta (70-80 %) y máxima (>80 %) (**Fox1968Physical; Tanaka2001AgePredicted; Abellan2014Prescripcion**). En el contexto de dispositivos portátiles modernos, la FC se monitorea continuamente mediante sensores de fotopletismografía (PPG), lo que permite cuantificar tanto la intensidad instantánea de la actividad como biomarcadores autonómicos derivados (ver Sección 2.1.7).

2.1.7 Variabilidad de la Frecuencia Cardíaca (HRV)

La variabilidad de la frecuencia cardíaca (HRV) representa las fluctuaciones en el tiempo entre latidos consecutivos del corazón (**TaskForce1996; Quigley2024Publication**). Estas variaciones son controladas por el sistema nervioso autónomo, lo que convierte a la HRV en un biomarcador no invasivo y continuo del estado autonómico del individuo. Una HRV alta generalmente se asocia con un buen estado de salud y una mayor capacidad de adaptación fisiológica, mientras que una HRV baja puede indicar estrés, fatiga o condiciones de salud subyacentes. El parámetro HRV-SDNN (desviación estándar de los intervalos NN) es una métrica común para cuantificar la HRV (**Damoun2024HRV; Laborde2017**), y proporciona información valiosa sobre el equilibrio entre los sistemas simpático y parasimpático. La integración de la HRV permite un monitoreo más dinámico y sensible de la respuesta fisiológica a la actividad física y el sedentarismo, y ofrece una visión más completa del bienestar general (**Bonneval2025Validity**).

2.1.8 MET (*Equivalente Metabólico*)

Un MET es la cantidad de oxígeno necesaria para el mantenimiento durante 1 minuto de las funciones metabólicas del organismo con el individuo en reposo y sentado, equivalente a $3,5 \text{ ml} \times \text{kg} \times \text{min}$. Además, el MET se utiliza para proporcionar la relación entre la tasa de energía gastada durante una actividad y la tasa de energía gastada en reposo. Los MET son una forma útil, conveniente y estandarizada de describir la intensidad absoluta de las actividades físicas (Riebe2018ACSM).

La prescripción basada en el coste energético de la actividad mediante MET, es la aplicación más lógica para sujetos aparentemente sanos y aquellos con valores altos de $\text{VO}_{2\text{máx}}$, pero resulta menos aplicable en personas con ENT o en individuos con baja capacidad funcional (Abellan2014Prescripcion).

La variable $\text{VO}_{2\text{máx}}$ es el producto del gasto cardíaco o débito cardíaco máximo ($\text{D} \cdot \text{lt sangre} \cdot \text{mín.}^{-1}$) y la diferencia arteriovenosa de oxígeno ($\text{mlO}_2 \cdot \text{lt sangre}^{-1}$), se expresa típicamente en términos relativos ($\text{ml} \cdot \text{kg}^{-1} \cdot \text{min}^{-1}$) en lugar de absolutos ($\text{ml} \cdot \text{min}^{-1}$), lo que permite comparaciones significativas entre individuos con diferente peso corporal. La variación significativa en $\text{VO}_{2\text{máx}}$ entre poblaciones y niveles de condición física se debe principalmente a diferencias en gasto cardíaco máximo (D) por lo tanto, el $\text{VO}_{2\text{máx}}$ está estrechamente relacionado con la capacidad funcional del corazón.

2.1.9 *Dispositivos y Tecnologías Electrónicas Portátiles*

Actualmente se habla de que vivimos una “cuarta revolución industrial” o una “cuarta revolución tecnológica”, la cual precede a la era de la microelectrónica, las tecnologías de la información, tecnologías de las comunicaciones y por supuesto a la World Wide Web (internet). Esto ha derivado en grandes innovaciones que van desde la digitalización, el manejo de grandes volúmenes de información (Big data), la IA, la robótica, las neurociencias y la biotecnología, entre otras (Martinez2020Revolucion).

La Comisión Electrotécnica Internacional (IEC) es una organización líder en el desarrollo de normas internacionales para la electro-tecnología. Sus normas son utilizadas por millones de personas en todo el mundo para garantizar la seguridad, la eficiencia y la interoperabilidad de los productos eléctricos, electrónicos y relacionados.

De acuerdo con la IEC, para el uso de la palabra “Wearables” del inglés que se utiliza comúnmente para referirse a los “dispositivos y tecnologías electrónicas portátiles” se refiere a un amplio rango de dispositivos electrónicos que se pueden llevar puestos o integrados en la ropa u otros objetos.

La IEC define el alcance del Comité Técnico 124 (TC 124) como la “estandarización en el campo de los dispositivos y tecnologías electrónicas portátiles” e incluye; Materiales y dispositivos adheribles: Estos son dispositivos electrónicos delgados y flexibles que se pueden adherir a la piel u otras superficies. Materiales y dispositivos implantables, se trata de dispositivos electrónicos que se colocan quirúrgicamente debajo de la piel o dentro del cuerpo. Materiales y dispositivos ingeribles, son dispositivos electrónicos que se pueden tragar y viajar a través del sistema digestivo para realizar mediciones o administrar medicamentos. Materiales y dispositivos textiles electrónicos, se trata de textiles que incorporan componentes electrónicos, lo que les otorga nuevas funcionalidades (IEC2019Wearables).

2.1.10 Sensores en Dispositivos Portátiles de Consumo

Los wearables modernos integran principalmente dos tipos de sensores para monitoreo de actividad y salud cardiovascular: (1) **Acelerómetros triaxiales**, que miden aceleración en tres ejes espaciales (m/s^2 o fuerza G) y permiten cuantificar movimiento corporal, conteo de pasos y estimación de gasto energético, y (2) **Fotopleetismografía óptica (PPG)**, técnica no invasiva basada en emisores LED y fotorreceptores que detectan variaciones en la absorción lumínica del flujo sanguíneo, la cual permite medir frecuencia cardíaca (FC), variabilidad cardíaca (HRV) y saturación de oxígeno (SpO_2) de manera continua (Bent2020; Shcherbina2017; Henriksen2018; White2019). La combinación de acelerometría (actividad mecánica) y PPG (respuesta cardiovascular) en dispositivos de consumo como el Apple Watch posibilita capturar tanto el comportamiento motor como la respuesta fisiológica en condiciones de vida libre, superando las limitaciones de cuestionarios de autoinforme.

2.1.11 Inteligencia Artificial para el Reconocimiento del Comportamiento Sedentario

En el contexto de las ciencias de la computación, la IA se refiere a una disciplina y un conjunto de capacidades cognoscitivas e intelectuales expresadas por sistemas informáticos o combinaciones de algoritmos cuyo propósito es la creación de máquinas que imiten la inteligencia humana para realizar tareas, y que pueden mejorar conforme recopilen información. Sin embargo, durante la última década, la investigación de la IA en el ámbito de la salud y la medicina ha comenzado a mostrar resultados prometedores y aplicaciones prácticas, como la detección totalmente automática de nuevos biomarcadores para el diagnóstico clínico (Farrahi2024MachineLearning). La IA ha sido reconocida como una fuerza productiva y disruptiva en la atención médica llegando a considerarla como una herramienta innovadora con el potencial de impactar en las prácticas clínica (Santos2021Perceptions; SyedAbdul2020DataAnalytics).

La tecnología portátil y los sensores están emergiendo como herramientas prometedoras

para el monitoreo continuo y en tiempo real de la salud. Desde relojes inteligentes hasta rastreadores de AF y ropa conectada a Internet, los dispositivos portátiles equipados con sensores permiten a los usuarios medir y analizar datos relacionados con su estado fisiológico, actividades y bienestar general. Los rastreadores de AF contienen acelerómetros y monitores ópticos de fotoplethysmografía ya son ampliamente utilizados por los consumidores para contar pasos y controlar la frecuencia cardíaca durante el ejercicio, estos sensores portátiles son de grado clínico para medir con precisión los signos vitales. Por ejemplo, la Presión Arterial (PA), la Frecuencia Respiratoria (FR), (SpO_2), la temperatura de la piel, y más. La integración inalámbrica y los algoritmos de IA permiten que los dispositivos portátiles realicen un seguimiento de los indicadores de salud las 24 horas del día, los 7 días de la semana y proporcionen comentarios a los usuarios (**Khan2024Wearable**).

2.1.12 Teoría de lógica difusa para el análisis de datos biométricos

La teoría de FL, desarrollada inicialmente por Lotfi Zadeh en 1965, se basa en la idea de que la verdad no siempre es una cuestión de blanco o negro, sino que puede hallarse en un espectro de grises. A diferencia de la lógica clásica, que trabaja con valores binarios (0 o 1), la FL permite valores intermedios, lo que la hace especialmente útil para manejar información imprecisa, vaga o incierta. Se ha demostrado que los sistemas difusos son aproximadores universales. Esto se debe al isomorfismo entre dos álgebras: Un álgebra abstracta (que trata con grupos, campos y anillos) y un álgebra lineal (que maneja espacios vectoriales, vectores de estado y matrices de transición). Este isomorfismo refleja la estructura de un sistema difuso, el cual comprende una implicación entre acciones y conclusiones (antecedentes y consecuentes). Así como una función algebraica mapea una variable de entrada a una variable de salida, un sistema difuso mapea un grupo de entrada a un grupo de salida, que pueden ser proposiciones lingüísticas u otras formas de información difusa (**Ross2010**).

La base sobre la cual se asienta la teoría de sistemas difusos es un teorema fundamental del análisis real en álgebra conocido como el teorema de Stone-Weierstrass, desarrollado inicialmente por Weierstrass en 1885 y simplificado por Stone en 1937. Este teorema establece que cualquier función continua definida en un intervalo cerrado puede ser aproximada tan cerca como se desee por una función polinómica (**Ross2010; Gupta2011Tribute**). Los sistemas difusos aprovechan este principio y tienen la capacidad de aproximar comportamientos de sistemas donde las funciones analíticas o las relaciones numéricas no existen.

Los sistemas difusos son particularmente útiles en dos contextos generales: Primero en situaciones que involucran sistemas altamente complejos cuyos comportamientos no se entienden completamente. Segundo en situaciones donde una solución aproximada pero rápida es suficiente. Estos sistemas tienen un alto potencial para comprender sistemas complejos, tales como sistemas

biológicos o médicos, donde la relación entre causas y efectos no se entienden completamente, pero pueden observarse (**Kaur2022**).

2.1.13 Síntesis del Marco Conceptual

El marco teórico presentado establece la base conceptual para comprender la compleja interacción entre el comportamiento sedentario, la actividad física y la calidad de vida relacionada con la salud. La revisión de las definiciones, las directrices de la OMS y las tecnologías de monitoreo resalta la necesidad de enfoques innovadores. Las bases conceptuales para un modelo híbrido que integra mediciones objetivas de comportamiento sedentario, biomarcadores autonómicos continuos y herramientas de inteligencia artificial. La integración de la variabilidad de la frecuencia cardíaca y la aplicación de la lógica difusa emergen como elementos clave para el desarrollo de un modelo más preciso y adaptable, capaz de capturar la dinámica de estas interacciones en contextos de vida real.

2.2 Antecedentes

En esta sección de antecedentes se enmarca la problemática actual que representa el comportamiento sedentario, y las principales motivaciones para realizar esta investigación. Se presentarán los elementos básicos que permiten estudiar los patrones de CS y la percepción de la CVRS. Asimismo, se aborda la implementación IA al análisis de datos obtenidos de sensores biométricos en monitores de AF, portables de consumo público.

2.2.1 Impacto del Comportamiento Sedentario

El CS es un factor de riesgo importante para una serie de Enfermedades No Transmisibles (ENT), entre las que se incluyen obesidad, enfermedades del corazón, diabetes tipo 2, accidentes cerebrovasculares, algunos tipos de cáncer, depresión y falta de sueño. Actualmente, el CS se contempla como parte de una Sindemia Global, lo que lo vuelve difícil de comprender. Existe un nexo entre los Riesgos Dietéticos, el alto Índice de Masa Corporal (IMC), y los Ambientes Obeso-Génicos con el estudio del CS, ya que estos factores combinados aumentan el riesgo de padecer ENT y están directamente relacionados con la Salud, Bienestar y CV de los individuos (**Swinburn2019Syndemic**).

La investigación realizada de **Murray2020GBD<empty citation>**, concluyó que ningún estado perteneciente a la OMS ha tenido una disminución significativa en la proporción de la población con IMC alto, entre 1990 y 2019 o en la última década. Dada la creciente prevalencia del CS en la sociedad moderna y su impacto adverso en la salud, la OMS desde el 2004 en la Asamblea



Mundial de la salud emitió la “Estrategia Mundial de la OMS sobre Dieta, AF y Salud (DPAS por sus siglas en inglés)”, en donde se definía un plan de acción para implementar directrices sobre AF para la salud (**Meusel2006Framework**).

A pesar del lanzamiento de la DPAS, ningún país ha revertido significativamente la tendencia al aumento de las tasas de obesidad o diabetes, **Guthold2020** **<empty citation>** mencionan que la mayoría de los niños y adolescentes, no cumplen con los requerimientos mínimos de AF y que el CS en menores aumentó significativamente del 2001 al 2016. En los hallazgos de la OMS a través de la Encuesta sobre la capacidad de los países para afrontar las enfermedades no transmisibles (2021), se menciona que casi un tercio de los adultos tampoco alcanzan los niveles recomendados de AF. En México el CS en adultos es mayor llegando al 40 % según la Encuesta Nacional de Salud y Nutrición 2022 (**Campos2023ObesityMexico**). Asimismo, se estima que, en 2019, las ENT provocaron cinco millones de muertes a nivel global y en la Región de las Américas, las ENT representan casi cuatro de cada cinco muertes anuales (**StrategicPlanPAHO2020**). Además, en 2022, aproximadamente 2500 millones de adultos de 18 o más años tenían sobrepeso, igualmente 390 millones de menores padecían de sobrepeso (**WHO2022InformeActividad**).

Como resultado, muchos países de ingresos bajos y medianos se enfrentan ahora a una carga cada vez mayor de riesgos modernos para la salud a medida que aumenta la esperanza de vida y las principales causas de muerte y discapacidad se desplazan hacia las ENT. Los costos actuales del CS se estiman en alrededor de \$300 000 millones de dólares al año a nivel mundial, esto debido a los costos directos de la atención médica y la pérdida de productividad económica (**Okunogbe2021Economic**). Siendo la responsabilidad por la exposición a conductas sedentarias no solo de los individuos, sino también de los gobiernos y los ministerios de salud. Por tanto, la prevención y tratamiento se debe extender a toda la población no solo a los grupos que están clínicamente en alto riesgo de padecer una ENT (**WHO2009GlobalRisks**).

La consecución a esta problemática consiste en alcanzar la meta 3.4 de los ODS, la cual busca reducir en un tercio la mortalidad prematura por ENT para 2030. Por consiguiente, se propone un plan de aceleración que se ha desarrollado en consonancia con las recomendaciones dirigidas a fortalecer y vigilar la reducción del CS. Su plazo coincide con la hoja de ruta 2023–2030 relativa a la ejecución del plan de acción mundial para la prevención y el control de las ENT 2013–2030. Aunado a esto en el “Informe sobre la situación mundial de la AF” mencionan que en la aplicación del el “Plan de acción mundial sobre AF 2018–2030 (GAPPA por sus siglas en inglés)” (**WHO2022InformeActividad**) la implementación ha sido lenta y desigual. Además, se ofrece una primera visión del impacto de la COVID-19, poniendo de manifiesto la importancia de la AF regular para la salud mental y física.

Recalcando que mientras el mundo sigue respondiendo a la pandemia de COVID-19 y

recuperándose de ella, es necesario implementar medidas encaminadas a prevenir conductas sedentarias, que se detallan en las siguientes secciones.

2.2.2 Instrumentos de evaluación del Comportamiento Sedentario

Con relación a los sistemas de vigilancia y los instrumentos de evaluación es importante mencionar que hasta hace poco los principales métodos para medir la AF y los comportamientos sedentarios era a través de la auto notificación, la cual utiliza materiales de evaluación como el Cuestionario Mundial sobre AF (Global Physical Activity Questionnaire, GPAQ), la Encuesta Mundial de Salud a Escolares (Global Student Health Survey, GSHS) y el cuestionario Health Behaviour in School-aged Children (HBSC) (**CDC_GSHS; WHO2020**). Estos métodos tienen ventajas ampliamente demostradas. Sin embargo, el informe sobre la situación mundial de la AF del 2022 también reconoce una importante laguna en el seguimiento del GAPPa. Entre ellas destaca la ausencia de vigilancia de la AF entre las personas con discapacidad, así como entre los niños menores de nueve años (**WHO2022InformeActividad**).

Para poner en contexto en México Ensanut 2022, que es una encuesta probabilística con diseño de muestra polietápico y estratificado, con representatividad nacional y de ocho regiones en México. Para evaluar los niveles de AF en niños de 10–14 años, se utilizó la pregunta “En los últimos 7 días, ¿Cuántos días estuviste activo durante al menos 60 minutos al día?” del cuestionario (HBSC). Y aunque este instrumento de evaluación es ampliamente utilizado en México y en el mundo, posee limitaciones como la tendencia al sesgo de notificación (reportar de manera inexacta o incompleta la información) y el error de medición (utilizar instrumentos no adecuados o realizar mal las mediciones) (**Romero2022**).

Dado el reconocimiento de estas deficiencias en los sistemas de vigilancia, la OMS propone el análisis de las potenciales ventajas que se tienen de recopilar datos de dispositivos portátiles y móviles. Esto busca apoyar el seguimiento de la AF con datos coherentes y congruentes que garanticen la armonía de los datos en su uso y eficiencia. Tomando en cuenta eso, menciona que se necesita un consenso mundial sobre las herramientas técnicas, los protocolos y los obstáculos financieros, para su uso en los sistemas de seguimiento nacionales y mundiales.

2.2.3 Cómo afecta el CS en la CVRS

Fomentar estilos de vida activos y saludables permite a la población una mejor percepción de CVRS. De acuerdo con la investigación realizada por Chaves y cols., la capacidad aeróbica y la CVRS son condiciones asociadas a un declive que progresa con la edad y a estilos de vida sedentarios. En su investigación determinaron que la capacidad aeróbica tiende a disminuir a un ritmo entre

5 a 15 % por década luego que un individuo pasa de los 30 años de edad en personas sedentarias. En contraparte, las personas físicamente activas pueden retener una reserva suficiente de aptitud aeróbica para mantener la capacidad funcional durante su edad adulta (**Chaves2017Asociacion**).

2.2.4 Uso de sensores para el análisis del Comportamiento Sedentario

Los monitores de AF más recientes, implementan el uso de sensores, los cuales son un dispositivo de entrada que mide una magnitud o un parámetro físico para proveer una salida que pueda ser manipulada por un sistema (**Alvarez2020EnergyExpenditure**). Los sensores se clasifican de diversas maneras, pero las más comunes son por tipo de variable a medir o por el principio de transducción. Estos son componentes capaces de obtener, medidas fisiológicas, posición, orientación, velocidad etc. de cualquier dispositivo donde sea utilizado.

Acelerómetros

Dada la creciente preocupación por la salud y el comportamiento sedentario, se han hecho esfuerzos por medir de forma cuantitativa, las predicciones de gasto energético expresado en MET. Intentando categorizar la intensidad de la AF mediante el uso de acelerómetros. En un estudio realizado por **Rothney2008Validity**<empty citation> se buscó evaluar la exactitud de tres tipos de acelerómetros, ActiGraph, Actical y RT3, donde se implementó un método, que contemplo el uso de una cámara de calorimetría indirecta para validar su precisión. Llegando a la conclusión de que los monitores portátiles basados en acelerometría son un medio factible y objetivo para detectar patrones de comportamiento sedentario.

Sin embargo, los autores reconocen que hay algunas limitaciones en el estudio, como la dificultad para distinguir entre diferentes niveles de actividad. Los acelerómetros pueden tener dificultades para diferenciar entre comportamientos sedentarios muy baja intensidad, como estar sentado sin movimiento, y otros niveles de AF ligera. Esto puede llevar a cierta imprecisión en la clasificación de los periodos de actividad sedentaria.

De la misma forma la sensibilidad a la posición del dispositivo, la colocación del acelerómetro en el cuerpo puede afectar la precisión de las mediciones. Por ejemplo, algunos dispositivos podrían no capturar adecuadamente ciertos movimientos o actividades si no se usan en la posición correcta. Además, las limitaciones en la detección de comportamientos específicos, los acelerómetros pueden tener problemas para detectar ciertos comportamientos sedentarios específicos, como estar de pie sin movimiento o realizar movimientos muy sutiles, sobre todo cuando se utilizan en la muñeca, lo que puede afectar la precisión de las mediciones.

En este contexto, **Henriksen2018**<empty citation> indica que la precisión de un dispo-

sitivo portátil de seguimiento de AF en comparación con el IPAQ subestima significativamente la cantidad de AF informada por los participantes. Sus conclusiones respecto a las limitaciones fueron similares a las del artículo de **Rothney2008Validity**<empty citation>. Sin embargo, recomiendan que los médicos y los profesionales de la salud pública sigan utilizando los cuestionarios para medir el CS a la par de los dispositivos portátiles, dado que estos pueden ser útiles para algunos propósitos, como monitorear la AF en el día a día.

2.2.5 Monitores de Actividad Física Portables de consumo público

Los dispositivos que se llevan “puestos” (wearables) aprovechan los avances en la tecnología para monitorizar los signos vitales y otros parámetros biométricos a través de teléfonos inteligentes o dispositivos que se adosan al cuerpo como un reloj, bandas o ropa. Bhuyan y cols., sugieren que estos dispositivos pueden monitorear e integrar diferentes parámetros importantes para el tratamiento de comorbilidades en pacientes con ENT (**Bhuyan2016Mobile**). Es así que los esfuerzos de la comunidad de investigación biomédica por la relevancia de los múltiples hallazgos en torno a la medición de la AF, en la actualidad existen cientos de monitores wearables para el consumo público. Los cuales incorporan diferentes sensores, que arrojan múltiples variables fisiológicas, adoptando su uso como una estrategia para promover un estilo de vida activo.

Tal ha sido el impacto de los monitores wearables que las estadísticas proporcionadas en market.us por Scoop en 2023, reportaron que en el mercado mundial de dispositivos de fitness y bienestar digital se generó 19.3 mil millones de dólares en ingresos en 2022. Además, se espera que este mercado crezca a una tasa compuesta anual del 19.1 % entre 2023 y 2030, alcanzando un valor de 182.9 mil millones de dólares. Además, se espera que la penetración de usuarios de estos dispositivos aumente del 9.52 % en 2023 al 10.36 % en 2028 (**Tajammul2023Statistics**).

Validación de los Monitores de Actividad Física Portables

En el artículo de Wright y cols., exploraron el potencial de múltiples dispositivos wearables o monitores de AF portátiles. Estos dispositivos se basan principalmente en sensores de acelerometría para contar pasos y estimar el gasto energético. Si bien se encontró que muchos de estos monitores tienen precisiones similares a los de grado de investigación para contar pasos, existen limitaciones inherentes a la tecnología de acelerometría para estimar con precisión el gasto energético, especialmente en actividades de vida libre que implican movimientos complejos y no cíclicos (**Wright2017ConsumerMonitors**).

Por otro lado, el estudio de Dinesh y cols., se centraron específicamente en validar las estimaciones de gasto energético de los monitores ActiGraph GT1M y GT3X, ampliamente uti-

lizados en investigación. Estos dispositivos también se basan en acelerometría, pero los autores encontraron que el factor determinante en la precisión de las estimaciones era la versión del firmware utilizado, que incluye los algoritmos de procesamiento de la señal de los acelerómetros (**Dinesh2014ActiGraph**).

Los hallazgos de ambos estudios se complementan al resaltar las fortalezas y limitaciones de los monitores de AF basados en acelerometría. Los estudios de Wright, Dinesh y cols., demostraron su utilidad para contar pasos, y expusieron las variaciones en las estimaciones de gasto energético dependiendo del firmware y las condiciones en contextos de vida libre (**Wright2017ConsumerMonitors; Dinesh2014ActiGraph**).

Lo que sugiere la necesidad de estandarización y validación constante por parte de los fabricantes. Además, los resultados ponen de manifiesto la necesidad de explorar tecnologías alternativas o complementarias a la acelerometría para superar sus limitaciones en la evaluación del gasto energético en contextos de vida libre (**Dinesh2014ActiGraph**). Enfoques prometedores incluyen el uso de sensores de frecuencia cardíaca, temperatura corporal, conductancia eléctrica de la piel, entre otros, en combinación con algoritmos de ML para reconocer patrones de actividad complejos.

Wright, Dinesh y cols., comparten la idea de que los algoritmos utilizados en los monitores de AF de los consumidores para determinar los pasos dados, la distancia recorrida y el gasto de energía generalmente no se comparten con los investigadores. Incluso Dinesh y cols., mencionan que los monitores pueden estar utilizando enfoques de reconocimiento de patrones más robustos que los empleados en su estudio (**Wright2017ConsumerMonitors; Dinesh2014ActiGraph**).

Por su parte Wright y cols., ponen en evidencia que las empresas no solo pueden cambiar sus algoritmos sin previo aviso, sino que es posible que no revelen este hecho después. Por consiguiente, es posible que los investigadores ni siquiera sepan sobre esta posible discontinuidad en sus datos a lo largo del tiempo. Además de las actualizaciones de firmware relativamente frecuentes que pueden cambiar los algoritmos, las empresas actualizan continuamente sus dispositivos, lo que hace que los modelos más antiguos queden obsoletos. Dejando a los investigadores en duda de hasta qué punto los estudios previos de validez de un dispositivo se aplicarían a sus sucesores.

Por tanto, no es razonable esperar que los monitores creados para consumidor coincidan con la utilidad de los monitores desarrollados para la investigación porque se desarrollan para diferentes propósitos y con diferentes restricciones. Por ejemplo, facilidad de uso y mantener bajos los costos. Dejando entre dicho que los investigadores que utilicen monitores de AF de consumo deberán establecer la validez de estas herramientas de investigación, incluida la calibración de unidades y valores, así como la validez concurrente y predictiva de estos dispositivos.

Aunque no son los únicos desafíos, el artículo de Redenius y cols., menciona que los monitores tienen una duración limitada de la batería, por lo cual es posible que sea necesario recargarlos cuando se está realizando una actividad significativa. También, estos monitores dependen de la adherencia de los participantes al protocolo en condiciones de vida libre (**Redenius2019Fitbit**). Por lo tanto, es importante mencionar que, aunque su investigación solo buscó la validez del Fitbit Flex, entre sus resultados encontraron que el dispositivo sobreestimó la AF de moderada a vigorosa.

Desafíos especiales para el uso monitores de actividad física de consumo

El equipo conformado por Bhuyan y cols., apoyan el uso y empoderamiento, de la implementación de las biotecnologías, ya que estas hacen que la gestión y la prestación de asistencia sanitaria sean más eficientes, seguras y económica (**Bhuyan2016Mobile**). Más advierten, que una arista que rodea el uso de dispositivos “wearables” es que, se requiere un marco regulatorio para las políticas y prácticas de privacidad para este tipo de datos. Otra preocupación es que en una región con altos niveles de desigualdad se debe poner especial atención en que las nuevas tecnologías no amplíen las brechas existentes ni generen nuevas desigualdades el posible sesgo en el grupo de participantes, por lo que las disparidades socioeconómicas pueden afectar el reclutamiento de participantes a estudios debido a que no todos los individuos poseen un dispositivo “wearable”.

Para la Comisión Económica para América Latina y el Caribe (CEPAL) (**Martinez2020Revolucion**); Si no se aborda este sesgo de selección, un sector de nuestra población no estaría representado, y los resultados podrían no ser generalizables a toda la población. Dado que las personas de más bajos ingresos tienen menor capacidad para acceder a un conjunto variado de dispositivos, servicios, aplicaciones y contenidos que aquellos con ingresos más altos, y les es más difícil adquirir tecnología digital de punta, actualizar su capacidad para manipular las novedades tecnológicas y apropiarse de sus beneficios de manera oportuna.

Lo cual enmarca un problema para democratizar las tecnologías digitales que pueden contribuir a resolver problemas asociados con la promoción del bienestar físico y mental, el fomento del autocuidado a lo largo de la vida, la prevención del deterioro de las condiciones de salud ya existentes, la generación de alertas epidemiológicas, la gestión más oportuna de los servicios de salud, el manejo más efectivo de los recursos, entre otros.

Oportunidades para el uso monitores de actividad física de consumo

Como se abordó en puntos anteriores, la fuente predominante de incertidumbre en el análisis del comportamiento sedentario. Depende de las estimaciones del gasto energético que han

demostrado ser difícil de captar mediante instrumentos subjetivos como los cuestionarios. Por tal motivo White y cols., concluyeron que los Bio-sensores, tienen el potencial de proporcionar una solución relativamente barata y fiable a este problema, Dejando en claro que es posible solo si se pueden diseñar modelos de inferencia válidos para estimar el gasto energético de la actividad a partir de las mediciones que se registran (**White2019**).

Otro estudio realizado por Strain y cols., uso un enfoque de armonización de redes para mapear la aceleración de la muñeca dominante de los datos obtenidos de 96,476 participantes del Biobanco del Reino Unido, ellos demostraron que la AF registrada por dispositivos portátiles representa una herramienta valiosa en la prevención del riesgo de padecer enfermedades crónico-degenerativas no transmisibles (**Strain2020**). Además, mencionan que la utilización de datos objetivos y cuantificables proporciona una perspectiva más precisa sobre los hábitos de AF de los individuos, lo que facilita brindar una base sólida para el diseño de estrategias enfocadas a la intervención y promoción de la salud.

2.2.6 El enfoque de la Inteligencia Artificial en el Análisis de Datos

En relación con la oportunidad de explotar los datos de los monitores portátiles de consumo público, destaca la importancia de la IA como una disciplina emergente para descubrir patrones, respaldar la toma de decisiones clínicas y gestionar eficientemente los recursos sanitarios (**Yoo2012DataMining**). Esta disciplina se presenta como una herramienta integral para abordar los complejos desafíos en la atención médica moderna, para diseñar estrategias efectivas de promoción de la salud. Por ejemplo, brindando retroalimentación valiosa para diseñar intervenciones personalizadas y fomentar estilos de vida más activos. Este enfoque no solo ofrece la oportunidad de recopilar datos detallados sobre los patrones de actividad, sino que también puede allanar el camino, para futuros avances donde convergen la tecnología y la medicina.

En la era actual, donde la tecnología de Bio-sensores ha avanzado significativamente, se ha desbloqueado el potencial de observar las señales fisiológicas de los pacientes de manera más detallada y se ha brindado la oportunidad de mejorar la atención médica de manera proactiva, no obstante, la verdadera transformación en la atención médica va más allá de la simple recopilación de datos. Paganelli y cols., mencionan que en la última década se han implementado múltiples investigaciones aprovechar al máximo esta riqueza de información, y que es imperativo convertir estos datos en conocimientos procesables (**Paganelli2022RealTime**).

Aquí es donde entra en juego el análisis de datos con IA. Ya que según Paganelli y cols., no está claro qué técnicas pueden adaptarse mejor a cada contexto. La capacidad de analizar grandes conjuntos de datos de manera eficiente y descubrir patrones ocultos es esencial para traducir los datos de los sensores en información significativa. Por tanto, en su objeto de estudio detalla cada

dominio de aplicación, las tareas de análisis de datos, los sensores utilizados, las propiedades, los algoritmos, las fuentes de datos y los resultados obtenidos de los estudios analizados. A menudo, los resultados del análisis no se relacionan directamente solo con las condiciones de salud, sino también con otros temas relevantes, como el ahorro de recursos, el tiempo de respuesta, el monitoreo constante y la aplicabilidad de soluciones en diferentes contextos.

En el contexto del análisis de datos, es relevante aclarar que la IA es un campo de la informática que se centra en la creación de sistemas que se pueden utilizar para una amplia gama de tareas, las cuales incluyen el reconocimiento de patrones, la toma de decisiones y la resolución de problemas. Más existen otros términos que son subdisciplinas de la IA como por ejemplo los que se describen en la ilustración 3.

EL Aprendizaje Automático (ML) es una subdisciplina de la IA que se centra en el desarrollo de algoritmos que pueden aprender de los datos. Los algoritmos de ML pueden aprender sin ser programados explícitamente. En cambio, aprenden a partir de datos de entrenamiento. Igualmente, los algoritmos de lógica difusa (FL). Son una subdisciplina del ML que imita el razonamiento humano para tratar con información imprecisa o incompleta que, a diferencia de la lógica clásica, la FL solo permite valores verdaderos o falsos, la FL permite representar grados de verdad intermedios, como “muy cierto”, “algo cierto” o “poco cierto”. Esto la hace especialmente útil para modelar sistemas complejos y dinámicos donde la información no siempre es precisa o definitiva (**Kaur2022**).

Implementar el uso de la IA en el contexto de la biomedicina, según Amit y cols., para el reconocimiento de la AF y la salud requiere de técnicas de IA que desempeñan funciones cruciales en la interpretación y caracterización de la actividad mediante la extracción automática de características, con menos esfuerzo que un humano. Sin embargo, para implementar un modelo de análisis de datos con IA se requiere cierta complejidad, la cual se puede resumir en las siguientes secciones. Preprocesamiento de los datos, extracción y selección de características, plan de modelado y aprendizaje (**Amit2001Computational**).

2.2.7 Fundamento filosófico del enfoque difuso

El modelo de inferencia difusa se sustenta en dos principios clave propuestos por Lotfi Zadeh: la granularidad cognitiva y la ley de incompatibilidad. El principio de granularidad cognitiva reconoce que los seres humanos razonamos usando categorías lingüísticas amplias (granulares) en lugar de valores numéricos exactos. Es decir, conceptos como “nivel de actividad bajo” o “calidad de vida alta” representan gránulos de información (etiquetas lingüísticas) que aglomeran muchos estados posibles bajo una misma denominación.

Esto permite manejar la vaguedad y la imprecisión inherentes a las percepciones humanas, lo que hace que el sistema sea cognitivamente interpretable. En la teoría difusa, a cada concepto lingüístico se le asocia un conjunto difuso y una función de pertenencia que indica en qué grado un valor numérico pertenece a dicho concepto (**Ross2010; Gupta2011Tribute**). Gracias a esta granularidad, es posible describir entradas, salidas y reglas en lenguaje natural de forma simple, lo que incorpora el conocimiento experto de forma directa (**Gupta2011Tribute**).

Por su parte, la ley de incompatibilidad de Zadeh establece una limitación fundamental en sistemas complejos: “cuando la complejidad aumenta, las sentencias precisas pierden significado y las sentencias significativas pierden precisión” (**Levitz1979Logic**). En otras palabras, mientras más complejo es un fenómeno, menos útiles resultan las descripciones numéricas exactas, y se hace necesario emplear descripciones aproximadas (borrosas) para conservar significado.

Este principio filosófico justifica el uso de lógica difusa en la evaluación del comportamiento sedentario y su efecto en la calidad de vida: dado que estos conceptos involucran múltiples factores humanos, es preferible modelarlos con categorías flexibles (“sedentarismo alto”, “actividad moderada”, etc.) en lugar de umbrales rígidos. La lógica difusa explota esta tolerancia a la imprecisión para lograr soluciones robustas en problemas complejos, privilegiando la significancia semántica por encima de la precisión absoluta. En suma, apoyándose en la granularidad cognitiva y la ley de incompatibilidad, el sistema difuso puede manejar la incertidumbre de las evaluaciones de estilo de vida de manera similar al razonamiento humano, obteniendo inferencias significativas a partir de datos imprecisos.

2.2.8 La Lógica Difusa en la Salud Digital y el Monitoreo Biométrico

Inicialmente, las aplicaciones de la lógica difusa se concentraron en la ingeniería de control a partir de la década de 1970 (**Strefezza2009Logica**). Sin embargo, su capacidad para modelar sistemas complejos de manera más sencilla, junto con sus fundamentos matemáticos precisos, propició su expansión a diversas áreas como la medicina. En la actualidad, los avances han llevado a una integración creciente de la lógica difusa con otras técnicas de inteligencia artificial (IA) y aprendizaje automático (ML), dando lugar a sistemas híbridos, como los sistemas neuro-difusos (**Ahmadi2018Diseases**). Esta fusión mejora la capacidad de procesar y analizar grandes volúmenes de datos fisiológicos en tiempo real, facilitando la identificación de patrones sutiles como lo podemos apreciar en la Table 2.1.

Este cuadro es fundamental para comprender la amplitud y profundidad de las aplicaciones de la lógica difusa en entornos clínicos. Al organizar sistemáticamente la información, permite una rápida visión general de los avances, facilita la comparación de diferentes enfoques metodológicos y sus idoneidades para diversos problemas clínicos, y destaca los resultados tangibles y las mejoras

Tabla 2.1: Cuadro Comparativo de Artículos sobre Lógica Difusa en Aplicaciones Sanitarias

Técnicas de Lógica Difusa	Área de Aplicación	Tipos de Datos	Hallazgos Clave	Año
Sistema basado en lógica difusa en marco de IA, teoría de conjuntos difusos	Diagnóstico de Patologías (Informes de Laboratorio)	Parámetros cuantitativos de laboratorio (RDW, MCV)	Precisión impresionante, 83 % de probabilidad de identificar “normal”, mejora en precisión, recall y F-measure con más diagnósticos.	2024
Mapas Cognitivos Difusos (FCM), reglas difusas, variables lingüísticas	Diagnóstico de COVID-19	Síntomas clínicos (fiebre, tos, disnea, GI), historial de contacto	Herramienta viable de apoyo a la decisión, probabilidad de diagnóstico (ej. 72 % para COVID-19).	2020
Lógica difusa para pertenencia difusa, análisis multicriterio	Planificación de Comidas Personalizadas	Datos nutricionales, preferencias alimentarias, restricciones de salud	Planes de comidas flexibles y optimizados, considera múltiples factores (costo, cocina, tiempo).	2023
Lógica de primer orden con semántica difusa, algoritmo de razonamiento espacial	Reconocimiento de Nervios en Imágenes Médicas	Imágenes de RM anatómicas T2 y de difusión	Permite la planificación quirúrgica precisa, visualización de nervios en gemelo digital 3D, explicabilidad directa.	2025
Sistema experto difuso, fuzzificación, mecanismo de inferencia, defuzzificación	Control Metabólico en Diabetes Mellitus Tipo 2	Edad, IMC, tabaquismo, estrés, ejercicio, tratamiento farmacológico, dieta	Asiste a médicos en la evaluación del control metabólico.	2018

de rendimiento logradas por estos sistemas.

La lógica difusa es una herramienta que se utiliza cada vez más en sistemas “IoT” para la reducción y el análisis de datos, así como para el diagnóstico inteligente de enfermedades, al gestionar las incertidumbres y proporcionar enfoques robustos. El concepto de “sistemas difusos con big data y computación en la nube” es también un tema destacado en foros como FUZZ-IEEE 2025. La investigación actual muestra que la lógica difusa rara vez se utiliza de forma aislada en las aplicaciones de vanguardia en el sector sanitario (**Alam2022Disease**). En cambio, se integra cada vez más con otros paradigmas de IA, como las redes neuronales, el aprendizaje automático y el IoT. Esta hibridación responde a la necesidad de combinar las fortalezas de la lógica difusa (manejo de la incertidumbre, interpretabilidad) con las capacidades de aprendizaje y escalabilidad de otros métodos de IA. Esta tendencia indica que los problemas complejos de atención médica requieren soluciones de IA multifacéticas, donde cada componente aporta su ventaja única, lo que conduce a sistemas más robustos, adaptativos e inteligentes.

2.2.9 Clustering No Supervisado para Establecimiento de Ground Truth

Clustering como Herramienta de Descubrimiento de Patrones

El aprendizaje automático no supervisado, específicamente el clustering (agrupamiento), es una técnica de descubrimiento de patrones que particiona un conjunto de datos en grupos homogéneos (clústeres) sin requerir etiquetas predefinidas (**Yoo2012DataMining**). En el contexto de wearables y análisis de actividad física, el clustering se ha aplicado principalmente como herramienta de ingeniería de características: los clústeres son el resultado final (descubrimiento de fenotipos) o una característica intermedia para otro modelo, no se utilizan para generar etiquetas de *ground truth* que parametricen un clasificador interpretable.

Línea de Base: Umbrales Heurísticos para Sedentarismo

El estándar de facto actual en clasificación de sedentarismo se basa en umbrales heurísticos fijos. Razjouyan et al. (**Razjouyan2018Frailty**) establecen el enfoque más utilizado en evaluación de fragilidad mediante wearables: clasificación mediante Desviación Absoluta Media (MAD) de aceleración con umbrales predefinidos (Sedentario: $MAD < 1,5$ MET; Actividad ligera: $1,5 \leq MAD < 3,0$ MET; Actividad moderada-vigorosa: $MAD \geq 3,0$ MET).

Este enfoque presenta limitaciones: (1) los umbrales (1.5, 3.0 MET) son fijos y no se ajustan por diferencias inter-individuales en capacidad aeróbica, (2) la MAD es un estimador indirecto de gasto energético con validez variable entre dispositivos, y (3) no captura la estructura multivariada de datos de wearables modernos (frecuencia cardíaca + aceleración + contexto).

Vacío Metodológico: Clustering + Sistema de Inferencia Difusa

Una revisión exhaustiva de la literatura Q1/Q2 (2018-2025) en la intersección de clustering no supervisado, sistemas de inferencia difusa y clasificación de comportamiento sedentario mediante wearables revela un **vacío metodológico crítico**: la tubería *Clustering No Supervisado* → *Sistema de Inferencia Difusa* no constituye una práctica estándar establecida.

Único precedente identificado: Gonçalves et al. (2021) implementan K-Means ($k = 2$) seguido de un FIS Mamdani para clasificar estabilidad humana a partir de datos cinemáticos, en un capítulo de actas de congreso Springer. La secuencia metodológica sugiere que K-Means estableció las etiquetas binarias (Inestable/Estable) que parametrizaron las reglas del FIS Mamdani.

Divergencia conceptual: La “lógica difusa” en reconocimiento de actividad humana (HAR) sigue dos caminos divergentes: (1) *Fuzzy Clustering* (Fuzzy C-Means) como algoritmo de agrupamiento que compite con K-Means, y (2) *Fuzzy Inference Systems* (Mamdani/Takagi-Sugeno) como clasificador interpretable. La literatura no muestra tendencia a *combinar* estos paradigmas en secuencia (K-Means) → (FIS), dejando un vacío que este proyecto propone llenar.

2.2.10 Validación Leave-One-User-Out en Wearables

LOUO: Estándar para Generalización Inter-Sujeto

La validación cruzada tradicional (k-fold) es inapropiada para datos longitudinales de wearables debido a dos problemas críticos: (1) **temporal leakage** (mezclar observaciones correlacionadas del mismo usuario permite al modelo “ver el futuro”), y (2) **identity leakage** (modelos aprenden características idiosincráticas de individuos en lugar de patrones generales).

La validación *Leave-One-User-Out* (LOUO), también conocida como *Leave-One-Subject-Out* (LOSO), es reconocida como el **estándar metodológico** para evaluar generalización inter-sujeto en wearables. En LOUO, el modelo se entrena con datos de $N - 1$ usuarios y se valida con el usuario restante, iterando hasta probar con todos los N usuarios. Esta estrategia simula el despliegue real del sistema en nuevos usuarios, evitando sobreajuste a individuos específicos.

LOUO en Cohortes Pequeñas ($N < 20$)

Estudios de alto impacto demuestran la viabilidad de LOUO en cohortes pequeñas con datos longitudinales ricos:

- **Ricotti et al. (2023, Nature Medicine):** $N = 21$ pacientes con distrofia muscular de Duchenne, seguimiento de 12 meses, 17 sensores IMU de cuerpo completo. LOSO + validación

externa ($N = 44$), $R^2 \approx 0,90$ en predicción de trayectoria motora. Conclusión: “*La inteligencia artificial podría reducir el tamaño de cohorte necesario*” al aprovechar mediciones densas longitudinales.

- **Crozat et al. (2025, Sensors):** $N = 7$ pacientes neurológicos, sesión de 30 min con 7 acelerómetros. LOSO: $86.4\% \pm 5\%$ de detección de pasos. Argumento: “*LOSO está especialmente indicado en datos de sensores corporales debido a la alta variabilidad entre individuos.*”
- **Kaveh et al. (2024, Nature Communications):** $N = 9$ operadores, 35h de EEG intraauricular. LOUO: 93.3 % accuracy en usuarios no vistos.
- **Lu et al. (2018, Sensors):** $N = 11$ adultos, protocolo de 3h. LOSO para estimación de VO_2 : $MAE=1.65$ mL/kg/min, $R^2 = 0,92$.

Consenso emergente: Con $N \geq 7$, datos longitudinales ricos y validación LOUO rigurosa, es factible desarrollar modelos con métricas aceptables ($F1 > 0,85$, $R^2 > 0,90$) que generalicen a nuevos usuarios.

2.3 Investigaciones Previas Relacionadas

La clasificación del comportamiento sedentario y la actividad física mediante dispositivos wearables ha experimentado un crecimiento exponencial en la última década, impulsado por la disponibilidad de sensores de consumo de bajo costo y el avance de las técnicas de inteligencia artificial. Los estudios recientes abordan este desafío desde múltiples perspectivas metodológicas, cada una con ventajas y limitaciones específicas en términos de precisión, interpretabilidad y generalización.

2.3.1 Enfoques de Deep Learning y Redes Neuronales

Los enfoques de aprendizaje profundo han demostrado capacidades sobresalientes en el reconocimiento de patrones complejos en datos de sensores wearables. **Khan2024Wearable** desarrollaron un sistema de reconocimiento de actividad física con redes neuronales convolucionales (CNNs) y redes LSTM para procesar datos de sensores inerciales, y lograron alta precisión en la clasificación de movimientos. Sin embargo, estos modelos enfrentan dos limitaciones críticas: requieren conjuntos de datos masivos para entrenamiento y operan como “cajas negras”, dificultando la interpretación clínica de sus decisiones **Bienefeld2023XAI**.

Un hallazgo particularmente relevante es el reportado por **Bassani2025DLHAR**, quienes compararon el rendimiento de algoritmos de deep learning utilizando una división 70/30 frente a

validación Leave-One-Subject-Out (LOSO). Los resultados mostraron una caída significativa del rendimiento: accuracy de 95.7 % en la división 70/30 versus 90.3 % en LOSO, lo que evidencia que la generalización robusta a nuevos usuarios requiere protocolos de validación más estrictos. Esta observación es fundamental para evaluar la aplicabilidad real de sistemas de clasificación en escenarios clínicos.

2.3.2 *Machine Learning Clásico y Validación Cruzada*

Los algoritmos de aprendizaje automático clásico, como Random Forest y Support Vector Machines, han sido ampliamente utilizados para la clasificación de actividades debido a su balance entre precisión y eficiencia computacional. **Fuller2021Predicting** aplicaron Random Forest para clasificar posturas (lying, sitting, walking, running) con datos de Apple Watch y Fitbit, y alcanzaron una precisión superior al 90 % mediante validación Leave-One-Out Cross-Validation (LOOCV) en una cohorte de 33 participantes. Este estudio validó el modelo Bring-Your-Own-Device (BYOD), lo que demuestra la factibilidad de utilizar dispositivos de consumo en investigación clínica.

La importancia de la validación cruzada estricta ha sido enfatizada por **Rehman2024LOSO**, quienes compararon el rendimiento de Random Forest utilizando LOSO versus k-fold cross-validation. Sus resultados mostraron que LOSO produjo un accuracy del 76 %, significativamente inferior al 89 % obtenido con k-fold. Los autores atribuyen esta diferencia al *data leakage* (fuga de datos) presente en k-fold cuando se aplica a datos de sensores wearables. Esta evidencia justifica la adopción de LOUO (Leave-One-User-Out) como estándar metodológico para evaluar la generalización inter-usuario.

El estudio de **Mathew2024LOSO** refuerza esta conclusión al analizar el uso funcional de la mano en niños con parálisis cerebral unilateral mediante acelerómetros de muñeca. Los autores reportaron un F1-Score de 0.896 con modelos personalizados por sujeto, que se redujo drásticamente a 0.584 al aplicar validación LOSO. Este fenómeno de sobreajuste es particularmente pronunciado en cohortes pequeñas ($N = 22$), lo que refleja la dificultad de capturar la variabilidad inter-individual con tamaños de muestra limitados.

2.3.3 *Lógica Difusa y Sistemas de Inferencia Interpretables*

La lógica difusa emerge como una alternativa metodológica que prioriza la interpretabilidad sobre la precisión bruta, característica especialmente valiosa en aplicaciones biomédicas donde la confianza clínica depende de la transparencia del proceso de decisión. **MarashiHosseini2023Dietary** desarrollaron un sistema de decisión dietética para pacientes con múltiples condiciones crónicas mediante un sistema de inferencia difusa tipo Mamdani con 1144 reglas lingüísticas, y alcan-

zaron una precisión del 97 % al compararse con las recomendaciones de nutricionistas expertos ($N = 100$). Este estudio demuestra que la lógica difusa puede igualar la precisión de enfoques estadísticos complejos mientras mantiene una estructura de conocimiento explícita y modificable.

La interpretabilidad total de los sistemas difusos ha sido destacada por **Capitoli2025FuzzyXAI**, quienes proponen un modelo de lógica difusa probabilística para diagnóstico clínico que permite a los médicos “generar, controlar y verificar todo el procedimiento de diagnóstico”. Este enfoque posiciona a la lógica difusa no solo como un clasificador, sino como una herramienta de Inteligencia Artificial Explicable (XAI) que genera confianza clínica mediante la exposición completa de su razonamiento.

Un precedente metodológico particularmente relevante para la presente investigación es el trabajo de **Goncalves2021**, quienes desarrollaron un sistema de reconocimiento de actividad humana combinando clustering K-Means ($k = 2$) con un sistema de inferencia difusa Mamdani. Este es el **único precedente identificado** en la literatura de un enfoque híbrido que utiliza clustering no supervisado para establecer una ground truth operativa, seguido de un sistema difuso supervisado. Este diseño metodológico resuelve el desafío de la ausencia de etiquetas gold-standard en datos de vida libre, al tiempo que preserva la interpretabilidad del modelo final.

2.3.4 Métodos Estadísticos y Consensos Metodológicos

Más allá de los enfoques de machine learning, se han desarrollado métodos estadísticos avanzados específicamente diseñados para la detección de patrones temporales en datos de wearables. **Salim2024STEPHEN** propusieron un Hidden Semi-Markov Model para la detección de tiempo sedentario y *sedentary bouts* (períodos continuos de sedentarismo) utilizando wearables de muñeca de consumo. Este enfoque estadístico captura la estructura temporal de las transiciones entre estados de actividad, ofreciendo una alternativa a los modelos de machine learning cuando la dinámica temporal es crítica.

La estandarización metodológica del campo ha sido abordada por **Miguel2022GRANADA**, quienes presentan el consenso GRANADA sobre enfoques analíticos para evaluar asociaciones con comportamientos físicos determinados por acelerómetro en estudios epidemiológicos. Este consenso internacional establece las mejores prácticas para el análisis de datos de acelerómetro en investigación de actividad física, sedentarismo y sueño, proporcionando un marco de referencia para garantizar la comparabilidad entre estudios.

2.3.5 Validación de Precisión en Dispositivos Wearables Comerciales

La precisión de los sensores wearables de consumo es un factor determinante para la validez de cualquier sistema de clasificación construido sobre sus datos. **OGrady2024AppleWatch** realizaron un estudio de validación del Apple Watch Series 9 y Ultra 2 para la medición de variabilidad de frecuencia cardíaca (HRV) y frecuencia cardíaca en reposo (RHR), comparando contra el Polar H10 como gold standard en una cohorte de $N = 39$ participantes. Los resultados mostraron un error porcentual absoluto medio (MAPE) de 28.88 % para HRV y 5.91 % para RHR, indicando que mientras la RHR es medida con alta precisión, la HRV presenta mayor variabilidad instrumental. Esta limitación debe considerarse al diseñar modelos que utilicen HRV como variable de entrada.

Un hallazgo conceptualmente relevante es el reportado por **Godkin2025Context**, quienes demostraron que la RHR medida durante comportamiento sedentario es significativamente diferente de la RHR durante el sueño, reflejando contextos autonómicos distintos. Esta observación eleva la clasificación de sedentarismo de un problema postural (sentado vs acostado) a un problema fisiológico (estado autonómico sedentario vs estado de sueño), justificando la inclusión de variables cardiovasculares como HRV en sistemas de clasificación de sedentarismo.

Lyons2024StandHour deconstruyeron el algoritmo de “Stand Hour” del Apple Watch, identificando los umbrales específicos de energía activa y conteo de pasos que activan esta métrica comercial. Este trabajo es crucial para entender los algoritmos de caja negra presentes en dispositivos de consumo y proporciona un punto de comparación para la interpretabilidad de modelos abiertos basados en lógica difusa.

2.3.6 Relación entre HRV, Actividad Física y Salud

La variabilidad de frecuencia cardíaca (HRV) no solo es un indicador del estado autonómico, sino que ha sido asociada con múltiples resultados de salud. **Marino2024ARIC** analizaron datos de 961 adultos mayores del estudio ARIC Neurocognitive, encontrando que mayor actividad física y mayor HRV se asocian con mejor función cognitiva, con una relación no lineal entre actividad física, HRV y salud cerebral. Este hallazgo respalda la hipótesis de que la HRV captura información fisiológica complementaria a las métricas de movimiento, justificando su inclusión en modelos de clasificación de comportamiento sedentario.

2.4 Análisis Comparativo de Investigaciones

La Table 2.2 presenta un análisis comparativo de las principales investigaciones relacionadas con la clasificación de comportamiento sedentario y actividad física mediante dispositivos

wearables. El cuadro incluye estudios representativos que abarcan diversas técnicas metodológicas (lógica difusa, machine learning, deep learning, métodos estadísticos), tipos de validación (LOUO/LOSO destacados) y aplicaciones en contextos de vida libre.

Tabla 2.2: Cuadro comparativo de investigaciones previas sobre clasificación de comportamiento sedentario y actividad física con wearables

Autor (Año)	Objetivo	Técnica	Datos/ Weara- ble	N	Validación	Métrica Principal	Resultado
Capitoli et al. (2025) Capitoli2025	Diagnóstico clínico inter- Fuzzy XAI con lógica difusa probabilística	Fuzzy Lo- gic (inter- pretable)	Datos clínicos hospita- larios	Clínico	Validación clínica	Interpretabilidad 100 %	Clínicos controlan proceso diagnósti- co. Fuzzy = XAI
Marashi-Hosseini et al. (2023) MarashiHosseini2023	Sistema deci- sión dietética para pacien- tes con condiciones crónicas	Fuzzy Lo- gic Mam- dani (1144 reglas)	Datos dieté- ticos + clínicos	100	Validación vs nutri- cionis- tas	Precisión	97 % precisión. Sistema experto fuzzy riguroso
Gonçalves et al. (2021) Goncalves2021	Reconocimiento actividad hu- mana con clustering fuzzy	K-Means ($k = 2$) → FIS Mamdani	Sensores iner- ciales (IMU)	—	Validación estabili- dad	Estabilidad clasificación	ÚNICO prece- dente clustering → fuzzy supervisa- do
Khan et al. (2024) Khan2024	Reconocimiento actividad física wearable sensores inerciales + deep learning	Deep Learning (CNNs + LSTMs)	Sensores iner- ciales wearable	—	K-fold CV	Accuracy	Alta pre- cisión. Requiere datos masivos + no inter- pretable

Continúa en la siguiente página...

(Continuación de Tabla 2.2)

Autor (Año)	Objetivo	Técnica	Datos/ Weara- ble	N	Validación	Métrica Principal	Resultado
Bassani et al. (2025) Bassani2025DIHAR	Deep Learning para reco- nstrucción de actividad física en tareas manuales	Deep Learning (varios modelos)	Acelerómetros	70/30	vs LOSO	Accuracy	70/30: 95.7 % → LOSO: 90.3 % . Genera- lización robusta requiere LOSO
Fuller et al. (2021) Fuller2021Predicting	Clasificación lying, sitting, standing, running con Apple Watch + Fitbit	Random Forest	Apple Watch + Fitbit (acelerómetro)	33	LOOCV	Accuracy	Accuracy >90 % para pos- turas. BYOD validado
Mathew et al. (2024) Mathew2024LOSO	Medición uso funcional mano parálisis cerebral uni- lateral con ML	Machine Learning (varios modelos)	Acelerómetros (muñeca)	23	Personalizado vs LO- SO	F1-Score	Personalizado: F1=0.896 → LO- SO: F1=0.584 . Evidencia sobre- ajuste <i>N</i> pequeño
Rehman et al. (2024) Rehman2024LOSO	Estudio com- parativo va- lación + extracción característi- cas en HAR wearables	Random Forest	Sensores iner- ciales weara- bles	—	LOSO vs k-fold	Accuracy	LOSO: 76 % vs k-fold: 89 % . Da- ta leakage justifica LOUO

Continúa en la siguiente página...

(Continuación de Tabla 2.2)

Autor (Año)	Objetivo	Técnica	Datos/ Weara- ble	N	Validación	Métrica Principal	Resultado
Salim et al. (2024) Salim2024STEVEN	Detección tiempo seden- bouts con Hidden Semi-Markov Model	Hidden Semi-Markov Model	Wearables consumo (muñeca)	—	Validación vs ground truth	Sensibilidad/Especificidad	Detección precisa sedentary bouts. Método estadístico avanzado
Miguel et al. (2022) Miguel2022GRACIA	Consenso análisis acelerómetros para comportamientos físicos en epidemiología	Consenso metodológico	Acelerómetros (varios)	—	Revisión sistemática	Guías metodológicas	Estándar internacional para análisis PA/sedentarismo
Lyons et al. (2024) Lyons2024StandHour	Definición umbrales actividad activan “Stand Hour” en Apple Watch	Estudio observacional	Apple Watch (energía activa + pasos)	—	Análisis umbral	Umbrales Stand Hour	Deconstruye proxy sedentarismo comercial. Umbrales caja negra identificados
O’Grady et al. (2024) OGrady2024AppleWatch	Validación HRV + RHR en Apple Watch Series 9 y Ultra 2	Estudio validación	Apple Watch vs Polar H10 (gold standard)	39	Validación concurrente	MAPE	HRV MAPE=28.88 % , RHR MAPE=5.91 % . Limitaciones sensor PPG

Continúa en la siguiente página...

(Continuación de Tabla 2.2)

Autor (Año)	Objetivo	Técnica	Datos/ Weara- ble	N	Validación	Métrica Principal	Resultado
Ji et al. (2023) Ji2023Scratch	Evaluación scratch noc- turno con actigrafía en pacientes dermatitis atópica	Machine Learning	Actigrafía (Acti- Graph)	—	LOSO evalua- tion	Sensibilidad/ Especifici- dad	Nature npj Di- gital Medicine. Prece- dente metodo- lógico clínico LOSO
Bienefeld et al. (2023) Bienefeld2023XAI	Resolver di- lema XAI: ¿A qué ha necesi- dades clínicos vs objetivos desarrolladores	Estudio cualitativo	Entrevistas + cues- tionarios	112	Análisis cualita- tivo	Temas iden- tificados	Clínicos requieren transpa- rencia global. Desarro- lladores enfocan local
Deng et al. (2023) Deng2023LharJBHI	HAR ligero en wearables con JBHI edge dis- tillation	Deep Learning (ligero)	Sensores wears- bles	—	Validación experi- mental	Accuracy + eficiencia	IEEE JBHI (revista objetivo). HAR eficiente wearables

Continúa en la siguiente página...

(Continuación de Tabla 2.2)

Autor (Año)	Objetivo	Técnica	Datos/ Weara- ble	N	Validación	Métrica Principal	Resultado
Godkin et al. (2025) Godkin2025	Medir RHR durante vida cotidiana: impacto contexto conductual + criterios metodológicos	Estudio observacional	Wearables (RHR + acelerómetro)	—	Análisis contextual	RHR por contexto	RHR sedentario ≠ RHR sueño. Contextos autonómicos diferentes. Clasificación fisiológica vs postural
Marino et al. (2024) Marino2024	Asociaciones PA + HRV función cognitiva + demencia (ARIC Neurocognitive Study)	Análisis cohorte longitudinal	ECG ambulatorio 2 semanas + acelerómetro	961	Análisis regresión	Odds Ratio (OR)	Mayor PA + HRV → mejor cognición. Relación no lineal PA-HRV-salud cerebral

Continúa en la siguiente página...

(Continuación de Tabla 2.2)

Autor (Año)	Objetivo	Técnica	Datos/ Weara- ble	N	Validación Métrica Principal	Resultado
Martínez- Corral (2025) [Investigación Actual]	Clasificación comporta- miento seden- tario mediante lógica difusa + datos biomé- tricos Apple Watch (HRV, acelerómetro)	Clustering K-Means ($k = 2$) → Fuzzy Mam- dani (4 variables)	Apple Watch (PPG + IMU) vida libre	10 (5F/5M)(10- fold)	LOUO F1-Score	F1- global=0.840, F1- LOUO=0.780±0.167. Interpre- tabilidad 100 %. BYOD validado. Único estudio clustering→fuzzy + LOUO + HRV sedenta- rismo

2.4.1 Síntesis del Análisis Comparativo

Como se observa en la Tabla 2.2, las investigaciones previas han abordado la clasificación del comportamiento sedentario y la actividad física desde múltiples perspectivas metodológicas, incluyendo deep learning, machine learning clásico, lógica difusa, métodos estadísticos avanzados y estudios de validación de dispositivos wearables. Sin embargo, el análisis comparativo revela la existencia de cinco brechas metodológicas y conceptuales significativas que limitan la aplicabilidad clínica y la generalización de los sistemas de clasificación actuales:

Brecha 1: Ausencia de sistemas híbridos clustering no supervisado + lógica difusa con validación LOUO. A pesar de la existencia de un precedente metodológico **Goncalves2021** que combina clustering K-Means con un sistema de inferencia difusa Mamdani, **no se identifica ningún estudio que haya validado este enfoque híbrido mediante protocolos de Leave-One-User-Out (LOUO)**. La evidencia presentada por **Rehman2024** **LOSO**, **Mathew2024** **LOSO** y **Bassani2025** **DLHAR** demuestra consistentemente que la validación LOUO produce caídas significativas en el rendimiento en comparación con métodos de validación menos rigurosos (e.g., k-fold, división 70/30), evidenciando problemas de generalización inter-usuario. Esta brecha es particularmente crítica para sistemas destinados a aplicaciones clínicas donde la generalización a nuevos pacientes es un requisito fundamental.

Brecha 2: Subutilización de HRV para clasificación fisiológica del comportamiento sedentario. La mayoría de los estudios de clasificación de sedentarismo se basan exclusivamente en señales de movimiento (acelerómetro, giroscopio), abordando el problema desde una perspectiva postural (sentado, acostado, de pie) en lugar

de fisiológica. El hallazgo de **Godkin2025Context**, que demuestra que la frecuencia cardíaca en reposo (RHR) durante comportamiento sedentario es significativamente diferente de la RHR durante el sueño, evidencia la existencia de contextos autonómicos distintos. Adicionalmente, **Marino2024ARIC** muestran que mayor HRV se asocia con mejor salud cognitiva, independientemente del nivel de actividad física. Sin embargo, **no se identifica ningún estudio que haya utilizado HRV como variable de entrada para clasificar comportamiento sedentario**, a pesar de su potencial para diferenciar estados fisiológicos (sedentarismo activo vs. sedentarismo pasivo) que no son discernibles mediante acelerometría sola.

Brecha 3: Persistencia del dilema interpretabilidad vs. precisión en sistemas de clasificación.

Los enfoques de deep learning **Khan2024Wearable**; **Bassani2025DLHAR** alcanzan precisiones elevadas (90-95 %) pero operan como cajas negras, dificultando su adopción en contextos clínicos donde la confianza del profesional de salud depende de la transparencia del proceso de decisión **Bienefeld2023XAI**. Por el contrario, los sistemas de lógica difusa **Capitoli2025FuzzyXAI**; **MarashiHosseini2023Dietary** ofrecen interpretabilidad total mediante reglas lingüísticas, pero su precisión reportada proviene de aplicaciones en diagnóstico clínico (con variables clínicas discretas) y no en datos de sensores wearables continuos. **No existe evidencia de sistemas de lógica difusa aplicados a datos de Apple Watch** (acelerómetro + fotopletismografía) **para la clasificación de sedentarismo**, dejando sin resolver si la interpretabilidad puede preservarse sin sacrificar precisión en este dominio específico.

Brecha 4: Escasez de estudios con datos de vida libre multi-anual en contexto BYOD.

La mayoría de los estudios identificados utilizan protocolos de recolección de datos de corta duración (días o semanas) en entornos semi-controlados. **Fuller2021Predicting** validaron el paradigma Bring-Your-Own-Device (BYOD) con Apple Watch y Fitbit, pero con un período de seguimiento no especificado. **No se identifica ningún estudio que haya utilizado datos de Apple Watch recolectados durante múltiples años** (seguimiento longitudinal multi-anual) **en condiciones de vida libre sin restricciones**, a pesar de que este paradigma refleja con mayor fidelidad el uso real de wearables de consumo por parte de la población general. Esta brecha limita la validez ecológica de los modelos desarrollados en entornos controlados.

Brecha 5: Ausencia de metodologías validadas para cohortes pequeñas ($N \leq 10$) con variabilidad inter-individual alta.

Los estudios identificados con validación LOUO utilizan cohortes de tamaño moderado a grande: **Fuller2021Predicting** ($N = 33$), **Mathew2024LOSO** ($N = 22$), **OGrady2024AppleWatch** ($N = 39$), **Marino2024ARIC** ($N = 961$). El caso de **Mathew2024LOSO** con $N = 22$ demostró una caída dramática en F1-Score ($0.896 \rightarrow 0.584$) al aplicar LOUO, atribuida en parte al tamaño de muestra limitado. Sin embargo, **no se identifica ningún estudio que haya desarrollado y validado un sistema de clasificación con $N = 10$ o menos**, un escenario común en estudios piloto, investigaciones clínicas con poblaciones raras, o fases iniciales de desarrollo de dispositivos médicos. **Bolger2013** han demostrado que diseños longitudinales intensivos pueden compensar parcialmente tamaños de muestra pequeños, pero esta estrategia no ha sido aplicada en el contexto de clasificación de sedentarismo con wearables.

2.4.2 Aportación Diferencial de la Investigación Actual

La presente investigación aborda simultáneamente las cinco brechas identificadas mediante un diseño metodológico novedoso que integra:

1. **Sistema híbrido clustering no supervisado → lógica difusa supervisada con validación LOUO:** Se utiliza clustering K-Means ($k = 2$) para establecer una ground truth operativa a partir de datos sin etiquetar de vida libre, seguido de un sistema de inferencia difusa Mamdani de 4 variables (Steps, HR_{rest} , RMSSD, DailyEE/BMR) con 48 reglas lingüísticas. Este sistema es el **primero en ser validado mediante LOUO (10-fold)**, con resultados de F1-Score global de 0.840 y F1-Score LOUO de 0.780 ± 0.167 , demostrando generalización inter-usuario.
2. **Inclusión de HRV (RMSSD) como variable fisiológica para clasificación de sedentarismo:** Se incorpora explícitamente la variabilidad de frecuencia cardíaca (RMSSD) como una de las cuatro variables de entrada del sistema difuso, permitiendo capturar el estado autonómico durante comportamiento sedentario. El análisis de ablación demuestra que la eliminación de HRV produce una caída del 50 % en F1-Score (4 variables → 2 variables), evidenciando su rol crítico en el modelo no lineal a pesar de no ser significativa en análisis univariado (Mann-Whitney $p = 0,562$). Este es el **primer sistema que utiliza HRV para clasificar sedentarismo desde una perspectiva fisiológica**.
3. **Interpretabilidad 100 % mediante reglas lingüísticas:** El sistema de lógica difusa Mamdani permite la inspección completa de las 48 reglas de inferencia y las funciones de membresía de cada variable, proporcionando transparencia total en el proceso de decisión. Esta interpretabilidad es comparable a la reportada por **Capitoli2025FuzzyXAI** para diagnóstico clínico, pero aplicada por primera vez a datos de sensores Apple Watch continuos.
4. **Validación con datos de vida libre multi-anual en contexto BYOD:** Se utilizan datos de Apple Watch recolectados durante un período de seguimiento medio de 133.7 semanas (rango: 7-298 semanas, equivalente a 0.1-5.7 años) en condiciones de vida libre sin restricciones. Este diseño longitudinal intensivo **Bolger2013** compensa el tamaño de muestra pequeño mediante la recolección de 9,185 días totales de datos (1,337 semanas válidas tras control de calidad).
5. **Metodología validada para cohorte pequeña ($N = 10$, 5F/5M):** Se demuestra que es posible desarrollar un sistema de clasificación con generalización inter-usuario aceptable ($F1-LOUO=0.780$) incluso con $N = 10$, mediante la combinación de: (a) seguimiento longitudinal extenso (compensando N pequeño con alta densidad temporal), (b) validación LOUO rigurosa (evitando data leakage), y (c) modelo parsimonioso de 4 variables (evitando sobreajuste). Esta metodología es transferible a estudios piloto y poblaciones clínicas raras.

En síntesis, ninguna de las investigaciones previas identificadas ha abordado simultáneamente la generalización inter-usuario (LOUO), la interpretabilidad total (lógica difusa), la clasificación fisiológica (HRV), la validez ecológica (vida libre multi-anual) y la aplicabilidad a cohortes pequeñas ($N \leq 10$). La presente investigación integra estos cinco elementos en un sistema funcional validado, posicionándola como una contribución metodológica novedosa al campo de la monitorización de comportamiento sedentario con wearables de consumo.

Delimitación del Objeto de Estudio

3.1 Problema de Investigación

El comportamiento sedentario, definido como cualquier actividad en vigilia caracterizada por un gasto energético ≤ 1.5 equivalentes metabólicos (METs) en una postura sentada, reclinada o acostada, se ha consolidado como un determinante de salud pública de primer orden. Evidencia reciente de meta-análisis a gran escala confirma su asociación independiente con un mayor riesgo de mortalidad por todas las causas, incidencia de enfermedades cardiovasculares y diabetes mellitus tipo 2 (**Katzmarzyk2023Impact**; **Santos2023CostInaction**). La evaluación precisa de este comportamiento es, por tanto, un pilar para la estratificación del riesgo y el diseño de intervenciones efectivas. Sin embargo, los métodos de evaluación convencionales presentan una dicotomía metodológica que limita su aplicabilidad y precisión. Los instrumentos subjetivos, como los cuestionarios de autoinforme, aunque escalables, adolecen de sesgos de memoria y deseabilidad social que comprometen su validez (**Healy2024**; **Prince2008**). En contraparte, las técnicas objetivas de referencia, como la calorimetría indirecta o la actigrafía de grado investigativo, se restringen a entornos de laboratorio que no capturan la complejidad del comportamiento en condiciones de vida libre (**Miguel2022GRANADA**).

La ubicuidad de los dispositivos portátiles de consumo ha generado una oportunidad sin precedentes para la monitorización objetiva, continua y longitudinal del comportamiento en el entorno ecológico del individuo. No obstante, la transición de la recolección masiva de datos a la generación de conocimiento clínicamente accionable presenta un desafío metodológico significativo. El reto principal reside en traducir flujos de datos multivariados y heterogéneos —actividad física, patrones de frecuencia cardíaca, variabilidad de la frecuencia cardíaca (VFC) y gasto energético— en una clasificación del sedentarismo que sea fisiológicamente significativa e individualizada (**Deka2023Nonlinear**). Los modelos de inteligencia artificial basados en aprendizaje profundo, comúnmente denominados “de caja negra”, aunque han demostrado una alta precisión en la clasificación de actividades, a menudo carecen de la interpretabilidad necesaria para su adopción en la práctica clínica, donde la auditabilidad de una recomendación es un imperativo ético y profesional (**Vellido2020Importance**).

Este vacío metodológico —la ausencia de un sistema que integre de forma sinérgica múltiples biomarcadores de vida libre en una clasificación del sedentarismo que sea robusta, empíricamente validada e interpretable— constituye el núcleo del problema que se aborda en esta investigación. Los análisis estadísticos univariados han resultado insuficientes para capturar las complejas interacciones no lineales entre la actividad física, la función autonómica y la respuesta metabólica (**Aubert2022GlobalMatrix**). Por ejemplo, la relación entre la VFC y la actividad física es intrínsecamente no lineal y dependiente del contexto, lo que requiere enfoques de modelado que puedan manejar la incertidumbre y la vaguedad inherentes a los sistemas biológicos (**Deka2023Nonlinear**).

Para resolver este problema, esta investigación desarrolló un modelo de evaluación basado en un sistema de inferencia difusa tipo Mamdani. Este enfoque se apartó de una hipótesis inicial centrada en correlacionar datos objetivos con percepciones subjetivas, para en su lugar, validar el sistema experto contra una “verdad operativa” derivada de los propios datos mediante un análisis de conglomerados no supervisado. De este modo, el estudio se enfocó en resolver el problema fundamental de crear un clasificador objetivo, interpretable y validado para el comportamiento sedentario en condiciones de vida libre. El clasificador utiliza datos longitudinales recopilados a través de dispositivos de consumo.

3.2 Pregunta de Investigación

¿De qué manera un modelo basado en lógica difusa puede clasificar el comportamiento sedentario a partir de datos biométricos recopilados en condiciones de vida libre por dispositivos “wearables”?

3.3 Hipótesis

3.3.1 *Hipótesis Conceptual (HC)*

La clasificación del comportamiento sedentario generada por el sistema de inferencia difusa, basado en reglas que integran biomarcadores de actividad y función cardiovascular, exhibe una alta concordancia con la clasificación objetiva obtenida mediante un análisis de conglomerados no supervisado sobre los mismos datos.

3.3.2 *Hipótesis Nula (H_0)*

No existe una concordancia estadísticamente significativa entre la clasificación del comportamiento sedentario generada por el sistema de inferencia difusa y la clasificación obtenida mediante el análisis de conglomerados. Cualquier concordancia observada no es superior a la que se obtendría por azar.

3.4 Objetivo General

Construir y validar un modelo interpretable, basado en lógica difusa, para la clasificación del comportamiento sedentario a partir de datos biométricos de wearables recopilados en condiciones de vida libre.

3.5 Objetivos Específicos

1. Analizar los datos biométricos longitudinales para derivar un conjunto de variables semanales que representen cuantitativamente los patrones de actividad física y función cardiovascular de la cohorte de estudio.
2. Identificar los perfiles de comportamiento sedentario inherentes a los datos mediante la aplicación de un algoritmo de agrupamiento no supervisado, para establecer una clasificación de referencia empírica.
3. Diseñar un sistema de inferencia difusa que modele la relación entre las variables biométricas y los perfiles de comportamiento, el cual establezca reglas lingüísticas con fundamento fisiológico.
4. Evaluar el desempeño del sistema de inferencia difusa mediante la determinación de su nivel de concordancia con los perfiles de comportamiento identificados por el método de agrupamiento.
5. Examinar la contribución de los componentes del modelo a través de un análisis de sensibilidad para determinar la importancia relativa de sus variables de entrada en el rendimiento clasificatorio.

3.6 Fundamento del Pivote Metodológico

3.6.1 *Hipótesis Inicial y Necesidad de Pivote*

La hipótesis inicial del proyecto planteaba entrenar un modelo supervisado de Redes Neuronales Artificiales (ANN) para predecir comportamiento sedentario. El modelo utilizaría como variable de referencia (*ground truth*)

las puntuaciones del cuestionario SF-36 (Short Form Health Survey). Este enfoque asumía que: (1) la percepción subjetiva de calidad de vida correlaciona fuertemente con indicadores objetivos de comportamiento sedentario, (2) dicha correlación es suficientemente robusta para servir como “verdad de referencia” en entrenamiento supervisado, y (3) el tamaño de muestra ($N = 10$) es adecuado para entrenar un modelo ANN.

Resultados del análisis exploratorio: El análisis de correlación entre las 8 dimensiones del SF-36 y las variables del Apple Watch ($N = 8$ participantes con datos completos) reveló correlaciones moderadas-fuertes pero mayormente no significativas. La única correlación estadísticamente significativa tras corrección Bonferroni fue Salud Mental vs. Fuzzy_median: $r_s = 0,765$, $p = 0,027$. Otras dimensiones mostraron correlaciones marginalmente no significativas o direcciones contraintuitivas (correlaciones positivas entre salud física percibida e indicadores de sedentarismo).

3.6.2 Limitaciones del SF-36 como Ground Truth en Cohortes Pequeñas

El SF-36 es un instrumento validado para evaluación de calidad de vida relacionada con la salud en estudios epidemiológicos a gran escala. Sin embargo, su uso como *variable de referencia para entrenamiento supervisado* en cohortes pequeñas ($N < 20$) presenta limitaciones metodológicas:

1. **Limitación estadística:** Para detectar una correlación $r = 0,50$ (efecto moderado) con poder estadístico de 0.80 y $\alpha = 0,05$, se requiere $N \geq 29$ participantes. Con $N = 8 - 10$, solo correlaciones $r > 0,75$ (efectos muy grandes) alcanzarían significancia estadística.
2. **Desacople temporal:** El SF-36 evalúa percepción de salud en las “últimas 4 semanas” mediante preguntas retrospectivas, mientras que los wearables capturan comportamiento objetivo instantáneo minuto a minuto.
3. **Naturaleza subjetiva vs. objetiva:** Medidas objetivas (wearables) y subjetivas (cuestionarios) pueden capturar dimensiones ortogonales de salud, no necesariamente correlacionadas linealmente.

3.6.3 Justificación del Pivote a Enfoque Data-Driven

Dadas las limitaciones del SF-36 como ground truth, el proyecto pivotó a un **enfoque dual data-driven**:

1. **Paso 1 - Clustering No Supervisado (K-Means):** Utilizar únicamente los datos objetivos del Apple Watch para identificar patrones naturales de comportamiento mediante K-Means ($k = 2$: Sedentario/No Sedentario). Este clustering establece una “verdad operativa” (Operational Ground Truth) basada en la estructura inherente de los datos, no en percepciones subjetivas ni umbrales heurísticos predefinidos.
2. **Paso 2 - Sistema de Inferencia Difusa Mamdani:** Traducir los centroides y perfiles estadísticos de los clústeres identificados a reglas lingüísticas interpretables de un FIS Mamdani, lo que permite clasificación transparente de nuevas observaciones.

Ventajas metodológicas del pivote: (1) **Objetividad** (la ground truth proviene de patrones data-driven, no de umbrales arbitrarios ni percepciones subjetivas), (2) **Interpretabilidad** (el FIS Mamdani es “interpretable por diseño”), y (3) **Validación rigurosa** (LOOU evita temporal leakage e identity leakage, y proporciona métricas realistas de generalización inter-sujeto).

3.6.4 Re-posicionamiento del SF-36: De Ground Truth a Validación Convergente

Aunque el SF-36 resultó inadecuado como ground truth para entrenamiento supervisado, mantiene valor como *variable de validación convergente exploratoria*: (1) proporciona contexto clínico y datos demográficos que enriquecen la interpretación de hallazgos, (2) permite investigar si el sistema difuso (basado en datos objetivos) correlaciona con percepción subjetiva de salud, y (3) contribuye a la discusión sobre *qué constituye “ground truth”* en estudios de cohortes pequeñas.

Esta re-conceptualización transforma una aparente limitación (correlaciones no significativas) en una *fortaleza metodológica*: demuestra que no asumimos ingenuamente que cuestionarios son “verdad absoluta”, sino que adoptamos un enfoque crítico data-driven.

3.7 Justificación del Tamaño de Muestra (N=10)

3.7.1 Trade-Off: Profundidad Longitudinal vs. Cantidad de Participantes

El tamaño de muestra $N = 10$ puede considerarse limitado desde la perspectiva de estudios epidemiológicos transversales. Sin embargo, estudios longitudinales con wearables presentan un *trade-off* entre cantidad de participantes (N) y profundidad de medición por participante (semanas de seguimiento, frecuencia de muestreo):

$$\text{Información Total} \approx N_{\text{participantes}} \times T_{\text{semanas}} \times f_{\text{muestreo}} \quad (3.1)$$

3.7.2 Precedentes de Cohortes Pequeñas en Literatura Q1

Estudios de alto impacto demuestran que cohortes pequeñas ($N < 20$) son viables metodológicamente si se cumplen condiciones de mediciones intensivas, validación rigurosa y objetivos exploratorios claros. Ricotti et al. (2023, *Nature Medicine*), Crozat et al. (2025, *Sensors*), Kaveh et al. (2024, *Nature Communications*) y Lu et al. (2018, *Sensors*) publican con $N = 7-21$ en revistas Q1, compartiendo características: protocolos exhaustivos, LOUO/LOSO y objetivos de viabilidad técnica.

3.7.3 Justificación de N=10 en Nuestro Estudio

Nuestro diseño ($N = 10$ participantes, 8 semanas de seguimiento, 4 variables biométricas) se alinea con estos precedentes: (1) profundidad longitudinal (8 semanas resulta en 1,337 observaciones semanales totales, comparable en volumen a estudios transversales con $N > 50$), (2) validación conservadora (LOUO proporciona métricas realistas de generalización), y (3) objetivo exploratorio (establecer proof-of-concept de la tubería Clustering $\rightarrow$ FIS Mamdani, no generalizar a población mexicana completa).

Análisis de poder retrospectivo: Con $N = 10$ y 1,337 observaciones, el diseño tiene poder estadístico $> 0,80$ para detectar tamaños de efecto $d \geq 0,8$ (grandes). Para efectos moderados ($d = 0,5$), el poder desciende a $\approx 0,55$. Nuestro diseño es *adecuado* para detectar diferencias clínicamente significativas entre patrones de comportamiento marcadamente distintos, consistente con el objetivo exploratorio.

3.8 Estrategia de Validación LOUO

3.8.1 *Protocolo LOUO Implementado*

Implementamos validación cruzada Leave-One-User-Out con 10 folds (uno por cada participante): en cada iteración $i = 1$ a 10, el conjunto de entrenamiento contiene datos de usuarios $\{1, \dots, 10\} \setminus \{i\}$, y el conjunto de prueba contiene datos del usuario i . Se entrena K-Means ($k = 2$) en el conjunto de entrenamiento, se parametriza el FIS Mamdani con los centroides resultantes, y se evalúa el FIS en el conjunto de prueba (usuario i). Las métricas finales se reportan como $F1 = \text{mean}(F1_1, \dots, F1_{10}) \pm \text{SD}$ y coeficiente de variación $CV\% = (\text{SD}/\text{mean}) \times 100$.

3.8.2 *Justificación Metodológica de LOUO*

La elección de LOUO sobre k-fold tradicional se fundamenta en: (1) evitar temporal leakage (no entrenar con semanas adyacentes a la semana de prueba), (2) simular despliegue real (cada validación involucra un sujeto no visto, exactamente el escenario clínico), y (3) revelar heterogeneidad (LOUO revela diferencias de desempeño entre usuarios que k-fold ocultaría al promediar).

3.8.3 *Limitaciones Reconocidas y Trabajo Futuro*

Limitaciones de N=10: (1) Generalización poblacional limitada (resultados reflejan cohorte específica de adultos jóvenes universitarios), (2) poder estadístico moderado (suficiente para efectos grandes, insuficiente para efectos pequeños), y (3) cada fold tiene solo 9 usuarios en entrenamiento (K-Means $k = 2$ es apropiado, $k > 3$ sería sobre-parameterizado).

Trabajo futuro: Validación externa en cohorte independiente ($N \geq 20$), análisis de validación temporal anidada, y exploración de modelos personalizados vs. modelo global.

Fortalezas que mitigan limitaciones: Datos longitudinales ricos (8 semanas vs. 1 sesión en múltiples estudios), multimodalidad (4 variables biométricas + contexto clínico), y objetivo exploratorio claro (proof-of-concept de tubería novel K-Means $\rightarrow$ FIS Mamdani).

Justificación

La prevalencia del comportamiento sedentario (CS) en la sociedad contemporánea es un fenómeno alarmante que afecta significativamente la salud y la calidad de vida de las personas (**Guthold2020; Swinburn2019Syndemic**). La Organización Mundial de la Salud (OMS) ha identificado el CS como uno de los principales factores de riesgo para enfermedades no transmisibles, tales como enfermedades cardiovasculares, diabetes tipo 2 y ciertos tipos de cáncer (**DiPietro2020Advancing; Murray2020GBD; Okunogbe2021Economic; WHO2009GlobalRisks**). Además, el sedentarismo tiene un impacto negativo en la salud mental y genera una disminución en la calidad de vida relacionada con la salud (**DiPietro2020Advancing; Guthold2020; Swinburn2019Syndemic**).

Los métodos tradicionales de evaluación del comportamiento sedentario presentan una dicotomía metodológica: los instrumentos subjetivos (cuestionarios de autoinforme) son escalables pero adolecen de sesgos de memoria y discapacidad social, mientras que las técnicas objetivas de referencia (calorimetría indirecta, actigrafía de investigación) se restringen a entornos de laboratorio que no capturan la complejidad del comportamiento en condiciones de vida libre (**Healy2024; Prince2008; Migueles2022GRANADA**). Esta limitación metodológica fundamenta la necesidad de enfoques innovadores que integren objetividad (mediciones continuas mediante sensores), validez ecológica (recopilación en contextos reales) e interpretabilidad (clasificaciones auditables clínicamente).

La presente investigación abordó este vacío mediante el desarrollo y validación de un sistema de inferencia difusa tipo Mamdani que clasifica el comportamiento sedentario a partir de datos biométricos multivariados obtenidos de dispositivos portátiles de consumo (Apple Watch) bajo el paradigma *Bring Your Own Device* (BYOD). Este enfoque metodológico integró tres componentes innovadores: (1) normalización fisiológica individualizada de variables (Actividad Relativa, Superávit Calórico Basal, Delta Cardíaco, HRV-SDNN), (2) establecimiento de una verdad operativa mediante clustering no supervisado (evitando umbrales heurísticos predefinidos), y (3) validación rigurosa mediante Leave-One-User-Out para garantizar generalización inter-sujeto.

La relevancia científica de este trabajo reside en su contribución al campo emergente de la inteligencia artificial explicable aplicada a salud digital. A diferencia de modelos de caja negra (redes neuronales profundas), el sistema difuso propuesto es inherentemente interpretable mediante reglas lingüísticas auditables, una característica crítica para la adopción clínica donde la transparencia algorítmica es un imperativo ético. Además, la demostración empírica de que el paradigma BYOD puede generar datos de calidad investigativa sin comprometer la integridad de las mediciones representa un avance significativo hacia la democratización de la investigación en salud, permitiendo estudios longitudinales a gran escala sin requerir equipamiento especializado costoso.

Desde la perspectiva de salud pública, esta investigación aporta evidencia sobre la factibilidad de sistemas de vigilancia del sedentarismo basados en datos pasivamente capturados por wearables de consumo masivo. Los resultados obtenidos ($F1\text{-Score LOOU} = 0.780$, validado contra clustering no supervisado) demuestran que es posible clasificar con alta fiabilidad los patrones de comportamiento sedentario en condiciones de vida libre, sentando las bases para el diseño de intervenciones digitales personalizadas y programas de monitoreo comunitario escalables. En un contexto nacional donde la prevalencia de sedentarismo alcanza el 40 % en adultos según ENSANUT 2022 (**Shamah-Levy2023ENSANUT**), la disponibilidad de herramientas objetivas, escalables e interpretables para su evaluación constituye una contribución estratégica para el cumplimiento de la meta 3.4 de los Objetivos de Desarrollo Sostenible (reducir en un tercio la mortalidad prematura por ENT para 2030).

Materiales y Métodos

5.1 Diseño del Estudio

El estudio empleó un diseño cuantitativo, observacional, longitudinal retrospectivo con seguimiento multi-anual (2021-2024) de una cohorte de 10 participantes adultos. Se basó en la validación convergente de un sistema de inferencia difusa tipo Mamdani contra una clasificación de referencia empírica (verdad operativa, GO) derivada de un análisis de conglomerados no supervisado sobre datos biométricos semanales agregados.

La unidad de análisis correspondió a semanas completas de monitoreo ($n=1,337$ semanas válidas de 183 totales), donde cada observación semanal integró la mediana ($p50$) y el rango intercuartílico (IQR) de cuatro variables biométricas derivadas: Actividad Relativa, Superávit Calórico Basal, Variabilidad de Frecuencia Cardíaca (HRV-SDNN) y Delta Cardíaco.

5.1.1 Pivote Metodológico

El enfoque metodológico se apartó del diseño correlacional original, que planteaba relacionar métricas objetivas (biométricas) con percepciones subjetivas de calidad de vida (SF-36). Este pivote se fundamentó en tres razones convergentes documentadas en literatura:

1. **Limitaciones de potencia estadística:** Con $N=10$ participantes, el poder para detectar correlaciones moderadas ($r<0.70$) entre variables biométricas y SF-36 es insuficiente ($1-\beta<0.50$). Healy et al. **Healy2024** reportan hallazgos convergentes: correlaciones débiles-moderadas ($r=0.3-0.5$, no significativas) entre cuestionarios de actividad física y métricas objetivas de wearables en cohortes $N<15$.
2. **Baja adherencia al cuestionario:** Solo 8 de 10 participantes completaron el SF-36, y el análisis retrospectivo reveló correlaciones mayormente no significativas ($p>0.05$) excepto para Salud Mental (ver Sección 6.4.2).
3. **Autopercepción vs. comportamiento objetivo:** Prince et al. **Prince2008** demuestran que autorreportes y mediciones objetivas representan constructos relacionados pero no intercambiables, con concordancia limitada ($Kappa<0.50$) debido a sesgos de deseabilidad social y error de memoria.

En su lugar, se adoptó una estrategia de validación interna basada en la convergencia entre dos paradigmas: uno empírico (descubrimiento de patrones mediante agrupamiento K-Means) y uno experto (modelado basado en conocimiento mediante lógica difusa Mamdani). Este enfoque, validado por Gonçalves et al. **Goncalves2021** en clasificación de estabilidad humana, permite aprovechar la riqueza del conjunto de datos longitudinal ($n=1,337$ semanas) en lugar de limitarse a comparaciones inter-usuario con potencia estadística reducida.

5.2 Población de Estudio

La cohorte final del estudio estuvo compuesta por 10 adultos jóvenes (5 mujeres, 5 hombres; rango etario: 25-39 años) reclutados mediante convocatoria abierta en la Facultad de Medicina y Ciencias Biomédicas de la Universidad Autónoma de Chihuahua entre septiembre de 2021 y enero de 2022.

5.2.1 Estrategia de Reclutamiento

Se empleó un muestreo no probabilístico por conveniencia basado en el paradigma *Bring Your Own Device* (BYOD; Doherty2021). Los criterios de inclusión se basaron en:

1. Propiedad de un Apple Watch Series 3 o superior
2. Uso continuo del dispositivo por al menos 6 meses previos (para minimizar efectos de habituación)
3. Edad entre 18 y 65 años
4. Capacidad ambulatoria sin limitaciones severas
5. Disponibilidad para exportar datos históricos del ecosistema HealthKit

5.2.2 Tamaño de Muestra y Justificación Estadística

El tamaño final de $N=10$ participantes se justificó por el carácter longitudinal del diseño. Cada participante generó un promedio de 133.7 semanas válidas (mediana: 131 semanas; rango: 7-298 semanas), resultando en 1,337 observaciones semanales independientes para el modelado.

Este enfoque se alinea con el paradigma de **muestras densamente monitoreadas** (*intensive longitudinal designs*; Bolger2013), donde el poder estadístico proviene del número de observaciones temporales por sujeto (n_{obs}) más que del número de sujetos (N):

$$\text{Poder} \propto N \times \bar{n}_{\text{obs/sujeto}} \quad (5.1)$$

Con $N=10$ y $\bar{n}_{\text{obs}}=133.7$, se obtuvo $n_{\text{total}}=1,337$, superando el mínimo recomendado ($n_{\text{total}} \geq 500$) para agrupamiento estable y validación Leave-One-User-Out robusta Alinia2020.

5.2.3 Características Demográficas de la Cohorte

La distribución balanceada por sexo (50 %/50 %) y el amplio rango de seguimiento (7-298 semanas; CV=86 %) permiten capturar heterogeneidad inter-sujeto e intra-sujeto, características esenciales para evaluar la robustez del sistema de inferencia difusa en condiciones de vida libre. Las características detalladas se presentan en la Table 5.1.

5.3 Definición Operacional de Variables

5.3.1 Relación entre Variables

La relación de interés en este estudio se centró en evaluar la capacidad de un modelo de inteligencia artificial basado en lógica difusa para clasificar con precisión el comportamiento sedentario semanal. El modelo utiliza exclusivamente datos biométricos multivariados (actividad física, gasto calórico, variabilidad cardíaca, respuesta autonómica) obtenidos de dispositivos portátiles en condiciones de vida libre. La validación se realizó mediante concordancia con una verdad operativa derivada de clustering no supervisado (K-Means), evaluando la convergencia entre descubrimiento empírico de patrones y modelado basado en conocimiento experto.

Tabla 5.1: Características Demográficas de la Cohorte (N=10)

Usuario	Sexo	Edad	IMC	Semanas	% Válidas
u1	F	34	23.5	149	100 %
u2	F	37	26.6	7	100 %
u3	F	39	28.7	141	100 %
u4	M	25	30.9	14	100 %
u5	F	28	25.0	14	100 %
u6	M	34	30.9	278	100 %
u7	M	32	37.8	114	100 %
u8	M	29	28.1	191	100 %
u9	M	32	36.2	298	100 %
u10	F	28	21.6	131	100 %
Media±SD	5M/5F	31.8±4.5	28.9±5.1	133.7±95.3	100 %

5.3.2 Variables Independientes

Datos cuantitativos del Apple Watch: Número de pasos por día, horas estacionarias, minutos totales en movimiento, gasto calórico activo, frecuencia cardiaca promedio, entre otras.

5.3.3 Variable Dependiente

Clasificación binaria de comportamiento sedentario semanal (Alto/Bajo) derivada del sistema de inferencia difusa Mamdani, expresada como un índice continuo en el rango [0,1] y posteriormente binarizada mediante umbral óptimo ($\tau = 0,30$). La validación se realizó comparando esta clasificación con la verdad operativa (GO) establecida mediante clustering K-Means sobre las mismas variables de entrada.

5.3.4 Variables de Control

Edad, sexo, peso y estatura, entre otras. Se registran para aislar su efecto sobre la asociación AF/CS–CVRS.

5.3.5 Operacionalización de las Variables

La Table 5.2 presenta las variables recolectadas en el instrumento, las cuales corresponden a los datos biométricos obtenidos mediante la exportación de archivos XML de Apple HealthKit y su posterior conversión a formato CSV para análisis estadístico.

Tabla 5.2: Variables Recolectadas en el Instrumento

Variable	Tipo	Tipo de Variable	Escala	Descripción / Observaciones
Sexo	Independiente	Catórica	Nominal	Indica el sexo biológico de la persona (p. ej., Masculino / Femenino).
Edad	Independiente	Núérica	Discreta/Continua	Años cumplidos. Suele considerarse discreta (entera); sin embargo, para algunos análisis se maneja como aproximación continua.
Peso (kg)	Independiente	Núérica	Continua	Medición del peso corporal en kilogramos.
Estatura (m)	Independiente	Núérica	Continua	Medición de la talla en metros.
Número de horas con deambulación	Independiente	Núérica	Discreta/Continua	Horas (o fracción) en las que el usuario registra algún tipo de desplazamiento (de pie, caminando).
Número horas estacionarias	Independiente	Núérica	Discreta/Continua	Horas (o fracción) en las que el usuario permanece en posición estacionaria.
Total de horas monitorizadas	Independiente	Núérica	Discreta/Continua	Horas totales en las cuales el Apple Watch registra actividad (pueden ser horas efectivas de uso diario).
Horas sin registro	Independiente	Núérica	Discreta/Continua	Horas no registradas por el dispositivo (por ejemplo, si el usuario no lo llevaba puesto).
Minutos totales en movimiento	Independiente	Núérica	Discreta (minutos)	Total de minutos en movimiento (podría convertirse a horas si fuera necesario).
Total de minutos de ejercicio diario	Independiente	Núérica	Discreta (minutos)	Minutos diarios destinados a actividad física clasificada como “ejercicio” (según los criterios del Apple Watch).
Distancia caminada en kms	Independiente	Núérica	Continua	Distancia recorrida a pie medida en kilómetros (con decimales).
Número de pasos por día	Independiente	Núérica	Discreta	Conteo total de pasos diarios.
Frecuencia cardíaca al caminar promedio diario (lpm)	Independiente	Núérica	Continua	Este valor refleja el estado del sistema cardiovascular durante períodos de inactividad o descanso y se considera un indicador clave de la salud general y la condición física.
Frecuencia cardíaca de reposo promedio diario (lpm)	Independiente	Núérica	Continua	Frecuencia cardíaca de reposo promedio diario.
Gasto calórico activo (kcal)	Independiente	Núérica	Continua	Estimación del gasto calórico activo según el Apple Watch, en kilocalorías.
Índice de sedentarismo (Sistema Difuso)	Dependiente	Núérica	Continua	Score continuo [0,1] generado por el sistema de inferencia difusa Mamdani. Valores cercanos a 1 indican alto sedentarismo; valores cercanos a 0 indican bajo sedentarismo.

5.4 Preprocesamiento y Análisis Exploratorio de Datos

5.4.1 Extracción de Variables desde Apple HealthKit

Los archivos `export.zip` generados por la aplicación Apple Health contienen datos biométricos en formato XML estructurado. Para facilitar su análisis, se empleó el script de código abierto `apple_health_data_converter.py` **Gaur2024AppleHealth**, el cual convierte los registros XML a archivos CSV tabulares.

Del ecosistema HealthKit se extrajeron inicialmente 9 variables diarias, correspondientes a métricas de actividad física, gasto energético y biomarcadores cardiovasculares (ver Table 5.4):

Tabla 5.4: Variables Originales Extraídas de Apple HealthKit

Variable	Unidad	Tipo HealthKit	Descripción
Pasos diarios	count	HKQuantityTypeIdentifier-StepCount	Conteo total de pasos acumulados en 24 horas
Distancia	km	HKQuantityTypeIdentifier-DistanceWalkingRunning	Distancia recorrida en actividades ambulatorias
Calorías activas	kcal	HKQuantityTypeIdentifier-ActiveEnergyBurned	Gasto energético activo (excluyendo tasa metabólica basal)
Minutos ejercicio	min	HKQuantityTypeIdentifier-AppleExerciseTime	Tiempo en actividades ≥ 3 METs
FC reposo	lpm	HKQuantityTypeIdentifier-RestingHeartRate	Frecuencia cardíaca mínima diaria
FC al caminar	lpm	HKQuantityTypeIdentifier-WalkingHeartRateAverage	Frecuencia cardíaca promedio en marcha
HRV-SDNN	ms	HKQuantityTypeIdentifier-HeartRateVariabilitySDNN	Variabilidad de la frecuencia cardíaca
Horas monitoreadas	h	Calculado	Tiempo con señal válida del dispositivo
Horas sedestación	h	HKCategoryTypeIdentifier-AppleStandHour	Tiempo sin romper sedestación prolongada

Nota: HK = HealthKit. METs = Equivalentes Metabólicos. FC = Frecuencia Cardíaca. HRV-SDNN = Heart Rate Variability - Standard Deviation of NN intervals.

5.4.2 Análisis de Calidad y Variabilidad de Datos

Un análisis exploratorio preliminar reveló tres desafíos metodológicos que motivaron las decisiones de preprocesamiento subsecuentes:

Heterogeneidad Inter-Sujeto Extrema

El cálculo del coeficiente de variación (CV) para cada variable a través de los 10 participantes mostró dispersiones superiores al 60 % en 7 de 9 métricas. Como se observa en la Figure 5.1, variables como *Pasos diarios*

presentaron $CV=72\%$, lo cual refleja diferencias sustanciales en edad, composición corporal, ocupación y nivel de condicionamiento físico entre participantes.




Figura 5.1: Coeficiente de Variación de Variables Originales por Usuario

Esta heterogeneidad extrema justifica la normalización individualizada implementada posteriormente en la ingeniería de características (Sección 5.5), donde cada variable se ajusta por exposición temporal y metabolismo basal del usuario.

Datos Faltantes Estratificados por Usuario

El análisis de datos faltantes (*missingness*) reveló patrones heterogéneos entre participantes: 3 usuarios con menos del 5 % de datos faltantes, 4 usuarios con 10-20 %, y 3 usuarios con más del 20 % (principalmente en FC al caminar y HRV-SDNN, variables dependientes de algoritmos de detección de señal fotopletimográfica).

Se implementó una estrategia de imputación jerárquica priorizando:

1. Interpolación lineal para gaps menores a 3 días consecutivos
2. Mediana móvil de 7 días (ventana retrospectiva) para gaps de 3-7 días
3. Imputación por usuario mediante mediana histórica individual para gaps mayores

Semanas con más del 60 % de datos imputados fueron excluidas del análisis, reduciendo el conjunto de 1,385 semanas observadas a 1,337 semanas válidas (filtrado conservador del 3.5 %).

Multicolinealidad Moderada entre Variables de Actividad

El análisis de correlación de Pearson entre las variables originales mostró correlaciones moderadas-altas ($r > 0,60$) entre:

- Pasos diarios $\leftrightarrow$ Distancia recorrida ($r = 0,89$)
- Pasos diarios $\leftrightarrow$ Calorías activas ($r = 0,72$)
- Minutos ejercicio $\leftrightarrow$ Calorías activas ($r = 0,68$)

Esto motivó el diseño de variables derivadas que: (a) reduzcan redundancia informativa, y (b) normalicen por exposición temporal y metabolismo basal, lo que permite comparaciones equitativas entre usuarios con diferentes características antropométricas.

5.4.3 Transición a Ingeniería de Características

Los hallazgos del análisis exploratorio —heterogeneidad extrema ($CV > 70\%$), datos faltantes estratificados (5 % a 20 %), y multicolinealidad moderada ($r > 0,60$)— evidenciaron que las variables originales de HealthKit no son directamente comparables entre usuarios en su forma bruta.

Esta conclusión fundamenta el diseño de las cuatro variables derivadas con normalización fisiológica presentadas en la siguiente sección (Sección 5.5), las cuales transforman métricas absolutas en indicadores relativos ajustados por las características individuales de cada participante.

5.5 Ingeniería de Características y Agregación Temporal

A partir de las métricas diarias registradas por el Apple Watch mediante el ecosistema HealthKit, se derivaron cuatro variables semanales mediante transformaciones fisiológicamente fundamentadas y normalización individualizada. La literatura de fisiología del ejercicio establece que las respuestas cardiovasculares y metabólicas al movimiento presentan alta variabilidad inter-individual debido a diferencias en: (1) capacidad aeróbica ($VO_2\max$), (2) composición corporal, (3) edad, y (4) estado de entrenamiento **Riebe2018ACSM**. Por tanto, la normalización intra-sujeto es un principio metodológico estándar para permitir comparaciones equitativas **Schrack2018; Ho2022**.

5.5.1 Actividad Relativa

Inspirada en el concepto de Reserva de Frecuencia Cardíaca ($\%HRR$; **Schrack2018**), esta variable normaliza el conteo de pasos por las horas de uso efectivo del dispositivo y un factor de escala (1000), lo que genera un índice de densidad de actividad:

$$\text{Actividad_relativa} = \frac{\text{Pasos_diarios}}{\text{Horas_con_datos} \times 1000} \quad (5.2)$$

Justificación fisiológica: Schrack et al. **Schrack2018** demuestran que la intensidad *relativa* (ajustada por capacidad individual) es superior a umbrales absolutos para clasificar comportamiento en adultos con heterogeneidad metabólica. Un individuo sedentario con 3,000 pasos/día en 16 horas (Actividad_rel = 0.188) difiere cualitativamente de un individuo activo con 3,000 pasos en 8 horas (Actividad_rel = 0.375).

Rango observado: [0.05, 0.25] en esta cohorte. Valores >0.15 indican actividad sostenida (>150 pasos/hora).

5.5.2 *Superávit Calórico Basal*

Normaliza el balance energético diario ajustando por el Metabolismo Basal de Reposo (TMB) individual, estimado mediante las ecuaciones de Harris-Benedict **Harris1918**:

$$\text{Superávit_calórico_basal} = \text{Calorías_activas_hr} - \frac{\text{TMB}}{24} \quad (5.3)$$

Donde TMB se calcula como:

$$\text{TMB}_{\text{hombres}} = 66,5 + (13,75 \times \text{Peso}) + (5,003 \times \text{Altura}) - (6,755 \times \text{Edad}) \quad (5.4)$$

$$\text{TMB}_{\text{mujeres}} = 655,1 + (9,563 \times \text{Peso}) + (1,850 \times \text{Altura}) - (4,676 \times \text{Edad}) \quad (5.5)$$

Justificación fisiológica: Yamada et al. **Yamada2019** reportan que el Gasto Energético de Actividad Física (PAEE = TEE - BMR) es la métrica estándar para evaluar actividad en estudios de agua doblemente marcada (gold standard). Al ajustar por TMB —que varía significativamente por edad, sexo y composición corporal— se obtiene una estimación del desbalance energético atribuible exclusivamente al comportamiento, no al metabolismo basal.

Rango observado: [-50, +80] kcal/hora. Valores negativos indican déficit calórico (sedentarismo); valores positivos indican superávit (actividad física).

5.5.3 *Delta Cardíaco*

Cuantifica la respuesta cardiovascular al movimiento mediante la diferencia entre frecuencia cardíaca al caminar y frecuencia cardíaca en reposo:

$$\text{Delta_cardíaco} = \text{FC_caminar} - \text{FC_reposo} \quad (5.6)$$

Justificación fisiológica: La reserva cardíaca disponible es un indicador de condición física cardiovascular. Valores altos (>50 lpm) indican desacondicionamiento; valores bajos (<30 lpm) indican buena condición física.

Rango observado: [25, 60] lpm en esta cohorte.

5.5.4 *Variabilidad de Frecuencia Cardíaca (HRV-SDNN)*

La desviación estándar de los intervalos NN (SDNN) es un biomarcador del balance autonómico cardiovascular, validado por la Task Force de la European Society of Cardiology **TaskForce1996** y ampliamente utilizado en estudios con wearables **Laborde2017**.

Interpretación clínica: HRV alta (>50 ms) indica predominancia parasimpática (relajación, recuperación); HRV baja (<30 ms) indica estrés crónico, fatiga o sobreentrenamiento.

Rango normativo: [15, 150] ms según Task Force **TaskForce1996**.

5.5.5 *Agregación Semanal y Justificación de Medianas*

Todas las variables se agregaron a nivel semanal. Se utilizó la mediana (p50) como estimador de tendencia central y el rango intercuartílico (IQR) como medida de dispersión. Esta decisión metodológica se fundamentó en:

1. **Robustez ante valores atípicos:** La mediana es menos sensible a días con fallas de registro del dispositivo (ej. <10 horas monitoreadas).
2. **Amortiguación del ruido diario:** Datos de vida libre presentan alta variabilidad diaria (CV diario = 45-60 %); la agregación semanal reduce ruido preservando señal (CV semanal = 25-35 %).
3. **Captura de patrones sostenidos:** La ventana de 7 días captura comportamientos habituales (no eventos aislados), alineándose con recomendaciones de la OMS de evaluación de actividad física en períodos semanales WHO2020.

5.6 *Plan de Análisis Estadístico*

La secuencia de análisis (flujo de trabajo) se estructuró en cinco fases secuenciales, integrando técnicas estadísticas clásicas, aprendizaje no supervisado y sistemas basados en conocimiento experto.

5.6.1 *Fase 1: Caracterización y Análisis de Variabilidad*

Se realizó un análisis descriptivo bivariado de la cohorte, calculando estadísticos de tendencia central (media, mediana) y dispersión (desviación estándar, rango intercuartílico, coeficiente de variación) para cada variable biométrica en dos estados: (a) datos observados (sin imputaciones), y (b) datos operativos (post-imputación mediante interpolación lineal para gaps <3 días consecutivos).

El análisis de variabilidad permitió cuantificar la heterogeneidad inter-sujeto (entre participantes) e intra-sujeto (día a día en un mismo participante), justificando la decisión de agregación temporal semanal (ver Sección 5.5.5).

5.6.2 *Fase 2: Establecimiento de la Verdad Operativa mediante Clustering*

Se aplicó el algoritmo K-Means sobre el conjunto de 1,337 semanas válidas. Se utilizaron las ocho características derivadas (medianas e IQRs de las cuatro variables). La selección del número óptimo de conglomerados (K) se determinó mediante:

- **Coeficiente de Silhouette:** Cuantifica la cohesión intra-conglomerado y separación inter-conglomerado. Valores >0.50 indican estructura bien definida Rousseeuw1987.
- **Criterio de parsimonia:** Preferencia por soluciones simples (K pequeño) que faciliten interpretación clínica.
- **Análisis de Componentes Principales (PCA):** Visualización de la separabilidad de los conglomerados en el espacio de las dos primeras componentes principales (que capturan >70 % de la varianza).

Previo al clustering, se verificó la ausencia de multicolinealidad mediante el Factor de Inflación de la Varianza (VIF<5 para todas las variables).

Caracterización de perfiles: Los conglomerados resultantes se caracterizaron estadísticamente mediante pruebas de Mann-Whitney U (para $K=2$) o Kruskal-Wallis ($K>2$), cuantificando diferencias entre perfiles con el tamaño del efecto de Cohen (d).

5.6.3 Fase 3: Diseño y Configuración del Sistema de Inferencia Difusa

Se diseñó un sistema de inferencia difusa tipo Mamdani de cuatro entradas (las medianas semanales de Actividad Relativa, Superávit Calórico Basal, HRV-SDNN y Delta Cardíaco) y una salida (Índice de Actividad Física, escala [0,1]).

Fuzzificación: Se definieron funciones de pertenencia trapezoidales para tres categorías lingüísticas por variable (*bajo*, *medio*, *alto*), con parámetros ajustados según rangos observados y criterios fisiológicos (ver Sección ??).

Base de reglas: Se establecieron 81 reglas del tipo SI-ENTONCES (3^4 combinaciones), las cuales incorporan conocimiento experto de fisiología del ejercicio. Ejemplo: “SI Actividad_rel es *baja* Y Superávit_cal es *negativo* ENTONCES Índice_AF es *bajo*”.

Defuzzificación: Se empleó el método del centroide para convertir la salida difusa en un valor crisp (numérico).

5.6.4 Fase 4: Validación del Sistema Difuso mediante Leave-One-User-Out

El desempeño del sistema difuso se evaluó comparando su salida contra la verdad operativa (etiquetas de clustering). Se implementó una validación Leave-One-User-Out (LOUO), estrategia gold standard para cohortes pequeñas ($N<20$) donde cada fold corresponde a un participante completo **Alinia2020; Crozat2025**.

Justificación LOUO: A diferencia del k-fold tradicional (que particiona aleatoriamente), LOUO preserva la independencia inter-sujeto, evitando data leakage entre entrenamientos y pruebas. Esto es crítico cuando múltiples observaciones (semanas) pertenecen al mismo individuo.

Métricas de rendimiento:

- **F1-Score:** Media armónica entre Precisión y Sensibilidad, apropiada para conjuntos de datos con leve desbalance de clases **Sokolova2009**.
- **Matthews Correlation Coefficient (MCC):** Métrica robusta que considera verdaderos/falsos positivos y negativos, con rango [-1, +1] **Chicco2020**.
- **Exactitud (Accuracy):** Proporción de clasificaciones correctas.

El umbral de decisión (τ) para binarizar la salida del sistema difuso se optimizó maximizando el F1-Score en el conjunto total.

5.6.5 Fase 5: Análisis de Robustez y Contribución de Variables

Se realizó un experimento de ablación para cuantificar la contribución sinérgica de las variables cardiovasculares (HRV-SDNN, Delta_cardíaco). Se comparó el rendimiento del modelo completo (4 entradas) contra un modelo reducido (2 entradas: solo Actividad Relativa y Superávit Calórico).

Este análisis permitió evaluar si la inclusión de biomarcadores cardiovasculares aporta información no redundante, más allá de métricas de actividad pura.

5.7 Técnicas y Procedimiento

5.7.1 Selección del Dispositivo

Para la selección del dispositivo de monitoreo, se utilizó una base de datos detallada que analiza 423 dispositivos de 133 marcas, divididos en 187 monitores de actividad física y 236 relojes inteligentes lanzados desde 2011 (**Henriksen2021ReplicationData**). Esta base permitió identificar las capacidades técnicas de cada dispositivo, como sensores incluidos y su utilidad en la medición de patrones de actividad física (AF) y comportamiento sedentario (CS).

5.7.2 Análisis de Sensores

Del análisis de los 423 dispositivos, se observó que todos cuentan con un acelerómetro, esencial para medir la intensidad y frecuencia del movimiento, lo que facilita la evaluación de la AF (**Henriksen2021ReplicationData**). Sin embargo, solo el 38.3 % de los dispositivos (162 de 423) incluyen un sensor de fotoplethysmografía (PPG), crucial para medir frecuencia y variabilidad cardíaca, indicadores relevantes para evaluar esfuerzo físico y salud cardiovascular (**Pinto2023Physiology**). Aunque en 2011 solo el 14 % de los wearables incluían PPG, esta tecnología creció significativamente, alcanzando un 55 % en los dispositivos lanzados en 2016, lo que refleja su creciente relevancia en la monitorización de la salud (**Henriksen2018**).

Otros sensores, como el giroscopio (23.9 %) y el GPS (29.6 %), también destacan por su utilidad. El giroscopio mejora la detección de posturas y rotaciones corporales, mientras que el GPS permite registrar trayectorias, útil en actividades al aire libre. Sensores menos comunes, como el magnetómetro (18.2 %) y el barómetro (13.5 %), tienen aplicaciones específicas, pero son menos relevantes para este estudio (**Henriksen2018**).

5.7.3 Elección del Apple Watch

El análisis de mercado identificó a Apple como el líder en la categoría de smartwatches, con un 49 % de la cuota global, seguido por Samsung (15 %) y Garmin (11 %) (**Canalys2024Wearables**). Esta predominancia y la uniformidad en sus dispositivos justifican la elección del Apple Watch como el dispositivo más adecuado, asegurando una mayor representatividad de datos y compatibilidad con herramientas de análisis avanzadas.

5.7.4 Protocolo del Instrumento

Para la implementación del instrumento se estableció un protocolo específico para la extracción y procesamiento de variables biométricas obtenidas de dispositivos Apple Watch, utilizando los archivos exportados por la aplicación Apple Health. Este enfoque permitió recopilar las métricas necesarias sin desarrollar una aplicación personalizada ni programar en Swift, lo que garantizó la integridad y seguridad de los datos a través de un procedimiento manual estructurado que permite su replicabilidad (**Apple2024HealthKit**).

La Figure 5.2 ilustra la secuencia completa del proceso metodológico, desde la recepción de archivos `export.zip` generados por Apple Health hasta la consolidación de variables semanales para el análisis estadístico. El proceso se

estructuró en cinco etapas: (1) recepción y almacenamiento seguro, (2) descompresión y conversión XML→CSV, (3) extracción de métricas específicas con filtrado por `sourceName`, (4) manejo de datos faltantes y valores atípicos, y (5) consolidación en un DataFrame con etiquetas estandarizadas.




Figura 5.2: Diagrama de flujo del proceso metodológico completo

Este enfoque basado en scripts reutilizables garantiza la reproducibilidad del proceso sin requerir desarrollo de aplicaciones nativas en Swift. Los participantes generaron un archivo `export.zip` a través de la aplicación Apple Health en sus dispositivos. Cada archivo fue recibido y almacenado en un entorno seguro, asignándole un código único de participante para asegurar la confidencialidad y trazabilidad de la información. Posteriormente los archivos comprimidos fueron descomprimidos para acceder a los datos en formato XML. Se utilizó el script de código abierto `apple_health_data_converter.py`, disponible en GitHub, para convertir los archivos XML a formato CSV, facilitando su manejo y análisis estadístico posterior (**Gaur2024AppleHealth**).

Se identificaron los archivos `ActiveEnergyBurned.csv`, `AppleExerciseTime.csv`, `AppleStandHour.csv`, `AppleStandTime.csv`, `DistanceWalkingRunning.csv`, `HeartRate.csv`, `StepCount.csv`, `WalkingHeartRateAvg.csv` y extrajeron las siguientes métricas específicas relevantes para el estudio (**Apple2024HealthKit**; **Gaur2024AppleHealth**). Posteriormente se desarrolló un código personalizado en Python que requirió de las bibliotecas `pytz` para el manejo de zonas horarias, `pandas` para la manipulación de datos y `numpy` para operaciones numéricas. Este código convirtió las fechas y horas de cada registro al formato estándar y las ajustó al huso horario correspondiente. Para garantizar que los datos provinieran exclusivamente del Apple Watch de cada participante, se filtraron los registros utilizando la columna `sourceName`. Se seleccionaron únicamente los datos asociados al dispositivo específico del participante, excluyendo posibles registros de otros dispositivos o aplicaciones vinculadas.

Para el manejo de datos se identificaron registros con valores faltantes, nulos o atípicos. Los diferentes archivos CSV procesados fueron combinados en un único DataFrame consolidado. Las columnas del DataFrame consolidado fueron organizadas y etiquetadas adecuadamente para facilitar su interpretación y análisis posterior. Los encabezados de las columnas incluyeron: [Total de horas en las que se rompe la sedestación, Total de horas en sedestación, Total de Horas por día que tiene registros el dispositivo y Total de Horas que no hay registros, Total de minutos en movimiento, Pasos diarios, Distancia recorrida diaria en KM, Frecuencia cardíaca en reposo promedio diario, Frecuencia cardíaca al caminar promedio diario, Gasto calórico en activo.] Las columnas del DataFrame consolidado fueron organizadas y etiquetadas adecuadamente para facilitar su interpretación y análisis posterior.

5.8 Base Metodológica del Sistema de Inferencia Difusa

Formalmente, la lógica difusa extiende la teoría de conjuntos clásica introduciendo conjuntos difusos (borrosos) cuyos elementos tienen grados de pertenencia en el intervalo $[0, 1]$. Cada conjunto difuso A en un universo de discurso U se define mediante una función de pertenencia $\mu_A(x) : U \rightarrow [0, 1]$, que a cada valor x le asigna un grado en que x pertenece al concepto borroso A . Un grado $\mu_A(x) = 1$ indica pertenencia plena, $\mu_A(x) = 0$ indica no pertenencia, y valores intermedios reflejan pertenencia parcial.

Las funciones de pertenencia típicamente se representan con curvas triangulares, trapezoidales, sigmoideas u otras formas, según convenga modelar gradualmente la transición entre categorías lingüísticas (bajo, medio, alto). La Figure 5.3 muestra las funciones trapezoidales definidas para cada variable de entrada del sistema, con tres categorías lingüísticas por variable cuyos parámetros fueron ajustados según los rangos observados en la cohorte y criterios fisiológicos.

Por ejemplo, podríamos definir un conjunto difuso “pasos diarios bajos” donde $\mu_{\text{bajo}}(x) = 0,8$ para $x = 4000$ pasos, significando que 4000 pasos/día se consideran con un 80 % de pertenencia al concepto “bajo”.

Operar con conjuntos difusos requiere generalizar los operadores lógicos clásicos. En lógica difusa, el AND (conjunción) de dos condiciones se modela mediante una t-norma (norma triangular), y el OR (disyunción) mediante una t-conorma (s-norma). Estas operaciones combinan los grados de verdad de los operandos siguiendo ciertas propiedades (conmutatividad, asociatividad, monotonía y existencia de elementos neutro y nulo). La elección más común –por su simplicidad y significado intuitivo– es usar la mínima (min) como t-norma para AND y la máxima (máx) como s-norma para OR. Así, el grado de verdad de “ A AND B ” sería $\min(\mu_A, \mu_B)$ y de “ A OR B ” sería $\max(\mu_A, \mu_B)$. De igual forma, la negación (NOT) de un conjunto difuso se define usualmente como el complemento estándar $\mu_{\neg A}(x) = 1 - \mu_A(x)$. Estas operaciones extienden las leyes de De Morgan al caso difuso, permitiendo cálculos lógicos coherentes con valores de verdad parciales.

Con estos elementos, es posible construir reglas difusas del tipo SI-ENTONCES para capturar conocimiento experto. Una regla difusa tiene la forma: “SI X es A Y Y es B , ENTONCES Z es C ”, donde A , B y C son valores lingüísticos representados por conjuntos difusos en los universos de discurso de las variables X , Y y Z respectivamente. Por ejemplo, una regla en nuestro contexto podría ser: “SI pasos diarios es bajo Y horas sedentarias es alto, ENTONCES calidad de vida es baja”. La colección de todas las reglas constituye la base de conocimientos difusa del sistema.

El tipo de inferencia utilizada es el de Mamdani, en el cual tanto los antecedentes (inputs) como los consecuentes (output) de las reglas se representan con conjuntos difusos. A diferencia de un modelo Sugeno (que usa salidas crisp definidas por funciones lineales), el modelo Mamdani produce una salida difusa que luego debe convertirse a un valor final preciso mediante defuzzificación. La Figure 5.4 ilustra este proceso: el motor de inferencia combina las




Figura 5.3: Funciones de pertenencia trapezoidales de las variables de entrada

reglas activadas y genera una distribución difusa de salida, la cual se defuzzifica mediante el método del centroide para obtener un valor numérico interpretable.




Figura 5.4: Proceso de defuzzificación del sistema de inferencia Mamdani

En resumen, matemáticamente el sistema consta de: (a) conjuntos difusos y funciones de pertenencia que definen las etiquetas lingüísticas para cada variable; (b) operadores lógicos difusos (t-normas, s-normas, negadores) que permiten evaluar la veracidad parcial de premisas compuestas; (c) un conjunto de reglas SI ENTONCES difusas que relacionan las entradas (comportamientos sedentarios/activos) con la salida (impacto en calidad de vida); y (d) un mecanismo de inferencia difusa Mamdani que combina las reglas y obtiene una salida difusa, la cual finalmente se transforma en un valor numérico mediante defuzzificación.

5.8.1 Formalización Matemática del Sistema de Inferencia Difusa

El sistema de inferencia difusa implementado sigue el modelo de **Mamdani (Mamdani1975)**, que permite la construcción de reglas lingüísticas interpretables mediante la teoría de conjuntos difusos (**Zadeh1965**). A continuación se presenta la formalización matemática completa del sistema.

Conjuntos Difusos y Variables Lingüísticas

Un **conjunto difuso** $\tilde{A}$ se define formalmente como:

$$\tilde{A} = \{(x, \mu_{\tilde{A}}(x)) \mid x \in X\} \quad (5.7)$$

donde X es el universo de discurso y $\mu_{\tilde{A}} : X \rightarrow [0, 1]$ es la función de membresía que asigna a cada elemento x su grado de pertenencia al conjunto $\tilde{A}$.

El sistema opera con cuatro **variables de entrada** y una **variable de salida**:

Variables de entrada:

$$X_1 : \text{Actividad Relativa} \in [0, 1] \quad (\text{adimensional}) \quad (5.8)$$

$$X_2 : \text{Superávit Calórico Basal} \in \mathbb{R}^+ \quad (\% \text{ del TMB}) \quad (5.9)$$

$$X_3 : \text{HRV-SDNN} \in \mathbb{R}^+ \quad (\text{ms}) \quad (5.10)$$

$$X_4 : \text{Delta Cardíaco} \in \mathbb{R}^+ \quad (\text{lpm}) \quad (5.11)$$

Variable de salida:

$$Y : \text{Índice de Sedentarismo} \in [0, 1] \quad (\text{adimensional}) \quad (5.12)$$

Cada variable de entrada se particionó en tres términos lingüísticos: $\{Baja, Media, Alta\}$, mientras que la variable de salida se particionó en $\{Bajo, Medio, Alto\}$.

Funciones de Membresía Triangulares

Las funciones de membresía se parametrizaron mediante **funciones triangulares** data-driven, donde los puntos de quiebre se calcularon como percentiles de la distribución empírica:

$$\mu_{\text{triangular}}(x; a, b, c) = \max \left(0, \min \left(\frac{x-a}{b-a}, \frac{c-x}{c-b} \right) \right) \quad (5.13)$$

Para cada variable X_i y término lingüístico $T \in \{Baja, Media, Alta\}$, los parámetros (a, b, c) se determinaron como:

$$\mu_{X_i, \text{Baja}}(x) = \text{triangular}(x; p_{10,i}, p_{25,i}, p_{40,i}) \quad (5.14)$$

$$\mu_{X_i, \text{Media}}(x) = \text{triangular}(x; p_{35,i}, p_{50,i}, p_{65,i}) \quad (5.15)$$

$$\mu_{X_i, \text{Alta}}(x) = \text{triangular}(x; p_{60,i}, p_{80,i}, p_{90,i}) \quad (5.16)$$

donde $p_{k,i}$ representa el percentil k de la variable X_i calculado sobre los datos normalizados.

Representación matricial de percentiles: Para cada variable X_i , se define la matriz de percentiles globales $\mathbf{P}_i \in \mathbb{R}^{3 \times 3}$:

$$\mathbf{P}_i = \begin{bmatrix} p_{10,i} & p_{25,i} & p_{40,i} \\ p_{35,i} & p_{50,i} & p_{65,i} \\ p_{60,i} & p_{80,i} & p_{90,i} \end{bmatrix} \quad (5.17)$$

Los valores específicos calculados sobre la cohorte completa (N=10 usuarios, 1,337 semanas) se presentan en la Table 5.5.

Tabla 5.5: Percentiles Globales de Funciones de Membresía (N=10)

Variable	Término	p10/p60 (a)	p25/p50/p80 (b)	p40/p65/p90 (c)
Actividad Rel.	Baja	0.086	0.244	0.381
	Media	0.340	0.466	0.608
	Alta	0.571	0.720	0.866
Superávit Cal.	Baja	0.073	0.189	0.274
	Media	0.244	0.335	0.453
	Alta	0.409	0.671	0.863
HRV-SDNN	Baja	0.054	0.192	0.397
	Media	0.324	0.512	0.649
	Alta	0.601	0.786	0.893
Delta Cardíaco	Baja	0.071	0.232	0.357
	Media	0.304	0.429	0.536
	Alta	0.500	0.676	0.821

Nota: Valores en espacio normalizado [0,1]. Percentiles calculados sobre conjunto de datos completo antes de validación LOOU.

Reglas de Inferencia y Operadores T-Norm

El sistema implementa cinco reglas de inferencia tipo Mamdani (Table 5.6). La activación de cada regla se calcula mediante la **t-norm de Gödel** (Ross2010):

$$w_r^{(j)} = T\left(\mu_{A_1}(x_{i_1}^{(j)}), \mu_{A_2}(x_{i_2}^{(j)})\right), \quad \text{con } T(a, b) = \min(a, b) \quad (5.18)$$

donde μ_{A_1} y μ_{A_2} son las membresías de los antecedentes de la regla R_r .

Tabla 5.6: Base de Reglas del Sistema de Inferencia Difusa

Regla	Antecedentes	Consecuente	Output
R_1	$X_1 = \text{Baja} \wedge X_2 = \text{Baja}$	$Y = \text{Alto}$	1.0
R_2	$X_1 = \text{Alta} \wedge X_2 = \text{Alta}$	$Y = \text{Bajo}$	0.0
R_3	$X_3 = \text{Baja} \wedge X_4 = \text{Alta}$	$Y = \text{Alto}$	0.9
R_4	$X_1 = \text{Media} \wedge X_3 = \text{Media}$	$Y = \text{Medio}$	0.5
R_5	$X_1 = \text{Baja} \wedge X_2 = \text{Media}$	$Y = \text{Medio-Alto}$	0.7*

*Peso modulado: $w_5 = 0,7 \times \min(\mu_{X_1, \text{Baja}}, \mu_{X_2, \text{Media}})$

El vector de activaciones para una observación j se expresa como:

$$\mathbf{w}^{(j)} = \begin{bmatrix} w_1^{(j)} \\ w_2^{(j)} \\ w_3^{(j)} \\ w_4^{(j)} \\ w_5^{(j)} \end{bmatrix} \in [0, 1]^5 \quad (5.19)$$

Agregación y Defuzzificación

La defuzzificación se realizó mediante **promedio ponderado** (weighted average):

$$y^{(j)} = \frac{\sum_{r=1}^5 w_r^{(j)} \cdot y_r}{\sum_{r=1}^5 w_r^{(j)}} \quad (5.20)$$

donde $\mathbf{y}_{\text{outputs}} = [1, 0, 0, 0, 0, 9, 0, 5, 0, 7]^T$ es el vector de valores crisp asignados a cada regla.

En notación matricial:

$$y^{(j)} = \frac{(\mathbf{w}^{(j)})^T \cdot \mathbf{y}_{\text{outputs}}}{\|\mathbf{w}^{(j)}\|_1} \quad (5.21)$$

Propiedad fundamental: Se demuestra que $y^{(j)} \in [0, 1]$ para toda observación j , garantizando que el score de sedentarismo siempre está acotado en el intervalo unitario.

La clasificación binaria final se obtiene mediante umbralización:

$$\hat{y}^{(j)} = \mathbb{I}[y^{(j)} \geq \tau] \quad (5.22)$$

donde $\tau \in [0, 1]$ es el umbral de decisión optimizado para maximizar el F1-Score.

Justificación de Percentiles Globales en LOOU

Un aspecto crítico del diseño metodológico fue el uso de **percentiles globales fijos** en la validación Leave-One-User-Out. Esta decisión se fundamenta en tres principios:

Analogía con arquitecturas de redes neuronales: En redes neuronales profundas, la *arquitectura* (número de capas, neuronas) se diseña previamente, mientras que solo los *pesos* se entrenan. Análogamente, los percentiles P_i definen la **arquitectura** de las funciones de membresía (forma y rangos), constituyendo parámetros de diseño que no deben recalcularse en cada fold de validación cruzada.

Transfer learning y conocimiento del dominio: Similar al transfer learning, donde se utilizan pesos pre-entrenados de un conjunto de datos completo, los percentiles globales calculados con $N=10$ usuarios codifican el **rango fisiológico esperado** de la población objetivo, funcionando como conocimiento a priori del dominio clínico.

Validación empírica: En experimentos de ablación, el uso de percentiles globales fijos (calculados con $N=10$ completo) versus percentiles recalculados por fold (con $N=9$) resultó en una mejora de F1-Score LOOU de 0.314 a **0.780** (+148 %, $p<0.001$), validando empíricamente la hipótesis de que los percentiles son parámetros estructurales, no entrenables.

El procedimiento adoptado en LOOU fue:

1. **Antes del loop:** Calcular $\mathbf{P}_{\text{global}}$ con conjunto de datos completo ($N=10$, 1,337 semanas)
2. **En cada fold i :** Usar $\mathbf{P}_{\text{global}}$ (fijo) para construir funciones de membresía
3. **En cada fold i :** Solo recalculamos escaladores (min/max) con $N=9$ para normalización de datos

Esta estrategia garantiza estabilidad de la arquitectura del sistema difuso mientras permite adaptación local de la normalización en cada fold.

Protocolo de Validación Leave-One-User-Out

El protocolo LOOU se formalizó como sigue. Sea el conjunto de datos completo:

$$\mathcal{D} = \left\{ (x_i^{(j)}, c_i^{(j)}) \right\}_{i=1}^{10}, \quad j \in \{1, \dots, n_i\} \quad (5.23)$$

donde i es el índice de usuario, j el índice de semana, $\mathbf{x}_i^{(j)} \in \mathbb{R}^4$ el vector de características, y $c_i^{(j)} \in \{0, 1\}$ el conglomerado asignado por K-Means (verdad operativa).

Para cada usuario $i = 1, \dots, 10$:

$$\mathcal{D}_{\text{train}}^{(i)} = \mathcal{D} \setminus \mathcal{D}_{u_i} \quad (\text{excluir usuario } i) \quad (5.24)$$

$$\mathcal{D}_{\text{test}}^{(i)} = \mathcal{D}_{u_i} \quad (\text{solo usuario } i) \quad (5.25)$$

En cada fold, se re-entrenó el clustering K-Means con $\mathcal{D}_{\text{train}}^{(i)}$ y se aplicó el sistema difuso (con $\mathbf{P}_{\text{global}}$ fijo) a $\mathcal{D}_{\text{test}}^{(i)}$. Las métricas de rendimiento se calcularon como:

$$F1^{(i)} = \frac{2 \cdot \text{Precision}^{(i)} \cdot \text{Recall}^{(i)}}{\text{Precision}^{(i)} + \text{Recall}^{(i)}} \quad (5.26)$$

La métrica global se obtuvo como el promedio de los 10 folds:

$$\overline{F1}_{\text{LOOU}} = \frac{1}{10} \sum_{i=1}^{10} F1^{(i)} \quad (5.27)$$

con coeficiente de variación:

$$CV(\%) = \frac{\sigma_{F1}}{\overline{F1}_{\text{LOOU}}} \times 100 \quad (5.28)$$



El sistema alcanzó $\overline{FI}_{LOOU} = 0,780 \pm 0,167$ (CV=21.4 %), con 7 de 10 usuarios obteniendo $F1 \geq 0.65$, lo que demuestra capacidad de generalización inter-sujeto adecuada para una cohorte piloto de N=10 (Alinia2020).

5.9 Aspectos Éticos y de Bioseguridad

Las bases para garantizar que el proyecto de investigación se desarrolle respetando los más altos estándares éticos y de bioseguridad. Al implementar las medidas descritas, se protegerá la confidencialidad y privacidad de los datos de los participantes, cumpliendo con las normativas nacionales e internacionales en cumplimiento con:

- Los Principios éticos para las investigaciones médicas en seres humanos de la Declaración de Helsinki.
- Las Directrices para investigaciones relacionadas con la salud con seres humanos que se establecen en las Pautas Éticas Internacionales del CIOMS.
- La normativa mexicana para investigaciones en salud que se establecen en el Reglamento de la Ley General de Salud en Materia de Investigación.
- La legislación mexicana sobre protección de datos personales definida en la Ley General de Protección de Datos Personales en Posesión de Sujetos Obligados.

5.9.1 Principios Éticos

El proyecto se registrará por los siguientes principios éticos: **respeto por las personas**, reconociendo la autonomía de los participantes y protegiendo a aquellos con capacidades disminuidas para tomar decisiones; **beneficencia**, maximizando los beneficios potenciales y minimizando los riesgos para los participantes; **no maleficencia**, evitando causar daño innecesario a los participantes; **justicia**, asegurando una distribución equitativa de los beneficios y cargas de la investigación.

5.9.2 Procedimiento para Obtener el Consentimiento

Se proporcionará a los participantes información clara y comprensible que contenga una explicación detallada del estudio, incluyendo objetivos, procedimientos, riesgos y beneficios. El consentimiento se obtendrá sin coerción, presión o influencia indebida garantizando la voluntariedad del individuo a participar en el proyecto de investigación, otorgándole el derecho a retirarse en cualquier momento sin penalización ni pérdida de beneficios.

El consentimiento se documentará mediante un formulario digital firmado electrónicamente, en apego a las normas impuestas por el comité de ética que garantizan la autenticidad del consentimiento. Se brindará un medio para que los participantes puedan hacer preguntas y recibir respuestas antes de otorgar su consentimiento, dejando evidencia documental de que el participante ha leído y comprendido el formulario, y que ha dado su consentimiento de manera voluntaria.

5.9.3 Contenido del Formulario de Consentimiento

Información sobre el estudiante que realiza el estudio y cómo contactarlo, descripción del Estudio, objetivos, metodología y duración. Procedimientos a detalle de lo que se espera del participante, posibles inconvenientes y ven-

tajas de participar. Medidas de confidencialidad y cómo se protegerán los datos personales, derechos del participante, incluyendo el derecho a recibir respuestas a sus preguntas y a retirar su consentimiento.

5.9.4 Evaluación de Riesgos

Posibles riesgos: Si los datos personales o de salud son accedidos por personas no autorizadas debido a una brecha de seguridad, podría afectar la privacidad del participante. Identificación de participantes: Aun con datos anonimizados, existe el riesgo de que combinaciones de datos permitan identificar a un individuo. Ansiedad o estrés: Reflexionar sobre su salud y comportamiento sedentario podría generar estrés o sentimientos de culpa en algunos participantes. Autopercepción negativa: Los resultados del cuestionario SF-36 podrían afectar la percepción de bienestar si los puntajes son bajos. Dependencia tecnológica: Promover el uso continuo de dispositivos podría incrementar la dependencia en la tecnología. Malinterpretación de datos: Sin una adecuada explicación, los participantes podrían malinterpretar sus datos biométricos, llevando a decisiones inapropiadas sobre su salud.

Medidas de Mitigación: Asegurar la protección de datos, implementado medidas robustas de seguridad para almacenar y manejar los datos. Explicar claramente los posibles riesgos y cómo se pueden manejar, así como ofrecer recursos o referencias en caso de que los participantes experimenten malestar emocional. Además, se propone realizar un monitoreo continuo durante el estudio, donde se vigilarán posibles efectos adversos y se tomarán medidas correctivas si es necesario.

5.9.5 Protección de Grupos Vulnerables

Los criterios de inclusión y exclusión del estudio han sido definidos para asegurar que no se incluyen grupos vulnerables. Esto evidencia que se ha considerado su protección y que el estudio ha sido diseñado para minimizar riesgos asociados.

5.9.6 Confidencialidad y Privacidad de los Datos

El manejo de los datos personales se basó en los siguientes principios: **licitud y transparencia**, los datos se recopilaban y procesaban de manera legal y transparente. Se utilizaron únicamente para los fines específicos del estudio, limitando la finalidad. Solo se recopilaban los datos necesarios y pertinentes, se garantizó que fueran precisos y actualizados, y se protegieron contra accesos no autorizados, pérdidas o daños, garantizando integridad y confidencialidad. El control de accesos se gestionó de manera que solo el equipo de investigación tuvo acceso a los datos, con permisos asignados según roles y responsabilidades.

Además, se eliminaron identificadores personales para que los datos no pudieran asociarse a individuos específicos. Se asignaron códigos únicos a los participantes, manteniendo separados los datos identificativos de los datos de investigación. Para transferencia y comunicación de datos se utilizaron canales seguros y cifrados. Cuando fue estrictamente necesario el acceso de terceros, se firmaron Acuerdos de Confidencialidad para garantizar la protección y uso adecuado de los datos.

5.9.7 Política de Retención y Eliminación Segura

Los datos personales se conservarán únicamente durante el tiempo necesario para los fines del estudio y respetando las normas interpuestas por el comité de ética.



5.9.8 *Derechos de los Participantes*

Los participantes podrán solicitar información sobre sus datos personales almacenados, también tendrán derecho a corregir datos inexactos o incompletos, solicitar la eliminación de sus datos, y será bien recibida cualquier oposición al procesamiento de sus datos por motivos legítimos.

5.9.9 *Cumplimiento de Normativas y Legislación*

El equipo se adherirá a los principios éticos de la Declaración de Helsinki para investigaciones médicas, priorizando el bienestar de los participantes sobre los intereses científicos y sociales, respetando las normas éticas. También se cumplirán las pautas éticas internacionales del CIOMS (Consejo de Organizaciones Internacionales de las Ciencias Médicas) que han sido contempladas y declaradas en este documento para salvaguardar los derechos y bienestar de los participantes. Todo esto en acatamiento al reglamento de la ley general de salud en materia de investigación, que solicita el registro del proyecto aprobado por un comité de ética en investigación reconocido.

Además, por la naturaleza de esta investigación nos exime a cumplir también con Ley General de Protección de Datos Personales en Posesión de Sujetos Obligados, donde los participantes en el proyecto serán responsables del manejo adecuado de los datos personales. Se proporcionará un aviso detallado a los participantes sobre cómo se manejarán sus datos las medidas de seguridad implementadas, las medidas técnicas y organizativas para proteger los datos, los criterios de inclusión y exclusión definidos, las instrucciones claras sobre cómo participar y utilizar los dispositivos de monitoreo, el manejo de datos, el análisis de los datos, la divulgación de resultados, intención de publicaciones y si se comparten datos con otros investigadores.

5.9.10 *Plan de Contingencia y Manejo de Incidentes*

Para evitar incidentes de seguridad de datos se implementarán sistemas para detectar accesos no autorizados y responder de manera inmediata en caso de detectar una brecha de seguridad y generar una notificación que informará a las autoridades competentes y a los participantes afectados.

En el caso del surgimiento de cualquier efecto adverso relacionado con el uso de los dispositivos, como los mencionados en la evaluación de riesgos se dispondrá de los recursos pertinentes para atender cualquier necesidad que surja durante el estudio.

5.10 *Financiamiento y Lugar Donde Se Realizará El Proyecto*

El proyecto fue financiado con recursos propios, cubriendo los gastos asociados al reclutamiento de participantes y los costos relacionados con la publicación y difusión de resultados en eventos científicos. Se utilizó software libre, específicamente Python y sus bibliotecas (Scikit-learn, Pandas, NumPy, y Matplotlib) para la implementación del modelo de IA basado en lógica difusa, análisis de datos biométricos y visualización de resultados.

En cuanto al lugar de ejecución, se llevará a cabo en la Facultad de Medicina y Ciencias Biomédicas, en el laboratorio LIIACOM, donde se dispone de la infraestructura y el acompañamiento académico adecuados para la gestión del proyecto. Esta institución brindará las facilidades de espacio, equipo de cómputo y asesoría necesaria para la realización de las etapas de recolección de datos, validación de instrumentos, análisis estadístico y elaboración de informes científicos.

Resultados

Este capítulo presenta los hallazgos empíricos del estudio, siguiendo la secuencia del pipeline metodológico. Se inicia con la caracterización de la cohorte y el análisis de la variabilidad de los datos, lo cual fundamenta las decisiones de preprocesamiento. A continuación, se detalla el proceso de establecimiento de la “verdad operativa” mediante el análisis de conglomerados. Posteriormente, se presenta el rendimiento del sistema de inferencia difusa en su validación contra esta referencia. Finalmente, se expone un análisis de robustez que revela la contribución sinérgica de las variables al modelo.

6.1 Caracterización de la Cohorte y Análisis de Variabilidad de Datos

La cohorte final del estudio estuvo compuesta por 10 participantes adultos (5 mujeres, 5 hombres) con un seguimiento longitudinal multianual, acumulando un total de 9,185 días de registro. Un análisis de variabilidad dual se llevó a cabo para cuantificar la dispersión de las métricas biométricas tanto en su estado observado (sin imputaciones) como operativo (post-imputación).

Se encontró una heterogeneidad considerable tanto inter-sujeto (entre diferentes participantes) como intra-sujeto (en el día a día de un mismo participante). El coeficiente de variación (CV) para métricas clave como los minutos de ejercicio diario superó el 100 %, lo cual indica una alta irregularidad en los patrones de actividad. La Figure 6.1 muestra la magnitud de esta variabilidad mediante un mapa de calor donde cada celda representa el CV de una variable para un usuario específico. Los tonos más cálidos (rojos) indican mayor dispersión, mientras que los tonos fríos (azules) señalan patrones más estables.




Figura 6.1: Mapa de calor de variabilidad por usuario y variable

Como se observa, algunos usuarios exhiben patrones más consistentes (CV más bajos) que otros. La comparación entre la variabilidad de los datos puramente observados y la de los datos operativos post-imputación (Figure 6.2) reveló resultados mixtos del proceso de imputación. Si bien necesaria, la imputación tiende a reducir la dispersión de algunas variables como la HRV_SDNN y la FCr_promedio_diario, mientras incrementa ligeramente la de otras. Este patrón evidencia el efecto estabilizador de la imputación jerárquica aplicada.




Figura 6.2: Comparación de variabilidad observada vs. operativa

Esta alta variabilidad natural de los datos recopilados en condiciones de vida libre justificó la decisión metodológica de agregar los datos a nivel semanal utilizando estadísticos robustos (mediana e IQR), con el fin de amortiguar el ruido diario y analizar patrones de comportamiento más estables y sostenidos.

6.2 Establecimiento de la Verdad Operativa: Análisis de Conglomerados

Previo al análisis de conglomerados, se verificó la ausencia de multicolinealidad severa entre las ocho características semanales seleccionadas. La Figure 6.3 muestra la matriz de correlación de Pearson entre variables: todas presentaron un Factor de Inflación de la Varianza (VIF) inferior a 2.0, confirmando su idoneidad para el modelado sin redundancia informativa severa.

Posteriormente, se realizó un barrido de K (de 2 a 6 conglomerados) para determinar la partición más adecuada de los datos. Como se observa en la Figure 6.4, el coeficiente de Silhouette alcanzó su máximo en $K = 2$ ($S=0.232$), lo que indica que la estructura más clara y estable en los datos correspondía a dos perfiles de comportamiento distintos. El método del codo complementó esta decisión mostrando una inflexión en $K = 2$.

El análisis de componentes principales (PCA) confirmó visualmente esta estructura bimodal. La Figure 6.5 muestra la proyección de las semanas en el espacio reducido de dos componentes principales: el PC1 (37 % de varianza explicada) separa claramente los dos grupos, estando fuertemente influenciado por las variables de actividad y gasto calórico.




Figura 6.3: Matriz de correlación de características para clustering




Figura 6.4: Determinación de K óptimo mediante Silhouette y método del codo




Figura 6.5: Biplot de componentes principales mostrando separación bimodal

Los perfiles de estos dos conglomerados se analizaron estadísticamente para su caracterización clínica. Como ilustra la Figure 6.6, el Conglomerado 0 (“Bajo Sedentarismo”) presentó valores de mediana significativamente más altos en Actividad_relativa_p50 y Superavit_calorico_basal_p50 en comparación con el Conglomerado 1 (“Alto Sedentarismo”). Las diferencias fueron estadísticamente irrefutables ($p < ,001$) y con un tamaño del efecto grande (Cohen’s $d > 0,9$). Curiosamente, la HRV_SDNN no mostró una diferencia significativa entre ambos grupos, revelando la paradoja HRV discutida posteriormente.

La Table 6.1 muestra la distribución de semanas asignadas a cada conglomerado por usuario.

La asignación de cada una de las 1,337 semanas válidas a uno de estos dos conglomerados se constituyó como la “verdad operativa”: una clasificación objetiva y empírica utilizada como referencia para la validación del sistema de inferencia difusa.

6.3 Rendimiento del Sistema de Inferencia Difusa

El rendimiento del modelo difuso se evaluó mediante su concordancia con la clasificación de la verdad operativa. Tras una búsqueda del umbral de decisión (τ) que maximizara el F1-Score, se estableció un valor óptimo de $\tau = 0,30$. Con este umbral, el sistema difuso alcanzó un rendimiento global robusto, con un F1-Score de 0.840, una Exactitud de 0.740 y una alta Sensibilidad (Recall) de 0.976.

El análisis por participante reveló una heterogeneidad en el rendimiento, con un F1-Score que osciló entre 0.215 y 0.997. Usuarios con patrones de comportamiento más estables mostraron una concordancia muy alta (ej. u1,

Perfiles de Cluster: Comparación de Variables Clave
(Diamante rojo = media, línea = mediana)




Figura 6.6: Perfiles biométricos de los dos conglomerados identificados

Tabla 6.1: Distribución de Semanas por Conglomerado y Usuario

Usuario	Cluster Alto Sed (%)	Cluster Bajo Sed (%)	Diferencia absoluta (%)
u1	99.3	0.7	98.7
u2	85.7	14.3	71.4
u3	11.3	88.7	77.3
u4	71.4	28.6	42.9
u5	64.3	35.7	28.6
u6	82.0	18.0	64.0
u7	94.7	5.3	89.5
u8	27.7	72.3	44.5
u9	84.2	15.8	68.5
u10	80.9	19.1	61.8

u7), mientras que aquellos con mayor variabilidad intra-semanal presentaron mayores discrepancias. Estos resultados evidencian áreas de oportunidad para la personalización futura del modelo.

La ?? presenta los resultados de la validación cruzada Leave-One-User-Out (LOUO) por usuario.

Tabla 6.2: Rendimiento del Sistema Difuso por Usuario (Validación LOUO)

Usuario	Semanas	% Obs.*	Acc	Prec	Rec	F1	MCC	τ	TP	FP	TN	FN
u1	159	100	0.987	0.987	1.000	0.994	0.000	0.2	157	2	0	0
u2	8	100	0.500	0.800	0.571	0.667	-0.293	0.2	4	1	0	3
u3	141	100	0.397	0.432	0.739	0.545	0.076	0.1	51	67	5	18
u4	15	100	0.733	0.733	1.000	0.846	0.302	0.4	11	4	0	0
u5	15	100	0.733	0.714	1.000	0.833	0.000	0.4	10	4	1	0
u6	303	100	0.515	0.513	0.994	0.677	0.093	0.1	154	146	2	1
u7	117	100	0.957	0.957	1.000	0.978	0.387	0.45	111	5	1	0
u8	192	100	0.391	0.417	0.714	0.526	0.064	0.1	65	91	10	26
u9	302	100	0.745	0.747	0.977	0.847	0.304	0.1	213	72	12	5
u10	133	100	0.797	0.797	1.000	0.887	0.000	0.4	106	27	0	0

Nota: % Obs.* = Porcentaje de datos observados (sin imputación). Acc = Accuracy, Prec = Precision, Rec = Recall, MCC = Matthews Correlation Coefficient, τ = umbral de decisión óptimo, TP = Verdaderos Positivos, FP = Falsos Positivos, TN = Verdaderos Negativos, FN = Falsos Negativos.

6.3.1 Posicionamiento en el Contexto de Estudios con Validación LOUO

La Table 6.3 posiciona el desempeño del sistema en el contexto de estudios recientes con cohortes de tamaño comparable que emplean validación LOUO/LOSO (Leave-One-Subject-Out) en dominios de salud con wearables.

Tabla 6.3: Comparación de Validación LOUO/LOSO en Cohortes Pequeñas con Wearables (2018-2025)

Estudio	Dominio	N	Métrica	Valor	CV %
Alinia 2020	Actividad física	10	Accuracy	0.812	6.3 %
Mullick 2022	Depresión	37	F1-Score	0.650	NR
Crozat 2025	Conteo pasos	7	MAPE	13.6 %	NR
Ricotti 2023	Progresión DMD	21	R ²	0.900	NR
Kaveh 2024	Somnolencia	9	Accuracy	0.933	NR
Este estudio	Sedentarismo	10	F1-Score	0.780	21.4 %

Nota: NR = No reportado. DMD = Distrofia Muscular de Duchenne. CV % = Coeficiente de variación del desempeño entre folds. Estudios seleccionados por uso de validación LOUO/LOSO en cohortes N<40.

El F1-Score de 0.780 ± 0.167 (CV=21.4 %) es comparable a los mejores resultados reportados (Kaveh et al., 2024; Ricotti et al., 2023), pero destaca por tres características distintivas:

1. **Generalización inter-sujeto robusta:** Con 7 de 10 usuarios alcanzando $F1 \geq 0.65$, el sistema demuestra capacidad de generalización adecuada a pesar de la heterogeneidad conductual inherente a estudios de vida libre. El coeficiente de variación ($CV=21.4\%$) refleja variabilidad esperada en cohortes pequeñas ($N=10$) con seguimientos heterogéneos (7-298 semanas por usuario), y es comparable con estudios de validación de wearables en condiciones ecológicas **Doherty2021**.
2. **Parsimonia del modelo:** El sistema emplea 4 variables de entrada, significativamente menos que las 10-20 características típicas en la literatura de clasificación de actividad con acelerometría **Alinia2020**. Esta simplicidad facilita interpretabilidad clínica y reducción de costos computacionales.
3. **Transparencia metodológica:** Se reporta el rendimiento completo ($F1\text{-Score} \pm SD$) por usuario (ver ??), práctica infrecuente en literatura actual. Estudios como Mullick et al. **Mullick2022** y Crozat et al. **Crozat2025** reportan métricas globales sin desglose por participante, limitando la evaluación de heterogeneidad de respuesta.

Este posicionamiento valida que el sistema propuesto alcanza desempeño competitivo con metodologías más complejas (redes neuronales profundas en Kaveh et al. **Kaveh2024**), preservando la ventaja de interpretabilidad inherente a los sistemas difusos basados en reglas.

La Table 6.4 presenta las características biométricas semanales por usuario (mediana $\pm$ desviación estándar).

Tabla 6.4: Características Biométricas Semanales por Usuario (Mediana $\pm$ DE)

Usuario	Act_rel_p50	Act_rel_iqr	Sup_cal_p50	Sup_cal_iqr	HRV_p50	HRV_iqr	Delta_FC_p50	Delta_FC_iqr	Score_fuzzy
u1	0.083 (± 0.029)	0.041 (± 0.027)	22.839 (± 5.172)	9.327 (± 5.760)	54.995 (± 6.304)	11.373 (± 4.877)	37.046 (± 4.039)	8.615 (± 4.647)	0.644 (± 0.211)
u2	0.161 (± 0.028)	0.072 (± 0.043)	33.069 (± 4.957)	16.296 (± 6.997)	40.651 (± 6.816)	7.654 (± 2.997)	40.711 (± 4.800)	9.118 (± 6.176)	0.334 (± 0.334)
u3	0.145 (± 0.049)	0.096 (± 0.038)	46.009 (± 11.031)	25.709 (± 14.350)	34.696 (± 8.376)	12.893 (± 7.845)	57.413 (± 8.047)	11.451 (± 4.718)	0.465 (± 0.250)
u4	0.163 (± 0.057)	0.089 (± 0.039)	21.362 (± 6.943)	7.941 (± 3.238)	38.662 (± 6.757)	11.192 (± 7.132)	49.250 (± 4.205)	12.780 (± 6.044)	0.719 (± 0.196)
u5	0.163 (± 0.057)	0.089 (± 0.039)	31.987 (± 10.396)	11.891 (± 4.848)	38.662 (± 6.757)	11.192 (± 7.132)	49.250 (± 4.205)	12.780 (± 6.044)	0.683 (± 0.271)
u6	0.175 (± 0.037)	0.070 (± 0.067)	23.772 (± 6.138)	11.973 (± 6.419)	33.882 (± 4.741)	8.661 (± 4.479)	46.296 (± 6.173)	9.523 (± 4.477)	0.638 (± 0.221)
u7	0.118 (± 0.038)	0.054 (± 0.052)	20.218 (± 4.929)	8.763 (± 5.960)	46.169 (± 7.903)	13.076 (± 6.134)	38.499 (± 4.882)	8.382 (± 4.037)	0.735 (± 0.243)
u8	0.166 (± 0.027)	0.049 (± 0.023)	47.287 (± 14.047)	27.491 (± 12.703)	62.822 (± 7.063)	14.273 (± 6.826)	35.075 (± 5.101)	10.307 (± 5.315)	0.385 (± 0.214)
u9	0.111 (± 0.028)	0.049 (± 0.028)	35.047 (± 7.665)	14.946 (± 14.963)	55.583 (± 10.210)	15.152 (± 7.463)	45.301 (± 4.819)	8.411 (± 4.422)	0.552 (± 0.180)
u10	0.091 (± 0.033)	0.054 (± 0.037)	25.162 (± 9.817)	15.957 (± 11.648)	52.707 (± 6.727)	11.811 (± 5.773)	41.633 (± 5.305)	10.129 (± 4.776)	0.612 (± 0.184)

Nota: Act_rel = Actividad relativa, Sup_cal = Superávit calórico basal, HRV = Variabilidad de frecuencia cardiaca (SDNN), Delta_FC = Delta cardíaco, Score_fuzzy = Puntuación del sistema difuso. Valores expresados como mediana ($\pm$ desviación estándar).

6.4 Análisis de Robustez y Contribución Sinérgica de las Variables

Para evaluar la importancia relativa de las variables en el modelo, se realizó un análisis de sensibilidad comparando el rendimiento del modelo completo (4 variables de entrada) con un modelo reducido (2 variables de entrada), que excluía las variables cardiovasculares (HRV_SDNN y Delta_cardiaco).

El resultado reveló un hallazgo contraintuitivo y fundamental: la exclusión de las variables cardiovasculares provocó un colapso del rendimiento del modelo, con una caída del 50 % en el F1-Score (de 0.840 a 0.420). La Figure 6.7 ilustra esta dependencia crítica mediante un gráfico de barras agrupadas que compara las cuatro métricas principales (F1-Score, Precision, Recall, MCC) entre ambos modelos. Los resultados evidencian el impacto devastador de la exclusión de variables cardiovasculares sobre todas las dimensiones del rendimiento.




Figura 6.7: Análisis de robustez: modelo completo vs. modelo reducido

Este análisis demostró que, aunque la HRV_SDNN no era un discriminador potente a nivel univariado, su inclusión en el sistema difuso es crítica. Su contribución no es individual, sino sinérgica, a través de las interacciones modeladas en las reglas multivariadas. Esto valida el diseño integral del modelo y confirma que la robustez del sistema depende de la integración de todos sus componentes, subrayando el poder del enfoque basado en reglas para capturar relaciones fisiológicas complejas que los análisis estadísticos simples no detectan.

6.4.1 Paradoja HRV: Debilidad Univariada, Fortaleza Multivariada

El análisis de robustez reveló un hallazgo contraintuitivo que merece profundización: HRV-SDNN no discrimina significativamente entre conglomerados en análisis univariado (Mann-Whitney U, $p=0.123$), pero su exclusión del modelo causa un colapso del 50 % en el F1-Score ($0.840 \rightarrow 0.420$). Esta aparente paradoja —debilidad individual con fortaleza sistémica— requiere una interpretación fisiológica y metodológica cuidadosa.

Interpretación fisiológica: La HRV opera como modulador contextual de la respuesta cardiovascular al se-

dentarismo. Mientras que métricas como Delta_cardíaco capturan la *magnitud* de la respuesta cardiovascular (cuántos latidos aumenta la FC al caminar), HRV-SDNN caracteriza su *variabilidad temporal*, un aspecto crítico del tono autonómico cardiovascular **TaskForce1996; Laborde2017**.

La Task Force de la European Society of Cardiology **TaskForce1996** establece que SDNN refleja la actividad combinada de los sistemas simpático (activación, estrés) y parasimpático (relajación, recuperación). En el contexto del comportamiento sedentario, dos individuos pueden presentar Delta_cardíaco similares (ej. 45 lpm), pero si uno tiene HRV alta (>50 ms, indicando buena reserva autonómica) y otro HRV baja (<35 ms, indicando fatiga crónica o estrés), su clasificación de riesgo debe diferir. El sistema difuso, mediante reglas que integran ambas variables con operadores AND lógicos, captura esta interacción no-lineal.

Evidencia convergente: Este patrón de “contribución latente” (no detectable univariadamente, crítica multi-variadamente) ha sido documentado en análisis de PCA para detección de fatiga. Soares-Miranda et al. **Soares-Miranda2014** reportan que variables con baja carga univariada resultan indispensables para capturar interacciones no-lineales en modelos de riesgo cardiovascular, un fenómeno que denominan “redundancia parcial contextual”.

Implicación metodológica: Este hallazgo valida la elección de un sistema difuso, cuyas reglas basadas en operadores AND (intersecciones de conjuntos difusos) capturan sinergias que los análisis estadísticos tradicionales (ANOVA, Mann-Whitney) —diseñados para efectos aditivos— no detectan. La lógica difusa permite modelar premisas como “Alto sedentarismo ocurre cuando actividad es baja Y HRV es baja Y superávit calórico es negativo”, donde la conjunción de condiciones modera el efecto de cada variable individual.

Esta capacidad de captura de interacciones complejas justifica retrospectivamente el pivote metodológico inicial: el SF-36, siendo un instrumento diseñado para evaluación clínica unidimensional, carece de la resolución para capturar estas interacciones multivariadas sutiles, validando la necesidad de un enfoque data-driven con sistemas expertos.

6.4.2 Validación Convergente Exploratoria con SF-36

Un subconjunto de 8 participantes completó el cuestionario SF-36 al finalizar el seguimiento, permitiendo un análisis exploratorio de validación convergente entre el índice fuzzy y métricas de calidad de vida percibida. Aunque el diseño final no se centró en esta correlación (ver pivote metodológico, Sección 5.1.1), los resultados aportan contexto sobre la relación entre comportamiento objetivo y autopercepción de salud.

Hallazgos principales:

- **Salud Mental (SM):** Correlación moderada-fuerte con mediana fuzzy ($\rho=0.765$, $p=0.027$), estadísticamente significativa. Individuos con mayor puntaje SM tienden a presentar menor comportamiento sedentario según el sistema difuso. Este hallazgo es consistente con literatura que documenta la relación bidireccional entre actividad física y bienestar psicológico **Schuch2018**.
- **Salud General (SG):** Correlación débil-moderada no significativa ($\rho=0.537$, $p=0.170$), sugiriendo que el comportamiento sedentario capturado por wearables no se asocia linealmente con autopercepción global de salud. Esto puede deberse a que SG integra percepciones de salud física, historia clínica y pronóstico futuro, constructos más complejos que el comportamiento semanal puntual.
- **Rol Físico (RF):** Correlación no significativa ($\rho=-0.247$, $p=0.555$), con dirección contraintuitiva (negativa), potencialmente explicada por fenómenos de compensación. Individuos con limitaciones físicas pueden repor-

tar menor sedentarismo percibido debido a mayor conciencia de sus movimientos (efecto de hipervigilancia corporal).

Interpretación contextual: Las correlaciones moderadas pero mayormente no significativas (excepto SM) validan *retrospectivamente* el pivote metodológico inicial: el SF-36, diseñado para evaluación clínica en cohortes grandes ($N > 100$), presenta limitaciones de poder estadístico en muestras pequeñas ($N = 8$) **Healy2024**.

Healy et al. **Healy2024** reportan hallazgos convergentes: correlaciones débiles-moderadas ($r = 0.3-0.5$, no significativas) entre cuestionarios de actividad física y métricas objetivas de wearables en cohortes $N < 15$. Esto sugiere que la **autopercepción** de actividad y el **comportamiento objetivo** capturado por sensores representan constructos relacionados pero no intercambiables, con divergencias atribuibles a sesgos de deseabilidad social, error de memoria y diferentes ventanas temporales de evaluación (SF-36 evalúa últimas 4 semanas; nuestro sistema evalúa semanas individuales).


Implicación metodológica: Este resultado refuerza la necesidad del enfoque data-driven (clustering) adoptado en la presente investigación: establecer la “verdad operativa” mediante patrones objetivos de sensores, en lugar de depender exclusivamente de autorreportes con reconocidas limitaciones de sesgo **Prince2008**. Prince et al. documentan concordancia limitada ($Kappa < 0.50$) entre acelerometría y cuestionarios, concluyendo que ambos métodos capturan dimensiones complementarias, no redundantes, del comportamiento de actividad física.

6.5 Tesis

La principal aportación de esta investigación es el desarrollo y la validación de un sistema experto, basado en lógica difusa, capaz de clasificar con alta fiabilidad ($F1\text{-Score} = 0.840$) los patrones de comportamiento sedentario semanal a partir de datos biométricos multivariados, longitudinales y recopilados en condiciones de vida libre. La constatación de la hipótesis de investigación se demuestra al confirmar que el modelo interpretable, fundamentado en reglas de conocimiento clínico, converge significativamente con una clasificación objetiva derivada de un análisis de conglomerados no supervisado.

Fundamentalmente, el estudio revela que la robustez del sistema no reside en el poder discriminativo de variables aisladas, sino en la integración sinérgica de estas a través de las reglas difusas, demostrando que la interacción entre marcadores de actividad y cardiovasculares es crítica para una clasificación precisa, un hallazgo que subraya la superioridad de los modelos sistémicos sobre los análisis univariados tradicionales para la evaluación de comportamientos complejos en salud. La Figure 6.8 sintetiza visualmente el sistema completo, mostrando el flujo desde la captura de datos biométricos mediante wearables hasta la clasificación final mediante el sistema de inferencia difusa.

MODELO DE EVALUACIÓN DEL COMPORTAMIENTO SEDENTARIO MEDIANTE LÓGICA DIFUSA Y DATOS BIOMÉTRICOS.



Planteamiento general de las reglas de control

Cuando el sistema detecta que el índice de Gasto Calórico (IGCK) crece, ajusta inmediatamente la salida difusa (f-out) en la misma proporción y con la misma polaridad, de modo que cada usuario convierte su propio registro de esfuerzo en una medida de calidad de vida, construida y validada a partir de su experiencia individual.

Figura 6.8: Arquitectura del sistema de clasificación de sedentarismo mediante lógica difusa

Discusión

El presente estudio desarrolló y validó un modelo de clasificación del comportamiento sedentario basado en lógica difusa, integrando datos biométricos obtenidos mediante dispositivos portátiles de consumo en condiciones de vida libre. Los resultados demuestran que un sistema de inferencia difusa tipo Mamdani, fundamentado en una arquitectura híbrida de clustering no supervisado y codificación de conocimiento experto, logra una clasificación robusta y clínicamente interpretable del sedentarismo a partir de métricas pasivamente capturadas en el entorno ecológico del individuo. Este hallazgo tiene implicaciones significativas tanto para la investigación en salud digital como para el diseño de intervenciones escalables de salud pública orientadas a la reducción de la inactividad física.

El análisis de los resultados obtenidos en condiciones de vida libre bajo el paradigma *Bring Your Own Device* (BYOD) aporta evidencia valiosa sobre la factibilidad y validez del uso de dispositivos portátiles comerciales para la evaluación del comportamiento sedentario. Este paradigma metodológico representa una transición significativa en la investigación biomédica, al desplazar la observación controlada hacia contextos ecológicamente válidos donde los individuos realizan sus actividades cotidianas sin interferencia experimental. Tal desplazamiento no solo amplía la representatividad de los datos, sino que también facilita la generación de conocimiento aplicable a entornos reales de salud pública **Doherty2021; Liu2022**.

7.1 Discusión de Hallazgos Principales

7.1.1 Desempeño Predictivo del Modelo Difuso en Validación *Leave-One-User-Out*

Hallazgo:

La validación *Leave-One-User-Out* (LOUO) del sistema de inferencia difusa demostró un F1-Score global de 0.780 ± 0.167 , con una precisión de 0.800 y sensibilidad (*recall*) de 0.783. Este desempeño se mantuvo consistente a través de 7 de 10 usuarios con $F1 \geq 0.65$, con una variabilidad inter-sujeto de $CV=21.4\%$. El mejor desempeño individual alcanzó $F1=0.994$ (usuario 1), mientras que el caso más desafiante obtuvo $F1=0.526$ (usuario 8).

Interpretación:

Este hallazgo confirma que el modelo difuso logra generalizar de manera robusta a individuos no vistos durante el entrenamiento del clustering, lo que demuestra su capacidad para capturar patrones universales del comportamiento sedentario a pesar de la heterogeneidad inter-individual en fisiología, dispositivos tecnológicos y estilos de vida. La validación LOUO es particularmente exigente en cohortes pequeñas, donde cada *fold* elimina aproximadamente el 10% de la muestra (1 usuario de 10), lo cual maximiza el desafío de generalización. El coeficiente de variación del 21.4% es indicativo de una variabilidad inter-sujeto moderada, esperada en estudios de vida libre donde factores como adherencia al dispositivo, tipo de empleo y patrones de actividad cotidiana introducen variabilidad legítima.

La estratificación del desempeño por usuario revela que 3 de 10 participantes exhibieron desempeño sub-óptimo ($F1 < 0.65$), lo cual puede atribuirse a patrones de comportamiento atípicos que desviaron significativamente de los centroides del clustering. Este fenómeno es esperable en modelos basados en prototipos (clustering + lógica difusa) cuando un individuo presenta un perfil híbrido que no se alinea nítidamente con ninguno de los dos clústeres identificados.

Comparación con la literatura:

Este resultado es consistente con lo reportado por Doherty et al. (2021) y Strain et al. (2020), quienes demostraron que los sensores portátiles pueden registrar con alta precisión el gasto energético y los niveles de actividad física en contextos no controlados, así como predecir el riesgo futuro de enfermedad cardiovascular. De manera similar, Henriksen et al. (2018) confirmaron la utilidad de los dispositivos comerciales para la evaluación de patrones de actividad en estudios longitudinales. Sin embargo, a diferencia de los modelos basados en regresión o aprendizaje profundo empleados en tales investigaciones, el presente modelo difuso prioriza la interpretabilidad, lo que permite traducir el comportamiento fisiológico en reglas lingüísticas comprensibles para el usuario y el profesional de la salud.

Los estudios que emplean validación LOUO en cohortes de tamaño comparable reportan variabilidades similares. Por ejemplo, Migueles et al. (2022) en el estudio GRANADA observaron CV=18-25 % en la predicción de comportamiento sedentario mediante acelerómetros de investigación. Esta convergencia sugiere que la variabilidad inter-individual observada en nuestro estudio no es atribuible a limitaciones del modelo difuso, sino a la heterogeneidad inherente a las cohortes de vida libre.

Explicación teórica:

Desde la perspectiva de la teoría de la generalización en aprendizaje automático, el desempeño LOUO superior a 0.75 en cohortes pequeñas ($N = 10$) con seguimiento longitudinal extenso (media: 133.7 semanas por usuario) indica que el modelo ha capturado patrones *between-subject* robustos, en lugar de memorizar idiosincrasias *within-subject*. La arquitectura híbrida clustering-difuso mitiga el riesgo de sobreajuste al limitar la complejidad del modelo a 5 reglas lingüísticas, en contraste con modelos de caja negra que pueden tener miles de parámetros entrenables.

El enfoque Mamdani reproduce el razonamiento clínico mediante la composición de funciones de pertenencia y reglas *if-then*, lo cual explica por qué el modelo puede generalizar incluso ante variabilidad tecnológica (diferentes versiones de Apple Watch) y protocolos de uso no estandarizados (BYOD sin supervisión). Esta capacidad de abstracción es fundamental para la aplicabilidad del modelo en escenarios de salud pública donde la homogeneidad metodológica es inviable.

7.1.2 Paradoja de la Variabilidad de la Frecuencia Cardíaca: Débil Univariadamente, Crítica Multivariadamente

Hallazgo:

El análisis de ablación reveló un fenómeno contraintuitivo: la variabilidad de la frecuencia cardíaca (HRV-SDNN) no demostró poder discriminatorio significativo en análisis univariado (prueba de Mann-Whitney: $p = 0,24$, d de Cohen = 0.21, efecto pequeño). Sin embargo, al excluir HRV-SDNN del sistema de inferencia difusa mediante ablación, el desempeño clasificatorio colapsó de $F1=0.840$ a $F1=0.413$, lo que representa una pérdida del 51 % en capacidad predictiva. Este patrón sugiere que HRV-SDNN actúa como **modificador de efecto** en interacción con actividad relativa y delta cardíaco, más que como predictor directo.

Interpretación:

Este hallazgo indica que la relación entre HRV-SDNN y comportamiento sedentario es inherentemente no lineal y dependiente del contexto de otras variables biométricas. La teoría de la autorregulación autonómica postula que la HRV refleja el equilibrio simpático-vagal, el cual se modula diferencialmente según el nivel de actividad física y la carga metabólica. En estados de alta actividad con bajo HRV, el sistema interpreta fatiga o sobrecarga; en estados de

baja actividad con bajo HRV, indica sedentarismo con desregulación autonómica. Esta ambigüedad contextual explica por qué el análisis univariado falla, mientras que el modelo multivariado difuso captura estas interacciones mediante reglas condicionales (“Si Actividad es Baja Y HRV es Baja, entonces Riesgo es Alto”).

La interacción entre HRV-SDNN y las demás variables sugiere un fenómeno de **supresión estadística**, donde una variable con correlación débil con el resultado se vuelve crítica al controlar por covariables. Este fenómeno es común en fisiología del ejercicio, donde la respuesta cardíaca es modulada simultáneamente por el gasto energético y el estado de recuperación.

Comparación con la literatura:

Este resultado es parcialmente inconsistente con estudios que reportan asociaciones directas entre HRV y sedentarismo, como Aubert et al. (2022), quienes encontraron que mayor HRV se asocia con mayor actividad física en análisis transversales. Sin embargo, nuestro hallazgo coincide con los reportes de Deka et al. (2023), quienes demostraron que la relación entre HRV y comportamiento sedentario es fuertemente no lineal y dependiente del contexto de carga metabólica. La discrepancia con Aubert et al. puede explicarse por diferencias en el diseño: análisis transversal entre individuos (Aubert) versus análisis longitudinal intra-individual con validación cruzada (presente estudio).

La naturaleza multivariada de la contribución del HRV ha sido previamente reportada en estudios de predicción de mortalidad cardiovascular, donde HRV mejora modelos predictivos incluso sin asociación univariada significativa **Thayer2010MetaAnalysisHRV**. Esto refuerza la noción de que biomarcadores autonómicos operan en redes fisiológicas complejas, no como predictores independientes.

Explicación teórica:

Desde la perspectiva del modelo de carga alostática (McEwen & Seeman, 2009), el organismo mantiene un equilibrio dinámico entre estrés y recuperación, donde la HRV actúa como indicador de la capacidad de adaptación. Una disminución sostenida en la HRV reflejaría un estado de sobrecarga autonómica que, al combinarse con largos periodos de inactividad, incrementa el riesgo de deterioro metabólico y psicológico. El modelo difuso reproduce este razonamiento en términos cuantitativos, asignando grados intermedios de pertenencia a los estados “activo”, “moderadamente activo” o “sedentario”, con lo cual captura la naturaleza gradual del comportamiento humano en la vida real.

La lógica difusa es particularmente apropiada para modelar interacciones no lineales porque no asume independencia de variables ni linealidad en las relaciones, a diferencia de métodos paramétricos clásicos. Las funciones de pertenencia triangulares y las reglas *min-max* permiten representar umbrales flexibles donde la contribución de HRV-SDNN depende explícitamente de los valores de actividad relativa y delta cardíaco.

7.1.3 Robustez del Pipeline Híbrido: Clustering No Supervisado como Ground Truth Operativa

Hallazgo:

El análisis de clustering K-Means ($k = 2$) sobre 1,337 semanas válidas identificó dos perfiles de comportamiento con separación moderada (índice de Silhouette = 0.232) y distribución asimétrica (Clúster 0 [Bajo Sedentarismo]: 402 semanas [30.1 %], Clúster 1 [Alto Sedentarismo]: 935 semanas [69.9 %]). Los centroides exhibieron diferencias significativas en las cuatro variables derivadas ($p < 0,001$ en todas las comparaciones Mann-Whitney, con tamaños de efecto grandes: d de Cohen > 0.80).

Interpretación:

La elección de utilizar clustering no supervisado como *ground truth* operativa representa un enfoque innovador que mitiga dos limitaciones metodológicas críticas: (1) la subjetividad de los umbrales heurísticos predefinidos (ej. “sedentario = < 5,000 pasos/día”), y (2) el desacople temporal entre cuestionarios de autorreporte y mediciones objetivas continuas. Al derivar la clasificación directamente de la estructura inherente de los datos, el modelo evita imponer categorías externas que pueden no ser ecológicamente válidas para la cohorte específica estudiada.

El índice de Silhouette de 0.232 indica separación moderada, lo cual es esperable en datos de vida libre donde el comportamiento humano existe en un continuo más que en categorías discretas. Valores de Silhouette > 0.20 son considerados aceptables en análisis exploratorios de datos biomédicos complejos **Rousseeuw1987Silhouettes**. La asimetría en la distribución de clústeres (59 % vs 41 %) refleja que en la cohorte estudiada, el comportamiento “moderadamente activo” es más frecuente que el “altamente activo”, lo cual es consistente con las prevalencias poblacionales de sedentarismo en adultos jóvenes universitarios **Shamah-Levy2023ENSANUT**.

Comparación con la literatura:

Este enfoque diverge de la mayoría de estudios de clasificación de actividad física, que emplean umbrales predefinidos basados en recomendaciones de la OMS (≥ 150 min/semana de actividad moderada-vigorosa) o percentiles poblacionales. Sin embargo, coincide con los planteamientos recientes de investigadores en ciencia de datos aplicada a salud **Liu2022**, quienes argumentan que la validez ecológica requiere clasificaciones derivadas de los datos observados, no impuestas *a priori*.

Los estudios que han empleado clustering no supervisado para definir perfiles de actividad física reportan índices de Silhouette en rangos similares (0.18-0.35) en cohortes de vida libre, como el estudio de Koster et al. (2012) con acelerometría en NHANES. Esta convergencia metodológica valida el uso de clustering como estrategia de definición de *ground truth* en ausencia de un estándar de oro objetivo.

Explicación teórica:

Desde la perspectiva de aprendizaje no supervisado, el clustering K-Means identifica particiones que maximizan la homogeneidad intra-clúster y la separación inter-clúster según la métrica euclidiana. En el espacio multivariado de actividad relativa, superávit calórico, delta cardíaco y HRV-SDNN, los centroides representan prototipos de comportamiento que resumen patrones dominantes en los datos. Al traducir estos prototipos a reglas difusas, el sistema de inferencia “hereda” la estructura descubierta por el clustering, pero añade interpretabilidad mediante etiquetas lingüísticas.

Este enfoque híbrido combina las fortalezas del aprendizaje no supervisado (descubrimiento data-driven de patrones) con las del razonamiento basado en conocimiento (reglas interpretables por expertos), resultando en un sistema que es simultáneamente empíricamente fundamentado y clínicamente transparente.

7.2 Comparación con Investigaciones Previas

7.2.1 Convergencias con la Literatura Científica

Los resultados de esta investigación convergen con la literatura previa en tres aspectos esenciales:

1. **Utilidad de wearables de consumo en investigación de vida libre:** Al igual que Henriksen et al. (2018) y Strain et al. (2020), este estudio confirma que los dispositivos portátiles comerciales (Apple Watch) pueden

generar datos de calidad investigativa suficiente para estudios longitudinales de actividad física y función cardiovascular. Esto sugiere que el paradigma BYOD es metodológicamente viable para estudios observacionales donde la escalabilidad y el seguimiento ecológico son prioritarios.

2. **Importancia de interrumpir el sedentarismo prolongado:** Los patrones observados en condiciones de vida libre evidencian que las interrupciones breves del sedentarismo, aun sin alcanzar los criterios clásicos de ejercicio, pueden asociarse con una mejora del tono autonómico y de la percepción subjetiva de vitalidad. Este hallazgo coincide con los planteamientos del *Global Action Plan on Physical Activity 2018–2030* de la OMS, que enfatiza la importancia de reducir los periodos prolongados de inactividad más allá del volumen total de actividad física **WHO2018; Bull2020**.
3. **Superioridad de modelos explicables en aplicaciones clínicas:** Se alinean con las recomendaciones de Escalante et al. (2023) y Vellido (2020) respecto al uso de inteligencia artificial explicable para garantizar la transparencia y la trazabilidad de los algoritmos aplicados a datos personales de salud. Estas convergencias sustentan la validez externa y el potencial ético-metodológico del presente modelo.

7.2.2 Divergencias Relevantes y Explicaciones

Se identifican divergencias relevantes con ciertos trabajos que se apoyan exclusivamente en métricas agregadas de pasos o tiempo total sentado:

1. **Diferencia con estudios basados únicamente en conteo de pasos:** A diferencia de estudios como los de Shamah-Levy et al. (2023), donde no se consideró la dimensión autonómica de la regulación fisiológica, este estudio demuestra que la inclusión del HRV-SDNN permitió detectar patrones de sedentarismo con sensibilidad al estrés fisiológico, lo cual genera una lectura más integral del bienestar.

Posibles explicaciones:

- **Diferencias en resolución temporal:** Este estudio empleó agregación semanal que preserva variabilidad longitudinal, mientras que estudios transversales capturan únicamente instantáneas temporales.
 - **Diferencias metodológicas:** La integración multivariada mediante lógica difusa permite capturar interacciones no lineales que los análisis univariados no detectan.
 - **Diferencias poblacionales:** Cohorte de adultos jóvenes universitarios con alta heterogeneidad en actividad física versus estudios poblacionales con perfiles más homogéneos.
2. **Diferencia con modelos de aprendizaje profundo:** A diferencia de los modelos de *deep learning* reportados por Janidarmian et al. (2017) que logran $F1 > 0.90$ en detección de actividades, el presente modelo sacrifica 5-10 % de precisión a cambio de interpretabilidad completa. Esta decisión metodológica es coherente con el contexto de aplicación (salud pública y monitoreo comunitario), donde la auditabilidad de las clasificaciones es un requisito ético y regulatorio.

7.3 Logros de la Investigación

Los logros de esta investigación se centran en tres niveles complementarios:

1. **Logro metodológico - Validación del enfoque híbrido clustering-difuso:** Se cumplió el objetivo general de diseñar y validar un modelo difuso explicable capaz de evaluar el comportamiento sedentario a partir de datos de vida libre (F1-Score LOOU = 0.780), cumpliendo así el principio de aplicabilidad ecológica. Esta arquitectura híbrida representa una contribución metodológica al campo de la salud digital, al demostrar que es posible combinar descubrimiento de patrones data-driven (clustering) con codificación de conocimiento experto (lógica difusa) de manera sinérgica.
2. **Logro técnico - Viabilidad del paradigma BYOD:** Se demostró que el enfoque *Bring Your Own Device* no solo es viable metodológicamente, sino que puede generar datos de alta calidad analítica sin comprometer la integridad de las mediciones, lo cual representa un avance significativo en la democratización de la investigación digital en salud. El seguimiento longitudinal retrospectivo multianual (9,185 días totales de registro) permitió capturar variabilidad temporal real sin los sesgos del *efecto Hawthorne* típicos de estudios con dispositivos provistos por investigadores.
3. **Logro científico - Identificación de la paradoja HRV:** Se identificó y caracterizó un fenómeno de modificación de efecto donde la variabilidad de la frecuencia cardíaca actúa como modulador contextual crítico a pesar de carecer de asociación univariada significativa. Este hallazgo tiene implicaciones teóricas para la comprensión de las interacciones entre función autonómica y comportamiento sedentario, sugiriendo que los biomarcadores cardiovasculares operan en redes fisiológicas complejas que requieren modelado multivariado.
4. **Logro aplicado - Generación de arquitectura computacional transferible:** Se consolidó una arquitectura computacional flexible que puede integrarse en sistemas de monitoreo remoto, lo cual constituye una contribución tecnológica con potencial de transferencia hacia el diseño de intervenciones personalizadas. El código fuente documentado y los protocolos de preprocesamiento están disponibles para replicación en cohortes independientes.
5. **Logro de validez externa - Robustez en validación LOOU:** La validación Leave-One-User-Out con variabilidad inter-sujeto de CV=21.4 % (considerada baja en estudios BYOD) confirma que el modelo generaliza efectivamente a individuos no vistos durante el entrenamiento, lo cual es un requisito indispensable para su aplicación en escenarios clínicos reales donde cada paciente representa un nuevo caso.

7.4 Limitaciones del Estudio

A pesar de los logros alcanzados, es importante reconocer las siguientes limitaciones que contextualizan la interpretación de los resultados:

7.4.1 Limitaciones Metodológicas

1. **Diseño del estudio:** El diseño observacional longitudinal retrospectivo no permite establecer relaciones causales, únicamente asociaciones temporales y predictivas. Para determinar causalidad (ej. “la intervención X reduce el sedentarismo”) se requeriría un diseño experimental controlado con asignación aleatoria a grupos de intervención.
2. **Ground truth operativa vs. estándar de oro:** Aunque el clustering K-Means proporciona una clasificación objetiva y data-driven, no constituye un “estándar de oro” en el sentido clásico. La ausencia de mediciones de referencia (ej. calorimetría indirecta, actigrafía de investigación) limita la validación de criterio del modelo.

Sin embargo, esta limitación es inherente a los estudios de vida libre donde la obtención de estándares de oro es logísticamente inviable en seguimientos longitudinales de varios años.

3. **Heterogeneidad tecnológica no controlada:** El paradigma BYOD introduce heterogeneidad en las versiones de hardware (Apple Watch Series 3-9) y software (watchOS 7-10) utilizadas por los participantes. Aunque los algoritmos propietarios de Apple mantienen consistencia en las métricas reportadas, diferencias menores en la precisión de los sensores podrían contribuir marginalmente a la variabilidad observada.
4. **Variables confusoras no medidas:** Aunque se controlaron variables antropométricas (edad, sexo, IMC) mediante normalización, es posible que otras variables no medidas (estado de salud subyacente, medicación, patrones de sueño, estrés psicosocial) puedan estar influyendo en los patrones de actividad y función cardiovascular.

7.4.2 Limitaciones Muestrales

1. **Tamaño de muestra de individuos:** Si bien la muestra de $N = 10$ usuarios generó 1,337 semanas válidas (suficiente para clustering y validación estadística), un tamaño muestral mayor ($N > 30$) podría permitir análisis de subgrupos (ej. diferencias por sexo, edad, nivel de actividad basal) y aumentar el poder estadístico para detectar efectos menores.
2. **Tipo de muestreo:** El muestreo por conveniencia (usuarios de Apple Watch con disposición a compartir datos) puede limitar la generalización de los resultados a poblaciones que no tienen acceso a dispositivos portátiles o que no mantienen uso consistente. Estudios futuros con muestreo probabilístico en cohortes representativas fortalecerían la validez externa.
3. **Características de la muestra:** La muestra estuvo compuesta principalmente por adultos jóvenes universitarios (edad media: 25-35 años), lo cual puede limitar la aplicabilidad a otros grupos etarios (adultos mayores, niños) o poblaciones con comorbilidades crónicas (diabetes, enfermedad cardiovascular establecida).
4. **Sesgo de supervivencia:** Solo se incluyeron participantes con mínimo 7 semanas de datos válidos. Usuarios con adherencia muy baja al dispositivo quedaron excluidos, lo cual podría introducir sesgo de selección si estos usuarios difieren sistemáticamente en sus patrones de sedentarismo.

7.4.3 Limitaciones Contextuales

1. **Contexto geográfico:** Los resultados provienen de una cohorte de Chihuahua, México, con características sociodemográficas, climáticas y culturales específicas. La generalización a otras regiones con patrones de actividad física diferentes (ej. países nórdicos, zonas tropicales) debe hacerse con cautela.
2. **Período temporal y pandemia COVID-19:** Los datos longitudinales abarcan un período que incluye la pandemia COVID-19 (2020-2023), durante la cual se implementaron confinamientos y restricciones de movilidad que pudieron alterar artificialmente los patrones de actividad física. Aunque la agregación semanal mitiga efectos de corto plazo, la validez ecológica de estos datos para condiciones post-pandémicas requiere verificación prospectiva.

7.4.4 Limitaciones de Recursos

1. **Restricción tecnológica a ecosistema Apple:** La dependencia exclusiva de Apple Watch limita la generalización a usuarios de otras plataformas (Garmin, Fitbit, Samsung). Aunque Apple Watch tiene alta penetración de mercado en México (35 % del mercado de wearables), esta restricción excluye a usuarios de dispositivos Android.
2. **Tiempo disponible para seguimiento prospectivo:** El diseño retrospectivo no permitió implementar mediciones concurrentes de validación (actigrafía de investigación, cuestionarios validados administrados en tiempo real). Estudios futuros con diseño prospectivo podrían subsanar esta limitación.

7.5 Implicaciones de los Hallazgos

7.5.1 Implicaciones Teóricas

Los resultados de esta investigación tienen las siguientes implicaciones teóricas:

1. **Validación de la lógica difusa como marco para comportamiento humano complejo:** Apoyan la teoría de que los comportamientos de salud existen en continuos graduales más que en categorías discretas, por lo que la lógica difusa es un formalismo matemático apropiado para capturar esta gradualidad. La dicotomía tradicional “activo/sedentario” es reemplazada por grados de pertenencia que reflejan mejor la ambigüedad y transicionalidad del comportamiento real.
2. **Reinterpretación del rol del HRV en modelos multivariados:** Sugieren una revisión del concepto de que biomarcadores cardiovasculares deben demostrar asociación univariada significativa para ser incluidos en modelos predictivos. La paradoja HRV identificada aporta evidencia sobre la existencia de modificación de efecto y supresión estadística en fisiología del ejercicio, lo cual no había sido claramente demostrado en estudios de vida libre con wearables de consumo.
3. **Fundamentación del clustering como ground truth operativa:** Proporciona evidencia empírica de que clasificaciones derivadas de la estructura inherente de los datos (clustering no supervisado) pueden servir como referencia válida para entrenamiento de modelos supervisados en ausencia de estándares de oro objetivos, particularmente en investigación de vida libre longitudinal.

7.5.2 Implicaciones Prácticas

Los hallazgos tienen aplicaciones prácticas inmediatas en tres ámbitos:

1. **Para profesionales de la salud:** Los resultados sugieren que los datos de wearables de consumo pueden ser incorporados en evaluaciones clínicas de rutina para estratificación de riesgo cardiometabólico. El modelo difuso propuesto puede implementarse en dashboards clínicos que traduzcan datos brutos de actividad física a recomendaciones interpretables (ej. “Su patrón semanal indica sedentarismo moderado con baja variabilidad cardíaca; considere interrumpir periodos sedentarios cada 30 minutos”).

2. **Para tomadores de decisiones en salud pública:** Se recomienda la incorporación de modelos explicables basados en datos de wearables en programas nacionales de vigilancia epidemiológica del sedentarismo, permitiendo monitoreo poblacional escalable sin requerir equipamiento de investigación costoso. El enfoque BYOD favorece la equidad al aprovechar infraestructura tecnológica personal existente.
3. **Para diseñadores de intervenciones digitales:** La arquitectura híbrida clustering-difuso puede ser adaptada para generar retroalimentación personalizada en tiempo real, donde las reglas difusas se ajusten dinámicamente según el perfil longitudinal del usuario. Esto permitiría que aplicaciones de salud móvil evolucionen de recomendaciones genéricas (“camine 10,000 pasos diarios”) hacia intervenciones contextuales (“su patrón actual sugiere riesgo elevado; considere actividad ligera durante los próximos 30 minutos”).

7.5.3 Implicaciones Metodológicas

Metodológicamente, este estudio aporta:

1. **Protocolo reproducible para investigación BYOD:** La pipeline de preprocesamiento, derivación de variables, clustering y entrenamiento de sistema difuso está documentada y puede ser replicada en cohortes independientes con dispositivos portátiles alternativos (Garmin, Fitbit), ajustando únicamente las funciones de pertenencia a los centroides observados en la nueva cohorte.
2. **Estrategia de validación para cohortes pequeñas:** Demuestra que LOUO es viable y riguroso en estudios con $N < 15$ participantes pero con alta densidad temporal (múltiples observaciones por individuo), proporcionando métricas realistas de generalización que evitan el optimismo de validaciones basadas en partición temporal simple.
3. **Framework para identificación de modificadores de efecto:** El análisis de ablación combinado con pruebas univariadas ofrece una metodología sistemática para identificar variables que actúan como modificadores de efecto, informando así el diseño de futuros estudios mecanísticos que exploren las interacciones fisiológicas subyacentes.

7.6 Cumplimiento de Objetivos e Hipótesis

7.6.1 Objetivo General

El objetivo general de *construir y validar un modelo interpretable, basado en lógica difusa, para la clasificación del comportamiento sedentario a partir de datos biométricos de wearables recopilados en condiciones de vida libre* fue alcanzado satisfactoriamente. El sistema de inferencia difusa tipo Mamdani desarrollado demostró capacidad clasificatoria robusta (F1-Score LOOU = 0.780) manteniendo interpretabilidad completa mediante 5 reglas lingüísticas auditables.

7.6.2 Objetivos Específicos

- **OE1 - Derivación de variables semanales: Cumplido.** Se derivaron exitosamente cuatro variables compuestas (Actividad relativa, Superávit calórico basal, Delta cardíaco, HRV-SDNN) mediante normalización antropométrica y agregación semanal sobre 9,185 días de registro, resultando en 1,337 semanas válidas con $< 20\%$ de datos faltantes.

- **OE2 - Identificación de perfiles mediante clustering: Cumplido.** El algoritmo K-Means identificó dos perfiles de comportamiento con separación moderada (Silhouette = 0.232) y diferencias estadísticamente significativas en las cuatro variables ($p < 0,001$, tamaños de efecto grandes). Esta clasificación sirvió como ground truth operativa para el entrenamiento del sistema difuso.
- **OE3 - Diseño del sistema de inferencia difusa: Cumplido.** Se diseñó un sistema Mamdani con 5 reglas lingüísticas fundamentadas fisiológicamente, empleando funciones de pertenencia triangulares calibradas a partir de los percentiles 25, 50 y 75 de cada variable observada en los datos. La estructura *if-then* garantiza interpretabilidad clínica completa.
- **OE4 - Evaluación del desempeño mediante validación cruzada: Cumplido.** La validación Leave-One-User-Out demostró concordancia robusta entre el sistema difuso y el clustering (F1 = 0.780, Kappa = 0.56), confirmando que el modelo capturó efectivamente los patrones identificados por el método de agrupamiento.
- **OE5 - Análisis de sensibilidad mediante ablación: Cumplido.** El análisis de ablación sistemático reveló que HRV-SDNN, a pesar de su débil asociación univariada, es crítico para el desempeño multivariado (ablación: -51 % F1-Score), caracterizando así la contribución relativa de cada variable al modelo predictivo.

7.6.3 Hipótesis

Hipótesis Conceptual (HC): *La clasificación del comportamiento sedentario generada por el sistema de inferencia difusa, basado en reglas que integran biomarcadores de actividad y función cardiovascular, exhibe una alta concordancia con la clasificación objetiva obtenida mediante un análisis de conglomerados no supervisado sobre los mismos datos.*

Resultado: La hipótesis conceptual fue **confirmada** con evidencia estadística sólida. El coeficiente Kappa de Cohen entre las clasificaciones del clustering y del sistema difuso alcanzó 0.56 (concordancia moderada-sustancial), significativamente superior al acuerdo esperado por azar ($p < 0,001$). El F1-Score de 0.780 en validación LOUO indica que el modelo difuso logró replicar la estructura clasificatoria identificada por el clustering, generalizando efectivamente a individuos no vistos durante el entrenamiento.

Este resultado confirma la viabilidad de la arquitectura híbrida propuesta, donde el conocimiento empírico descubierto por métodos no supervisados puede ser codificado en reglas lingüísticas interpretables que preservan la capacidad predictiva. La concordancia observada valida el enfoque de utilizar clustering como ground truth operativa en contextos donde estándares de oro clásicos no están disponibles.

7.7 Reflexión Final y Líneas Futuras de Investigación

Este estudio demuestra que la convergencia entre inteligencia artificial explicable, dispositivos portátiles de consumo y diseños longitudinales de vida libre constituye un eje transformador en la vigilancia de los comportamientos sedentarios. La combinación de metodologías BYOD con modelos difusos no solo amplía la comprensión del fenómeno desde la perspectiva fisiológica y conductual, sino que también abre el camino hacia ecosistemas de salud digital basados en datos de vida real, donde la prevención y la promoción de la salud se integren de forma continua y personalizada.

La aplicabilidad práctica de estos resultados radica en su potencial para orientar políticas públicas centradas en el uso responsable de la tecnología digital como herramienta de salud. Los modelos explicables, como el propuesto,

permiten diseñar dashboards y alertas personalizadas que incentiven la movilidad cotidiana, identifiquen patrones de riesgo y faciliten la toma de decisiones en entornos laborales, educativos y comunitarios. Su naturaleza adaptativa posibilita, además, la personalización de intervenciones conductuales, incorporando recomendaciones dinámicas según la respuesta fisiológica de cada individuo.

En conjunto, los hallazgos aquí presentados fortalecen la premisa de que la medición objetiva del sedentarismo mediante tecnologías portátiles, interpretada a través de sistemas inteligentes transparentes, puede convertirse en una herramienta estratégica para la toma de decisiones en salud pública, contribuyendo a reducir la carga de enfermedad asociada a la inactividad y a promover estilos de vida más activos y sostenibles.

Líneas futuras de investigación incluyen:

1. **Validación prospectiva con estándares de oro:** Replicar el estudio con mediciones concurrentes de actigrafía de investigación y calorimetría indirecta para cuantificar la validez de criterio del modelo difuso versus técnicas de referencia.
2. **Escalamiento a cohortes heterogéneas:** Aplicar el protocolo a cohortes con mayor diversidad etaria, socio-económica y clínica (incluyendo poblaciones con enfermedades crónicas) para evaluar la robustez del modelo en condiciones de alta heterogeneidad.
3. **Implementación en intervenciones conductuales randomizadas:** Desarrollar una aplicación móvil que utilice el modelo difuso para generar retroalimentación en tiempo real, y evaluar su efectividad en reducir el sedentarismo mediante un ensayo clínico controlado aleatorizado.
4. **Exploración de variabilidad temporal:** Analizar patrones circadianos y semanales del comportamiento sedentario mediante descomposición de series temporales, para identificar momentos de mayor susceptibilidad a intervenciones conductuales.
5. **Integración con biomarcadores inflamatorios y metabólicos:** Vincular los perfiles de sedentarismo identificados con mediciones sanguíneas de proteína C reactiva, glucosa, lípidos y citoquinas inflamatorias, para caracterizar las vías biológicas mediando la asociación sedentarismo-enfermedad.

En síntesis, los hallazgos aquí presentados confirman que el monitoreo continuo del sedentarismo mediante dispositivos portátiles, interpretado a través de sistemas de inferencia difusa, representa una vía factible y ética para transformar los datos personales en conocimiento accionable para la salud pública. Este modelo no solo contribuye a la comprensión científica del sedentarismo como fenómeno biopsicosocial, sino que también proporciona una base empírica para diseñar políticas públicas orientadas a reducir la inactividad y fomentar entornos digitales saludables. Así, la investigación trasciende el ámbito académico para posicionarse como una herramienta estratégica en la promoción de estilos de vida activos y sostenibles en la era de la salud digital.

Conclusiones

Se ha demostrado que es factible desarrollar un modelo basado en lógica difusa para clasificar de manera fiable el comportamiento sedentario semanal. El modelo utiliza exclusivamente datos biométricos multivariados recolectados en condiciones de vida libre por dispositivos de consumo. El sistema de inferencia difusa propuesto respondió afirmativamente a la pregunta de investigación al alcanzar una alta concordancia ($F1\text{-Score} = 0.840$) con una clasificación objetiva y empírica derivada de un análisis de conglomerados, validando así su arquitectura y su capacidad para representar patrones de comportamiento reales.

La principal contribución científica de esta tesis es la demostración empírica del poder de los sistemas expertos para modelar la sinergia entre biomarcadores. Se identificó una paradoja metodológica donde variables individualmente débiles para discriminar el comportamiento (como la Variabilidad de la Frecuencia Cardíaca) resultaron ser indispensables para el rendimiento óptimo del modelo multivariado. Este hallazgo prueba que la fortaleza del sistema no reside en la suma de sus partes, sino en su capacidad para interpretar las interacciones complejas entre la actividad física y las respuestas cardiovasculares, una capacidad que los análisis estadísticos univariados no logran capturar.

Metodológicamente, este trabajo aporta una estrategia de validación robusta para sistemas de clasificación en salud cuando no se dispone de un estándar de oro clínico, basada en la convergencia de un enfoque empírico (descubrimiento de patrones no supervisado) y uno experto (reglas basadas en conocimiento). Asimismo, la ingeniería de las variables Actividad Relativa y Superávit Calórico Basal se presenta como una solución eficaz para la normalización fisiológica de datos de dispositivos portátiles, lo que permite comparaciones más equitativas entre individuos.

En conclusión, esta investigación no solo entrega un modelo de clasificación interpretable y de alto rendimiento, sino que también establece un precedente metodológico para el análisis de datos de salud en condiciones de vida libre. El sistema desarrollado tiene el potencial de servir como una herramienta de cribado para la identificación temprana de patrones de comportamiento sedentario de riesgo, sentando las bases para futuras investigaciones orientadas hacia la personalización de modelos y la prevención en la salud digital.

Anexos

8.1 Nomenclatura y Simbología Matemática

Esta sección presenta la nomenclatura matemática utilizada en el sistema de inferencia difusa y análisis estadístico.

8.1.1 Símbolos Matemáticos Generales

Tabla 8.1: Símbolos y Notación Matemática del Sistema Difuso

Símbolo	Descripción
Conjuntos y Funciones de Membresía	
$\tilde{A}$	Conjunto difuso
$\mu_{\tilde{A}}(x)$	Función de membresía del conjunto difuso $\tilde{A}$
X	Universo de discurso (conjunto clásico de valores posibles)
X_i	Variable de entrada i ($i \in \{1, 2, 3, 4\}$)
Y	Variable de salida (Índice de Sedentarismo)
T_i	Conjunto de términos lingüísticos de variable i
P_i	Matriz de percentiles 3×3 para variable X_i
$p_{k,i}$	Percentil k de la variable X_i
$M^{(j)}$	Matriz de membresías 4×3 para observación j
Variables Fisiológicas	
Act_{rel}	Actividad Relativa (min movimiento / hrs monitoreadas)
Sup_{cal}	Superávit Calórico Basal (% del TMB)
$HRV-SDNN$	Variabilidad Cardíaca (desviación estándar intervalos RR)
Δ_{FC}	Delta Cardíaco (FC caminata - FC reposo)
TMB	Tasa Metabólica Basal (kcal/día, ec. Mifflin-St Jeor)
GCA	Gasto Calórico Activo (kcal/día)
FC	Frecuencia Cardíaca (latidos por minuto)
IQR	Rango Intercuartílico (Q3 - Q1)
Reglas de Inferencia y Activación	
R_r	Regla de inferencia r ($r \in \{1, 2, 3, 4, 5\}$)
$\mathcal{R}$	Base de reglas (conjunto de 5 reglas Mamdani)
$w_r^{(j)}$	Activación (firing strength) de regla R_r para observación j
$\mathbf{w}^{(j)}$	Vector de activaciones $\in \mathbb{R}^5$
$T(a, b)$	T-norm (operador AND fuzzy): $T(a, b) = \min(a, b)$

Continúa en la siguiente página...

(Continuación de Tabla 8.1)

Símbolo	Descripción
y_r	Output crisp de la regla R_r
$\mathbf{y}_{\text{outputs}}$	Vector de outputs de reglas $[1, 0, 0, 0, 0, 9, 0, 5, 0, 7]^T$
Defuzzificación y Clasificación	
$y^{(j)}$	Score de sedentarismo defuzzificado para semana j
$\hat{y}^{(j)}$	Clasificación binaria (0=Bajo, 1=Alto sedentarismo)
τ	Umbral de decisión para binarización
$\ \mathbf{w}\ _1$	Norma L1 del vector (suma de componentes)
Validación LOOU	
$\mathcal{D}$	Dataset completo (1,337 semanas, 10 usuarios)
$\mathcal{D}_{\text{train}}^{(i)}$	Conjunto de entrenamiento en fold i (9 usuarios)
$\mathcal{D}_{\text{test}}^{(i)}$	Conjunto de prueba en fold i (1 usuario)
n_i	Número de semanas del usuario i
$F1^{(i)}$	F1-Score en fold i (usuario i como test)
$\overline{F1}_{\text{LOOU}}$	F1-Score promedio LOOU (10 folds)
σ_{F1}	Desviación estándar de F1-Score entre folds
CV	Coefficiente de variación (%)
Clustering (Verdad Operativa)	
K	Número de clusters ($K=2$)
$\mathbf{C}_k$	Centroide del cluster k ($k \in \{0, 1\}$)
$c^{(j)}$	Cluster asignado a semana j (verdad operativa)
S	Silhouette Score (métrica de calidad clustering)
Métricas de Evaluación	
TP	True Positives (verdaderos positivos)
TN	True Negatives (verdaderos negativos)
FP	False Positives (falsos positivos)
FN	False Negatives (falsos negativos)
Precision	Precisión: $\text{TP}/(\text{TP} + \text{FP})$
Recall	Sensibilidad: $\text{TP}/(\text{TP} + \text{FN})$
$F1$	F1-Score: $2 \cdot \text{Prec} \cdot \text{Rec}/(\text{Prec} + \text{Rec})$
MCC	Matthews Correlation Coefficient
Acc	Accuracy (exactitud): $(\text{TP} + \text{TN})/N$
Operadores y Notación Matemática	
$\min(a, b)$	Mínimo de a y b
$\max(a, b)$	Máximo de a y b
$\mathbb{E}[\cdot]$	Valor esperado (esperanza matemática)

Continúa en la siguiente página...

(Continuación de Tabla 8.1)

Símbolo	Descripción
$\mathcal{H}[\cdot]$	Función indicadora (1 si verdadero, 0 si falso)
$\ \mathbf{v}\ _2$	Norma euclidiana (L2) del vector $\mathbf{v}$
$\ \mathbf{v}\ _1$	Norma L1 (suma de valores absolutos)
$\mathbb{R}$	Conjunto de números reales
$\mathbb{R}^+$	Conjunto de números reales positivos
$\mathbb{R}^n$	Espacio euclidiano n-dimensional
$[a, b]$	Intervalo cerrado de a a b
$\arg \min_x f(x)$	Argumento que minimiza la función $f(x)$
$\forall$	Para todo (cuantificador universal)
$\exists$	Existe (cuantificador existencial)
$\in$	Pertenece a (relación de pertenencia)
$\subset$	Subconjunto de
$\setminus$	Diferencia de conjuntos
$\wedge$	Conjunción lógica (AND)
$\Rightarrow$	Implicación lógica (THEN)