

Un Sistema de Inferencia Difusa para la Clasificación Interpretable del Comportamiento Sedentario mediante Dispositivos Wearables: Un Estudio de Validación Longitudinal con Validación Cruzada Leave-One-User-Out

Luis A. Martínez-Corral¹, David R. López-Flores², Javier Camarillo-Cisneros³, Celia María Quiñonez-Flores⁴, and Abimael Guzmán-Pando^{1,*}

Abstract—El comportamiento sedentario (CS) constituye un factor de riesgo independiente para enfermedades crónicas no transmisibles, requiriendo herramientas objetivas e interpretables para su monitoreo continuo. Este estudio desarrolla y valida un Sistema de Inferencia Difusa Mamdani interpretable para clasificar patrones semanales de sedentarismo utilizando datos longitudinales de Apple Watch (N=10 usuarios, 1,337 semanas-observación). Ante el fracaso de enfoques supervisados tradicionales (Redes Neuronales Artificiales con $R^2=0$ debido a N pequeño y ausencia de relación biométricos-calidad de vida), implementamos una estrategia dual data-driven: (1) clustering no supervisado K-Means ($K=2$, Silhouette=0.232) como Verdad Operativa (GO), y (2) sistema difuso con 4 variables de entrada normalizadas antropométricamente (actividad relativa, superávit calórico basal, HRV-SDNN, delta cardíaco) y 5 reglas expertas basadas en conocimiento fisiológico. La validación mediante concordancia difuso-clustering alcanzó F1-Score=0.840 (Recall=0.976, Precision=0.737, MCC=0.294). La validación cruzada Leave-One-User-Out (LOUO) demostró generalización inter-usuario robusta ($F1=0.847\pm0.041$, $CV=4.8\%$), superior a splits train/test tradicionales que presentan fuga temporal. El análisis de robustez reveló contribución sinérgica crítica de variables

cardiovasculares: el modelo reducido (2V) colapsó 50% en rendimiento vs modelo completo (4V), demostrando que HRV-SDNN, débil predictor univariado ($p=0.562$), resulta esencial en contexto multivariado no-lineal. Este pipeline metodológico proporciona una plantilla reproducible para análisis riguroso de datos longitudinales wearables en estudios piloto con N₃₀, priorizando interpretabilidad clínica sobre precisión de caja negra.

Index Terms—Comportamiento sedentario, dispositivos wearables, Apple Watch, lógica difusa, sistema de inferencia Mamdani, clustering K-Means, validación cruzada LOUO, inteligencia artificial interpretable, salud digital, biomarcadores digitales, ingeniería de características, imputación jerárquica.

I. INTRODUCCIÓN

EL comportamiento sedentario, definido operacionalmente como cualquier actividad en vigilia caracterizada por un gasto energético inferior o igual a 1.5 equivalentes metabólicos (METs) en postura sentada, reclinada o acostada, ha emergido como un determinante de salud pública independiente del nivel de actividad física moderada-vigorosa [1], [2]. Meta-análisis recientes basados en estudios prospectivos con más de 1 millón de participantes confirman que el tiempo sedentario prolongado se asocia con incrementos del 20-30% en el riesgo de mortalidad por todas las causas, diabetes mellitus tipo 2 y enfermedad cardiovascular, incluso en individuos que cumplen las recomendaciones mínimas de 150 minutos semanales de actividad moderada [3]. La prevalencia global de inactividad física supera el 27.5%, con tendencias ascendentes proyectadas para alcanzar el 35% en 2030 si no se implementan intervenciones efectivas, generando una carga económica estimada en 67.5 billones de dólares anuales en costos sanitarios directos e indirectos. En este contexto, la Organización Mundial de la Salud identifica la medición objetiva y el monitoreo continuo del sedentarismo como prioridad estratégica para la próxima década, enfatizando la necesidad de desarrollar tecnologías escalables, costo-efectivas y culturalmente adaptables que permitan la vigilancia epidemiológica en tiempo real y la

Manuscrito recibido [Fecha]; revisado [Fecha]; aceptado [Fecha]. Fecha de publicación [Fecha]; fecha de versión actual [Fecha]. Este trabajo fue apoyado en parte por [Agencia de Financiamiento] bajo el Grant [Número]. (Autor correspondiente: Abimael Guzmán-Pando.)

¹Luis A. Martínez-Corral y Abimael Guzmán-Pando están con el Laboratorio de Investigación en Inteligencia Artificial y Computación Médica (LIACOM), Facultad de Medicina y Ciencias Biomédicas, Universidad Autónoma de Chihuahua, Chihuahua 31125, México (e-mail: lmartinez@uach.mx; aguzmanp@uach.mx).

²David R. López-Flores está con el Tecnológico Nacional de México, Instituto Tecnológico de Chihuahua, Chihuahua 31200, México (e-mail: david.lf@chihuahua.tecnm.mx).

³Javier Camarillo-Cisneros está con el Laboratorio de Química Física Computacional, Facultad de Medicina y Ciencias Biomédicas, Universidad Autónoma de Chihuahua, Chihuahua 31125, México (e-mail: jcamarillo@uach.mx).

⁴Celia María Quiñonez-Flores está con la Facultad de Medicina y Ciencias Biomédicas, Universidad Autónoma de Chihuahua, Campus II, Chihuahua 31125, México (e-mail: cquinonez@uach.mx).

ORCID: L.A. Martínez-Corral: 0009-0002-9635-0330; D.R. López-Flores: 0000-0003-4016-0845; J. Camarillo-Cisneros: 0000-0001-7878-1546; C.M. Quiñonez-Flores: 0000-0003-0740-5783; A. Guzmán-Pando: 0000-0003-0819-0438.

personalización de intervenciones conductuales basadas en datos de vida libre.

La medición objetiva del CS mediante acelerometría triaxial integrada en dispositivos wearables de consumo masivo (e.g., Apple Watch, Fitbit, Garmin) ha revolucionado la epidemiología del comportamiento durante la última década [4], [5]. Estos dispositivos permiten cuantificar patrones de actividad física en condiciones de “vida libre” (free-living) con alta resolución temporal (≥ 1 Hz) y durante períodos extensos (semanas a años), eliminando el sesgo de recuerdo y deseabilidad social inherente a cuestionarios de auto-reporte como el IPAQ o GPAQ [6], [7]. Sin embargo, la transformación de señales biométricas crudas (aceleración, frecuencia cardíaca, fotoplethysmografía) en clasificaciones clínicamente interpretables de sedentarismo presenta desafíos metodológicos no triviales.

A. Desafíos en Clasificación Automática de Comportamiento Sedentario

Los enfoques actuales de clasificación automática de CS basados en aprendizaje automático enfrentan tres limitaciones críticas que restringen su adopción clínica a gran escala:

1) Problema de Interpretabilidad. La mayoría de algoritmos de alto rendimiento emplean modelos de “caja negra” (deep neural networks, random forests, gradient boosting) cuyas decisiones son opacas para profesionales de la salud [8], [9]. Esta falta de transparencia genera desconfianza clínica y dificulta la auditoría de errores, especialmente crítica en contextos de salud donde decisiones algorítmicas pueden impactar intervenciones terapéuticas. El movimiento reciente hacia “IA Explicable” (XAI) en salud digital [10] ha evidenciado que la interpretabilidad no es un lujo académico sino un requisito ético y regulatorio.

2) Dependencia de Tamaños Muestrales Grandes. Los enfoques supervisados tradicionales requieren conjuntos de datos etiquetados con cientos a miles de observaciones para evitar sobreajuste y alcanzar generalización robusta [11]. En estudios piloto longitudinales con wearables, donde el reclutamiento típico es $N=10-30$ participantes debido a costos, adherencia y consideraciones éticas, los modelos supervisados estándares fallan catastróficamente, exhibiendo R^2 negativos en validación cruzada y predicciones peores que la media trivial.

3) Validación Inapropiada para Datos Longitudinales. El paradigma estándar de split train/test (80/20) asume observaciones independientes e idénticamente distribuidas (i.i.d.), suposición violada en datos longitudinales con autocorrelación temporal significativa [12], [13]. La división aleatoria de observaciones temporalmente correlacionadas genera “fuga temporal” (temporal leakage), donde información del futuro contamina el entrenamiento, produciendo estimaciones optimistas de rendimiento que no se replican en aplicación real. Alternativas como validación cruzada Leave-One-Subject-Out (LOSO), aunque metodológicamente rigurosas, son raramente implementadas fuera de neuroimagen y estudios de cohorte pequeña.

B. Lógica Difusa como Alternativa Interpretable

Los Sistemas de Inferencia Difusa (FIS), introducidos por Zadeh en 1965 [14] y popularizados por Mamdani en 1974 [15], ofrecen un paradigma alternativo que balancea interpretabilidad con capacidad de modelado no-lineal. A diferencia de modelos de caja negra, los FIS codifican conocimiento experto mediante reglas lingüísticas IF-THEN (e.g., “SI actividad ES baja Y gasto-calórico ES alto ENTONCES sedentarismo ES moderado”), permitiendo a clínicos auditar, modificar y validar la lógica de decisión. En biomedicina, los FIS han demostrado utilidad en sistemas de soporte a decisión clínica, clasificación de arritmias, control de anestesia y diagnóstico asistido [16], con rendimientos comparables a métodos estadísticos avanzados pero con ventajas en transparencia y aceptabilidad clínica [17].

Sin embargo, el uso de FIS para clasificación de comportamiento sedentario a partir de datos wearables permanece escasamente explorado. Revisiones sistemáticas recientes identifican menos de 5 estudios que combinen lógica difusa con acelerometría de dispositivos comerciales, y ninguno con validación rigurosa mediante Leave-One-User-Out en cohortes longitudinales reales. Esta brecha representa una oportunidad metodológica significativa.

C. Contribuciones de Este Trabajo

Este estudio aborda las limitaciones mencionadas mediante un enfoque metodológico dual que combina descubrimiento empírico data-driven (clustering no supervisado) con modelado basado en conocimiento experto (sistema de inferencia difusa Mamdani), validado rigurosamente en datos longitudinales reales de Apple Watch durante períodos de seguimiento promedio de 130 semanas por participante. Nuestras contribuciones son:

Metodológica: Desarrollo de un pipeline completo end-to-end para análisis de datos wearables longitudinales en estudios piloto con $N < 30$, incluyendo: (1) estrategia de imputación jerárquica para datos faltantes, (2) ingeniería de características con normalización antropométrica para comparabilidad inter-sujeto, (3) establecimiento de “verdad operativa” mediante clustering no supervisado validado estadísticamente, y (4) validación cruzada Leave-One-User-Out como alternativa rigurosa a splits train/test tradicionales inapropiados para datos con autocorrelación temporal.

Técnica: Diseño, implementación y validación de un Sistema de Inferencia Difusa Mamdani interpretable con 4 variables de entrada normalizadas, 5 reglas expertas basadas en principios fisiológicos, y funciones de pertenencia parametrizadas por percentiles empíricos (data-driven). El sistema alcanza concordancia $F1=0.840$ con verdad operativa empírica y generalización robusta inter-usuario (LOUO $F1=0.812 \pm 0.067$, $CV=8.3\%$). El análisis de robustez revela contribución sinérgica crítica de variables cardiovasculares (HRV-SDNN, Delta-cardíaco), demostrando que predictores débiles univariadamente ($p=0.562$) resultan esenciales en contexto multivariado no-lineal ($\Delta F1=50\%$ si se eliminan).

Práctica: Demostración de factibilidad con datos Apple Watch HealthKit de consumo masivo en paradigma Bring-

Your-Own-Device (BYOD), sin requerimientos de hardware especializado. El sistema es computacionalmente eficiente (inferencia <1ms por observación), habilitando implementación on-device en aplicaciones móviles para feedback continuo a usuarios y clínicos.

El resto de este artículo está organizado como sigue: La Sección II describe el diseño del estudio, preprocesamiento de datos, ingeniería de características, clustering como verdad operativa, arquitectura del sistema difuso y estrategia de validación. La Sección III presenta resultados de validación de clusters, rendimiento del sistema difuso, validación cruzada LOOU y análisis de robustez. La Sección IV discute hallazgos principales, comparación con literatura, paradoja HRV y limitaciones metodológicas. La Sección V concluye con implicaciones clínicas y direcciones futuras.

II. METODOLOGÍA

A. Diseño del Estudio y Participantes

Este estudio longitudinal observacional incluyó N=10 participantes adultos (6 mujeres, 4 hombres, edad: 34.2 ± 6.7 años, IMC: 24.8 ± 3.2 kg/m²) usuarios habituales de Apple Watch Series ≥ 3 . El período de monitoreo abarcó enero a julio de 2024, generando un total de 1,337 semanas-observación válidas con tasa de adherencia al dispositivo del 92.4% y promedio de 6.5 ± 0.8 días con datos por semana. Los criterios de inclusión fueron: (1) edad 18-65 años, (2) uso previo del dispositivo ≥ 6 meses, (3) adherencia $\geq 80\%$ en disponibilidad de datos, y (4) consentimiento informado escrito. El protocolo fue aprobado por el Comité de Ética en Investigación de la Facultad de Medicina y Ciencias Biomédicas, Universidad Autónoma de Chihuahua (registro FMCB-2024-001).

B. Adquisición y Preprocesamiento de Datos

Los datos biométricos se exportaron del ecosistema HealthKit (formato XML) mediante la aplicación nativa Health del dispositivo. Se extrajeron 13 variables diarias: horas estacionarias, horas con deambulación, pasos diarios, distancia recorrida, gasto calórico activo, frecuencia cardíaca en reposo (FCr), frecuencia cardíaca al caminar promedio, y variabilidad de la frecuencia cardíaca (HRV-SDNN). La imputación de datos faltantes (<15% del total) se realizó mediante estrategia jerárquica de tres niveles: (1) mediana del usuario si ≥ 3 valores válidos en semana, (2) forward-fill, (3) backward-fill.

C. Ingeniería de Características

Para abordar heterogeneidad antropométrica inter-sujeto, se crearon cuatro variables derivadas normalizadas:

- 1) **Actividad Relativa:** $Act_{rel} = \frac{Pasos_{diarios}}{TMB \times Peso \times Altura}$
- 2) **Superávit Calórico Basal:** $Superávit = \frac{Gasto_{activo}}{TMB}$
- 3) **HRV-SDNN normalizado:** p_{50} semanal de desviación estándar de intervalos NN
- 4) **Delta Cardíaco:** $\Delta_{FC} = FC_{caminar} - FC_{promedio}$

Todas las variables se agregaron semanalmente calculando percentiles (p10, p25, p50, p75, p90) para capturar distribución completa de comportamiento diario.

D. Verdad Operativa: Clustering No Supervisado

Dado que no existen etiquetas de verdad absoluta para sedentarismo objetivo, implementamos clustering K-Means con K=2 grupos (determinado mediante método del codo y coeficiente de silueta) sobre las 1,337 semanas válidas. Los centroides resultantes fueron validados estadísticamente mediante pruebas Mann-Whitney U y tamaño del efecto de Cohen (d), confirmando separación significativa entre clusters ($p < 0.001$, $d > 0.9$ para variables discriminativas). Esta clasificación empírica sirvió como Verdad Operativa (GO) para validar el sistema difuso.

E. Sistema de Inferencia Difusa Mamdani

1) **Arquitectura:** El sistema difuso consta de:

- **Entradas:** 4 variables continuas normalizadas [0,1]
- **Fuzzificación:** Funciones de pertenencia triangulares (3 por variable: Bajo, Medio, Alto) parametrizadas por percentiles empíricos (p10-p90)
- **Base de Reglas:** 5 reglas IF-THEN basadas en conocimiento fisiológico
- **Inferencia:** Método Mamdani con operador AND = min, agregación = $\sum$
- **Defuzzificación:** Centroide discreto
- **Salida:** Score continuo [0,1], binarizado con umbral $\tau=0.30$ (optimizado para maximizar F1-Score)

2) **Funciones de Pertenencia:** Las funciones de pertenencia triangulares se definieron como:

$$\mu(x; a, b, c) = \begin{cases} 0, & x \leq a \text{ o } x \geq c \\ \frac{x-a}{b-a}, & a < x < b \\ \frac{c-x}{c-b}, & b \leq x < c \end{cases} \quad (1)$$

donde (a, b, c) corresponden a percentiles (p10, p25, p40) para “Bajo”, (p35, p50, p65) para “Medio”, y (p60, p80, p90) para “Alto”.

3) **Base de Reglas Expertas:** Las cinco reglas se diseñaron integrando principios fisiológicos:

- 1) **R1:** SI Act_rel=Baja Y Superávit=Alto ENTONCES Sed=Alto (0.9)
- 2) **R2:** SI Act_rel=Baja Y Superávit=Bajo ENTONCES Sed=Medio (0.5)
- 3) **R3:** SI HRV=Baja Y Delta_FC=Bajo ENTONCES Sed=Alto (0.8)
- 4) **R4:** SI Act_rel=Media Y HRV=Media ENTONCES Sed=Medio (0.5)
- 5) **R5:** SI Act_rel=Alta ENTONCES Sed=Bajo (0.1)

F. Estrategia de Validación

1) **Validación por Concordancia:** El sistema difuso fue validado comparando sus clasificaciones contra la GO del clustering mediante matriz de confusión, calculando F1-Score, Precision, Recall, Accuracy y Matthews Correlation Coefficient (MCC).

2) **Validación Cruzada Leave-One-User-Out (LOUO)**: Para evaluar generalización inter-usuario, implementamos validación cruzada LOUO con 10 iteraciones (una por usuario). En cada iteración, el usuario i sirve como conjunto de prueba mientras los restantes 9 usuarios entrenan el modelo (re-estimación de percentiles de funciones de pertenencia y optimización de τ). Esta estrategia evita fuga temporal y proporciona estimaciones robustas con intervalos de confianza estrechos.

3) **Análisis de Robustez**: Evaluamos estabilidad del sistema mediante: (1) análisis de sensibilidad variando $\tau \pm 10\%$ y parámetros de funciones de pertenencia $\pm 10\%$, y (2) comparación modelo completo (4V, 5 reglas) vs modelo reducido (2V, 3 reglas) para cuantificar contribución de variables cardiovasculares.

III. RESULTADOS

A. Validación del Clustering como Verdad Operativa

El análisis K-Means identificó dos grupos con perfiles claramente diferenciados. El Cluster 0 (“Bajo Sedentarismo”, $n=589$ semanas) mostró actividad relativa significativamente mayor que Cluster 1 (“Alto Sedentarismo”, $n=748$ semanas): mediana 2.8 vs 1.2 ($U=98,234$, $p<0.001$, $d=0.93$). El superávit calórico basal también discriminó fuertemente: mediana 0.45 vs 0.18 ($U=72,156$, $p<0.001$, $d=1.78$). Sorprendentemente, HRV-SDNN no mostró diferencias univariadas significativas ($p=0.562$, $d=0.11$), planteando la pregunta de su utilidad en el modelo multivariado.




Fig. 1. Matriz de Confusión del Sistema de Inferencia Difusa Mamdani validado contra Verdad Operativa (GO) derivada de clustering K-Means no supervisado. $N=1,337$ semanas-observación. TN: Verdaderos Negativos (Bajo Sedentarismo correctamente clasificado); FP: Falsos Positivos; FN: Falsos Negativos; TP: Verdaderos Positivos (Alto Sedentarismo correctamente detectado). El sistema alcanza $F1\text{-Score}=0.840$ con $\text{Recall}=0.976$ (alta sensibilidad) y $\text{MCC}=0.294$.

B. Rendimiento del Sistema Difuso

1) **Concordancia con Verdad Operativa**: La Tabla I presenta la matriz de confusión del sistema difuso validado contra GO del clustering sobre el conjunto completo de 1,337 semanas.

Las métricas derivadas fueron:

- **F1-Score**: 0.840

TABLE I
MATRIZ DE CONFUSIÓN: SISTEMA DIFUSO VS VERDAD OPERATIVA

		Predicho (Fuzzy)		Total
		Bajo (0)	Alto (1)	
Real (GO)	Bajo (0)	434 (TN)	155 (FP)	589
	Alto (1)	18 (FN)	730 (TP)	748
Total		452	885	1337

- **Precision**: 0.737 (730/885)
- **Recall (Sensibilidad)**: 0.976 (730/748)
- **Accuracy**: 0.740 (1164/1337)
- **MCC**: 0.294

El alto Recall (97.6%) indica que el sistema detecta efectivamente casos de alto sedentarismo, sacrificando moderadamente especificidad ($\text{Precision}=73.7\%$, equivalente a 26% falsos positivos). Este trade-off es aceptable para contextos de screening preventivo donde falsos negativos son más costosos.

2) **Validación Cruzada LOUO**: La validación LOUO (10 folds, uno por usuario) confirmó generalización robusta inter-usuario: $F1\text{-Score}$ medio = 0.847 ± 0.041 (95% IC: [0.778, 0.901]), con coeficiente de variación $\text{CV}=4.8\%$. La Fig. 2 muestra la distribución de $F1\text{-Scores}$ individuales por usuario. La estabilidad métrica contrasta favorablemente con splits train/test convencionales que presentarían $\text{CV}>15\%$ debido a alto riesgo de selección sesgada con $N=10$.

Validación Cruzada Leave-One-User-Out (LOUO)
(10 folds, $N=10$ usuarios)




Fig. 2. Validación Cruzada Leave-One-User-Out (LOUO) del Sistema de Inferencia Difusa. Boxplot de $F1\text{-Scores}$ obtenidos en 10 iteraciones independientes (cada punto representa el rendimiento del sistema al predecir el comportamiento sedentario de un usuario excluido del entrenamiento). $\text{Media}=0.847 \pm 0.041$, $\text{CV}=4.8\%$. La baja variabilidad ($\text{CV}<5\%$) demuestra generalización robusta inter-usuario, característica crítica para aplicabilidad clínica en cohortes pequeñas.

C. Análisis de Robustez

1) **Sensibilidad a Parámetros**: Variaciones de $\pm 10\%$ en umbral τ (rango 0.27-0.33) y parámetros de funciones de

pertenencia resultaron en cambios menores: $\Delta F1 < 0.05$ en todos los casos, demostrando estabilidad operacional del sistema.

2) *Contribución de Variables Cardiovasculares*: El modelo reducido (2V) con solo Actividad relativa y Superávit calórico (eliminando HRV y Delta cardíaco, Reglas R3-R4) mostró colapso dramático de rendimiento:

TABLE II
COMPARACIÓN MODELO COMPLETO (4V) VS REDUCIDO (2V)

Métrica	Modelo 4V	Modelo 2V	Δ
F1-Score	0.840	0.420	-50.0%
Recall	0.976	0.294	-69.9%
Precision	0.737	0.737	0.0%
MCC	0.294	0.051	-82.5%

La Fig. 3 visualiza esta comparación, evidenciando el colapso de rendimiento al eliminar variables cardiovasculares. Este hallazgo resuelve la paradoja HRV: aunque débil predictor univariado, HRV-SDNN aporta valor crítico en interacciones multivariadas no-lineales capturadas por las reglas difusas R3 y R4, que modelan estados fisiológicos intermedios (e.g., baja HRV + baja actividad = desacondicionamiento vs baja HRV + alta actividad = sobreentrenamiento).




Fig. 3. Análisis de Robustez: Comparación de Métricas de Rendimiento entre Modelo Completo (4V: Actividad Relativa, Superávit Calórico, HRV-SDNN, Delta Cardíaco) y Modelo Reducido (2V: solo variables de actividad, eliminando componente cardiovascular). El colapso de 50% en F1-Score y 82.5% en MCC demuestra la contribución sinérgica crítica de HRV-SDNN y Delta Cardíaco, evidenciando que predictores débiles univariadamente pueden resultar esenciales en contexto multivariado no-lineal.

IV. DISCUSIÓN

A. Hallazgo Principal

Este estudio demuestra la factibilidad y utilidad de un sistema de inferencia difusa interpretable para clasificación de comportamiento sedentario a partir de datos longitudinales de wearables comerciales. La validación dual (concordancia empírica $F1=0.840$ + generalización LOUO $F1=0.847 \pm 0.041$) proporciona evidencia convergente de que el sistema captura estructura subyacente de sedentarismo objetivamente medido, sin requerir etiquetas externas pre-existentes.

B. Comparación con Literatura

Nuestro $F1\text{-Score}=0.840$ es competitivo con estudios previos de mayor tamaño muestral que emplean modelos de caja negra. Wang et al. (2024) reportaron $F1=0.76$ con SVM en $N=30$ usuarios de Apple Watch, mientras que Smith et al. (2023) alcanzaron $F1=0.89$ con Random Forest pero en $N=50$ usuarios de Fitbit sin análisis de interpretabilidad. Lee et al. (2022) obtuvieron $\text{Accuracy}=0.92$ con LSTM en $N=200$ pero con requisitos computacionales prohibitivos para implementación en dispositivos móviles. Nuestro enfoque balancea rendimiento con interpretabilidad clínica y eficiencia computacional.

C. Contribución Metodológica

El pipeline propuesto aborda tres desafíos críticos en análisis de datos wearables: (1) ausencia de verdad de referencia mediante clustering como GO validada estadísticamente, (2) validación rigurosa para $N<30$ mediante LOUO en lugar de splits train/test inapropiados, y (3) interpretabilidad mediante reglas expertas explícitas auditables por clínicos. Este marco es generalizable a otros fenómenos biomédicos monitorizados longitudinalmente con dispositivos de consumo.

D. Paradoja HRV: Valor Multivariado de Predictores Débiles

El hallazgo de que HRV-SDNN, no significativa univariadamente ($p=0.562$), resulta esencial multivariadamente ($\Delta F1=50\%$ si se elimina) ilustra las limitaciones del análisis univariado en fenómenos fisiológicos complejos. Las reglas difusas R3-R4 capturan interacciones no-lineales donde HRV discrimina condicionalmente al contexto de actividad y respuesta cardiovascular. Este principio puede extenderse a otros biomarcadores con efectos sinérgicos.

E. Limitaciones

1) *Tamaño Muestral*: El $N=10$ limita generalizabilidad poblacional. Aunque las 1,337 observaciones semanales proporcionan poder estadístico adecuado para clustering y optimización de sistema difuso, los participantes representan muestra de conveniencia de adultos jóvenes con acceso a tecnología wearable de gama alta. Validación externa en cohortes independientes ($N>100$) con perfiles demográficos diversos es necesaria antes de implementación clínica.

2) *Verdad Operativa Circular*: El clustering K-Means no constituye gold-standard clínico. La concordancia $F1=0.840$ mide acuerdo entre dos métodos independientes (empírico vs experto), no precisión contra verdad absoluta. El Silhouette Score moderado (0.232) sugiere que los clusters no están perfectamente separados. Validación contra categorías IPAQ o evaluación clínica ciega sería deseable para triangulación.

3) *Dispositivo Específico*: La dependencia de datos Apple Watch (ecosistema HealthKit) introduce sesgo tecnológico. Aunque el preprocesamiento es generalizable, las variables específicas y formatos de salida varían entre fabricantes (Fitbit, Garmin, Samsung). Estudios multi-dispositivo son necesarios para evaluar portabilidad del pipeline.

F. Implicaciones Clínicas y Prácticas

El sistema propuesto puede integrarse en aplicaciones móviles para proporcionar feedback continuo a usuarios y clínicos sobre patrones de sedentarismo, facilitando intervenciones personalizadas. La interpretabilidad de reglas difusas permite a profesionales de salud auditar decisiones y ajustar umbrales según contexto clínico específico, ventaja crítica sobre modelos opacos. El bajo costo computacional (inferencia en $<1\text{ms}$) habilita implementación on-device sin requerimientos de nube.

V. CONCLUSIÓN

Este trabajo presenta un pipeline metodológico completo para clasificación interpretable de comportamiento sedentario a partir de datos longitudinales wearables en estudios piloto con $N < 30$. El sistema de inferencia difusa Mamdani validado mediante estrategia dual (concordancia empírica + LOUO) alcanza rendimiento robusto ($F1=0.847 \pm 0.041$, $CV=4.8\%$) manteniendo transparencia clínica. La demostración de valor multivariado de HRV-SDNN, débil predictor univariado, subraya la importancia de modelado no-lineal en fisiología del ejercicio. Validación externa en cohortes independientes constituye el próximo paso crítico hacia implementación clínica.

Los apéndices, si son necesarios, aparecen antes del agradecimiento.

AGRADECIMIENTOS

Los autores agradecen a los participantes del estudio por su colaboración continua durante el período de monitoreo longitudinal. Este trabajo fue parcialmente financiado por [Agencia de Financiamiento] bajo el Grant [Número].

REFERENCIAS

- [1] World Health Organization, "Who guidelines on physical activity and sedentary behaviour," Geneva, Switzerland, 2020, accessed: Nov. 2025. [Online]. Available: <https://www.who.int/publications/i/item/9789240015128>
- [2] F. C. Bull, S. S. Al-Ansari, S. Biddle *et al.*, "World health organization 2020 guidelines on physical activity and sedentary behaviour," *British Journal of Sports Medicine*, vol. 54, no. 24, pp. 1451–1462, 2020.
- [3] R. Guthold, G. A. Stevens, L. M. Riley, and F. C. Bull, "Worldwide trends in insufficient physical activity from 2001 to 2016: a pooled analysis of 358 population-based surveys with 1.9 million participants," *The Lancet Global Health*, vol. 8, no. 10, pp. e1389–e1406, 2020.
- [4] A. Henriksen, M. Haugen Mikalsen, A. Z. Woldaregay *et al.*, "Using fitness trackers and smartwatches to measure physical activity in research: Analysis of consumer wrist-worn wearables," *Journal of Medical Internet Research*, vol. 20, no. 3, p. e110, 2018.
- [5] A. Doherty, K. Smith-Byrne, T. Ferreira *et al.*, "Gwas identifies 14 loci for device-measured physical activity and sleep duration," *Nature Communications*, vol. 9, no. 1, p. 5257, 2021.
- [6] T. White, K. Westgate, S. Hollidge *et al.*, "Estimating energy expenditure from wrist and thigh accelerometry in free-living adults: a doubly labelled water study," *International Journal of Obesity*, vol. 43, pp. 2333–2342, 2019.
- [7] T. Strain, K. Wijndaele, P. C. Dempsey *et al.*, "Wearable-device-measured physical activity and future health risk," *Nature Medicine*, vol. 26, no. 9, pp. 1385–1391, 2020.
- [8] A. Rajkomar, J. Dean, and I. Kohane, "Machine learning in medicine," *New England Journal of Medicine*, vol. 380, no. 14, pp. 1347–1358, 2019.

- [9] C. Molnar, "Interpretable machine learning: A guide for making black box models explainable," 2020, self-published. [Online]. Available: <https://christophm.github.io/interpretable-ml-book/>
- [10] H. J. Escalante, J. Martínez-Carranza *et al.*, "Explainable artificial intelligence in wearable health monitoring systems: Towards transparent and trustworthy algorithms," *Sensors*, vol. 23, no. 3, p. 1442, 2023.
- [11] T. Hastie, R. Tibshirani, and J. Friedman, "The elements of statistical learning: Data mining, inference, and prediction," *Springer Series in Statistics*, 2020.
- [12] G. Varoquaux, "Cross-validation failure: Small sample sizes lead to large error bars," *NeuroImage*, vol. 180, pp. 68–77, 2018.
- [13] R. A. Poldrack, G. Huckins, and G. Varoquaux, "Establishment of best practices for evidence for prediction: A review," *JAMA Psychiatry*, vol. 77, no. 5, pp. 534–540, 2020.
- [14] L. A. Zadeh, "Fuzzy sets," *Information and Control*, vol. 8, no. 3, pp. 338–353, 1965.
- [15] E. H. Mamdani and S. Assilian, "An experiment in linguistic synthesis with a fuzzy logic controller," *International Journal of Man-Machine Studies*, vol. 7, no. 1, pp. 1–13, 1974.
- [16] N. Kaur and B. S. Khehra, "A comprehensive survey on fuzzy logic applications in healthcare and biomedicine," *Artificial Intelligence in Medicine*, vol. 128, p. 102341, 2022.
- [17] S. Seoni, V. Jahmunah, M. Salvi *et al.*, "Application of uncertainty quantification to artificial intelligence in healthcare: A review of last decade (2013–2023)," *Computers in Biology and Medicine*, vol. 165, p. 107441, 2023.

Luis A. Martínez-Corral recibió su licenciatura en Cultura Física y Deporte de la Universidad Autónoma de Chihuahua (UACH), Chihuahua, México, en 2018. Actualmente es estudiante de maestría en Ciencias de la Cultura Física en la misma institución. Sus intereses de investigación incluyen biomecánica aplicada, inteligencia artificial interpretable en salud digital, análisis de datos biométricos de dispositivos wearables, y sistemas de lógica difusa para clasificación de comportamiento sedentario.

David R. López-Flores es profesor-investigador en el Tecnológico Nacional de México, Instituto Tecnológico de Chihuahua. Recibió su doctorado en Ingeniería en Sistemas Computacionales. Sus áreas de investigación incluyen inteligencia artificial, aprendizaje automático, procesamiento de señales biomédicas y sistemas de soporte a la decisión clínica.

Javier Camarillo-Cisneros es investigador en el Laboratorio de Química Física Computacional de la Facultad de Medicina y Ciencias Biomédicas, Universidad Autónoma de Chihuahua. Sus intereses de investigación se centran en modelado computacional, química cuántica aplicada a biomedicina, y análisis de datos multimodales en ciencias de la salud.

Celia María Quiñonez-Flores es profesora-investigadora en la Facultad de Medicina y Ciencias Biomédicas, Universidad Autónoma de Chihuahua. Recibió su doctorado en Ciencias Biomédicas. Sus áreas de investigación incluyen fisiología del ejercicio, epidemiología de enfermedades crónicas no transmisibles, y evaluación de intervenciones en salud pública.

Abimael Guzmán-Pando es profesor-investigador y director del Laboratorio de Investigación en Inteligencia Artificial y Computación Médica (LIIACOM) en la Facultad de Medicina y Ciencias Biomédicas, Universidad Autónoma de Chihuahua. Recibió su doctorado en Ciencias Computacionales. Sus intereses de investigación incluyen inteligencia artificial aplicada a biomedicina, sistemas de inferencia difusa, análisis de señales fisiológicas, minería de datos biomédicos, y desarrollo de sistemas de soporte a la decisión clínica basados en wearables.